

Entwicklung domänenspezifischer Datensätze und automatisierter Evaluation für ein Framework zur neuronalen Textvereinfachung in leichte Sprache

Fiete Scheel

8. August 2026

Inhaltsverzeichnis

1. Einleitung	3
1.1. Problemstellung & Motivation	3
1.2. Zielsetzung & Forschungsfragen	3
1.3. Aufbau der Arbeit	4
2. Theoretical Background & Stand der Forschung	6
2.1. Das Konzept der Leichten Sprache und verfügbare Datenbasis	6
2.2. Maschinelle Textvereinfachung und Satz-Alignment	8
2.3. Evaluierungsmetriken für die Vereinfachung	8
2.4. Präferenzoptimierung (DPO) in der Textgenerierung	9
3. Themenblock 1: Datenbasis & Korpus-Erstellung	10
3.1. Multi-Quellen-Crawling & Datenakquise	12
3.2. Alignment & Das 1:n-Problem	12
3.3. Quality Assurance & Similarity Sweet-Spot	12
3.4. Datenbereinigung & Normalisierung	12
3.5. Korpus-Statistiken & Lexikalische Diversität	12
4. Themenblock 2: Metrik & Bewerten von Sprachkomplexität	13
4.1. Klassifikationsmodelle	13
4.2. Out-of-Domain-Generalisierung & Empirische Bias-Kontrolle	13
4.3. Continuous MixUp Regression	13
4.4. Evaluierung synthetischer Sprachstufen	13
5. Themenblock 3: Modellierung der Übersetzung & Reward-Guided Fine-Tuning	14
5.1. Datenvorbereitung & Trainings-Splits	14
5.2. Supervised Fine-Tuning (SFT)	14
5.3. Reward-Guided Optimization (RLHF / DPO)	14
5.4. Mehrdimensionale Evaluierung	14
6. Diskussion & Gesamtevaluation	15
6.1. Inhaltssynthese der drei Themenblöcke	15
6.2. Stärken, Grenzen & Systemrestriktionen	15
6.3. Beantwortung der Forschungsfragen	15
7. Fazit & Ausblick	16
7.1. Zusammenfassung der Kernergebnisse	16
7.2. Ausblick & Zukünftige Forschungsarbeiten	16
A. Anhang	19

1. Einleitung

1.1. Problemstellung & Motivation

Für manche eine optionale Lesehilfe, für andere der einzige Zugang zu gesellschaftlicher Teilhabe.

Beim Thema Barrierefreiheit denken viele an physische Barrieren wie Rampen, Aufzüge oder automatische Türen. Durch die Digitalisierung und die Verlagerung von Dienstleistungen und Informationen ins Internet ist es damit jedoch nicht mehr getan. Barrierefreie Gestaltung betrifft zunehmend digitale Räume und insbesondere die Sprache, in der Informationen bereitgestellt werden.

Menschen mit kognitiven Einschränkungen, Lernschwierigkeiten, geringer Lese- und Schreibkompetenz oder Deutsch als Zweitsprache werden durch komplexe Texte, bürokratische Fachsprache und verschachtelte Satzstrukturen vom Zugang zu grundlegenden Informationen und Dienstleistungen ausgeschlossen. Das Konzept der *Leichten Sprache* (LS) bietet hierfür ein klar reglementiertes Regelwerk, um Texte durch Vereinfachung des Vokabulars und der Syntax verständlich zu machen.

Mit dem Inkrafttreten des Barrierefreiheitsstärkungsgesetzes (BFSG) in Deutschland sowie europäischen Richtlinien (wie der Web-Accessibility-Directive) wächst der rechtliche Druck auf öffentliche und private Akteure, Informationen auch in Leichter Sprache anzubieten. Die manuelle Übersetzung von Alltagssprache (AS) in Leichte Sprache (LS) durch menschliche Übersetzer ist jedoch extrem zeitintensiv, kostspielig und durch einen Mangel an Fachkräften limitiert.

Hieraus ergibt sich ein dringender Forschungs- und Entwicklungsbedarf im Bereich der maschinellen Textvereinfachung. Bisherige neuronale Übersetzungsmodelle scheitern jedoch häufig an den spezifischen syntaktischen und strukturellen Besonderheiten der Leichten Sprache oder leiden unter dem Mangel an qualitativ hochwertigen, parallelen Trainingsdaten. Es bedarf daher systematischer Ansätze zur automatisierten Erstellung paralleler Korpora, robuster Metriken zur Komplexitätsbewertung und optimierter Trainingsstrategien.

1.2. Zielsetzung & Forschungsfragen

Ziel dieser Arbeit ist die Entwicklung, Optimierung und Evaluierung eines methodischen Frameworks zur automatisierten Übersetzung deutscher Alltagssprache in Leichte Sprache. Dies umfasst den gesamten Prozess von der automatisierten Datenakquise über die Bewertung von Sprachkomplexität bis hin zum Training und der Optimierung generativer Sprachmodelle.

Im Zentrum dieser Arbeit steht die folgende übergreifende Leitfrage:

Wie lässt sich die automatische Übersetzung in Leichte Sprache (LS) durch die Kombination aus semantisch optimierten Korpora, strukturellen Klassifikatoren und zielgerichteten Trainingsstrategien systematisch verbessern und evaluieren?

Zur Beantwortung dieser Leitfrage werden drei zentrale Forschungsbereiche (Themenblöcke) untersucht:

1. Datenbasis & Alignment (Themenblock 1):

- *FF 2.1*: Wie stark beeinträchtigt das 1:n-Satzalignment das Training von Sequenz-zu-Sequenz-Modellen und kann ein absatzweises Alignment semantische Einheiten besser wahren?
- *FF 2.2 & 2.3*: Welcher Filterbereich der Kosinus-Ähnlichkeit bei parallelen Textpaaren liefert den qualitativen „Sweet Spot“ für das Modelltraining und inwiefern helfen Long-Context Embeddings bei der Rauschreduktion?

2. Klassifikation & Sprachkomplexität (Themenblock 2):

- *FF 3.1 & 3.2*: Lässt sich Sprachkomplexität besser auf Satz- oder Dokumentenebene klassifizieren und wie gut generalisieren diese Klassifikatoren auf unabhängige, proprietäre Testdaten?
- *FF 3.3*: Wie lassen sich systematische Shortcuts (Längen-, Layout- und typografische Biases) in den Klassifikationsmodellen empirisch ausschließen?

3. Übersetzung & Reward-Guided Fine-Tuning (Themenblock 3):

- *FF 5.3 & 5.4*: Inwiefern verbessert ein mit Reinforcement Learning (DPO) optimiertes Übersetzungsmodell unter Nutzung eines Komplexitätsklassifikators als Reward-Funktion die Einhaltung formaler Regeln im Vergleich zu reinem Supervised Fine-Tuning (SFT)?

1.3. Aufbau der Arbeit

Die vorliegende Arbeit folgt einer logischen Struktur, die sich an den drei Säulen des entwickelten Übersetzungssystems orientiert:

- **Kapitel 2 (Theoretical Background & Stand der Forschung)** legt das theoretische Fundament. Es erörtert die sprachlichen Regeln der Leichten Sprache, den aktuellen Stand der maschinellen Übersetzung (Seq2Seq, LLMs, LoRA-Tuning) sowie Methoden zur automatisierten Evaluation.
- **Kapitel 3 (Datenbasis & Korpus-Erstellung)** beschreibt die erste Stufe der Pipeline. Im Fokus steht das Crawling paralleler Texte, die Behandlung des 1:n-Alignment-Problems und die qualitative Filterung mittels semantischer Embeddings.

- **Kapitel 4 (Metrik & Bewerten von Sprachkomplexität)** widmet sich der zweiten Stufe: der Entwicklung von Klassifikationsmodellen (BiLSTM vs. SBERT) und dem Entwurf einer *Continuous MixUp Regression* zur stufenlosen Komplexitätsbewertung.
- **Kapitel 5 (Modellierung der Übersetzung & Fine-Tuning)** stellt das eigentliche Übersetzungsmodell vor. Hierbei werden die Implementierung des Supervised Fine-Tunings (SFT) sowie das Reward-Guided Fine-Tuning (DPO) zur Regeleinhaltung evaluiert.
- **Kapitel 6 (Diskussion & Gesamtevaluation)** führt die Ergebnisse der drei Stufen zusammen, beantwortet systematisch die aufgeworfenen Forschungsfragen und beleuchtet kritisch die Systemrestriktionen sowie Fragen zur Faktentreue.
- **Kapitel 7 (Fazit & Ausblick)** fasst die Kernergebnisse der Arbeit zusammen und gibt einen Ausblick auf zukünftige Forschungsarbeiten und praktische Anwendungsfelder.

2. Theoretical Background & Stand der Forschung

2.1. Das Konzept der Leichten Sprache und verfügbare Datenbasis

Das Konzept der Leichten Sprache (LS) stellt eine stark reglementierte Sprachvariante der deutschen Standardsprache dar, die primär darauf abzielt, Barrierefreiheit in der schriftlichen Kommunikation für Menschen mit kognitiven Einschränkungen, Lernschwierigkeiten oder geringer Lese- und Schreibkompetenz zu gewährleisten. Syntaktisch zeichnet sich LS unter anderem durch kurze Hauptsätze (Subjekt-Prädikat-Objekt), den Verzicht auf Nebensätze, Passivkonstruktionen, den Genitiv sowie den Konjunktiv aus. Auf lexikalischer Ebene werden abstrakte Begriffe durch konkrete Beispiele ersetzt, und lange zusammengesetzte Wörter werden mittels typografischer Hilfsmittel wie Bindestrichen oder dem Mediopunkt (z. B. *Bundestags-Wahl* oder *Bundestags · wahl*) segmentiert.

Vom Konzept der Leichten Sprache ist die sogenannte *Einfache Sprache* (Plain German) abzugrenzen. Während die Leichte Sprache als hochspezialisierte Sprachvariante mit strengen, normierten Richtlinien konzipiert ist und in Deutschland rechtlich durch die Barrierefreie-Informationstechnik-Verordnung (BITV 2.0) für öffentliche Stellen vorgeschrieben wird (Überwachungsstelle des Bundes für Barrierefreiheit von Informationstechnik, 2026), besitzt die Einfache Sprache ein weitaus weniger restriktives Regelwerk. Letztere richtet sich an eine breitere Zielgruppe (wie Menschen mit Deutsch als Zweitsprache oder funktionale Alphabeten) und lässt komplexere Satzstrukturen sowie einen größeren Wortschatz zu. Ein weiterer kritischer Unterschied liegt im Qualitätssicherungsprozess: Texte in Leichter Sprache müssen zwingend von Personen aus der primären Zielgruppe auf ihre Verständlichkeit hin geprüft werden, was bei Texten in Einfacher Sprache nicht vorgeschrieben ist. Einen guten Überblick über den aktuellen Stand und die verfügbaren Ressourcen für Leichte und Einfache Sprache in Deutschland geben Madina et al. (2023). Sie zeigen dabei vor allem auf, wie unterschiedlich die bestehenden Datensätze strukturiert sind und dass es an standardisierten Werkzeugen zur automatischen Bewertung der Texte fehlt.

Die Erforschung datengetriebener, maschineller Übersetzungsverfahren (Automatic Text Simplification, ATS) für das Deutsche litt historisch unter einer eklatanten Datenknappheit. Erste Versuche, ein paralleles Korpus aufzubauen, gehen auf Klapper et al. (2013) mit dem *KLAPER*-Korpus zurück, das jedoch mit ca. 250 parallelen Textpaaren (rund 7.000 Sätze und 70.000 Tokens) für moderne Deep-Learning-Ansätze deutlich zu klein war.

Einen Meilenstein stellte die Arbeit von Battisti et al. (2020) dar, die ein umfang-

reiches, multimodales Korpus für das Deutsche zusammenzutragen. Die AutorInnen entwickelten Web-Scraper, um Texte in Leichter und Einfacher Sprache von verschiedenen deutschsprachigen Webportalen und Institutionen der Behindertenhilfe (wie etwa gesundheitlichen Informationsdiensten, öffentlich-rechtlichen Nachrichtenportalen und sozialen Trägern) zu extrahieren. Insgesamt umfasst das Korpus 6.217 Dokumente bzw. fast 211.000 Sätze mit rund 5,5 Millionen geschriebenen Tokens. Ein zentrales Merkmal der Arbeit ist die Aufteilung des Korpus: Es besteht zu einem großen Teil aus 5.461 monolingualen Dokumenten in vereinfachter Sprache, während der parallele Teil mit lediglich 378 parallelen Dokumentenpaaren (jeweils 378 Ausgangs- und Zieltexte) im Vergleich dazu sehr klein ausfällt. Neben den reinen Texten erfassten die AutorInnen systematisch typografische Metadaten (Schriftart, -größe und -stil), Absatz- und Zeilenstrukturen sowie Informationen zu eingebetteten Bildern (Vorhandensein, Dimensionen und Positionierung). Sie wiesen nach, dass diese visuellen Layout-Features die automatische Bewertung der Lesbarkeit (Readability Assessment) stark verbessern.

Für den Bereich der „Einfachen Sprache“ (Plain German) präsentierten Stodden et al. (2023) mit *DEplain* ein professionell erstelltes paralleles Korpus. Dieses teilt sich auf in einen Nachrichtenbereich (DEplain-APA) mit ca. 500 Dokumentenpaaren (rund 13.000 manuell ausgerichteten Satzpaaren) und einen Webbereich mit ca. 150 manuell ausgerichteten Dokumenten (ca. 2.000 Satzpaaren). Um die Datenknappheit weiter zu reduzieren, stellt das Framework zusätzlich einen Web-Harvester zur automatischen Extraktion und Ausrichtung bereit, wodurch der Webbereich auf ca. 750 Dokumentenpaare (ca. 3.500 automatisch ausgerichtete Satzpaare) vergrößert werden kann. Die Autoren zeigten, dass Modelle, die auf Dokumentenebene trainiert werden, oft Probleme haben, die feinkörnigen semantischen Übergänge beizubehalten, weshalb präzise Alignments eine kritische Ressource für das Training von Seq2Seq-Modellen darstellen. An dieser Stelle ist jedoch hervorzuheben, dass eine direkte Vergleichbarkeit mit Systemen zur Übersetzung in Leichte Sprache erschwert ist: Obwohl das DEplain-Framework methodisch wertvolle Ansätze liefert, bezieht es sich durch den Fokus auf Einfache Sprache auf eine andere linguistische Ziel- und Datendomäne.

Einen weiteren Beitrag zur Generierung paralleler Ressourcen leisteten Toborek et al. (2023) mit der Vorstellung des *New Aligned Simple German Corpus*. Ihr Datensatz besteht aus ca. 700 Dokumentenpaaren auf Dokumentenebene und über 10.000 Satzpaaren auf Satzebene, die teils manuell annotiert und teils automatisch berechnet wurden. Das Korpus kombiniert dabei das systematische Scraping paralleler Webinhalte mit automatischer Satz-Ausrichtung. Allerdings fasst die Arbeit Texte sowohl der Leichten als auch der Einfachen Sprache unter einem gemeinsamen Vereinfachungsbegriff zusammen, was eine feine Unterscheidung der spezifischen syntaktischen und semantischen Richtlinien von Leichter Sprache erschwert.

2.2. Maschinelle Textvereinfachung und Satz-Alignment

Die maschinelle Textvereinfachung lässt sich formal als Monolingual Machine Translation begreifen, bei der ein komplexer Ausgangstext in eine vereinfachte Zielsprachvariante übersetzt wird. Eine fundamentale Herausforderung im Vergleich zur klassischen maschinellen Übersetzung (z. B. Deutsch-Englisch) ist die Asymmetrie der Satzstrukturen: Eine Vereinfachung erfordert häufig Satzaufspaltungen (Sentence Splitting), Auslassungen irrelevanter Informationen (Compression) oder Paraphrasierungen. Folglich liegt selten ein einfaches 1:1-Satzalignment vor; stattdessen dominieren 1:n-, n:1- oder n:m-Alignments.

Zur automatisierten Ausrichtung paralleler Dokumente auf Satz- und Absatzebene hat sich das Werkzeug *CATS* von Štajner et al. (2018) etabliert. CATS implementiert verschiedene lexikalische und semantische Ähnlichkeitsmetriken (wie Character N-Grams (CNG) und gemittelte Word-Embeddings) und kombiniert diese mit dem *Most Similar Text* (MST) bzw. *MST-LIS* (Longest Increasing Subsequence) Suchalgorithmus. Štajner et al. (2018) wiesen nach, dass die Einbeziehung semantischer Vektoren (WAVG) und kontinuierlicher Wort-Alignments (CWASA) im Vergleich zu rein lexikalischen Maßen robustere Alignments bei stark paraphrasierten Sätzen liefert, wie sie für Leichte Sprache typisch sind. Dennoch bleibt die automatische Filterung verrauschter Alignments auf Basis kosinusähnlicher Schwellenwerte ein aktives Forschungsfeld, da zu niedrige Schwellenwerte fehlerhafte Übersetzungen und zu hohe Schwellenwerte einen Informationsverlust im Trainingsdatensatz induzieren.

2.3. Evaluierungsmetriken für die Vereinfachung

Die automatische Evaluierung von Textvereinfachungssystemen stellt eine große methodische Hürde dar. Traditionelle Metriken der maschinellen Übersetzung wie BLEU, die primär auf n-Gramm-Präzision im Vergleich zu einer Referenzübersetzung basieren, erweisen sich für die Vereinfachung oft als ungeeignet. Wie Alva-Manchego et al. (2021) empirisch belegen, korreliert BLEU nur schwach mit dem menschlichen Urteil über Einfachheit und Textqualität. Der Grund liegt darin, dass BLEU lexikalische Variationen und strukturelle Modifikationen (wie Satzteilung und Umformulierung) als Fehler abstrafte, obwohl genau diese für eine gute Vereinfachung essenziell sind.

Als Alternative etablierte sich die Metrik *SARI* (System Accessibility and Readability Index), eingeführt von Xu et al. (2016). SARI vergleicht die Systemausgabe sowohl mit dem komplexen Ausgangstext als auch mit den Referenzübersetzungen. Dabei berechnet SARI separat die Präzision und den Recall für eingefügte (add), gelöschte (delete) und beibehaltene (keep) Wörter:

$$\text{SARI} = \frac{F_{\text{add}} + F_{\text{keep}} + P_{\text{del}}}{3} \quad (2.1)$$

Dadurch belohnt SARI explizit Vereinfachungsoperationen, die sich vom komplexen Ausgangstext wegbewegen.

Für die deutsche Sprache stellt die neu entwickelte Metrik *DETECT* von Stodden et al. (2026) einen wichtigen Fortschritt dar. DETECT versucht, die Dimensionen Verständlichkeit (Ease), Grammatikalität und semantische Konsistenz (Textual Clarity) über ein erlerntes Evaluierungsmodell abzubilden, das auf synthetischen LLM-Generaten trainiert wurde. Dies adressiert die Schwäche klassischer Referenzmetriken, die die semantische Abweichung (Information Loss) bei extremen Kürzungen oft nicht hinreichend quantifizieren können.

2.4. Präferenzoptimierung (DPO) in der Textgenerierung

Während Supervised Fine-Tuning (SFT) darauf abzielt, die Token-Verteilung eines Referenzkorpus zu imitieren, stößt dieser Ansatz bei der Durchsetzung spezifischer Stil- und Formatierungsregeln (wie den Richtlinien der Leichten Sprache) an Grenzen. Um generative Modelle präziser auf menschliche Qualitätsurteile und formale Textregeln auszurichten, wurde traditionell Reinforcement Learning from Human Feedback (RLHF) über Proximal Policy Optimization (PPO) eingesetzt. Dieser Prozess ist jedoch rechenzeitintensiv und hyperparameter-instabil.

Mit der Einführung von *Direct Preference Optimization* (DPO) zeigten Rafailov et al. (2023), dass die explizite Modellierung eines separaten Reward-Modells mathematisch umgangen werden kann. DPO optimiert die Policy direkt auf Präferenzdaten der Form (x, y_w, y_l) — bestehend aus einem Prompt x , einer bevorzugten Antwort y_w (winning) und einer abgelehnten Antwort y_l (losing) — mittels einer geschlossenen Verlustfunktion:

$$\mathcal{L}_{\text{DPO}}(\theta; \pi_{\text{ref}}) = -\mathbb{E}_{(x, y_w, y_l)} \left[\log \sigma \left(\beta \log \frac{\pi_{\theta}(y_w|x)}{\pi_{\text{ref}}(y_w|x)} - \beta \log \frac{\pi_{\theta}(y_l|x)}{\pi_{\text{ref}}(y_l|x)} \right) \right] \quad (2.2)$$

wobei π_{ref} die SFT-Referenz-Policy darstellt, β ein Regularisierungsparameter ist und σ die Sigmoidfunktion bezeichnet.

Die Anwendung von DPO auf deutsche Textvereinfachung wurde kürzlich von Anonymized (2025) untersucht. Die Autoren nutzten den *HF4ATS*-Datensatz (Human Feedback for Automatic Text Simplification), um LLMs gezielt auf die Präferenzen von Menschen mit kognitiven Einschränkungen auszurichten. Sie wiesen nach, dass DPO-trainierte Modelle im Vergleich zu reinem SFT nicht nur eine signifikant höhere subjektive Verständlichkeit erzielen, sondern auch formale Kriterien der Leichten Sprache (wie das Vermeiden von Genitiven und Nebensätzen) stabiler einhalten, ohne dabei halluzinierte Fakten oder unzusammenhängende Sätze zu erzeugen. Dies motiviert den in dieser Arbeit gewählten Ansatz, DPO unter Verwendung eines trainierten Komplexitätsklassifikators als automatische Reward-Instanz zur Optimierung einzusetzen.

3. Themenblock 1: Datenbasis & Korpus-Erstellung

Die Erstellung eines qualitativ hochwertigen, repräsentativen und ausreichend großen parallelen Korpus bildet das Fundament für jedes datengetriebene Übersetzungssystem. Wie im vorangegangenen Kapitel dargelegt, leidet die maschinelle Textvereinfachung (ATS) für die deutsche Leichte Sprache unter einer eklatanten Datenknappheit. Während bestehende Ressourcen wie das Korpus von Battisti et al. (2020) einen wertvollen Grundstein legten, weisen sie für das Training moderner Seq2Seq- und Präferenzoptimierungsmodelle (wie DPO) entscheidende Limitierungen auf: Entweder ist ihr paralleler Anteil mit wenigen hundert Dokumenten zu gering, oder sie fokussieren sich, wie das DEplain-Korpus von Stodden et al. (2023), primär auf Einfache Sprache (Plain German), was sich linguistisch und regulatorisch signifikant von der Leichten Sprache unterscheidet.

Um diese Forschungslücke zu schließen, wurde im Rahmen dieser Arbeit eine eigene, automatisierte Pipeline zur Akquise und Aufbereitung von Trainingsdaten entwickelt.

Ein zentrales methodisches Charakteristikum der in dieser Arbeit entwickelten Pipeline und der nachfolgenden Modellierung ist die bewusste Entscheidung für ein **artikelbasiertes** (bzw. dokumentenweites) Training sowohl der Komplexitätsmetrik als auch des Übersetzungsmodells. In der bisherigen Forschung wurden Vereinfachungssysteme primär auf Satzebene trainiert und evaluiert, was jedoch erhebliche Defizite aufweist:

1. **Kontext- und Kohärenzverlust:** Satzbasierte Ansätze isolieren Sätze aus ihrem diskursiven Zusammenhang. Dadurch gehen anaphorische Bezüge, der rote Faden sowie die globale Kohärenz verloren. Zudem können makrostrukturelle Vereinfachungen wie die Umstrukturierung ganzer Absätze oder das Einfügen von erklärenden Hintergrundinformationen – welche im Konzept der Leichten Sprache essenziell sind – auf Satzebene nicht gelernt werden.
2. **Verrauschte Satz-Alignments:** Die Modellierung auf Satzebene setzt voraus, dass präzise Alignments vorliegen. Wie Stodden et al. (2023) und Štajner et al. (2018) zeigen, führt die asymmetrische Natur der Vereinfachung (z. B. n:m-Alignments und Satzteilungen) dazu, dass automatische Satz-Aligner entweder stark fehlerhafte Paare erzeugen oder einen massiven Informationsverlust durch das Verwerfen nicht-linearer Übergänge in Kauf nehmen müssen.
3. **Verlust struktureller Metadaten:** Wie Battisti et al. (2020) nachwiesen, spielen visuelle Layoutmerkmale, Absatzstrukturen und die Gliederung auf Dokumentenebene eine entscheidende Rolle für das Verständnis von Leichter Sprache. Ein satzbasiertes Alignment eliminiert diese Strukturen vollständig.

Indem wir den gesamten Artikel als Basiseinheit wählen, kann das Übersetzungsmodell lernen, globale Kürzungen vorzunehmen und Texte kohärent umzuformulieren. Gleichzeitig erlaubt dies der Komplexitätsmetrik, die Verständlichkeit eines Textes im Kontext des gesamten Dokuments statt isolierter Sätze zu bewerten. Die methodischen Entscheidungen dieser Pipeline spiegeln dabei direkt die in Kapitel 2.2 und 2.3 diskutierten Herausforderungen des Forschungsstandes wider:

- **Multi-Quellen-Crawling & Datenakquise (Abschnitt 3.1):** Um eine breite lexikalische und domänenspezifische Abdeckung zu erzielen und nicht auf eine einzelne Textgattung beschränkt zu sein, wurde ein modularer Scraper für eine Vielzahl deutschsprachiger Webportale implementiert. Dies erweitert den Ansatz von Battisti et al. (2020) und stellt sicher, dass sowohl behördliche Texte (im Kontext der BITV 2.0) als auch journalistische Beiträge und Alltagstexte vertreten sind.
- **Alignment & Das 1:n-Problem (Abschnitt 3.2):** Wie in Abschnitt 2.2 erläutert, übersetzen menschliche Übersetzer Leichte Sprache selten in Form von 1:1-Satzentsprechungen. Häufiger sind Satzaufspaltungen (Sentence Splitting) und starke Komprimierungen. Daher wird eine dynamische Alignment-Strategie benötigt, die über klassische Satzähnlichkeiten hinausgeht und semantische Einbettungen nutzt, um asymmetrische Satzbeziehungen (1:n) zuverlässig abzubilden.
- **Quality Assurance & Similarity Sweet-Spot (Abschnitt 3.3):** Um das von Štajner et al. (2018) beschriebene Rauschen in den ausgerichteten Daten zu minimieren, wird eine filterbasierte Qualitätssicherung eingeführt. Diese zielt darauf ab, den „Similarity Sweet-Spot“ zu identifizieren: Einerseits müssen zu unähnliche Satzpaare (die auf fehlerhaften Alignments beruhen) ausgeschlossen werden; andererseits müssen auch identische oder nahezu identische Satzpaare (die keinen Vereinfachungseffekt aufweisen) herausgefiltert werden, um dem Modell das Erlernen trivialer Kopieroperationen zu erschweren.
- **Datenbereinigung & Normalisierung (Abschnitt 3.4):** Da Texte aus unterschiedlichen Quellen stark variierende HTML-Strukturen, typografische Besonderheiten (z. B. die Verwendung von Bindestrichen oder Mediopunkten zur Worttrennung) und Layout-Elemente aufweisen, ist eine sorgfältige Vorverarbeitung essenziell.
- **Korpus-Statistiken & Lexikalische Diversität (Abschnitt 3.5):** Abschließend wird das resultierende Korpus quantitativ und qualitativ evaluiert. Hierbei wird analysiert, inwiefern die bereinigten und ausgerichteten Daten die theoretischen Anforderungen der Leichten Sprache erfüllen und welche lexikalische Vielfalt sie aufweisen.

Dieses Kapitel beschreibt den detaillierten Ablauf dieser Schritte und dokumentiert die Designentscheidungen bei der Konstruktion des finalen Datensatzes.

- 3.1. Multi-Quellen-Crawling & Datenakquise**
- 3.2. Alignment & Das 1:n-Problem**
- 3.3. Quality Assurance & Similarity Sweet-Spot**
- 3.4. Datenbereinigung & Normalisierung**
- 3.5. Korpus-Statistiken & Lexikalische Diversität**

4. Themenblock 2: Metrik & Bewerten von Sprachkomplexität

4.1. Klassifikationsmodelle

4.2. Out-of-Domain-Generalisierung & Empirische Bias-Kontrolle

4.3. Continuous MixUp Regression

4.4. Evaluierung synthetischer Sprachstufen

5. Themenblock 3: Modellierung der Übersetzung & Reward-Guided Fine-Tuning

5.1. Datenvorbereitung & Trainings-Splits

5.2. Supervised Fine-Tuning (SFT)

5.3. Reward-Guided Optimization (RLHF / DPO)

5.4. Mehrdimensionale Evaluierung

6. Diskussion & Gesamtevaluation

6.1. Inhaltssynthese der drei Themenblöcke

6.2. Stärken, Grenzen & Systemrestriktionen

6.3. Beantwortung der Forschungsfragen

7. Fazit & Ausblick

7.1. Zusammenfassung der Kernergebnisse

7.2. Ausblick & Zukünftige Forschungsarbeiten

Literatur

- Alva-Manchego, F., Scarton, C., & Specia, L. (2021). The (Un)Suitability of Automatic Evaluation Metrics for Text Simplification. *Computational Linguistics*, 47(4), 861–889.
- Anonymized, A. (2025). Evaluating the Effectiveness of Direct Preference Optimization for Personalizing German Automatic Text Simplifications for Persons with Intellectual Disabilities. *Proceedings of the 2025 Conference on Empirical Methods in Natural Language Processing*.
- Battisti, A., Pfütze, D., Säuberli, A., Kostrzewa, M., & Ebling, S. (2020). A Corpus for Automatic Readability Assessment and Text Simplification of German. *Proceedings of the 12th Language Resources and Evaluation Conference*, 3302–3311.
- Klaper, D., Ebling, S., & Volk, M. (2013). KLAPER: A German/Simplified German Parallel Corpus. *Proceedings of the 17th International Conference on System Theory, Control and Computing*.
- Madina, M., Gonzalez-Dios, I., & Siegel, M. (2023). Easy-to-Read in Germany: A Survey on its Current State and Available Resources. *arXiv preprint arXiv:2306.03189*.
- Rafailov, R., Sharma, A., Mitchell, E., Ermon, S., Manning, C. D., & Finn, C. (2023). Direct Preference Optimization: Your Language Model is Secretly a Reward Model. *Advances in Neural Information Processing Systems*.
- Štajner, S., Franco-Salvador, M., Rosso, P., & Ponzetto, S. P. (2018). CATS: A Tool for Customized Alignment of Text Simplification Corpora. *Proceedings of the 11th Language Resources and Evaluation Conference*.
- Stodden, R., et al. (2026). DETECT: Determining Ease and Textual Clarity of German Text Simplifications. *Proceedings of the 18th Conference of the European Chapter of the Association for Computational Linguistics*.
- Stodden, R., Momen, O., & Kallmeyer, L. (2023). DEplain: A German Parallel Corpus with Intralingual Translations into Plain Language for Sentence and Document Simplification. *Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, 8391–8412.
- Toborek, V., Busch, M., Boßert, M., Bauckhage, C., & Welke, P. (2023). A New Aligned Simple German Corpus. *Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, 11416–11432.
- Überwachungsstelle des Bundes für Barrierefreiheit von Informationstechnik. (2026). *Leichte Sprache – Übergreifende Anforderungen für Web und App*. Verfügbar 8. August 2026 unter https://www.barrierefreiheit-dienstekonsolidierung.bund.de/Webs/PB/DE/barrierefreie_it/uebergreifende-anforderungen-web-und-app/leichte-sprache/leichte-sprache-artikel.html

Xu, W., Napoles, C., Pavlick, E., Chen, Q., & Callison-Burch, C. (2016). Optimizing Statistical Machine Translation for Text Simplification. *Transactions of the Association for Computational Linguistics*, 4, 401–415.

A. Anhang