

Hochschule Flensburg
University of Applied Sciences
Master of Science Angewandte Informatik

M A S T E R - T H E S I S

**Entwicklung domänenspezifischer Datensätze und automatisierter
Evaluation für ein Framework zur neuronalen Textvereinfachung in
leichte Sprache**

Fiete Scheel
Matrikel-Nr.:
Erstprüfer: Max Mustermann
Zweitprüfer: Manuela Musterfrau
Abgabe: xx.xx.xxxx

Hochschule Flensburg

M A S T E R - T H E S I S

Thema: Entwicklung domänenspezifischer Datensätze und automatisierter Evaluation
für ein Framework zur neuronalen Textvereinfachung in leichte Sprache

von: Fiete Scheel

Matrikel-Nr.:

Studiengang: Master of Science Angewandte Informatik

Betreuer/in und
Erstbewerter/in: Prof. Dr.-Ing. Marc Aubreville

Zweitbewerter/in: Prof. Dr. Peter John

Ausgabedatum: 21.05.2026

Abgabedatum: 10.09.2026

Abstract

Der barrierefreie Zugang zu Informationen in Leichter Sprache ist eine grundlegende Voraussetzung für gesellschaftliche Teilhabe, Chancengleichheit und selbstbestimmte Information. Vor dem Hintergrund gesetzlicher Vorgaben wie dem Barrierefreiheitsstärkungsgesetz (BFSG) stehen Institutionen und Unternehmen vor der Herausforderung, komplexe Alltagstexte in großem Umfang verlässlich zu vereinfachen. Bisherige datengetriebene Ansätze zur maschinellen Textvereinfachung (Automatic Text Simplification, ATS) für das Deutsche scheiterten jedoch an drei zentralen Hürden: einem akuten Mangel an qualitätsgesicherten parallelen Trainingskorpora, dem Fehlen stufenloser und differenzierbarer Evaluierungsmetriken für Sprachkomplexität sowie der unzureichenden linguistischen Regeleinhaltung generativer Sprachmodelle.

Die vorliegende Masterarbeit begegnet diesen Herausforderungen durch die Konzeption, Implementierung und empirische Evaluation eines in sich geschlossenen, modularen Frameworks für die deutsche Leichte Sprache.

Im ersten Schritt wurde eine automatisierte Pipeline zur Korpusgewinnung entwickelt. Durch die gezielte Extraktion der Hauptinhalte (DOM-Content-Isolation), regelbasierte Bereinigungsschritte und eine semantische Ähnlichkeitsfilterung im Intervall $[0,60; 0,98]$ über Text-Embeddings konnte aus 12 heterogenen Webquellen ein bereinigtes Parallelkorpus von 860 konsistenten Artikelpaaren aufgebaut werden, das störende Web-Artefakte und Formatierungsreste verlässlich entfernt.

Zur referenzfreien Bewertung der sprachlichen Einfachheit wurde im zweiten Schritt ein kontinuierlicher Komplexitätsregressor auf Basis eines bidirektionalen LSTMs (BiLSTM) konzipiert. Durch das kontrollierte Mischen latenter Satzrepräsentationen (Latent MixUp) erlernt das Modell kontinuierliche Zwischenstufen der Textschwere, ohne auf künstliche Zwischentexte angewiesen zu sein. Auf einem unabhängigen Testset der *Lebenshilfe Schleswig-Holstein* erzielt die Metrik eine Paar-Rangtreue von knapp 80 %, korreliert stark mit qualitativen Expertenurteilen ($\rho = 0,6750$) und generalisiert stabil auf externe Sprachkorpora (MERLIN und TextComplexityDE).

Die generative Übersetzung wird im dritten Schritt als Sequenz-zu-Sequenz-Transformation (mBART-50) mit parametereffizienten LoRA-Adaptoren modelliert. Während das überwachte Feintuning (SFT) die grundlegende Textverkürzung etabliert (Satzlänge $12,50 \rightarrow 7,61$ Wörter), schärft die anschließende direkte Präferenzoptimierung (DPO) anhand des gelernten MixUp-Belohnungssignals die formale Regeleinhaltung gezielt nach und reduziert Passiv- sowie Genitivstrukturen auf unter 1 %.

In einer verblindeten Expertenstudie mit einer zertifizierten Fachkraft der Lebenshilfe bestätigt sich eine kontinuierliche Qualitätssteigerung über alle Modellstufen hinweg ($1,58 \rightarrow 3,00 \rightarrow 3,50 \rightarrow 3,92$). Eine ergänzende Konsistenzanalyse zeigt jedoch auf, dass gängige Ähnlichkeitsmetriken bei isolierten Faktenfehlern an Grenzen stoßen, womit die weitere Qualitätssteigerung des Trainingsalignments sowie NLI-basierte Konsistenzprüfungen als zentrale Hebel für zukünftige Arbeiten identifiziert werden. Die Arbeit liefert damit den

methodischen Nachweis, dass eine autonome, referenzfreie Übersetzungspipeline für deutsche Leichte Sprache prinzipiell realisierbar ist.

Erklärung zur Nutzung generativer Künstlicher Intelligenz

Generative KI wurde im Verlauf dieser Masterarbeit regelmäßig als unterstützendes Werkzeug eingesetzt. Sie wurde als standardmäßiger Bestandteil moderner Arbeitsabläufe betrachtet – in gleicher Weise, wie eine integrierte Entwicklungsumgebung oder eine Rechtschreibprüfung ein Standardbestandteil beim Schreiben von Programmcode und Fließtext ist. Der Einsatz erfolgte stets unterstützend und zu keinem Zeitpunkt als passive Abgabe von Aufgaben. Jede Ausgabe unterlag einer engen manuellen Überwachung, wurde wiederholt überarbeitet und durch den Autor verifiziert.

Die folgenden Werkzeuge kamen zum Einsatz:

- **DeepL Write** wurde für das sprachliche Lektorat und das grammatikalische Korrekturlesen verwendet.
- **Gemini (Google)** wurde zur Unterstützung beim Brainstorming, zur Klärung technischer Konzepte und zur Generierung von Formulierungsvorschlägen für nicht-technische Erklärungstexte genutzt. Zudem diente es als erster Schritt bei der Informationssuche anstelle einer konventionellen Suchmaschine.
- **Antigravity (Google)** wurde als agentische Entwicklungsumgebung und über die Befehlszeilenschnittstelle (CLI) für Programmieraufgaben, technische Beratung, Code-Reviews sowie das Korrekturlesen der Abschlussarbeit eingesetzt (u. a. zur automatisierten Überprüfung auf argumentative Konsistenz, präzise Wortwahl sowie Rechtschreibung und Grammatik).

Die KI-Werkzeuge dienten zudem als Diskussions- und Sparringspartner sowie zum »Rubber Ducking«. Das strukturierte Formulieren eines Problems gegenüber dem System trug oft bereits vor Erhalt einer Antwort zur Klärung bei. Sämtliche methodischen Vorgehensweisen und erarbeiteten Lösungsansätze wurden darüber hinaus fortlaufend in den wöchentlichen Master-Meetings mit dem betreuenden Professor, den Doktoranden und weiteren Masterstudierenden gegengeprüft, diskutiert und entweder bestätigt, verworfen oder gezielt weiterentwickelt.

Alle durch KI-Werkzeuge generierten Inhalte wurden vom Autor kritisch geprüft, editiert und verifiziert. Kein generatives KI-System wurde zur Erzeugung originärer wissenschaftlicher Resultate, experimenteller Messdaten, Beweise oder der finalen Implementierungen der Algorithmen herangezogen. Das Forschungsdesign, die Analyse sowie die Interpretation der Ergebnisse sind originäre Leistungen des Autors. Der Autor übernimmt die uneingeschränkte Verantwortung für den Inhalt, die Richtigkeit und die Eigenständigkeit dieser Arbeit.

Ich versichere, dass ich meine Arbeit selbstständig und ohne fremde Hilfe verfasst, keine anderen als die angegebenen Quellen und Hilfsmittel benutzt, alle wörtlich oder sinngemäß übernommenen Stellen einschließlich generierter Texte in der Arbeit gekennzeichnet habe, und dass die Arbeit in gleicher oder ähnlicher Form in noch keiner anderen Prüfung vorgelegen hat. Ich stimme der Überprüfung der Arbeit durch eine Plagiatssoftware zu.

Ort, Datum

Unterschrift

Inhaltsverzeichnis

1	Einleitung	1
1.1	Problemstellung & Motivation	1
1.2	Zielsetzung & Forschungsfragen	1
1.3	Aufbau der Arbeit	2
2	Theoretischer Hintergrund	3
2.1	Das Konzept der Leichten Sprache	3
2.2	Linguistische Maße & Lesbarkeitsmetriken	3
2.2.1	Traditionelle Lesbarkeitsformeln	3
2.2.2	Lexikalische Diversität: TTR vs. MATTR	4
2.2.3	Faktenerhalt & Faktentreue (Named Entity Recognition)	4
2.3	Textrepräsentationen & Einbettungsmodelle	5
2.3.1	Subword-Tokenisierung	5
2.3.2	Text-Embeddings & Sentence-BERT (SBERT)	5
2.3.3	Long-Context-Embeddings & ALiBi-Attention	5
2.3.4	Semantische Ähnlichkeitsmessung	6
2.4	Architekturen moderner neuronaler Sprachmodelle	6
2.4.1	Rekurrente Neuronale Netze, LSTM & BiLSTM	6
2.4.2	Transformer & Attention-Mechanismus	6
2.4.3	Transformer-Modellfamilien im NLP	7
2.5	Feinabstimmung & Parameter-Efficient Fine-Tuning (PEFT)	7
2.5.1	Supervised Fine-Tuning (SFT)	7
2.5.2	Low-Rank Adaptation (LoRA)	8
2.6	Präferenzoptimierung & Reinforcement Learning (RLHF & DPO)	8
2.6.1	Das klassische RLHF-Paradigma & PPO	8
2.6.2	Direct Preference Optimization (DPO)	9
2.7	Generierungs- und Decoding-Strategien	9
3	Stand der Forschung	10
3.1	Verfügbare Datenbasis und Korpora (Themenblock 1)	10
3.2	Evaluierungsmetriken für die Vereinfachung (Themenblock 2)	11
3.3	Maschinelle Übersetzung und Optimierungsverfahren (Themenblock 3)	12
4	Themenblock 1: Datenbasis & Korpus-Erstellung	13
4.1	Multi-Quellen-Crawling & Datenakquise	14
4.1.1	Domänen- und Quellenabdeckung	15
4.1.2	Technische Extraktions- & Verknüpfungsmechanismen	16
4.1.3	Ergebnis der Datenakquise (Roh-Korpus)	17
4.2	Datenaufbereitung, Normalisierung & Qualitätssicherung	18
4.2.1	Web-Boilerplate-Bereinigung & Interpunktionsicherung	18

4.2.2	Typografische Normalisierung & Listen-Transformation	19
4.2.3	Semantische Qualitätssicherung & Optimaler Ähnlichkeitsbereich . .	20
4.2.4	Empirische Fallstudien zur Bias- & Halluzinations-Prävention	21
4.3	Korpus-Statistiken & Linguistische Analyse	23
4.3.1	Quantitative Korpusmaße & Quellcharakteristika	23
4.3.2	Lexikalische Diversität: TTR vs. MATTR & Längen-Bias	24
4.3.3	Faktenerhalt vs. Faktentreue: Grenzen von NER als Metrik	25
4.3.4	Regeleinhaltung nach BMAS-Richtlinien	25
4.3.5	Synthese der Korpuseigenschaften	26
5	Themenblock 2: Metrik & Bewerten von Sprachkomplexität	29
5.1	Vorstufe: Binäre Klassifikation als Machbarkeitsnachweis & Architektur-Baseline	29
5.1.1	Motivation, Lesbarkeitsmetriken & BiLSTM-Architektur	29
5.1.2	Granularitäts-Vergleich: Satzebene vs. Articlebene	30
5.1.3	Dummy-Content-Test: Prüfung auf Längen- und Padding-Bias . . .	31
5.1.4	Synthese: Erlernbarkeit des Signals & Überleitung zur stetigen Sprachstufenmodellierung	31
5.2	Erster Lösungsansatz: Synthetische Sprachstufengenerierung via Large Language Models	32
5.2.1	Konzeption, Prompt-Design & Generierung mit FlensGen-GPT . . .	32
5.2.2	Empirische Ergebnisse auf dem Lebenshilfe-Goldstandard	33
5.2.3	Methodische Grenzen & Motivation für ein stochastisches Text-MixUp	33
5.3	Zweiter Lösungsansatz: Continuous MixUp Regression	34
5.3.1	Konzeption des textuellen MixUp & Dynamische Target-Berechnung	34
5.3.2	Vergleich der Trainings- und Sampling-Strategien	34
5.3.3	Einfluss der Kontextlänge auf die MixUp-Regression	35
5.4	Validierung der kontinuierlichen Abstufungsfähigkeit auf externen Benchmarks (TextComplexityDE & MERLIN)	37
5.4.1	Das Problem fehlender Zwischenstufenkorpora & Motivation der externen Benchmarks	37
5.4.2	Satzebene: Evaluation auf TextComplexityDE & Analyse der Längendynamik	38
5.4.3	Dokumentebene: Evaluation auf dem MERLIN CEFR-Benchmark . .	39
5.4.4	Kritische Synthese: Validität des Zero-Shot-Transfers & Fazit	40
5.5	Synthese & Modellauswahl für die generative Übersetzung (Themenblock 3)	41
6	Themenblock 3: Modellierung der Übersetzung & Reward-Guided Fine-Tuning	45
6.1	Supervised Fine-Tuning (SFT)	45
6.1.1	Datenbasis, Trainings-Splits & Sequence-to-Sequence-Modellierung .	45
6.1.2	Parameter-Efficient Fine-Tuning (PEFT / LoRA)	46
6.1.3	Trainingsverlauf und Auswahl des besten Modells	47

6.1.4	Einfluss der Datenmenge auf die Modellleistung	47
6.1.5	Einfluss der Kontextlänge & Dokumentenintegrität	48
6.1.6	Zwischenfazit & Synthese der SFT-Phase	49
6.2	Reward-Guided Optimization (DPO)	49
6.2.1	Erstellung des Präferenzdatensatzes mit schrittweiser Temperatur- Erhöhung	49
6.2.2	Speichereffiziente Umsetzung der Präferenzoptimierung	51
6.2.3	Kombinierte Bewertung aus Stil und Inhalt & Einfluss der Gewichtung	52
6.2.4	Einfluss des Parameters β auf Stil und Inhalt	53
6.2.5	Einfluss der Sequenzlänge & Skalierungsdynamik bei DPO	53
6.2.6	Einhaltung der Sprachregeln bei SFT und DPO	54
6.2.7	Zwischenfazit der DPO-Phase	56
6.3	Empirische Validierung durch Fachexperten (Lebenshilfe Kiel)	56
6.3.1	Motivation & Zielsetzung der Expertenstudie	56
6.3.2	Studiendesign: Einzeltext-Bewertung	56
6.3.3	Web-basierte Studienumgebung & Admin-Dashboard	58
6.3.4	Statistische Auswertungsmethodik	58
6.3.5	Ergebnisse der Experten-Evaluation	59
7	Diskussion & Gesamtevaluation	62
7.1	Inhaltssynthese der drei Themenblöcke	62
7.2	Stärken, Grenzen & Systemrestriktionen	63
7.3	Beantwortung der Forschungsfragen	66
7.3.1	Beantwortung von FF1: Automatisierte Korpusgewinnung & Quali- tätsfilterung	66
7.3.2	Beantwortung von FF2: Kontinuierliche Komplexitätsmodellierung & Validierung	67
7.3.3	Beantwortung von FF3: Regel-Lernbarkeit (SFT) & Reward-Guided Alignment (DPO)	67
7.3.4	Beantwortung von FF4: Übereinstimmung mit dem qualitativen Ex- pertenurteil	68
8	Fazit & Ausblick	70
8.1	Zusammenfassung der Kernergebnisse	70
8.2	Ausblick & Zukünftige Forschungsarbeiten	71
	Abkürzungsverzeichnis	73
	Abbildungsverzeichnis	75
	Tabellenverzeichnis	76
	Literaturverzeichnis	77

A Anhang	82
A.1 Ergänzende Evaluation auf TextComplexityDE (Naderi et al., 2019)	82
A.2 Ergänzende Evaluation auf dem MERLIN CEFR-Benchmark (Boyd et al., 2014)	84
A.3 Ergänzende Evaluation der Klassifikationsmodelle (Ähnlichkeitsbereiche & Granularitätsvergleich)	85
A.4 Ergänzende Evaluation der MixUp Trainings- und Sampling-Strategien (Varianten A–D)	87
A.5 Ergänzende Evaluation der BiLSTM MixUp Regressoren (Längenvergleich)	90
A.6 Ergänzende Evaluation des Synthetischen Regressors & Prompt-Design . . .	91
A.6.1 Master-Benchmark auf dem Lebenshilfe-Goldstandard	91
A.6.2 Prompt-Design zur Generierung synthetischer Zwischenstufen	93
A.7 Ergänzende Auswertung zur SFT-Datenskalierung	94
A.8 Ergänzende Kenngrößen des DPO-Präferenzdatensatzes (mBART-50) . . .	95
A.9 Ergänzende Evaluation zur Kontextlängenskalierung (SFT vs. DPO)	96
A.10 Ergänzende Auswertung zur Einhaltung der Sprachregeln	97
A.11 Übersicht der Hyperparameter und Trainingskonfigurationen	98
A.12 Synthetischer 256-Token Regel-Sensitivitäts-Benchmark	99

1 Einleitung

1.1 Problemstellung & Motivation

Für manche eine optionale Lesehilfe, für andere der einzige Zugang zu gesellschaftlicher Teilhabe.

Beim Thema Barrierefreiheit denken viele an physische Barrieren wie Rampen, Aufzüge oder automatische Türen. Durch die Digitalisierung und die Verlagerung von Dienstleistungen und Informationen ins Internet ist es damit jedoch nicht mehr getan. Barrierefreie Gestaltung betrifft zunehmend digitale Räume und insbesondere die Sprache, in der Informationen bereitgestellt werden.

Menschen mit kognitiven Einschränkungen, Lernschwierigkeiten, geringer Lese- und Schreibkompetenz oder Deutsch als Zweitsprache werden durch komplexe Texte, bürokratische Fachsprache und verschachtelte Satzstrukturen vom Zugang zu grundlegenden Informationen und Dienstleistungen ausgeschlossen. Das Konzept der *Leichten Sprache* (LS) bietet hierfür ein klar reglementiertes Regelwerk, um Texte durch Vereinfachung des Vokabulars und der Syntax verständlich zu machen.

Mit dem Inkrafttreten des Barrierefreiheitsstärkungsgesetzes (BFSG) in Deutschland sowie europäischen Richtlinien (wie der Web-Accessibility-Directive) wächst der rechtliche Druck auf öffentliche und private Akteure, Informationen auch in Leichter Sprache anzubieten. Die manuelle Übersetzung von Alltagssprache (AS) in Leichte Sprache (LS) durch menschliche Übersetzer ist jedoch extrem zeitintensiv, kostspielig und durch einen Mangel an Fachkräften limitiert.

Hieraus ergibt sich ein dringender Forschungs- und Entwicklungsbedarf im Bereich der maschinellen Textvereinfachung. Bisherige neuronale Übersetzungsmodelle scheitern jedoch häufig an den spezifischen syntaktischen und strukturellen Besonderheiten der Leichten Sprache oder leiden unter dem Mangel an qualitativ hochwertigen, parallelen Trainingsdaten. Es bedarf daher systematischer Ansätze zur automatisierten Erstellung paralleler Korpora, robuster Metriken zur Komplexitätsbewertung und optimierter Trainingsstrategien.

1.2 Zielsetzung & Forschungsfragen

Ziel dieser Arbeit ist die Entwicklung, Optimierung und empirische Evaluierung eines methodischen Frameworks zur automatisierten Übersetzung deutscher Alltagssprache in Leichte Sprache. Dies umfasst die gesamte Pipeline: von der Akquise und Bereinigung paralleler Web-Korpora über die kontinuierliche, referenzfreie Modellierung von Textsimplizität bis hin zur dateneffizienten Modelladaption (LoRA) und dem Präferenz-Alignment (DPO).

Im Zentrum dieser Arbeit steht die folgende übergreifende Leitfrage:

Wie lässt sich die automatische Übersetzung in Leichte Sprache (LS) durch die Kombination aus rauschbereinigten Korpora, kontinuierlichen Simplitätsmetriken und zielgerichteten Alignment-Strategien (DPO) systematisch optimieren und validieren?

Zur systematischen Beantwortung dieser Leitfrage werden vier forschungsleitende Kernfragen (FF1 bis FF4) formuliert, die den logischen Bogen über die methodischen Hauptsäulen der Arbeit spannen:

1. FF1 (Datenbasis & Korpusqualität – Themenblock 1):

Wie lässt sich aus heterogenen Webquellen ein qualitativ hochwertiges, artikelbasiertes Parallelkorpus für die deutsche Leichte Sprache automatisiert gewinnen, bereinigen und semantisch filtern?

2. FF2 (Metrik & Sprachkomplexität – Themenblock 2):

Wie kann auf Basis rein bimodal vorliegender Sprachdaten eine stufenlose, differenzierbare Metrik zur referenzfreien Bewertung von Textsimplizität modelliert und validiert werden?

3. FF3 (Übersetzungsmodellierung & Alignment – Themenblock 3):

Inwieweit sind generative Sprachmodelle in der Lage, die Regeln der Leichten Sprache anhand eines automatisiert akquirierten Web-Datensatzes zu erlernen, und wie lassen sich diese Modelle mithilfe eines gelernten Reward-Signals gezielt weiter anpassen?

4. FF4 (Expertenvalidierung & Ökologische Validität – Diskussion):

Inwieweit stimmen die automatisierten Modell- und Metrikbewertungen mit dem qualitativen Urteil einer Fachkraft für Leichte Sprache (Lebenshilfe Kiel) in der Praxis überein?

1.3 Aufbau der Arbeit

Die vorliegende Arbeit gliedert sich in acht aufeinander aufbauende Abschnitte: Nach der Darlegung der linguistischen Grundlagen (Abschnitt 2) und des aktuellen Forschungsstands (Abschnitt 3) bildet die dreistufige Übersetzungspipeline den methodischen Kern. Themenblock 1 (Abschnitt 4) widmet sich der automatisierten Akquise, Bereinigung und semantischen Qualitätssicherung des parallelen Web-Korpus. In Themenblock 2 (Abschnitt 5) werden die Konzeption und empirische Validierung der kontinuierlichen Komplexitätsmetrik dargelegt. Themenblock 3 (Abschnitt 6) beschreibt das generative Übersetzungsmodell mittels Supervised Fine-Tuning, Reward-Guided DPO-Alignment und verblindeter Expertenvalidierung. Eine zusammenführende Diskussion mit systematischer Beantwortung der Forschungsfragen (Abschnitt 7) sowie ein Fazit mit Ausblick (Abschnitt 8) runden die Arbeit ab.

2 Theoretischer Hintergrund

2.1 Das Konzept der Leichten Sprache

Die Leichte Sprache (LS) ist eine geregelte Sprachvariante des Deutschen. Sie soll Barrierefreiheit in der schriftlichen Kommunikation für Menschen mit Lernschwierigkeiten, kognitiven Einschränkungen oder geringer Lese- und Schreibkompetenz ermöglichen (Bundesministerium für Arbeit und Soziales, 2025). Syntaktisch zeichnet sich LS durch kurze Hauptsätze in Subjekt-Prädikat-Objekt-Struktur sowie den Verzicht auf Nebensätze, Passivformen, Genitive und Konjunktive aus. Auf lexikalischer Ebene werden abstrakte Begriffe durch konkrete Umschreibungen oder Beispiele ersetzt. Lange Komposita werden typografisch durch Bindestriche oder den Mediopunkt gegliedert (z. B. *Bundestags-Wahl* oder *Bundestagswahl*).

Von der Leichten Sprache ist die sogenannte *Einfache Sprache* (Plain German) zu unterscheiden. Während Leichte Sprache festen Richtlinien folgt und in Deutschland für öffentliche Stellen durch die Barrierefreie-Informationstechnik-Verordnung (BITV 2.0) rechtlich verankert ist (Bundesministerium des Innern, für Bau und Heimat, 2019), besitzt Einfache Sprache ein weniger restriktives Regelwerk (Portal Barrierefreiheit / BFIT Bund, 2026). Sie richtet sich an eine breitere Zielgruppe — etwa Menschen mit Deutsch als Zweitsprache oder funktionale Analphabeten — und erlaubt komplexere Satzstrukturen sowie einen größeren Wortschatz. Ein wesentlicher Unterschied betrifft zudem die Qualitätssicherung: Texte in Leichter Sprache müssen verpflichtend durch Personen aus der Zielgruppe auf Verständlichkeit geprüft werden, was bei Einfacher Sprache nicht vorgeschrieben ist (Portal Barrierefreiheit / BFIT Bund, 2026).

2.2 Linguistische Maße & Lesbarkeitsmetriken

2.2.1 Traditionelle Lesbarkeitsformeln

Traditionelle Lesbarkeitsformeln schätzen die Textschwierigkeit deterministisch anhand von Oberflächenmerkmalen (Silben-, Wort- und Satzlängen):

1. **Flesch Reading Ease (FRE) nach Amstad (1978):** Die an das Deutsche adaptierte Formel berechnet einen Lesbarkeitsindex auf einer Skala von 0 (extrem schwer) bis 100 (sehr leicht):

$$\text{FRE} = 180 - \text{ASL} - (58,5 \cdot \text{ASW}) \quad (1)$$

wobei ASL die durchschnittliche Satzlänge (*Average Sentence Length* in Wörtern) und ASW die durchschnittliche Silbenanzahl pro Wort (*Average Number of Syllables per Word*) bezeichnet.

2. **Wiener Sachtextformel (WSTF) nach Bamberger und Vanecek (1984):** Die WSTF gibt das geschätzte Schulstufenniveau an, das zum Textverständnis erforderlich ist:

$$\text{WSTF} = 0,1935 \cdot \text{MS} + 0,1672 \cdot \text{SL} + 0,1297 \cdot \text{IW} - 0,0327 \cdot \text{ES} - 0,875 \quad (2)$$

mit dem Prozentsatz an Wörtern mit mindestens drei Silben (MS), der mittleren Satzlänge (SL), dem Prozentsatz an Wörtern mit mehr als sechs Buchstaben (IW) und dem Anteil einsilbiger Wörter (ES). Niedrigere Werte stehen für eine leichtere Lesbarkeit (z. B. Stufen 4–6 für Grund- und Hauptschulniveau).

3. **LIX-Lesbarkeitsindex nach Björnsson (1968):** Der LIX quantifiziert die Lesbarkeit sprachunabhängig als Summe der mittleren Satzlänge und des Prozentanteils langer Wörter (> 6 Zeichen, LW):

$$\text{LIX} = \frac{\text{Wörter}}{\text{Sätze}} + \left(\frac{\text{LW}}{\text{Wörter}} \cdot 100 \right) \quad (3)$$

2.2.2 Lexikalische Diversität: TTR vs. MATTR

Die lexikalische Vielfalt eines Textes wird traditionell über die *Type-Token-Ratio* (TTR = $|V|/N$, Chotlos, 1944; Templin, 1957) gemessen, wobei $|V|$ die Anzahl distinkter Worttypen und N die Gesamtwortzahl bezeichnet. Mit zunehmender Textlänge flacht der Zuwachs neuer Worttypen jedoch naturgemäß ab, da sich Funktionswörter und Kernbegriffe im fortlaufenden Text wiederholen. Längere Texte weisen daher systematisch eine niedrigere TTR auf als kurze Abschnitte, was den direkten Vergleich unterschiedlich langer Texte verzerrt.

Um diesen Längeneinfluss zu eliminieren, verwendet man die *Moving-Average Type-Token-Ratio* (MATTR) nach Covington und McFall (2010). Die MATTR berechnet die TTR über ein gleitendes Fenster fester Wortbreite W (standardmäßig $W = 50$):

$$\text{MATTR}_W = \frac{1}{N - W + 1} \sum_{i=1}^{N-W+1} \frac{|V_{i,W}|}{W} \quad (4)$$

wobei $|V_{i,W}|$ die Anzahl distinkter Worttypen im i -ten Fenster angibt. Die MATTR ist dadurch unabhängig von der Gesamtlänge des Textes.

2.2.3 Faktenerhalt & Faktentreue (Named Entity Recognition)

Zur Überprüfung des inhaltlichen Faktenerhalts wird *Named Entity Recognition* (NER) eingesetzt. Das Verfahren extrahiert benannte Entitäten wie Personen, Organisationen und Orte (Nadeau und Sekine, 2007). In dieser Arbeit erfolgt die Entitätenerkennung mit **spaCy** (Honnibal et al., 2020) über das deutsche Sprachmodell **de_core_news_lg**.

In Anlehnung an Devaraj et al. (2022) wird der Entitätenabgleich über zwei Mengenmaße definiert: Für die Entitätenmenge E_{AS} des Ausgangstexts und E_{LS} der vereinfachten Fassung gilt:

$$\text{Faktenerhalt (Recall}_{\text{AS} \rightarrow \text{LS}}) = \frac{|E_{\text{AS}} \cap E_{\text{LS}}|}{|E_{\text{AS}}|} \quad (5)$$

$$\text{Faktentreue (Recall}_{\text{LS} \rightarrow \text{AS}}) = \frac{|E_{\text{AS}} \cap E_{\text{LS}}|}{|E_{\text{LS}}|} \quad (6)$$

Hierbei bezeichnet $|E_{\text{AS}} \cap E_{\text{LS}}|$ die Anzahl der in beiden Texten vorkommenden Entitäten. Der Faktenerhalt gibt an, wie viele Entitäten aus dem Original übernommen wurden,

während die Faktentreue misst, wie viele Entitäten des Zieltexts durch das Original belegt sind.

2.3 Textrepräsentationen & Einbettungsmodelle

Neuronale Sprachmodelle verarbeiten Text über mathematische Repräsentationen. Der Prozess gliedert sich in Tokenisierung, Einbettung und Vektordistanzberechnung:

2.3.1 Subword-Tokenisierung

Reine wortbasierte Vokabulare scheitern häufig an Wörtern außerhalb des Trainingslexikons (Out-of-Vocabulary, OOV). Moderne neuronale Modelle nutzen daher Subword-Tokenisierung wie Byte-Pair Encoding (BPE) nach Sennrich et al. (2016) oder SentencePiece. Ausgehend von Einzelzeichen werden häufige Zeichenpaare iterativ zu Subword-Einheiten verschmolzen. Dadurch lassen sich auch seltene Komposita (z. B. *Behindertengleichstellungsgesetz*) in bekannte Sub-Tokens zerlegen, während die Vokabulargröße kompakt und fest begrenzt bleibt.

2.3.2 Text-Embeddings & Sentence-BERT (SBERT)

Wörter liegen zunächst als diskrete Symbole ohne inhärente Abstandsmetrik vor. *Embeddings* bilden Wörter auf kontinuierliche Vektoren $\mathbf{e} \in \mathbb{R}^d$ ab, sodass semantisch ähnliche Begriffe im Vektorraum eng benachbart sind.

Für den paarweisen Vergleich ganzer Sätze oder Absätze ist das Standard-BERT-Modell (Devlin et al., 2019) rechenintensiv: Beide Sequenzen müssen gemeinsam als Paar durch alle Transfomerschichten propagiert werden (*Cross-Encoder*), was bei N Texten mit $\mathcal{O}(N^2)$ skaliert. *Sentence-BERT* (SBERT) nach Reimers und Gurevych (2019) umgeht diesen Engpass über eine siamesische Architektur (*Bi-Encoder*): Zwei identische BERT-Netzwerke mit geteilten Gewichten berechnen über *Mean-Pooling* separate Vektoren $\mathbf{u} \in \mathbb{R}^d$ für jeden Text. Auf dieser Basis können semantische Ähnlichkeiten im Vektorraum effizient über die Kosinus-Ähnlichkeit ermittelt werden.

2.3.3 Long-Context-Embeddings & ALiBi-Attention

Herkömmliche Transformer-Modelle (wie MiniLM) sind durch statische Positionskodierungen meist auf Sequenzlängen von 128 bis 512 Tokens begrenzt. Längere Dokumente müssen daher abgeschnitten werden (*Truncation*), was zu Informationsverlust führt.

Das in dieser Arbeit zur Dokumentenfilterung genutzte Modell `jina-embeddings-v2-base-de` (Günther et al., 2023) überwindet diese Grenze mithilfe von *Attention with Linear Biases* (ALiBi) nach Press et al. (2022). Anstelle absoluter Positionsvektoren addiert ALiBi eine lineare Distanzstrafe direkt auf die Aufmerksamkeitsmatrix (Attention Scores) der Token-Paare. Dies erlaubt die Verarbeitung von Sequenzen mit bis zu 8.192 Tokens, sodass auch längere behördliche Texte und Artikel vollständig eingebettet werden können.

2.3.4 Semantische Ähnlichkeitsmessung

Die inhaltliche Nähe zweier Sequenzen x und y mit den Einbettungen $\mathbf{u} = \text{Embed}(x)$ und $\mathbf{v} = \text{Embed}(y)$ wird über die Kosinus-Ähnlichkeit im Vektorraum quantifiziert:

$$\text{sim}_{\cos}(\mathbf{u}, \mathbf{v}) = \frac{\mathbf{u} \cdot \mathbf{v}}{\|\mathbf{u}\|_2 \|\mathbf{v}\|_2} \in [-1, 1] \quad (7)$$

Zur Normalisierung auf das Intervall $[0, 1]$ dient die lineare Skalierung $\text{sim}_{\text{norm}} = \frac{\text{sim}_{\cos} + 1}{2}$.

2.4 Architekturen moderner neuronaler Sprachmodelle

In der modernen Computerlinguistik bilden rekurrente Architekturen und Aufmerksamkeits-basierte Transformer-Netzwerke die beiden dominanten Modellparadigmen.

2.4.1 Rekurrente Neuronale Netze, LSTM & BiLSTM

Klassische rekurrente neuronale Netze (*RNNs*) verarbeiten Sequenzen schrittweise und aktualisieren in jedem Zeitschritt einen internen Zustand (*Hidden State* $\mathbf{h}_t$). Bei längeren Textfolgen führt das Training über viele Zeitschritte zum Problem verschwindender Gradienten (*Vanishing Gradient Problem*), wodurch weiter zurückliegende Kontextinformationen verloren gehen.

Das *Long Short-Term Memory* (LSTM) nach Hochreiter und Schmidhuber (1997) adressiert diese Limitierung über einen dedizierten Zellzustand $\mathbf{C}_t$ sowie drei funktionale Steuerungstore (*Gates*):

- **Forget Gate:** Reguliert, welche Anteile des vorherigen Zellzustands $\mathbf{C}_{t-1}$ verworfen werden.
- **Input Gate:** Steuert, welche neuen Informationen aus der aktuellen Eingabe in den Zellzustand einfließen.
- **Output Gate:** Bestimmt, welche Anteile des aktualisierten Zellzustands $\mathbf{C}_t$ als neuer Hidden State $\mathbf{h}_t$ ausgegeben werden.

Das *Bidirektionale LSTM* (BiLSTM) nach Schuster und Paliwal (1997) erweitert diese Architektur, indem es den Text gleichzeitig in zwei Richtungen verarbeitet: Eine Vorwärts-Schicht liest den Satz von links nach rechts, während eine parallele Rückwärts-Schicht den Satz von rechts nach links durchläuft. Durch das Zusammenführen beider Zustände kann das Modell an jeder Textposition simultan den gesamten vorherigen und nachfolgenden Kontext erfassen.

2.4.2 Transformer & Attention-Mechanismus

Die Transformer-Architektur (Vaswani et al., 2017) löst die rein sequentielle Abarbeitung rekurrenter Netze durch eine vollständig parallele Verarbeitung der gesamten Sequenz ab.

Grundlage hierfür ist der *Scaled Dot-Product Attention*-Mechanismus. Die Eingabesequenz wird über trainierbare Projektionsmatrizen in Abfragen (*Queries* $\mathbf{Q}$), Schlüssel (*Keys*

$\mathbf{K}$) und Werte (*Values* $\mathbf{V}$) überführt. Die Aufmerksamkeitsgewichte berechnen sich über das skalierte Skalarprodukt:

$$\text{Attention}(\mathbf{Q}, \mathbf{K}, \mathbf{V}) = \text{softmax}\left(\frac{\mathbf{Q}\mathbf{K}^T}{\sqrt{d_k}}\right) \mathbf{V} \quad (8)$$

Über *Multi-Head Attention* wird dieser Mechanismus mehrfach parallel mit unterschiedlichen Projektionsräumen ausgeführt. Dadurch kann das Modell an jeder Token-Position zeitgleich unterschiedliche syntaktische und semantische Relationen im Satz erfassen.

2.4.3 Transformer-Modellfamilien im NLP

Je nach Verknüpfung der Aufmerksamkeitsschichten werden drei primäre Architekturtypen unterschieden:

1. **Sequence-to-Sequence / Encoder-Decoder-Modelle:** Diese Architektur (wie BART nach Lewis et al. (2020) sowie dessen mehrsprachige Erweiterungen mBART-25 (Liu et al., 2020) und mBART-50 (Tang et al., 2021)) kombiniert einen bidirektionalen Encoder zur vollständigen Erfassung des Ausgangstextes mit einem autoregressiven Decoder. Der Decoder generiert die Zielsequenz Token für Token und greift über *Cross-Attention* auf die kontextualisierten Repräsentationen des Encoders zu. Sprachspezifische Tokens (wie `de_DE` in mBART-50) steuern dabei die Zielsprache.
2. **Causal Decoder-Only-Modelle:** Modelle wie LLaMA, Mistral oder Qwen nutzen ausschließlich kausal maskierte Aufmerksamkeitsschichten (*Causal Masking*), sodass jedes Token nur auf vorangegangene Positionen zugreifen kann. Sie werden über die autoregressive Vorhersage des nächsten Tokens (*Next-Token Prediction*) vortrainiert und über Prompting oder Instruction Fine-Tuning gesteuert.
3. **Bidirektionale Encoder-Only-Modelle:** Modelle wie BERT (Devlin et al., 2019) oder GBERT verarbeiten Eingabesequenzen vollständig bidirektional. Sie eignen sich für Sequenzklassifikation und Einbettungsgenerierung, nicht jedoch zur autoregressiven Textgenerierung.

2.5 Feinabstimmung & Parameter-Efficient Fine-Tuning (PEFT)

Das unüberwachte Vortraining großer Sprachmodelle vermittelt allgemeine linguistische Repräsentationen. Um Modelle auf zielspezifische Aufgaben wie die Textvereinfachung auszurichten, existieren verschiedene Adaptionstrategien.

2.5.1 Supervised Fine-Tuning (SFT)

Beim überwachten Feintuning (*Supervised Fine-Tuning*, SFT) lernt das vortrainierte Sprachmodell anhand von parallelen Datenpaaren (z. B. komplexer Ausgangstext und Zielübersetzung in Leichter Sprache). Das Modell wird darauf trainiert, für jeden Eingabetext Schritt

für Schritt die wahrscheinlichsten Folgewörter der menschlichen Referenzübersetzung zu erzeugen.

Bei einem vollständigen Feintuning (*Full Fine-Tuning*) werden alle Modellparameter aktualisiert. Dies erfordert erhebliche Hardware-Ressourcen und birgt das Risiko des katastrophalen Vergessens (*Catastrophic Forgetting*), bei dem zuvor erlernte generalistische Fähigkeiten des Modells degradieren.

2.5.2 Low-Rank Adaptation (LoRA)

Um Modelle ressourceneffizient anzupassen, führte Hu et al. (2022) die *Low-Rank Adaptation* (LoRA) im Rahmen von *Parameter-Efficient Fine-Tuning* (PEFT) ein:

- **Fixierung der Basisgewichte:** Die vortrainierten Modellgewichte $\mathbf{W}_0 \in \mathbb{R}^{d \times k}$ bleiben während des gesamten Trainings eingefroren.
- **Niedrigrang-Zerlegung des Gewichts-Updates:** Das Parameter-Update $\Delta \mathbf{W}$ wird durch das Produkt zweier kleiner Matrizen niedrigen Rangs approximiert: $\Delta \mathbf{W} = \mathbf{B}\mathbf{A}$, mit $\mathbf{B} \in \mathbb{R}^{d \times r}$, $\mathbf{A} \in \mathbb{R}^{r \times k}$ und Rang $r \ll \min(d, k)$.

Hierdurch reduziert LoRA die Zahl der trainierbaren Parameter typischerweise um über 99%, was den Speicher- und Rechenbedarf beim Training minimiert. Nach dem Training können die Adaptermatrizen durch einfache Addition $\mathbf{W} = \mathbf{W}_0 + \frac{\alpha}{r}\mathbf{B}\mathbf{A}$ direkt in das Basismodell integriert werden (*Weight Merging*), wodurch zur Inferenzzeit keine zusätzliche Latenz entsteht.

2.6 Präferenzoptimierung & Reinforcement Learning (RLHF & DPO)

Da reines SFT lediglich die statistische Wortverteilung des Trainingskorpus nachahmt, jedoch keine gezielte Stil- oder Regeleinhaltung belohnt, werden Alignment-Verfahren eingesetzt, um das Modell auf hohe Qualität und Verständlichkeit auszurichten.

2.6.1 Das klassische RLHF-Paradigma & PPO

Im klassischen *Reinforcement Learning from Human/AI Feedback* (RLHF) nach Ouyang et al. (2022) wird zunächst ein separates Reward-Modell trainiert, das Textqualität mit einem skalaren Punktwert bewertet. Anschließend wird das Sprachmodell über *Proximal Policy Optimization* (PPO) (Schulman et al., 2017) optimiert, indem das Modell während des Trainings Texte online generiert und anhand des Rewards anpasst.

In der praktischen Umsetzung ist PPO mit hohem Rechen- und Speicheraufwand verbunden, da bis zu vier Modellinstanzen gleichzeitig vorgehalten werden müssen (Akteurs-, Kritiker-, Reward- und Referenzmodell). Zudem neigt das Online-Verfahren zu Trainingsinstabilitäten und erfordert eine feinteilige Hyperparameterabstimmung.

2.6.2 Direct Preference Optimization (DPO)

Die *Direct Preference Optimization* (DPO) nach Rafailov et al. (2023) umgeht diese Komplexität, indem sie die implizite Belohnungsfunktion des Bradley-Terry-Präferenzmodells direkt über die Sprachmodell-Policy parametrisiert. DPO verzichtet vollständig auf ein separates Reward-Modell sowie dynamisches Online-Sampling. Stattdessen wird die Policy π_θ direkt auf statischen Präferenzpaaren (x, y_w, y_l) optimiert, wobei y_w die bevorzugte und y_l die abgelehnte Sequenz darstellt:

$$\mathcal{L}_{\text{DPO}}(\theta; \pi_{\text{ref}}) = -\mathbb{E}_{(x, y_w, y_l) \sim \mathcal{D}_{\text{pref}}} \left[\log \sigma \left(\beta \log \frac{\pi_\theta(y_w | x)}{\pi_{\text{ref}}(y_w | x)} - \beta \log \frac{\pi_\theta(y_l | x)}{\pi_{\text{ref}}(y_l | x)} \right) \right] \quad (9)$$

Der Hyperparameter β kontrolliert dabei die Regularisierung gegenüber der Referenz-Policy π_{ref} (KL-Divergenz-Strafe), um ein Abdriften des Sprachflusses zu verhindern. DPO ermöglicht dadurch ein stabiles und speichereffizientes Alignment.

2.7 Generierungs- und Decoding-Strategien

Bei der autoregressiven Textgenerierung bestimmt die Decoding-Strategie, wie aus den modellierten Wahrscheinlichkeitsverteilungen $P(y_t | y_{<t}, x)$ die finale Zielsequenz generiert wird:

1. **Greedy Search vs. Beam Search:** *Greedy Search* wählt in jedem Zeitschritt deterministisch das Token mit der höchsten Einzelwahrscheinlichkeit $\arg \max_{y_t} P(y_t | y_{<t}, x)$. Dies ist recheneffizient, kann jedoch zu suboptimalen lokalen Maxima führen. *Beam Search* verfolgt stattdessen zu jedem Schritt die B wahrscheinlichsten Teilhypothesen (*Beams*). Am Sequenzende wird der Pfad mit der höchsten kumulierten Wahrscheinlichkeit ausgewählt, was in der Regel zu syntaktisch stabileren Generierungen führt.
2. **Stochastisches Sampling & Top-p (Nucleus):** Beim *Sampling* wird das nächste Token stochastisch aus der Wahrscheinlichkeitsverteilung gezogen. Eine Temperatur $T > 0$ skaliert die Logits (z_i/T) und bestimmt, ob die Verteilung spitzer (geringere Varianz) oder flacher (höhere Diversität) ausfällt. Beim *Top-p (Nucleus) Sampling* wird die Auswahl auf die kleinste Menge an Tokens beschränkt, deren kumulierte Wahrscheinlichkeit einen Schwellenwert p erreicht, wodurch unwahrscheinliche Tokens aus dem Verteilungsende (*Tail*) abgeschnitten werden.
3. **Wiederholungsstrafen (*Repetition Penalty* & N-Gramm-Sperren):** Insbesondere bei einfacher oder stichpunktartiger Sprache neigen Sprachmodelle zu unerwünschten Repetitionen. Eine *Repetition Penalty* reduziert die Logits bereits generierter Tokens multiplikativ. Ein *N-Gram Banning* (`no_repeat_ngram_size`) setzt die Wahrscheinlichkeit für Tokens auf null, die zu einer Wiederholung bereits aufgetretener n -Gramme fester Länge führen würden.

3 Stand der Forschung

3.1 Verfügbare Datenbasis und Korpora (Themenblock 1)

Einen guten Überblick über den aktuellen Stand und die verfügbaren Ressourcen für Leichte und Einfache Sprache in Deutschland geben Madina et al. (2023). Sie zeigen dabei vor allem auf, wie unterschiedlich die bestehenden Datensätze strukturiert sind und dass es an standardisierten Werkzeugen zur automatischen Bewertung der Texte fehlt.

Die Erforschung automatischer Textvereinfachung (Automatic Text Simplification, ATS) für das Deutsche litt lange Zeit unter einem deutlichen Mangel an Trainingsdaten. Erste Versuche, ein paralleles Korpus aufzubauen, gehen auf Klaper et al. (2013) mit dem *KLAPER*-Korpus zurück, das jedoch mit ca. 250 parallelen Textpaaren (rund 7.000 Sätze und 70.000 Tokens) für moderne Deep-Learning-Ansätze deutlich zu klein war.

Einen wesentlichen Fortschritt hinsichtlich des Korpusumfangs erzielten Battisti et al. (2020) mit einem multimodalen Korpus aus 6.217 Dokumenten (rund 211.000 Sätze, 5,5 Millionen Tokens). Trotz des Gesamtumfangs weist der Datensatz eine deutliche Asymmetrie auf: Während 5.461 Dokumente rein monolingual vorliegen, umfasst der parallel ausgerichtete Teil lediglich 378 Dokumentenpaare. Dies unterstreicht die Knappheit paralleler Trainingsdaten für überwachte Modelle im Deutschen.

Für den Bereich der Einfachen Sprache (Plain German) stellten Stodden et al. (2023) mit *DEplain* ein paralleles Korpus vor. Dieses gliedert sich in einen Nachrichtenbereich (*DEplain-APA*) mit rund 500 Dokumentenpaaren (ca. 13.000 manuell ausgerichtete Satzpaare) und einen Webbereich mit ca. 150 manuell ausgerichteten Dokumenten (rund 2.000 Satzpaare). Ein zugehöriger Web-Harvester ermöglicht die automatische Vergrößerung des Webbereichs auf rund 750 Dokumentenpaare (ca. 3.500 automatisch ausgerichtete Satzpaare). Die Autoren zeigten, dass auf Dokumentenebene trainierte Modelle feinkörnige semantische Übergänge teils unzureichend abbilden, weshalb präzise Satz-Alignments eine wesentliche Voraussetzung für Seq2Seq-Modelle darstellen. Allerdings unterscheidet sich das *DEplain*-Korpus durch seinen Fokus auf Einfache Sprache strukturell und linguistisch von den strengeren Vorgaben der Leichten Sprache.

Einen weiteren Beitrag leisteten Toborek et al. (2023) mit dem *New Aligned Simple German Corpus*. Der Datensatz umfasst rund 700 Dokumentenpaare und über 10.000 teils manuell, teils automatisch berechnete Satzpaare. Das Korpus kombiniert Web-Scraping mit automatischer Satz-Ausrichtung. Allerdings fasst die Arbeit Texte der Leichten und der Einfachen Sprache unter einem gemeinsamen Begriff zusammen, was die gezielte Modellierung der spezifischen Richtlinien Leichter Sprache erschwert. Dieser Kompromiss verdeutlicht die methodische Herausforderung: Ein Korpusaufbau, der sich strikt auf Leichte Sprache beschränkt, ist durch die begrenzte Verfügbarkeit frei zugänglicher Parallelquellen im deutschsprachigen Web erschwert.

3.2 Evaluierungsmetriken für die Vereinfachung (Themenblock 2)

Die automatische Evaluierung von Textvereinfachungssystemen stellt eine methodische Herausforderung dar. Traditionell stützt sich die Lesbarkeitsbewertung im deutschen Sprachraum auf deterministische Formeln wie den *Flesch Reading Ease* (Amstad, 1978), die *Wiener Sachtextformel* (Bamberger und Vanecek, 1984) oder den *LIX-Index* (Björnsson, 1968) (Definitionen in Abschnitt 2.2). Diese Metriken erfassen die Oberflächenkomplexität anhand von Silben-, Wort- und Satzlängen. Während sie für allgemeine Sachtexte eine rechen-effiziente Orientierung bieten, sind sie konzeptionell nicht darauf ausgelegt, spezifische Regeln der Leichten Sprache — wie Passivvermeidung, kurze Hauptsatzstrukturen oder die Bindestrich-Gliederung von Komposita — zu erfassen.

Klassische referenzbasierte N-Gramm-Metriken der maschinellen Übersetzung wie BLEU (Papineni et al., 2002) und ROUGE (Lin, 2004) messen die lexikalische Übereinstimmung mit einer Referenzübersetzung. Für die automatische Textvereinfachung erweisen sich diese jedoch oft als ungeeignet: Wie Alva-Manchego et al. (2021) empirisch belegen, korreliert BLEU im Vereinfachungskontext nur schwach oder sogar negativ mit dem menschlichen Urteil über Einfachheit und Textqualität. Der Grund liegt darin, dass BLEU unzulässige 1:1-Kopien des komplexen Originals mit hohen Punktwerten belohnt, während legitime lexikalische Variationen und strukturelle Modifikationen (wie Satzteilungen und Umschreibungen) fälschlicherweise als Fehler abgestraft werden.

Als Alternative für die Textvereinfachung etablierte sich die Metrik *SARI* (*System Accessibility and Readability Index*) nach Xu et al. (2016). SARI vergleicht die Systemgenerierung y simultan mit dem komplexen Ausgangstext x und den Referenzübersetzungen R :

$$\text{SARI} = \frac{F_{\text{add}} + F_{\text{keep}} + P_{\text{del}}}{3} \quad (10)$$

Hierbei messen F_{add} und F_{keep} den F_1 -Score für erfolgreich eingefügte bzw. beibehaltene N -Gramme, während P_{del} die Präzision für getilgte N -Gramme des komplexen Originals bewertet. Dadurch honoriert SARI explizit Modifikationen, die über ein reines Kopieren des Ausgangstexts hinausgehen.

Im Laufe der Entstehungszeit dieser Arbeit wurde mit *DETECT* von Korobeynikova et al. (2026) eine neuartige, erlernbare Evaluierungsmetrik speziell für die deutsche Textvereinfachung vorgestellt. DETECT adaptiert das LENS-Framework für den deutschsprachigen Raum und zielt darauf ab, die Qualität automatischer Vereinfachungen über drei Dimensionen abzubilden: Verständlichkeit (*Simplicity / Ease*), semantische Inhaltsbewahrung (*Meaning Preservation*) sowie grammatikalische Korrektheit und Sprachfluss (*Fluency / Textual Clarity*). Um den Mangel an manuell annotierten Trainingsdaten zu überwinden, wird das Regressionsmodell auf synthetisch durch Large Language Models generierten Qualitäturteilen trainiert. In empirischen Validierungen auf einem eigens erhobenen Datensatz (*SimpEvalDE*) wiesen die Autoren nach, dass DETECT stärkere Korrelationen mit menschlichen Qualitätsbewertungen erzielt als traditionelle Maße wie BLEU, SARI oder BERTScore.

Gleichzeitig verdeutlicht dieser Ansatz verbleibende Forschungslücken: Da der zugrundeliegende Evaluierungsdatensatz (*SimpEvalDE*) primär auf Korpora der Einfachen Sprache (DEplain-APA und LHA-APA) aufbaut, sind spezifische Richtlinien der Leichten Sprache — wie das Vermeiden von Passiv- und Genitivkonstruktionen oder die typografische Gliederung von Komposita — nicht explizit modelliert. Zudem sind rein referenzbasierte Satzmetriken nur bedingt geeignet, um die Komplexität ganzer Dokumente referenzfrei zu bewerten oder als kontinuierliches Steuerungssignal während des Modelltrainings eingesetzt zu werden.

Obwohl das Thema Leichte Sprache in der deutschsprachigen NLP-Forschung über viele Jahre hinweg nur wenig Beachtung gefunden hat, zeigt das Erscheinen neuerer Arbeiten die zunehmende Dynamik und Relevanz dieses Forschungsfelds.

3.3 Maschinelle Übersetzung und Optimierungsverfahren (Themenblock 3)

Die maschinelle Übersetzung von Alltagssprache (AS) in Leichte Sprache (LS) lässt sich formal als monolinguale maschinelle Übersetzung (*Monolingual Machine Translation*) modellieren. Im Gegensatz zur klassischen bilingualen Übersetzung erfordert dieser Transformationsprozess asymmetrische Strukturänderungen: Komplexe Satzgefüge müssen aufgeteilt (*Sentence Splitting*), Passiv- in Aktivkonstruktionen überführt, irrelevante Textpassagen gekürzt (*Compression*) und Fachbegriffe verständlich umschrieben werden.

Erste systematische Benchmarks neuronaler Übersetzungsmodelle für deutsche Leichte Sprache von Säuberli et al. (2020) zeigten, dass Sequence-to-Sequence-Modelle grundlegende Satzkürzungen und Worts substitutionen erlernen können, bei komplexen syntaktischen Umstellungen jedoch stark durch die geringe Menge paralleler Trainingsdaten limitiert werden.

Bisherige Ansätze konzentrieren sich weitgehend auf isolierte Satzebenen oder stützen sich auf manuell annotierte Präferenzdaten. Eine zentrale Forschungslücke besteht darin, wie sich generative Übersetzungsmodelle auf Dokumenten- und Artekelebene trainieren und durch eine automatisierte Reward-Steuerung über gelernte Komplexitätsmetriken optimieren lassen.

4 Themenblock 1: Datenbasis & Korpus-Erstellung

Die Erstellung eines qualitativ hochwertigen, repräsentativen und ausreichend großen parallelen Korpus bildet das Fundament für jedes datengetriebene Übersetzungssystem. Wie im vorangegangenen Kapitel dargelegt, ist die maschinelle Textvereinfachung (ATS) für die deutsche Leichte Sprache durch eine ausgeprägte Datenknappheit gekennzeichnet. Während bestehende Ressourcen wie das Korpus von Battisti et al. (2020) einen wertvollen Grundstein legten, weisen sie für das Training moderner generativer Modelle und Präferenzoptimierungsverfahren (wie DPO) entscheidende Limitierungen auf: Entweder ist ihr parallel ausgerichteter Anteil mit wenigen hundert Dokumenten zu gering, oder sie fokussieren sich, wie das DEplain-Korpus von Stodden et al. (2023), primär auf Einfache Sprache (Plain German), die sich linguistisch und regulatorisch deutlich von der Leichten Sprache unterscheidet. Einen wichtigen methodischen Impuls zur automatisierten Datengewinnung lieferten Toborek et al. (2023) mit dem *New Aligned Simple German Corpus*. Ihr Ansatz demonstrierte, wie parallele Webinhalte über seitenspezifische Selektoren und Sprachumschalter im Internet automatisiert identifiziert und extrahiert werden können. Diese Vorgehensweise bildete den primären Ausgangspunkt für die in dieser Arbeit entwickelte Crawling- und Extraktions-Pipeline. Allerdings fokussieren Toborek et al. (2023) primär auf ein Satz-Alignment.

Deshalb wurde im Rahmen dieser Arbeit eine eigene, automatisierte Pipeline zur Akquise und Aufbereitung von Trainingsdaten entwickelt, welche die Scraping-Prinzipien von Toborek et al. (2023) als methodisches Fundament aufgreift, auf 12 heterogene Quellen ausweitet und zu einer artikelbasierten, qualitätsgesicherten Korpus-Pipeline weiterentwickelt. Da diese Vorarbeit mittlerweile rund drei Jahre zurückliegt und im deutschsprachigen Web in diesem Zeitraum zahlreiche neue Informationsangebote sowie redaktionelle Portale in Leichter Sprache entstanden sind, wurde ein vollständig neues, zeitgemäßes und breiter aufgestelltes Parallelkorpus aufgebaut.

Ein zentrales methodisches Charakteristikum der in dieser Arbeit entwickelten Pipeline und der nachfolgenden Modellierung ist die bewusste Entscheidung für ein artikelbasiertes (bzw. dokumentenweites) Training sowohl der Komplexitätsmetrik als auch des Übersetzungsmodells. In der bisherigen Forschung wurden Vereinfachungssysteme primär auf Satzebene trainiert und evaluiert, was jedoch erhebliche Defizite aufweist:

1. **Kontext- und Kohärenzverlust:** Satzbasierende Ansätze trennen Sätze von dem, was sie im Kontext bedeuten. Dadurch gehen Anspielungen, der rote Faden und die Verbindung zwischen den einzelnen Elementen verloren. Zudem können makrostrukturelle Vereinfachungen wie die Umstrukturierung ganzer Absätze oder das Einfügen von erklärenden Hintergrundinformationen – welche im Konzept der Leichten Sprache essenziell sind – auf Satzebene nicht gelernt werden.
2. **Verrauschte Satz-Alignments:** Die Modellierung auf Satzebene setzt voraus, dass präzise Alignments vorliegen. Wie Stodden et al. (2023) und Štajner et al. (2018) zeigen, führt die asymmetrische Natur der Vereinfachung (z. B. n:m-Alignments und

Satzteilungen) dazu, dass automatische Satz-Aligner entweder stark fehlerhafte Paare erzeugen oder einen massiven Informationsverlust durch das Verwerfen nicht-linearer Übergänge in Kauf nehmen müssen.

Durch die Wahl des gesamten Artikels als Basiseinheit kann das Übersetzungsmodell lernen, globale Kürzungen vorzunehmen und Texte kohärent umzuformulieren. Gleichzeitig erlaubt dies der Komplexitätsmetrik, die Verständlichkeit eines Textes im Kontext des gesamten Dokuments statt isolierter Sätze zu bewerten.

Dieses Kapitel beschreibt den detaillierten Ablauf dieser Schritte und dokumentiert die Designentscheidungen bei der Konstruktion des finalen Datensatzes.

4.1 Multi-Quellen-Crawling & Datenakquise

Die automatisierte Akquise paralleler Textdaten für die deutsche Leichte Sprache stellt aufgrund der heterogenen Weblandschaft und des Fehlens zentraler Repositorien eine erhebliche methodische Herausforderung dar. Während im englischsprachigen Raum Plattformen wie die *Simple English Wikipedia* als quasi-standardisierte Datenquelle dienen, existiert im deutschsprachigen Raum kein vergleichbares, monolithisches Korpus. Parallele Sprachversionen verteilen sich stattdessen über behördliche Portale, öffentlich-rechtliche Rundfunkanstalten, Verbände der Behindertenhilfe und journalistische Magazine.

Um diesen heterogenen Datenbestand automatisiert und reproduzierbar zu erschließen, wurde im Rahmen dieser Arbeit eine modulare, zweistufige Dokumenten-Crawling-Architektur entwickelt. Diese trennt die logische URL-Identifikation strikt von der inhaltlichen DOM-Extraktion:

1. **Stufe 1: URL-Discovery & Alignment-Heuristiken** (`scripts/data_collection/crawl_scraper/`): In diesem Schritt navigieren spezialisierte Crawler durch die Zielportale, identifizieren Artikel in Leichter Sprache (LS) und ermitteln über seiten-spezifische Verknüpfungsmechanismen die korrespondierende URL der Alltagssprache (AS). Das Ergebnis jeder Quelle wird als JSON-Struktur standardisierter URL-Paare abgelegt.
2. **Stufe 2: Selektive DOM-Content-Extraktion** (`scripts/data_collection/corpus_scrapers/`): Aufbauend auf den identifizierten URL-Paaren lädt die zweite Stufe die HTML-Dokumente asynchron herunter. Anstatt den gesamten Seiteninhalt ungefiltert zu erfassen, extrahiert ein zielgerichteter DOM-Parser ausschließlich den redaktionellen Fließtext über semantische HTML5-Container (`<main>`, `<article>`, `div.paragraph`). Navigationsleisten, Kopf- und Fußzeilen, Cookie-Banner sowie interaktive Schaltflächen werden dadurch bereits auf Extraktionsebene systematisch eliminiert.

4.1.1 Domänen- und Quellenabdeckung

Um eine breite stilistische und thematische Varianz zu gewährleisten und eine Überanpassung an ein einzelnes redaktionelles Regelwerk zu verhindern, wurden 12 frei zugängliche deutschsprachige Webquellen aus drei gesellschaftlich relevanten Domänen erschlossen:

- **Öffentliche Verwaltung & Kommunalportale:** Dieser Sektor besitzt besondere gesellschaftliche und rechtliche Relevanz, da für staatliche und öffentlich-rechtliche Träger die Barrierefreie-Informationstechnik-Verordnung (BITV 2.0) gilt. Zu Beginn der Datenerhebung lag die naheliegende Annahme nahe, dass öffentliche Stellen durch die BITV 2.0 dazu verpflichtet seien, ihre Webangebote und Fachinhalte umfassend in Leichter Sprache zur Verfügung zu stellen. Eine genaue Analyse des gesetzlichen Verordnungstextes (§ 4 BITV 2.0, Bundesministerium des Innern, für Bau und Heimat, 2019) offenbarte jedoch eine erhebliche rechtliche Ernüchterung: Gemäß § 4 Abs. 1 BITV 2.0 sind öffentliche Stellen des Bundes lediglich verpflichtet, auf der Startseite grundlegende Erläuterungen bereitzustellen – namentlich Hinweise zu den wesentlichen Inhalten, zur Navigation, zur Erklärung zur Barrierefreiheit sowie Hinweise auf etwaige weitere vorhandene Informationen in Leichter Sprache (Portal Barrierefreiheit / BFIT Bund, 2026). Die Verordnung verpflichtet Webseitenbetreiber somit keineswegs dazu, den gesamten inhaltlichen Korpus eines Internetauftritts barrierefrei bereitzustellen, sondern beschränkt sich auf einen minimalen Einstiegs- und Orientierungsrahmen.

Aus Sicht der Barrierefreiheit ist dieser rechtliche Befund für alle darauf angewiesenen Menschen überaus ernüchternd. Bereits während der Datenakquise dieser Arbeit erwies es sich selbst für Personen ohne kognitive Einschränkungen als außerordentlich mühsam und zeitintensiv, vollwertige parallele Artikel in Leichter Sprache auf staatlichen Webseiten überhaupt aufzufinden, da diese meist tief verschachtelt, uneinheitlich verlinkt oder auf wenige Überblicksseiten beschränkt sind. Umso wertvoller sind jene Kommunen, die freiwillig weit über das gesetzliche Mindestmaß hinausgehen: Erfasst wurden die Stadt- und Kommunalportale *Hannover.de* (welches aufgrund seines Umfangs als quantitativer Schwerpunkt dient), *Hamburg.de*, *Koeln.de*, der *Main-Taunus-Kreis* (*mtk.org*), *Stuttgart.de* und *Wiesbaden.de*.

- **Medien & Journalismus:** Zur Abdeckung tagesaktueller Berichterstattung und nachrichtlicher Diskursformen umfasst das Korpus die Angebote des Mitteldeutschen Rundfunks (*MDR Nachrichten in Leichter Sprache*), der Tageszeitung (*taz*) sowie des Wirtschaftsmagazins *brand eins*.
- **Gesundheit, Soziales & Politik:** Zur Erfassung medizinischer und sozialrechtlicher Fachtexte wurden das Portal der *Apotheken Umschau*, die Veröffentlichungen des *Beauftragten der Bundesregierung für die Belange von Menschen mit Behinderten* sowie das Bildungsportal *Sozialpolitik.com* integriert.

Ergänzend zu den Webquellen wurde ein unabhängiger Out-of-Domain-Testdatensatz (OOD) auf Basis realer Dokumente der *Lebenshilfe Schleswig-Holstein e. V.* aufgebaut.

Dieser Datensatz umfasst behördliche Bescheide, Hausordnungen, Vereinbarungen und Prüfberichte, die von professionellen Übersetzungsbüros übertragen und von zertifizierten Prüfgruppen aus Menschen mit Lernschwierigkeiten validiert wurden. Die Extraktion erfolgte über ein spezialisiertes Parsing-Skript, welches proprietäre Dateiformate (.docx, .rtf, .odt) verarbeitet und für die spätere modellunabhängige Generalisierungsevaluation bereitstellt.

4.1.2 Technische Extraktions- & Verknüpfungsmechanismen

Da Webseiten keine standardisierten Metadaten für sprachliche Vereinfachungen bereitstellen, wurden für die 12 Webquellen fünf distinkte Verknüpfungsmechanismen implementiert:

1. **Canonical Link Header Exploration:** Die Stadt Hannover implementiert eine technisch vorbildliche Verknüpfung. Jeder LS-Artikel besitzt im HTML-Kopf ein Canonical-Tag (`<linkrel="canonical"href="...">`), welches direkt auf den ursprünglichen Volltext in Alltagssprache verweist. Der Scraper durchsucht ausgehend von der Übersichtsseite rekursiv alle internen Pfade und bildet über diese Referenz deterministische Paare.
2. **DOM Language Switcher Detection:** Bei Quellen wie dem *Behindertenbeauftragten* (.c-language-switch__l--as), *Hamburg.de* (.km1-icon--original-language) oder *Sozialpolitik.com* (.underline.easy mit hreflang="de-DE") existieren dedizierte Umschalt-Schaltflächen im DOM. Der Crawler parst die LS-Seite, liest das Link-Ziel des Sprachumschalters aus und verknüpft die Dokumente.
3. **URL-Parameter- & Routing-Heuristiken:** Einige kommunale Content-Management-Systeme routen Sprachvarianten über URL-Query-Parameter. Bei *Stuttgart.de* wird die Zielsprache über den Parameter `?sp:out=easy` gesteuert; bei *Wiesbaden.de* erfolgt die Auslieferung über `?sp:easylanguage=1`. Das Alignment erfolgt hierbei durch gezieltes Setzen bzw. Entfernen des Parameters bei identischem URL-Stamm.
4. **Kontextuelle Backlinks & Text-Trigger:** Redaktionelle Angebote betten Links zur Ausgangssprache häufig direkt in den Fließtext oder Teaser-Boxen ein. Beim *MDR* sucht der Scraper nach dem standardisierten Block »Hier können Sie diese Nachricht auch in schwerer Sprache lesen:«; die *taz* verlinkt den Originalartikel im Schlusssatz innerhalb kursiver Elemente (`<em>`), während die *Apotheken Umschau* Links mit dem Titelattribut »mehr Informationen« außerhalb des vereinfachten Verzeichnispfads auswertet.
5. **Aufteilung anhand von Textfarben (CSS-Formatierung):** Das Magazin *brand eins* publiziert beide Sprachfassungen gemeinsam auf einer einzigen Webseite innerhalb desselben Textcontainers (`section.textblock`). Das Alignment erfolgt hier über die Textfarbe: Absätze in Leichter Sprache sind im Inline-CSS rot formatiert (`color: #fa4600` bzw. `#ff4948`), während der schwarze Standardtext der Alltagssprache entspricht.

Für historische oder umstrukturierte Webseiten (*Stadt Köln*, *brand eins*) wurde das Scraping über die *Wayback Machine* des Internet Archive realisiert. Um Verbindungsabbrüche durch serverseitige Rate-Limits zu verhindern, implementieren die Scraper eine robuste Retry-Logik mit exponentiellem Backoff (Intervall $2\text{ s} \rightarrow 4\text{ s} \rightarrow 8\text{ s}$).

4.1.3 Ergebnis der Datenakquise (Roh-Korpus)

Durch den Einsatz dieser zielgerichteten Scraper-Infrastruktur konnten in der ersten Pipelineinstufe insgesamt 1.458 parallele Artikelpaare über alle 12 Webquellen hinweg akquiriert werden. Tabelle 1 fasst den Rohdatenbestand nach Quellen zusammen.

Tabelle 1: Übersicht des akquirierten Rohdatenbestands der ersten Pipelineinstufe nach Quellen mit $N = 1.458$ Artikelpaaren bei Byte-Pair-Encoding-Tokenisierung (`c1100k_base`, BPE) für Alltagssprache (AS) und Leichte Sprache (LS) unter Einbeziehung überregionaler Medien wie dem Mitteldeutschen Rundfunk (MDR) und der tageszeitung (*taz*).

Quelle	Artikel-paare	AS-Tokens	LS-Tokens	Token-Ratio (LS/AS)
Hannover.de	750	819.717	799.286	0,98
MDR Nachrichten	221	234.915	102.977	0,44
Apotheken Umschau	161	436.753	241.320	0,55
Behindertenbeauftragter	58	55.197	37.405	0,68
Hamburg.de	54	70.805	58.984	0,83
Stuttgart.de	42	121.157	45.424	0,37
Koeln.de	41	46.438	62.376	1,34
Main-Taunus-Kreis	39	16.781	13.998	0,83
Wiesbaden.de	37	20.632	12.056	0,58
brand eins	33	13.006	9.909	0,76
Sozialpolitik.com	15	25.596	9.724	0,38
taz (die tageszeitung)	7	12.833	6.415	0,50
Gesamt (Rohdaten)	1.458	1.873.830	1.399.874	0,75

Insgesamt umfasst der Rohdatenbestand rund 1,87 Millionen Tokens in der Ausgangssprache (1.873.830) und rund 1,40 Millionen Tokens in Leichter Sprache (1.399.874, gemessen mit dem Tokenisierer `c1100k_base`, insgesamt über 3,27 Millionen Tokens). Wie die Token-Ratios in Tabelle 1 verdeutlichen, unterscheidet sich das Längenverhalten zwischen den Quellen erheblich: Während journalistische, gesundheitsbezogene und politische Quellen (MDR, Sozialpolitik, Stuttgart, Apotheken Umschau, Wiesbaden) stark komprimieren (Ratio $\approx 0,37$ bis $0,58$), weisen kommunale Quellen (Hannover mit $0,98$, Main-Taunus-Kreis mit $0,83$, Köln mit $1,34$) ausgeglichene oder expandierende Längenverhältnisse auf.

Die Unterschiede in der Token-Ratio spiegeln die unterschiedlichen redaktionellen Strategien wider: In Nachrichten und journalistischen Beiträgen steht die inhaltliche Kürzung auf zentrale Kernaussagen im Vordergrund. Behördliche und kommunale Portale streben

hingegen meist eine vollständige Informationsübernahme an. Fachtermini und bürokratische Abläufe werden hierbei durch ausführliche Erläuterungen in mehreren einfachen Sätzen aufgeschlüsselt, was zu einer Expansion des Textumfangs führt.

Gleichzeitig weist der Rohdatenbestand noch Qualitätsunterschiede auf, da fehlerhafte Verlinkungen, leere Teaser-Seiten sowie verbleibendes Web-Boilerplate enthalten sind. Die nachfolgenden Abschnitte beschreiben daher die methodischen Schritte zur Vorverarbeitung, Qualitätssicherung und empirischen Korpusevaluation.

4.2 Datenaufbereitung, Normalisierung & Qualitätssicherung

Die Rohdaten sind sehr uneinheitlich. Da Webseiten für Browser optimiert sind, enthält der ausgelesene Web-Code viele störende Elemente wie Cookie-Banner, Navigationslinks, Bildnachweise und Prüfsiegel. Für das Training neuronaler Übersetzungsmodelle sind diese Elemente eine Fehlerquelle: Die Modelle lernen solche wiederkehrenden Web-Phrasen mit und geben sie später fälschlicherweise in den Übersetzungen aus.

Um eine saubere und inhaltlich konsistente Datenbasis für das nachfolgende Modelltraining sicherzustellen, durchlaufen die akquirierten Rohdaten eine dreistufige Pipeline aus regelbasierter Boilerplate-Bereinigung, typografischer Normalisierung und semantischer Qualitätssicherung mittels Long-Context-Embeddings.

4.2.1 Web-Boilerplate-Bereinigung & Interpunktionsicherung

Die Beseitigung redaktioneller und web-spezifischer Artefakte erfolgt über ein mehrstufiges Filtersystem, das universelle Bereinigungsmuster mit quellenspezifischen Heuristiken kombiniert:

1. **Interpunktionsicherung bei HTML-Blockelementen:** Beim Parsen strukturierter HTML-Dokumente werden Absätze (`<p>`), Überschriften (`<h1>`–`<h6>`), Listenelemente (`<li>`) und Container (`<div>`) als isolierte Textblöcke extrahiert. Häufig enden Überschriften oder Aufzählungspunkte im HTML-Quelltext ohne abschließende Interpunktion. Werden diese Blöcke unkorrigiert zusammengefügt, verschmelzen aufeinanderfolgende Sätze zu ungrammatischen Satzgefügen (z. B. »Informationen zur Beantragung Sie benötigen folgende Unterlagen«). Deshalb wird das letzte Zeichen jedes extrahierten Textblocks geprüft und deterministisch ein Punkt (.) gesetzt, falls kein valides Satzzeichen (., !, ?, :) vorliegt. Am Blockende stehende Kommata oder Semikola werden in Punkte überführt. Diese Absicherung erwies sich für das spätere Modelltraining als essenziell: Vortests zeigten, dass neuronale Übersetzer bei unsauberen Blockgrenzen dazu neigen, Satzabschlüsse in Leichter Sprache unvollständig offen zu lassen (kein terminaler Satzpunkt) oder Sätze fehlerhaft mit doppelten Punkten (..) zu beenden. Durch die gezielte Satzzeichenergänzung lernt das Modell stattdessen saubere und grammatisch geschlossene Satzstrukturen.
2. **Universelle Boilerplate-Klassen:** Anhand einer empirischen Analyse des Gesamtkorpus wurden sechs distinkte Klassen von Web-Artefakten definiert und über reguläre

Ausdrücke automatisiert entfernt:

- *Navigation & Link-Verweise*: Phrasen wie »Hier erfahren Sie mehr«, »Klicken Sie hier«, »Mehr Informationen in Alltagssprache«, Hyperlinks sowie Datumsangaben des Seitenabrufs (<https://...>, (Abgerufen am...)).
 - *Frageketten & interaktive Suchwerkzeuge*: Standardisierte Teaser-Fragen und Web-Tool-Prompts (z. B. »Wo finde ich weitere Informationen?«, »Unser Tool durchsucht unsere Artikel«, »Ihre Frage wird nicht gespeichert«).
 - *Disclaimer & Link-Warnungen*: Hinweistexte beim Verlassen geschützter Sprachbereiche (z. B. »Achtung: Dieser Link führt aus unserem Einfache-Sprache-Angebot heraus. Die Informationen sind dann nicht mehr in Leichter Sprache«).
 - *Credits, Übersetzer- & Prüfstellennachweise*: Signaturen von Übersetzungsbüros, Prüfgruppen und Illustratorinnen (z. B. »Forschungsstelle Leichte Sprache«, »Büro für Leichte Sprache«, »Stefan Albers«, »European Easy-to-Read Logo«, »Inclusion Europe«).
 - *Kicker- & Dachzeilen-Präfixe*: Führende Rubriken und Ortsmarken am Textanfang (z. B. »Sachsen-Anhalt:«, »Mitteldeutschland:«, »in Leichter Sprache Ticker:«, »Glossar:«).
 - *Regionale & Layout-Artefakte*: Technische und bildbezogene Floskeln (z. B. »Icon für die Mobilversion«, »Von der Straße aus fotografiert«, »MEHR ANZEIGEN«).
3. **Quellenspezifische Bereinigungsfilter** (`clean\_source\_specific`): Da jede der 12 Webquellen individuelle redaktionelle Templates nutzt, wurden maßgeschneiderte Filter implementiert. Beim *MDR* wird der standardisierte Rückverweis »Über dieses Thema berichtet der MDR auch in schwerer Sprache...« am Artikelende entfernt; bei der *Apotheken Umschau* werden medizinische Haftungsausschlüsse (»Achtung: In diesem Text finden Sie nur allgemeine Informationen...«) und Suchassistenten bereinigt; bei *brand eins* werden führende Datums- und Autorenstempel (»Januar 2024. Max Mustermann«) abgeschnitten.

4.2.2 Typografische Normalisierung & Listen-Transformation

Neben Web-Boilerplate erfordern typografische Eigenheiten und barrierefreie Layout-Elemente eine gezielte Harmonisierung:

- **Mediopunkt-Normalisierung**: In Webtexten werden Mediopunkte (·) oder Aufzählungspunkte (•) bisweilen als Layout-Aufzählungszeichen im Fließtext genutzt, anstatt strukturierte HTML-Listen (`<li>`) zu verwenden. Da der Mediopunkt in der Leichten Sprache primär der morphologischen Gliederung langer Komposita dient (z. B. *Wohn·geld·an·trag*), werden rein layoutbezogene Mediopunkte an Satzanfängen oder zwischen Sätzen im Normalisierungsschritt bereinigt, um Fehlinterpretationen beim Modelltraining zu vermeiden.

- **Satzzeichen-Harmonisierung:** Durch das Entfernen von Links, Klammerzusätzen und Listenpunkten entstehen häufig fehlerhafte Satzzeichenkombinationen. Mehrfache Punkte (... , ...) werden auf einfache Satzpunkte reduziert; Kombinationen wie :... , ;... oder ... ; werden typografisch aufgelöst. Zudem werden fehlende Leerzeichen nach Punkten vor nachfolgenden Großbuchstaben automatisch eingefügt (`re.sub(r'([a-z0-9])\.( [A-Z])', r'\1.\2')`), um Satzgrenzen für Sentence-Splitter eindeutig erkennbar zu machen.
- **Listen- und Bullet-Point-Transformation:** Texte in Leichter Sprache nutzen häufig vertikale Aufzählungslisten mit Bullet-Points (•) oder Asterisks (*). Werden diese ungefiltert zusammengefügt, entstehen unvollständige Satzfragmente. Die Normalisierungsroutine transformiert Listenpunkte kontextsensitiv: Führt ein Doppelpunkt in eine Liste (» : •«), wird der Doppelpunkt beibehalten und das Aufzählungszeichen entfernt. Steht ein Aufzählungspunkt vor einer Konjunktion (» • und«, » • oder«), wird er durch ein Leerzeichen ersetzt. Zwischen rein nominalen Elementen werden Bullets in Kommata überführt (• → ,).
- **Inhaltsverzeichnis-Bereinigung & Frage-Antwort-Erhaltung:** Ein zentrales didaktisches Leitprinzip der Leichten Sprache ist die Untergliederung von Texten in überschaubare Sinnabschnitte, wobei Zwischenüberschriften bevorzugt als konkrete W-Fragen formuliert werden (» Was ist ...?«, » Wer kann teilnehmen?«), auf die unmittelbar der erklärende Antwortabsatz folgt (Bundesministerium für Arbeit und Soziales, 2025). Auf Webseiten (insbesondere der *Apotheken Umschau* und der *Stadt Hannover*) stellen Redaktionen dem Artikel häufig ein Inhaltsverzeichnis mit internen Sprungmarken-Links voran. Beim unstrukturierten HTML-Scraping werden diese Navigationslisten als Ketten von 4 bis 8 aufeinanderfolgenden Fragen unmittelbar vor die erste Zwischenüberschrift extrahiert. Die Bereinigungsroutine analysiert einleitende Fragesequenzen und schneidet die führende Linkliste deterministisch ab. Entscheidend ist hierbei die strukturelle Selektion: Die unmittelbar vor dem ersten Erklärsatz stehende Frage wird als legitime Zwischenüberschrift erhalten, ebenso wie alle nachfolgenden Zwischenüberschriften im Fließtext. Strikte Selektionskriterien stellen zudem sicher, dass reguläre Inhaltslisten (z. B. medizinische Symptom- oder Verhaltensaufzählungen ohne interne Anker-Links) vollständig im Fließtext verbleiben.

4.2.3 Semantische Qualitätssicherung & Optimaler Ähnlichkeitsbereich

Während die vorangegangene Vorverarbeitung primär syntaktische und layoutbezogene Artefakte beseitigt, garantiert sie noch keine inhaltliche Konsistenz der alignierten Artikelpaare. Heuristische Sprachumschalter und Canonical-Links in Content-Management-Systemen (CMS) können dazu führen, dass thematisch divergierende Artikel verknüpft werden oder Webseiten in beiden Sprachfassungen identische Texte ausliefern.

Um solche Fehler automatisiert auszuschließen, setzt die Pipeline auf eine semantische Vektorisierung mittels `jina-embeddings-v2-base-de` (Günther et al., 2023). Im Gegensatz

zu klassischen Sentence-BERT-Modellen mit strikter Begrenzung auf 128 bis 512 Tokens verarbeitet dieses Modell Eingabesequenzen von bis zu 8.192 Tokens dank linearer Positionsgewichtung (ALiBi, vgl. Abschnitt 2.3). Dadurch wird ein künstliches Abschneiden (*Truncation Bias*) langer Dokumente vermieden, bei denen wesentliche Sachinformationen oft erst im späteren Textverlauf folgen.

Auf Basis der generierten Dokumenten-Einbettungen $\mathbf{u} = \text{Jina}(\text{AS})$ und $\mathbf{v} = \text{Jina}(\text{LS})$ wird die semantische Kosinus-Ähnlichkeit $\text{sim}_{\cos}(\mathbf{u}, \mathbf{v})$ berechnet und ein empirisch validierter Bereich optimaler Textähnlichkeit definiert:

$$\mathcal{C}_{\text{opt}} = \{(\text{AS}, \text{LS}) \mid 0,60 \leq \text{sim}_{\cos}(\mathbf{u}, \mathbf{v}) \leq 0,98\} \quad (11)$$

Die Schwellenwerte schließen systematisch zwei dominante Fehlerklassen aus:

- **Ausschluss der Untergrenze ($\text{sim}_{\cos} < 0,60$):** Beseitigt thematische Fehlverlinkungen (z. B. *Apotheken Umschau*: »Amsler-Gitter Netzhaut-Check« fälschlich verknüpft mit »Altersbedingte Makula-Degeneration«; $\text{sim}_{\cos} = 0,27$), radikale Teaser-Kürzungen (z. B. *brand eins*: mehrseitiger Fachaufsatz auf einen Einzelsatz reduziert; $\text{sim}_{\cos} = 0,13$) sowie unvollständige Platzhalterseiten mit lateinischem Blindtext (»Lorem Ipsum«; $\text{sim}_{\cos} < 0,10$).
- **Ausschluss der Obergrenze ($\text{sim}_{\cos} > 0,98$):** Eliminiert unvollständig gepflegte Webseiten, bei denen der alltagssprachliche Originaltext unverändert in den Leichte-Sprache-Bereich kopiert wurde. Ein Verbleib dieser Dubletten würde dazu führen, dass das Modell eine triviale Identitätsfunktion ($\text{LS} = \text{AS}$) lernt und aktive Vereinfachungsoperationen unterdrückt werden.

Ergänzend werden Paare mit weniger als 30 Wörtern sowie extreme Längenverhältnis-Ausreißer ($\text{LS}/\text{AS} < 0,20$ oder $\text{LS}/\text{AS} > 4,00$) ausgeschlossen. Die geringe Korrelation zwischen Längenverhältnis und Jina-Ähnlichkeit ($r = -0,098$) belegt, dass diese Filterung eine echte semantische Inhaltsprüfung darstellt. Durch das Zusammenspiel aus regelbasierter Vorverarbeitung, semantischer Ähnlichkeitsfilterung und der Bereinigung doppelter Webseiten (insbesondere 535 redundante URL-Kopien bei *Hannover.de*) reduziert sich der akquirierte Rohbestand von 1.458 auf 860 qualitätsgesicherte Artikelpaare (Retention 59,0 %).

4.2.4 Empirische Fallstudien zur Bias- & Halluzinations-Prävention

Die Notwendigkeit dieser zielgerichteten Bereinigungsschritte lässt sich anhand dreier konkreter Modellierungssphänomene belegen, die bei ersten Vortests mit unbereinigten Trainingsdaten auftraten:

1. **Suffix-Boilerplate-Halluzination (Fallbeispiel Hannover):** In den Rohdaten der Stadt Hannover endete ein Großteil aller Webseiten mit der standardisierten Klick-Aufforderung: »Sie interessieren sich für ein bestimmtes Thema? Dann klicken Sie auf ein Feld.« Da Hannover im Rohkorpus mit 750 Artikeln mehr als die Hälfte

aller Daten stellte, lernte ein auf unbereinigten Daten trainiertes Seq2Seq-Modell eine starke Scheinkorrelation: Es generierte diesen Satz stereotyp als Schlusselement jeder Übersetzung – vollkommen unabhängig vom Ausgangstext. Wurde dem Modell beispielsweise ein biologischer Fachtext über Haushunde vorgelegt (*»Hunde begleiten den Menschen seit Jahrtausenden...«*), produzierte das unbereinigte Modell:

»Was sind Hunde? Hunde sind Haustiere. Sie begleiten den Menschen schon seit Jahrtausenden... Mit einem Hund kann man viele Dinge machen. ›Sie interessieren sich für ein bestimmtes Thema? Dann klicken Sie auf ein Feld.«

Erst nach der vollständigen Beseitigung dieser Phrase aus dem Trainingsbestand verschwand die Halluzination in den Inferenz-Outputs vollständig und das Modell schloss Übersetzungen inhaltlich adäquat ab.

2. **Präfix-Kicker-Verzerrung (Fallbeispiel MDR):** Die Nachrichtentexte des Mitteldeutschen Rundfunks begannen in den Rohdaten ausnahmslos mit einer vorangestellten Rubriken- oder Bundesland-Kennung (z. B. »Sachsen:«, »Sachsen-Anhalt:«, »Thüringen:«, »Mitteldeutschland:« oder »in Leichter Sprache Ticker:«). Aufgrund der hohen Frequenz dieser Muster im nachrichtlichen Teilkorpus entwickelte das Sprachmodell einen ausgeprägten Präfix-Bias: Es lernte, dass eine valide Vereinfachung zwingend mit dem Wort »Sachsen« oder »Sachsen-Anhalt« als erstem Token beginnen müsse, und setzte diesen Kicker selbst vor überregionale oder allgemeinsprachliche Texte. Durch das Entfernen dieser Kicker-Präfixe wurde die Verzerrung nachhaltig behoben.
3. **Inhaltsverzeichnis- & Fragenketten-Bias (Fallbeispiel Apotheken Umschau & Hannover):** In den Rohdaten der *Apotheken Umschau* wiesen 90,8 % aller Artikel ein führendes Inhaltsverzeichnis aus 4 bis 8 Sprungmarken-Fragen auf (z. B. *»Was ist Baldrian? Wie wirkt Baldrian? Welche Nebenwirkungen kann Baldrian haben? Welche Wechselwirkungen sind möglich? Wer darf Baldrian nicht nehmen? Was ist Baldrian? Baldrian ist eine Heilpflanze...«*). Erste Vortests mit einem auf unbereinigten Daten trainierten SFT-Übersetzer zeigten, dass das Modell diese Verteilung ungefiltert memorisierte: In über 40 % aller Testübersetzungen produzierte das unbereinigte Modell lange Ketten von bis zu 8 aufeinanderfolgenden Fragen, ohne die zugehörigen Antworten zu generieren (z. B. bei der Übersetzung juristischer Fachtexte: *»Was ist die Gerichts-Hilfe? Wie kann ich Hilfe bekommen? Was passiert bei Straftaten? Was sind die Aufgaben von den Gerichten? Was muss ich beachten? Wer kann mich anrufen? Welche Organisationen können mich unterstützen?«*). Hierdurch wurde das didaktische Frage-Antwort-Prinzip untergraben und wertvolles Kontextfenster blockiert. Durch die Integration des oben beschriebenen Filters sank der Anteil von ≥ 5 -Frageketten bei der *Apotheken Umschau* von 90,8 % auf 3,9 % (wobei die verbleibenden Fälle legitime medizinische Symptom-Checklisten im Textkörper darstellen). Im Ergebnis beginnen 99,3 % aller bereinigten Artikel direkt mit einer sauberen 1:1 Frage-Antwort-Struktur, wodurch das translationale Sprachmodell lernt, Zwischenüberschriften direkt durch substantielle Erklärungen zu beantworten.

4.3 Korpus-Statistiken & Linguistische Analyse

Nach dem mehrstufigen Scraping, der regelbasierten Bereinigung und der Filterung nach Textähnlichkeit liegt ein konsolidiertes, qualitätsgesichertes Parallelkorpus vor. Um die linguistische Eignung dieses Datensatzes für das nachfolgende Training neuronaler Übersetzungs- und Bewertungsmodelle zu evaluieren, erfolgt in diesem Abschnitt eine quantitative und qualitative Korpusanalyse. Diese gliedert sich in die Untersuchung deskriptiver Längen- und Kompressionsmaße, die Analyse der lexikalischen Diversität (TTR vs. MATTR unter Berücksichtigung des Längen-Bias), die empirische Evaluierung des bidirektionalen Entitätenerhalts (NER) sowie die Überprüfung der Regeleinhaltung anhand der amtlichen Richtlinien für Leichte Sprache (Bundesministerium für Arbeit und Soziales, 2025).

4.3.1 Quantitative Korpusmaße & Quellcharakteristika

Das finale, qualitätsgesicherte Parallelkorpus umfasst insgesamt 860 Artikelpaare aus 12 heterogenen Quellen. Der Gesamtumfang beläuft sich auf 1.126.538 BPE-Tokens (entsprechend 519.957 Wörtern) in der Ausgangssprache (AS) sowie 706.724 BPE-Tokens (377.572 Wörter) in Leichter Sprache (LS). Im Durchschnitt umfasst ein Alltagssprachlicher Artikel 604,6 Wörter (1.309,9 BPE-Tokens), während ein Artikel in Leichter Sprache im Mittel 439,0 Wörter (821,8 BPE-Tokens) aufweist. Tabelle 2 fasst die zentralen statistischen Kennzahlen nach Quellen zusammen.

Tabelle 2: Übersicht der quantitativen Korpusstatistiken des bereinigten Master-Datensatzes ($N = 860$ Artikelpaare) nach Quellen mit Byte-Pair-Encoding-Tokenisierung (c1100k_base, BPE) für Alltagssprache (AS) und Leichte Sprache (LS) inklusive der Beiträge des Mitteldeutschen Rundfunks (MDR) und der tageszeitung (taz).

Quelle	Artikel-paare	Wörter (AS)	Wörter (LS)	Tokens (AS)	Tokens (LS)	Token-Ratio (LS/AS)
MDR Nachrichten	219	109.157	54.937	231.922	101.729	0,44
Hannover.de	215	109.826	109.514	235.020	195.181	0,83
Apotheken Umschau	153	174.757	101.142	383.702	200.371	0,52
Behindertenbeauftragter	47	17.420	17.386	38.442	34.539	0,90
Hamburg.de	46	21.876	20.515	47.378	36.957	0,78
Koeln.de	39	21.229	30.035	44.799	55.387	1,24
Main-Taunus-Kreis	36	6.585	7.092	14.062	13.592	0,97
Stuttgart.de	35	32.535	20.751	75.442	39.538	0,52
Wiesbaden.de	34	8.225	5.963	18.340	11.365	0,62
brand eins	19	3.588	3.619	7.640	5.998	0,79
Sozialpolitik.com	13	10.408	4.727	21.460	8.684	0,40
taz (die tageszeitung)	4	4.351	1.891	8.331	3.383	0,41
Gesamt	860	519.957	377.572	1.126.538	706.724	0,63

Wie die aggregierten Längenverhältnisse ($\text{Ratio}_{\text{BPE}} = 0,63$ bzw. $\text{Ratio}_{\text{Wort}} = 0,73$) verdeutlichen, unterscheidet sich das Längenverhalten zwischen den 12 Domänen signifikant.

Die Analyse offenbart die Koexistenz zweier distinkter redaktioneller Übersetzungskonzepte:

1. **Inhaltsfilternde Verdichtung (Nachrichten- & Fachjournalismus):** Quellen wie *Sozialpolitik.com* (Ratio = 0,40), die *taz* (0,41), der *MDR* (0,44) sowie die *Apotheken Umschau* (0,52) praktizieren eine gezielte Selektion. Nebeninformationen, historische Exkurse und komplexe Ausschweifungen werden gekürzt, um die Kernbotschaft auf elementare Aussagen zu verdichten.
2. **Explikative Expansion (Kommunal- & Behördenverwaltung):** Kommunale Angebote wie *Koeln.de* (Ratio = 1,24), der *Main-Taunus-Kreis* (0,97) und der *Behindertenbeauftragte* (0,90) weisen hingegen ausgeglichene oder expandierende Umfänge auf. Um juristische und administrative Vorgänge (z. B. Beantragung eines Personalausweises oder Wohngeldes) verständlich zu machen, werden formale Fachtermini durch mehrsätzliche Schritt-für-Schritt-Anleitungen und Begriffsdefinitionen ausführlich expliziert.

Die semantische Textausrichtung wurde über das Long-Context-Embedding-Modell `jina-embeddings-v2-base-de` quantifiziert. Mit einem Mittelwert von $\bar{\text{sim}}_{\text{cos}} = 0,833 \pm 0,074$ (Median 0,849, Q1 0,794, Q3 0,886) liegt eine hohe semantische Konsistenz über alle Quellen hinweg vor: 73,7 % aller Artikelpaare weisen eine Kosinus-Ähnlichkeit von $\geq 0,80$ auf (davon 32,4 % $\in [0,85, 0,90]$ und 16,6 % $\geq 0,90$), während lediglich 6,7 % im moderaten Randbereich ($< 0,70$) liegen.

Empirische Truncation-Analyse bei festen Token-Limits: Eine systematische Überprüfung fester Kontextbegrenzungen unterstreicht die Notwendigkeit des gewählten artikelbasierten Modellierungsansatzes: Bei einem sequenzbasierten Limit von $L = 256$ BPE-Tokens werden 94,7 % aller AS-Dokumente (814/860) und 90,8 % aller LS-Dokumente (781/860) abgeschnitten. Hierbei gehen 80,7 % des gesamten AS- und 69,6 % des LS-Tokenvolumens verloren; lediglich 2,8 % aller Artikelpaare (24/860) passen vollständig in diesen engen Rahmen. Selbst bei einer Verdopplung auf $L = 512$ Tokens verbleiben noch 78,3 % der AS-Artikel in der Truncation (63,5 % Tokenverlust), sodass lediglich 16,5 % aller Dokumentenpaare unbeschnitten bleiben. Diese quantitative Truncation-Analyse belegt empirisch, dass standardisierte Satz- oder Kurzfenstermodelle für die deutsche Leichte Sprache zu erheblichem Informationsverlust führen und rechtfertigt die Auslegung der gesamten Pipeline auf lange Dokumenten-Kontexte.

4.3.2 Lexikalische Diversität: TTR vs. MATTR & Längen-Bias

Zur längeninvarianten Messung der lexikalischen Diversität wird die Moving-Average Type-Token-Ratio mit einem festen Gleitfenster von $W = 50$ Wörtern (MATTR_{50}) eingesetzt, um die bekannte Verzerrung der klassischen Type-Token-Ratio (TTR) durch variable Textlängen zu vermeiden (vgl. Abschnitt 2.2). Wie in Abbildung 1 visualisiert, verläuft die MATTR_{50} unabhängig von der Dokumentenlänge. Im Gesamtkorpus sinkt die MATTR_{50}

von durchschnittlich $0,782 \pm 0,043$ (Median 0,788) in der Alltagssprache auf $0,686 \pm 0,048$ (Median 0,684) in Leichter Sprache ($\Delta\text{MATTR} = 0,097 \pm 0,051$, gepaarter t-Test: $t = 55,318, p < 10^{-280}$), was die gezielte Reduktion auf einen barrierefreien Grundwortschatz über alle 12 Quellen hinweg empirisch belegt.




Abbildung 1: Lexikalische Diversität und Längenbereinigung im bereinigten Parallelkorpus ($N = 860$ Paare) anhand der Moving-Average Type-Token-Ratio mit einem Fenster von 50 Wörtern (MATTR_{50}) über der Tokenanzahl sowie als quellenweiser Vergleich zwischen Alltagssprache (AS) und Leichter Sprache (LS).

4.3.3 Faktenerhalt vs. Faktentreue: Grenzen von NER als Metrik

Um zu prüfen, ob der Recall benannter Entitäten (Named Entity Recognition via `spacy de_core_news_lg`) als Optimierungsmetrik für Leichte Sprache geeignet ist, wurde der Entitätenerhalt bidirektional über alle 12 Quellen evaluiert (Abbildung 2). Die Ergebnisse zeigen eine Entitäten-Kompression um 40,3% (von 19.418 Entitäten in AS auf 11.586 in LS) sowie geringe Überlappungsraten: Der mittlere Faktenerhalt (AS $\rightarrow$ LS) liegt bei nur $20,8\% \pm 19,6\%$, während die Faktentreue (LS $\rightarrow$ AS) bei $32,8\% \pm 24,6\%$ liegt ($t = 14,263, p < 10^{-40}$). Dieser scheinbare Informationsverlust resultiert primär aus der regelkonformen Paraphrasierung von Fachbegriffen und behördlichen Eigennamen durch leicht verständliche Umschreibungen (Bundesministerium für Arbeit und Soziales, 2025). Da der NER-Recall diese Paraphrasen nicht erfasst und nur schwach mit der semantischen Kosinus-Ähnlichkeit korreliert ($r = 0,242$), eignet er sich nicht als direkte Reward-Metrik für Übersetzungsmodelle.

4.3.4 Regeleinhaltung nach BMAS-Richtlinien

Zur quantitativen Überprüfung der Regeleinhaltung wurden die zentralen normativen Vorgaben des Bundesministeriums für Arbeit und Soziales (Bundesministerium für Arbeit und Soziales, 2025) über einen automatisierten linguistischen Parser evaluiert (Abbildung 3). Die Analyse belegt eine hohe Konformität mit den Kernregeln in den Zieltexten: Die durchschnittliche Satzlänge sinkt über alle Quellen hinweg um rund ein Drittel auf 7,4 Wörter pro Satz und unterschreitet damit die empfohlene Obergrenze von zehn Wörtern.




Abbildung 2: Bidirektionaler Recall zur Erkennung benannter Entitäten (Named Entity Recognition, NER via `spacy de_core_news_lg`) über alle 12 Korpusquellen ($N = 860$ Artikelpaare) zur Gegenüberstellung von Faktenerhalt aus der Alltagssprache in die Leichte Sprache ($AS \rightarrow LS$) und Faktentreue ($LS \rightarrow AS$).

Zudem werden Genitivattribute in den meisten Domänen weitgehend eliminiert und durch Dativ-Umschreibungen ersetzt. Diese strukturellen Vereinfachungen spiegeln sich auch in der Wiener Sachtextformel (WSTF) wider, deren Schwierigkeitsgrad von gymnasialem Niveau (durchschnittlich 11,2) um über vier Schulstufen auf 6,7 in den angestrebten Zielkorridor für Leichte Sprache absinkt. Beim Passivgebrauch offenbart sich hingegen ein redaktioneller Stilunterschied: Während behördliche und kommunale Portale Passivkonstruktionen konsequent in adressatenorientierte Aktivsätze umwandeln, behalten nachrichtliche Redaktionen wie der MDR das unpersönliche Zustandspassiv als etabliertes Informationsmuster größtenteils bei.

4.3.5 Synthese der Korpuseigenschaften

Die quantitative und qualitative Korpusanalyse belegt, dass der bereinigte Datensatz ($N = 860$) die formalen und inhaltlichen Kriterien der Leichten Sprache in hoher Güte erfüllt. Gleichzeitig verdeutlichen die empirischen Unterschiede bei der Regeleinhaltung – wie bereits in Abschnitt 4.1 sowie bei den Längenverhältnissen dargelegt –, wie unterschiedlich das Regelwerk in der Praxis interpretiert und redaktionell umgesetzt wird: Während nachrichtliche Medien den Fokus auf eine inhaltliche Kompression legen und dabei etablierte Muster wie das Zustandspassiv teilweise beibehalten, priorisieren behördliche Angebote die informationelle Vollständigkeit durch explizierende Beschreibungen.

Diese redaktionelle Heterogenität unterstreicht die methodische Herausforderung der automatischen Textvereinfachung (ATS): Es existiert kein starres Zielbild, sondern ein breites Spektrum legitimer sprachlicher Vereinfachungsstrategien. Das im Rahmen dieser Arbeit erstellte Multidomänen-Korpus bildet diese reale stilistische Vielfalt über alle 12 Quellen hinweg systematisch ab. Durch die Kombination aus Längenbereinigung (MATTR), semantischer Ähnlichkeitsfilterung und nachgewiesener Regeleinhaltung schafft es eine verlässliche Datengrundlage für das nachfolgende Training neuronaler Regressionsmetriken




Abbildung 3: Linguistische Regeleinhaltung nach den Vorgaben des Bundesministeriums für Arbeit und Soziales (BMAS) sowie der Barrierefreie-Informationstechnik-Verordnung (BITV 2.0) über 12 Korpusquellen ($N = 860$ Artikelpaare) im Vergleich zwischen Alltagssprache (AS) und Leichter Sprache (LS) für Satzlänge, Genitiv-Quote, Passiv-Dichte und Wiener Sachtextformel (WSTF).

(Kapitel 5.1) sowie für die generative Übersetzung.

5 Themenblock 2: Metrik & Bewerten von Sprachkomplexität

Die automatisierte, referenzfreie Bewertung von Sprachkomplexität bildet eine zentrale Grundlage dieser Arbeit. Um Texte in Leichter Sprache objektiv zu bewerten und ein stufenloses Belohnungssignal (*Reward*) für das spätere Modelltraining bereitzustellen, wird in diesem Themenblock eine eigene Metrik-Pipeline entwickelt und systematisch evaluiert.

5.1 Vorstufe: Binäre Klassifikation als Machbarkeitsnachweis & Architektur-Baseline

Bevor ein generatives Sprachmodell über überwachtes Feintuning (SFT) oder Präferenzoptimierung (DPO) zur Textvereinfachung trainiert werden kann, wird ein Bewertungsmodell benötigt, das den Grad sprachlicher Einfachheit objektiv und reproduzierbar misst.

5.1.1 Motivation, Lesbarkeitsmetriken & BiLSTM-Architektur

Klassische lesbarkeitsmetrische Ansätze wie der *Flesch Reading Ease* (Amstad, 1978) oder die *Wiener Sachtextformel* (Bamberger und Vanecek, 1984) basieren primär auf statistischen Oberflächenmerkmalen wie der mittleren Silbenanzahl oder Satzlänge (vgl. Abschnitt 2.2). Zwar bieten diese Zählformeln eine recheneffiziente Basis zur groben Abschätzung allgemeiner Textschwierigkeit, sie stoßen bei der Bewertung von Leichter Sprache jedoch an Grenzen: Da sie für allgemeine Lesbarkeitsstufen im Bildungswesen entwickelt wurden, berücksichtigen sie die spezifischen Regeln der Leichten Sprache nicht. Weder syntaktische Vorgaben wie die Vermeidung von Passivkonstruktionen und Genitiven, die Auflösung von Nebensätzen in kurze Hauptsätze noch Besonderheiten wie Bindestrich-Kopplungen bei Komposita (z. B. »*Werkstatt-Vertrag*«) werden von reinen Zählformeln erfasst. Zudem liefern feste Formeln keine stufenlosen Gradienten für das spätere Reward-Modeling im Präferenztraining.

Dieser Nachteil lässt sich durch einen datengetriebenen Ansatz beheben: Neuronale Modelle können die syntaktischen, morphologischen und lexikalischen Muster Leichter Sprache direkt aus den bereinigten Parallelkorpora lernen. Die binäre Klassifikation dient dabei als Machbarkeitsnachweis (*Proof of Concept*): *Ist ein rekurrentes Modell in der Lage, anhand der linguistischen Merkmale trennscharf zwischen alltagssprachlichen Ausgangstexten (AS, $y = 0$) und Versionen in Leichter Sprache (LS, $y = 1$) zu unterscheiden?*

Als neuronales Modell dient das in Abschnitt 2.4 theoretisch hergeleitete Bidirektionale LSTM (BiLSTM). Die Eingabetexte werden mittels `spaCy` tokenisiert und über eine Einbettungsschicht in zwei bidirektionale LSTM-Schichten eingespeist. Die aggregierte Sequenzrepräsentation wird nach Regularisierung über Dropout durch einen linearen Klassifikationskopf mit Sigmoid-Aktivierung in eine kontinuierliche Klassifikationswahrscheinlichkeit für Leichte Sprache überführt. Das Training erfolgt mittels binärer Kreuzentropie und dem AdamW-Optimierer (Loshchilov und Hutter, 2019) mit Early Stopping. Die vollständigen

Schichtdimensionen, Lernraten und Trainingsparameter aller Metrikmodelle sind in der Hyperparameter-Tabelle 21 im Anhang A.11 dokumentiert.

Auf dem internen Test-Split des Master-Korpus bestätigt das Modell den ermittelten optimalen Ähnlichkeitsbereich ($0,80 \leq \text{sim}_{\text{cos}} \leq 0,98$): Das BiLSTM erzielt eine Balanced Accuracy von 92,99 % auf Satzebene sowie 99,03 % auf Artikelebene (der vollständige In-Domain-Vergleich über Ähnlichkeitsbereiche ist in Tabelle 14 im Anhang A.3 dokumentiert). Dies belegt die hohe Qualität der Trainingsdaten und die Eignung des BiLSTM-Modells zur Erkennung einfacher Sprachstrukturen.

5.1.2 Granularitäts-Vergleich: Satzebene vs. Artikelebene

Zur Bestimmung der optimalen Modellierungs- und Aggregationsebene sowie zur Überprüfung der Out-of-Domain-Generalisierung wurde eine systematische Vergleichsstudie auf dem unabhängigen, verifizierten *Lebenshilfe*-Goldstandard ($N = 37$ Artikelpaare / 74 Dokumente, 6.901 Einzelsätze aus behördlich-juristischen Kontexten) durchgeführt. Untersucht wurden das Satzmodell (isoliert sowie aggregiert via Majority Voting) und direkte Artikel-Klassifikatoren über maximale Kontextlängen von 256, 512 und 1.024 Tokens. Tabelle 3 stellt die Ergebnisse gegenüber klassischen Lesbarkeitsmetriken dar (ergänzende KDE-, ROC- und Konfusionsanalysen finden sich im Anhang A.3).

Tabelle 3: Benchmark der auf bidirektionalen Long-Short-Term-Memory-Netzwerken basierenden Klassifikationsmodelle (BiLSTM) über Granularitätsebenen und Sequenzlängen auf dem Lebenshilfe-Goldstandard ($N = 37$ Artikelpaare / 74 Dokumente) im Vergleich zwischen Alltagssprache (AS) und Leichter Sprache (LS) inklusive Majority Voting über Einzelsätze (MajVote) und des relativen Paar-Rankings (Pair Match).

Modell	Ebene / Input	$\emptyset$ Score (LS)	$\emptyset$ Score (AS)	Separation (Δ)	Balanced Acc	Pair Match
BiLSTM Satz-Klassifikator	Satzebene ($N = 6.901$)	$0,721 \pm 0,37$	$0,160 \pm 0,29$	0,561	79,94 %	–
BiLSTM Satz-Klassifikator (MajVote)	Dokument (r_{LS} Ratio)	$0,719 \pm 0,09$	$0,116 \pm 0,13$	0,603	98,65 %	100,0 % (37/37)
BiLSTM Artikel-Klassifikator (256)	Dokument (256 Tok.)	$0,756 \pm 0,36$	$0,003 \pm 0,00$	0,754	90,54 %	97,3 % (36/37)
BiLSTM Artikel-Klassifikator (512)	Dokument (512 Tok.)	$0,781 \pm 0,36$	$0,009 \pm 0,03$	0,772	90,54 %	94,6 % (35/37)
BiLSTM Artikel-Klassifikator (1.024)	Dokument (1.024 Tok.)	$0,413 \pm 0,40$	$0,000 \pm 0,00$	0,413	70,27 %	100,0 % (37/37)
Flesch Reading Ease (Baseline)	Dokument (Silben/Satz)	$0,973 \pm 0,16$	$0,189 \pm 0,39$	0,784	89,19 %	100,0 % (37/37)
Wiener Sachtextformel (Baseline)	Dokument (Wortlänge)	$0,919 \pm 0,27$	$0,108 \pm 0,31$	0,811	90,54 %	100,0 % (37/37)

Die Ergebnisse liefern zwei fundamentale Erkenntnisse:

1. **Satzmodell und Aggregation via Majority Voting:** Auf Einzelsatzebene fällt die Performanz mit 79,94 % Balanced Accuracy moderat aus, da isolierte Phrasen (z. B. kurze Überschriften oder Begrüßungen) oft keine eindeutigen Merkmale Leichter Sprache enthalten. Wird das Modell jedoch über die Simple-Sentence-Ratio

$$r_{LS} = \frac{1}{|S|} \sum_{s \in S} \mathbb{I}(\hat{y}_s = 1) \in [0,0, 1,0] \quad (12)$$

mittels Majority Voting aggregiert, gleicht die Mittelung lokale Unsicherheiten weitgehend aus: Die Balanced Accuracy steigt auf 98,65 %, der ROC-AUC auf 0,9949 und das Paar-Matching erreicht fehlerfreie 100,0 % (37/37).

2. **Signalverlust bei langen Artikeln:** Im direkten Kontrast dazu zeigen sich direkte Artikel-Klassifikatoren bei langen Sequenzen anfällig für Informationsverlust: Während bei 256 und 512 Tokens noch eine Balanced Accuracy von 90,54 % erzielt wird, bricht die Performanz bei 1.024 Tokens auf 70,27 % ein. Die KDE-Analyse (Abbildung 16) deckt eine deutliche Asymmetrie auf: Während Alltagssprache mit spitzen Peaks bei 0,0 sehr sicher erkannt wird ($\emptyset$ -Score $\leq 0,009$), überdecken neutrale Passagen und Eigennamen die Merkmale Leichter Sprache über lange Sequenzen hinweg. Der mittlere LS-Score sinkt auf 0,413 ab und unterschreitet die Entscheidungsschwelle $\tau = 0,50$, wodurch der LS-Recall auf 40,54 % fällt (mehr falsch-negative Einstufungen).

Einordnung der traditionellen Baselines gegenüber den neuronalen Modellen

Die empirischen Ergebnisse in Tabelle 3 verdeutlichen die Stärken und Grenzen der traditionellen Formeln: Mit einer Balanced Accuracy von 89,19 % (Flesch) bzw. 90,54 % (Wiener Sachtextformel) und einem fehlerfreien Paar-Matching von 100,0 % (37/37) erweisen sich die klassischen Formeln als robuste Baselines auf Dokumentenebene. Da Texte in Leichter Sprache deutlich kürzere Sätze und Wörter aufweisen, wirkt sich dieser Oberflächeneffekt auf Dokumentenebene stark aus. Die Formeln übertreffen damit den direkten 1.024-Token-Artikel-Klassifikator (70,27 %, 40,54 % LS-Recall), dessen Leistung durch die Signalüberlagerung über lange Sequenzen und die geringe Zahl eigenständiger Trainingsartikel abfällt. Gegenüber dem hierarchisch aggregierten BiLSTM-Satzmodell (r_{LS}) mit 98,65 % Balanced Accuracy und einem ROC-AUC von 0,9949 offenbaren die Formeln jedoch eine deutliche Schwäche: Ihre Dichteverteilungen (Abbildung 16) weisen eine breite Überlappungszone im Übergangsbereich auf, da sie grammatikalische und stilistische Unterschiede nicht erfassen. Das neuronale Satzmodell schließt diese Lücke und erreicht eine trennscharfe Klassifikation ($\Delta = 0,603$).

5.1.3 Dummy-Content-Test: Prüfung auf Längen- und Padding-Bias

Um auszuschließen, dass das BiLSTM lediglich oberflächliche Längenunterschiede oder das Zero-Padding (*Shortcut Learning*) lernt, wurde ein gezielter Dummy-Content-Test auf dem Lebenshilfe-Goldstandard durchgeführt. Hierbei werden alle Wörter der Testdokumente durch ein einheitliches, neutrales Token (den Punkt ».<« bzw. den Artikel »der«) ersetzt, während die originären Sequenzlängen und das Zero-Padding exakt unverändert bleiben ($\mathbf{T}_{\text{dummy}} = (t_{\text{dummy}}, \dots, t_{\text{dummy}}, \text{PAD}, \dots)$). In diesem Szenario bricht die Balanced Accuracy von über 90 % auf exakt 50,00 % (reines Zufallsniveau) zusammen. Dies belegt, dass das Modell keine rein längen- oder paddingbasierten Heuristiken nutzt, sondern tatsächliche linguistische Merkmale verarbeitet.

5.1.4 Synthese: Erlernbarkeit des Signals & Überleitung zur stetigen Sprachstufenmodellierung

Zusammenfassend belegen die Ergebnisse, dass das BiLSTM linguistische Merkmale Leichter Sprache zuverlässig lernt und Dokumentenpaare verlässlich relativ rankt (ROC-AUC $> 0,94$,

Pair-Match bis zu 100,0 %). Für die spätere Steuerung generativer Modelle (Themenblock 3) erfordert das Fehlen kontinuierlicher Gradienten (Sigmoid-Sättigung des binären Klassifikationskopfes) jedoch ein stufenloses, differenzierbares Gütesignal $\lambda \in [0,0, 1,0]$.

Da natürliche Parallelkorpora der Leichten Sprache ausschließlich bimodal strukturiert sind (Ausgangstext in Alltagssprache vs. finale Übersetzung in Leichter Sprache) und in der Praxis keine authentischen Zwischenstufen vorliegen, muss ein kontinuierlicher Übergangsbereich modelliert werden. Im folgenden Abschnitt wird hierfür zunächst ein intuitiver Ansatz untersucht: die diskrete Generierung von Sprachkomplexitätsstufen mittels großer Sprachmodelle (LLMs).

5.2 Erster Lösungsansatz: Synthetische Sprachstufengenerierung via Large Language Models

Als erster methodischer Ansatz zur Konstruktion eines stetigen Zwischenraums wurde die gezielte Generierung diskreter Sprachkomplexitätsstufen mittels großer Sprachmodelle (Large Language Models, LLMs) untersucht. Die Kernidee dieses Ansatzes bestand darin, ein Gütesignal auf Basis linguistisch modulierter Ganztexte zu erlernen, indem ein leistungsfähiges generatives Modell angewiesen wird, Zwischenversionen mit kontrolliertem Vereinfachungsgrad zu verfassen.

5.2.1 Konzeption, Prompt-Design & Generierung mit FlensGen-GPT

Zur semantischen Generierung der Zwischenstufen wurde das an der Hochschule Flensburg betriebene Open-Source-Großsprachmodell **FlensGen-GPT-OSS-120B** über einen lokalen Inferenzendpunkt per Instruction Prompting angesteuert. Für jedes parallele Artikelpaar des bereinigten Master-Korpus sowie des Lebenshilfe-Datensatzes wurden unter Vorlage beider Originalfassungen (Alltagssprache als Stufe 0,00 und Leichte Sprache als Stufe 1,00) drei diskrete Zwischenstufen synthetisiert:

- **Stufe 0,25 (Nahe Alltagssprache):** Leicht vereinfachter Fließtext; Schachtelsätze werden aufgeteilt, schwierige Fachtermini kurz paraphrasiert.
- **Stufe 0,50 (Einfache Sprache):** Typische »Einfache Sprache«; Verzicht auf Schachtelsätze bei Standard-Kombination aus Haupt- und Nebensatz, alltäglicher Wortschatz.
- **Stufe 0,75 (Nahe Leichte Sprache):** Sehr leicht verständliche Sprache; überwiegend einfache Hauptsätze, jedoch ohne die extremen zeilenweisen Umbrüche Leichter Sprache.

Das vollständige System- und User-Prompt-Design inklusive aller Regelvorgaben ist in Anhang A.6 dokumentiert. Auf dem resultierenden 5-Stufen-Datensatz (4.300 Text-Samples aus 860 Artikeln) wurde eine BiLSTM-Architektur identischer Kapazität (Hidden-Dim 128, Embedding-Dim 128, MSE-Loss) als *Synthetischer Regressor* trainiert.

5.2.2 Empirische Ergebnisse auf dem Lebenshilfe-Goldstandard

Bei der empirischen Überprüfung auf dem unabhängigen *Lebenshilfe*-Goldstandard zeigte der synthetische Regressor prinzipiell das erwünschte Verhalten: Das Modell erlernt die grundlegende Richtung der Sprachkomplexität und weist Texten in Leichter Sprache im Durchschnitt höhere Werte zu als den alltagssprachlichen Originalen ($\emptyset$ -Score(LS) = $0,575 \pm 0,35$ vs. $\emptyset$ -Score(AS) = $0,145 \pm 0,18$, $\Delta = +0,429$). Auch bei der relativen Gegenüberstellung gegebener Artikelpaare ordnet das Modell in 89,2 % der Fälle der vereinfachten Fassung einen höheren Score zu (ROC-AUC = 0,8495, Balanced Accuracy 78,38 %, Pair Match 89,2 % [33/37]). Entlang der fünf diskret generierten Stufen spiegelt sich zudem ein erkennbarer, stetiger Anstieg der vorhergesagten Werte wider.

Gleichzeitig offenbart die empirische Verteilungsanalyse jedoch erhebliche Schwächen (vgl. Abbildung 22 sowie Tabelle 16 im Anhang): Die Vorhersagen des synthetischen Regressors streuen spürbar breit, und insbesondere im mittleren Komplexitätsbereich fallen die Übergänge zwischen den Zwischenstufen diffus und überlappend aus.

5.2.3 Methodische Grenzen & Motivation für ein stochastisches Text-MixUp

Obwohl der synthetische Ansatz als Machbarkeitsnachweis für LLM-basierte Komplexitätsmodulation funktionierte, erwies er sich für den praktischen Einsatz als Reward-Modell im generativen Alignment als unzureichend. Die Ursachen für diese Limitationen liegen in drei methodischen Kernproblemen begründet:

1. **Granularitätsgrenze generativer Sprachmodelle:** Während das LLM grobe Niveaus trennen kann, stößt es bei feineren Zwischenstufen an eine Auflösungsgrenze. Eine Erhöhung auf beispielsweise 10 oder 20 Stufen erzeugt keinen Informationsgewinn, da aktuelle Modelle solch minimale Komplexitätsunterschiede nicht deterministisch steuern können und zu stilistischer Regression neigen.
2. **Datenvolumen und statische Limitation:** Der synthetische Ansatz ist auf 5 diskrete Texte pro Artikel limitiert (4.300 statische Samples). Bei Millionen Parametern neigt das rekurrente Netz bei wiederholter Epochen-Präsentation identischer Texte zu Overfitting.
3. **Miterlernen künstlicher Modellierungsartefakte:** Der synthetische Ansatz trainiert auf maschinell generierten Zwischentexten. Dadurch lernt das rekurrente Netz unvermeidbare LLM-Artefakte, Halluzinationsmuster und unnatürliche Satzstrukturen als Scheinsignale mit, anstatt die authentischen sprachlichen Gesetzmäßigkeiten Leichter Sprache zu generalisieren.

Aus diesen Gründen reicht die diskrete synthetische Generierung allein nicht aus, um ein stufenloses, robustes Belohnungssignal bereitzustellen. Im folgenden Abschnitt wird daher ein zweiter Lösungsansatz entwickelt: Ein stochastisches Mischverfahren, das ausschließlich auf authentischen, von Menschen erstellten Paralleltexten aufbaut und kontinuierliche Zielwerte erzeugt.

5.3 Zweiter Lösungsansatz: Continuous MixUp Regression

Um die Limitationen der synthetischen LLM-Generierung (Datenknappheit, diskrete Stufen und künstliche Textartefakte) zu überwinden, wird in diesem Abschnitt das Verfahren der *Continuous MixUp Regression* entwickelt. Die Kernüberlegung besteht darin, den kontinuierlichen Übergangsraum direkt auf den authentischen, von menschlichen Fachexperten erstellten Parallelkorpora zu konstruieren.

5.3.1 Konzeption des textuellen MixUp & Dynamische Target-Berechnung

Das klassische MixUp-Verfahren (H. Zhang et al., 2018) erzeugt neue Trainingsdaten, indem es bestehende Eingaben und deren Zielwerte stufenlos miteinander vermischt. Da Wörter und Texte diskrete Strukturen sind und sich nicht direkt numerisch überblenden lassen, wird dieses Prinzip im Rahmen dieser Arbeit auf Satzebene übertragen: Kontinuierliche Zwischenstufen der Sprachkomplexität entstehen durch das kontrollierte, zufällige Mischen von Sätzen aus beiden Sprachfassungen:

Für jedes parallele Artikelpaar (D_{AS}, D_{LS}) des Trainingskorpus werden die Sätze segmentiert. Ein gemischtes Dokument D_{mix} entsteht durch zufälliges Ziehen und Zusammenfügen von Sätzen aus beiden Sprachfassungen:

$$D_{mix} = \text{Concat}(\text{sample}(S_{LS}, k_{LS}) \cup \text{sample}(S_{AS}, k_{AS})) \quad (13)$$

wobei die Sätze vor dem Zusammenfügen zufällig durchmischt werden, um zu verhindern, dass das rekurrente Netz bestimmte Sprachmuster rein anhand ihrer Position im Text lernt.

Da Sätze in Alltagssprache und Leichter Sprache stark divergierende Wort- und Satzlängen aufweisen, würde ein reiner Satzanzahl-Anteil den tatsächlichen sprachlichen Anteil systematisch verzerren. Der kontinuierliche Zielwert $\lambda \in [0,0, 1,0]$ wird daher dynamisch über den relativen Zeichenlängenanteil der Leichten Sprache im gemischten Text berechnet:

$$\lambda = \frac{\text{CharLen}(S_{LS, \text{gezogen}})}{\text{CharLen}(S_{LS, \text{gezogen}}) + \text{CharLen}(S_{AS, \text{gezogen}})} \quad (14)$$

Hierbei repräsentiert $\lambda = 0,0$ reine Alltagssprache und $\lambda = 1,0$ reine Leichte Sprache, während alle Zwischenwerte stufenlose Simplitätsgrade quantifizieren.

5.3.2 Vergleich der Trainings- und Sampling-Strategien

Bei der methodischen Entwicklung des textuellen MixUp-Trainings wurden vier Dataloader- und Optimierungsstrategien systematisch verglichen:

- **Variante A (Statisch):** Feste Vorabmischung des Trainingskorpus bei der Dataset-Initialisierung ($p_{dynamic} = 0,0$).
- **Variante B (Dynamisch):** Rein dynamisches On-the-Fly-Shuffling in jedem Batch ($p_{dynamic} = 1,0$).
- **Variante C (Hybrid):** Epochenabhängiges Curriculum-Mischen mit kontinuierlichem Übergang von statischen zu dynamischen Mischungen ($p_{dynamic} = \frac{\text{Epoche}}{\text{Gesamtepochen}}$).

- **Variante D (Hybrid + Cyclic LR):** Hybride Mischung kombiniert mit zyklischem Lernratenscheduling mittels *CosineAnnealingWarmRestarts* nach Loshchilov und Hutter (2017) zur Vermeidung lokaler Minima.

Einfluss der Trainings- und Sampling-Strategien auf die Regressionsgüte In frühen Experimenten mit stark begrenzter Datenmenge ($M = 10$ Mischungen pro Artikelpaar, entsprechend ca. 5.130 Samples) zeigten sich deutliche Unterschiede zwischen den Ansätzen: Die statische Vorabmischung neigte durch die wiederholte Präsentation identischer Satzkombinationen zu Overfitting. Die rein dynamische Variante konvergierte bei wenigen Iterationen ($N = 513$) aufgrund des hohen Gradientenrauschens nur langsam. Die hybride Variante mit zyklischem Scheduler erwies sich in dieser Phase als am stärksten, da sie eine stabile anfängliche Repräsentationsbildung ermöglichte und durch periodische Lernratenanstiege lokalen Minima entkommen konnte.

Wird der Trainingskorpus jedoch voll skaliert ($M = 160$, über 82.000 Mischungen pro Epoche über 100 Epochen), gleichen sich die Ergebnisse der vier Ansätze weitgehend an: Durch die große Zahl unterschiedlicher Satzkombinationen konvergieren alle vier Varianten zu einem nahezu identischen Leistungsniveau (Val-MSE $\approx 0,027$, Test-Balanced-Accuracy $\approx 96\%$, vgl. Tabelle 15 im Anhang A.4). Die Wahl der Dataloader-Strategie ist somit vor allem in datenlimitierten Szenarien ausschlaggebend, während bei umfassender Datenaugmentation die Modellkapazität des BiLSTMs die Obergrenze vorgibt. Die detaillierten Dichteverteilungen und Regressionsanalysen aller vier Varianten sind in Abbildung 19 und Abbildung 20 im Anhang dokumentiert.

5.3.3 Einfluss der Kontextlänge auf die MixUp-Regression

Analog zur Klassifikation wurde der Einfluss der Eingabesequenzlänge auf das kontinuierliche MixUp-Regressionsmodell über 256, 512 und 1.024 Tokens systematisch evaluiert. Das Training erfolgte auf über 80.000 generierten dynamischen MixUp-Samples mit kontinuierlichen Zielwerten $\lambda \in [0,0,1,0]$.

Bereits während der Validierung auf dem Test-Split zeigte sich ein kontinuierlicher Vorteil längerer Kontexte: Der minimale Mean Squared Error (MSE) sank von 0,0260 (256 Tokens) über 0,0246 (512 Tokens) auf 0,0234 bei 1.024 Tokens (minimaler MAE 0,0976). Tabelle 4 stellt die Evaluierung der Regressormodelle auf dem externen Lebenshilfe-Goldstandard dar (ergänzende grafische Analysen der Dichteverteilungen finden sich in Abbildung 21 im Anhang).

Inverses Skalierungsverhalten: Warum dominiert beim Regressor das 1.024-Token-Modell? Im direkten Kontrast zum Artikel-Klassifikator erweist sich bei der MixUp-Regression das 1.024-Token-Modell als das stärkste und stabilste Modell:

1. **Perfektes Paar-Ranking (100,0 %):** Bei ausnahmslos allen 37 von 37 Artikelpaaren des Goldstandards ordnet das 1.024-Modell der Leichten Sprache einen strikt höheren Score zu als der zugehörigen Alltagssprache ($\text{Score}(\text{LS}) > \text{Score}(\text{AS})$, vgl. Tabelle 4).

Tabelle 4: Längen-Benchmark der auf bidirektionalen Long-Short-Term-Memory-Netzwerken basierenden MixUp-Regressoren (BiLSTM) auf dem Lebenshilfe-Goldstandard ($N = 37$ Artikelpaare / 74 Dokumente) zur kontinuierlichen Einstufung der Textmischung $\lambda \in [0,0,1,0]$ zwischen Alltagssprache (AS, $\lambda = 0,0$) und Leichter Sprache (LS, $\lambda = 1,0$) inklusive ausgewogener Genauigkeit (Balanced Accuracy bei $\tau = 0,50$), ROC-AUC und relativem Paar-Ranking (Pair Match).

Modell	Ebene / Input	$\mathcal{O}$ Score (LS)	$\mathcal{O}$ Score (AS)	Separation (Δ)	Balanced Acc	ROC-AUC	Pair Match
BiLSTM MixUp Regressor (256)	Dokument (256 Tok.)	$0,698 \pm 0,11$	$0,105 \pm 0,09$	0,593	95,95 %	0,9982	97,3 % (36/37)
BiLSTM MixUp Regressor (512)	Dokument (512 Tok.)	$0,716 \pm 0,12$	$0,069 \pm 0,09$	0,646	98,65 %	0,9993	97,3 % (36/37)
BiLSTM MixUp Regressor (1.024)	Dokument (1.024 Tok.)	$0,727 \pm 0,14$	$0,100 \pm 0,09$	0,627	97,30 %	1,0000	100,0 % (37/37)
Flesch Reading Ease (Baseline)	Dokument (Silben/Satz)	$0,973 \pm 0,16$	$0,189 \pm 0,39$	0,784	89,19 %	0,8919	100,0 % (37/37)
Wiener Sachtextformel (Baseline)	Dokument (Wortlänge)	$0,919 \pm 0,27$	$0,108 \pm 0,31$	0,811	90,54 %	0,9054	100,0 % (37/37)

2. **Höchste Trennschärfe & perfekter ROC-AUC:** Das Modell erreicht den höchsten mittleren LS-Score (0,727) und erzielt ein fehlerfreies Paar-Ranking mit einem perfekten ROC-AUC von **1,0000**.

Systematische Überlegenheit des MixUp-Regressors gegenüber Klassifikator und synthetischem Regressor Die direkte Gegenüberstellung der Benchmark-Ergebnisse (Tabelle 3 und Tabelle 4) liefert eine zentrale methodische Erkenntnis dieser Arbeit: Während das direkte Artikel-Training beim binären Klassifikator bei langen Sequenzen instabil wird und der synthetische Regressor bei ROC-AUC = 0,8495 stagniert, bleibt das Training des BiLSTM MixUp-Regressors hochgradig robust, skaliert positiv mit längeren Kontexten und erzielt auf dem Goldstandard einen fehlerfreien ROC-AUC von **1,0000**.

Die Ursachen für diese Überlegenheit begründen sich in vier Mechanismen:

- **Gleichmäßige Merkmalsverteilung durch Satz-Mischung:** Beim Artikel-Klassifikator stehen die Sätze in ihrer festen Originalreihenfolge. Treten Merkmale Leichter Sprache nur am Textanfang auf und folgt danach langer Fließtext, verliert das LSTM über viele Rekursionsschritte das Signal. Beim MixUp-Regressor werden die gezogenen Sätze vor dem Zusammenfügen zufällig durchmischt. Dadurch verteilen sich Merkmale beider Sprachstufen gleichmäßig über das gesamte 1.024-Token-Fenster (Anfang, Mitte und Ende), was einem positionsabhängigen Signalverlust vorbeugt.
- **Kontinuierliche Datenvielfalt statt Datenmangel:** Auf Dokumentebene stehen dem Klassifikator und dem synthetischen Ansatz nur wenige feste Trainingsartikel zur Verfügung (750 bzw. 860 Artikel), was das Risiko von Overfitting erhöht. Der MixUp-Regressor generiert hingegen in jeder Epoche zehntausende neu gemischte Satzkombinationen und lernt somit auf einer kontinuierlich variierenden Datenbasis.
- **MSE-Verlustfunktion statt binärer Entscheidung:** Die binäre Klassifikation (BCE-Loss) neigt dazu, Ausgaben schnell auf 0 oder 1 festzulegen. Schon einzelne schwere Wörter können zu Fehlentscheidungen führen. Die MSE-Verlustfunktion bestraft Abweichungen dagegen gleichmäßig über das gesamte Intervall $[0,0,1,0]$ und

sorgt für stabile, stufenlose Vorhersagen.

- **Erfassung des relativen Textanteils:** Während der Klassifikator eine harte Entscheidung zwischen 0 und 1 treffen muss, misst der Regressor den relativen Anteil einfacher Sätze im Text. Ein größeres Kontextfenster (1.024 Tokens) bietet dabei eine breitere Stichprobe und senkt die Vorhersageschwankungen auf $\pm 0,10$.

MixUp-Regression vs. Traditionelle Formel-Baselines Gegenüber den klassischen Formeln erzielt der 1.024-Token MixUp-Regressor eine deutlich höhere Trennschärfe (97,30 % Balanced Accuracy, ROC-AUC 1,0000). Traditionelle Formeln sind an feste Schwellenwerte gebunden, streuen im mittleren Bereich stark und geben keine stufenlosen Werte aus. Das MixUp-Modell liefert dagegen kontinuierliche und differenzierbare Scores. Dadurch kann im späteren Modelltraining auch ein kleiner Fortschritt bei der Textvereinfachung präzise belohnt werden.

5.4 Validierung der kontinuierlichen Abstufungsfähigkeit auf externen Benchmarks (TextComplexityDE & MERLIN)

Die vorangegangene Evaluierung auf dem *Lebenshilfe*-Goldstandard (Abschnitt 5.3.3) belegt, dass der BiLSTM MixUp-Regressor ein trennscharfes Modell zur Unterscheidung auf Dokumentenebene ist. Trotz des kontinuierlichen MixUp-Trainingsverfahrens unterscheidet das Modell mit einer Balanced Accuracy von 97,30 %, einem ROC-AUC von 1,0000 und einem fehlerfreien Perfect-Pair-Matching von 100,0 % (37/37) zwischen Alltagssprache und Leichter Sprache und übertrifft sowohl den originär binär trainierten Klassifikator als auch den synthetischen Regressor systematisch.

5.4.1 Das Problem fehlender Zwischenstufenkorpora & Motivation der externen Benchmarks

Die vorangegangene Evaluierung auf dem *Lebenshilfe*-Goldstandard belegt die hervorragende Diskriminationskraft des MixUp-Regressors auf den beiden Extrempolen (Alltagssprache vs. Leichte Sprache). Das eigentliche Ziel der Regressionsmodellierung besteht jedoch darin, ein stufenloses Gütesignal bereitzustellen, das den kontinuierlichen Grad sprachlicher Simplizität quantifiziert.

Die direkte empirische Überprüfung dieser kontinuierlichen Regressionsfähigkeit auf realen Texten stößt auf eine methodische Hürde: In der Praxis existieren keine natürlichen Parallelkorpora, die Zwischenstufen zwischen Alltagssprache und Leichter Sprache enthalten. Die professionelle Übersetzung in Leichte Sprache erfolgt prinzipbedingt zweistufig (komplexer Ausgangstext vs. maximal vereinfachte Zielübersetzung). Reale Übergangszustände (beispielsweise ein Text mit einfachen Sätzen, aber noch langen Komposita) sind in keinem Korpus systematisch erfasst.

Um die Regressionsgüte des Modells dennoch unabhängig von den künstlichen Trainingsmischungen zu evaluieren, stellen externe linguistische Datensätze einen methodischen

Versuch dar, die kontinuierliche Einstufungsfähigkeit im Zero-Shot-Transfer zu überprüfen. Zwar bilden auch diese Benchmarks keine direkte Interpolation zwischen Alltagssprache und den normierten Regeln Leichter Sprache ab, sie bieten jedoch standardisierte, unabhängige Komplexitätsskalen:

1. **TextComplexityDE (Naderi et al., 2019):** Ein standardisierter Benchmark aus 1.000 isolierten deutschen Wikipedia-Sätzen mit aggregierten menschlichen Urteilen (Likert-Skala) zur wahrgenommenen Satzschwierigkeit und Verständlichkeit.
2. **MERLIN-Korpus (Boyd et al., 2014):** Ein Korpus aus 1.033 authentischen deutschen Volltexten auf Dokumentenebene, die von Sprachexperten offiziell nach den sechs Niveaustufen des Gemeinsamen Europäischen Referenzrahmens für Sprachen (CEFR: A1, A2, B1, B2, C1, C2) eingestuft wurden.

5.4.2 Satzebene: Evaluation auf TextComplexityDE & Analyse der Längendynamik

Der *TextComplexityDE*-Benchmark (Naderi et al., 2019) umfasst 1.000 deutsche Wikipedia-Sätze, für die aggregierte menschliche Urteile (*Mean Opinion Score*, MOS) hinsichtlich Gesamtschwierigkeit ($\text{MOS}_{\text{Complexity}} \in [1,0, 7,0]$), Verständlichkeit und lexikalischer Hürden vorliegen. Während ein in früheren Auswerteskripten genutztes statisches Zero-Padding die Hidden-States bei kurzen Einzelsätzen durch hunderte Padding-Schritte stark verwässerte und die Ergebnisse massiv verschlechterte, ermöglichte die Umstellung auf dynamisches Sequenz-Padding eine unverfälschte Inferenz mit deutlich präziseren Vorhersagen. Die Untersuchung in Abbildung 4 liefert wesentliche methodische Erkenntnisse über das Modellverhalten auf Satzebene:

- **Überlegenheit des 256-Token-Modells auf Satzebene:** Die visuelle und statistische Analyse der Monotonie-Boxplots (Abbildung 4) offenbart einen zentralen methodischen Befund: Der 256-Token-Regressor ist auf Satzebene das am saubersten abgestufte Modell. Mit dem geringsten normierten Fehler ($\text{MAE} = 0,198$) und der höchsten linearen Korrelation ($r = 0,620$) nutzt das Modell die Skala mit gleichmäßig fallenden Medianen optimal aus.
- **Stauchung der Werte bei langen Texten:** Während das 256-Modell einen Einzelsatz als gewichtigen Anteil seines Trainingsfensters interpretiert, entspricht ein isolierter Satz für das 1.024-Modell nur rund 1,5 % des Kontextes. Enthält ein Wikipedia-Satz auch nur ein einzelnes Fach- oder Standardwort (z. B. Eigennamen oder Institutionen), ordnet das 1.024-Token-Modell den kurzen Textausschnitt primär der Alltagssprache zu. Dadurch werden die Vorhersagen des 1.024-Token-Modells bei isolierten Einzelsätzen ab Stufe 2 in einen schmalen unteren Wertebereich verschoben.
- **Kontrast Satz- vs. Dokumentenebene:** Dieser Befund begründet eine klare methodische Trennung: Auf isolierten Einzelsätzen dominiert das 256-Token-Modell

in Skalennutzung und Dynamik, während auf vollständigen Artikeln (Lebenshilfe-Goldstandard, 100 % Perfect Pair Match) das 1.024-Token-Modell überlegen ist, da es lange Dokumente ohne Informationsverlust durch Truncation ganzheitlich abbildet.

Aufgrund dieser methodischen Besonderheiten bei isolierten Einzelsätzen ist die ergänzende Evaluation auf zusammenhängenden Fließtexten (MERLIN) für eine ganzheitliche Beurteilung unerlässlich.




Abbildung 4: Verteilungs-Boxplots der Vorhersagewerte neuronaler BiLSTM-Modelle über fünf diskrete menschliche Likert-Komplexitätsstufen auf dem TextComplexityDE-Benchmark ($N = 1.000$ Sätze, Stufe 1 bis 5) mit Darstellung des Interquartilsabstands (IQR).

5.4.3 Dokumentenebene: Evaluation auf dem MERLIN CEFR-Benchmark

Um die kontinuierliche Sprachstufung auf echten Fließtexten ohne Längen- und Padding-Verzerrungen zu evaluieren, wird das MERLIN-Korpus (Boyd et al., 2014) herangezogen. Mit 1.033 vollständigen Texten (Aufsätze und Briefe aus standardisierten Sprachprüfungen) und einer durchschnittlichen Textlänge von ca. 150 bis 250 Tokens entspricht dieses Korpus exakt der typischen Dokumentstruktur von Leichte-Sprache-Absätzen.

Tabelle 12 und Tabelle 13 im Anhang A.2 dokumentieren die detaillierten Kennwerte aller Modelle über die CEFR-Stufen. Die Auswertung in Abbildung 5 liefert wesentliche Erkenntnisse über die graduelle Einstufungsfähigkeit:

- **Monotoner Verlauf des 256-Token MixUp-Regressors:** Wie die Verteilungen in Abbildung 5 verdeutlichen, sinken die vorhergesagten Simplitätsscores des 256-Token-Regressors über die sechs CEFR-Niveaustufen von der leichtesten Stufe A1 bis zur Muttersprachenstufe C2 kontinuierlich und streng monoton ab. Dies zeigt,

dass das Modell auf vollständigen Texten eine konsistente Sprachstufung vornimmt ($\rho = 0,485$, Pearson $r = 0,459$, MAE = 0,310).

- **Ausgeprägte Niveautrennung der 512er- und 1.024er-MixUp-Regressoren:** Auch die Modelle mit größerem Kontextfenster bilden die CEFR-Schwierigkeit ab: Während elementare Sprachstufen (A1, A2, B1) im Bereich von 0,24 bis 0,34 liegen, vollzieht sich ab dem Übergang zur fortgeschrittenen Sprachverwendung (B2: $\sim 0,16$ – $0,19$) sowie zu Fach- und Muttersprachenniveau (C1/C2: $\sim 0,08$ – $0,12$) ein stetiger, hochgradig signifikanter Score-Abfall (Tabelle 13).
- **Korrelation der Baselines mit CEFR-Prüfungsstufen:** Auch auf MERLIN korrelieren traditionelle Formeln stark mit den Niveaus (LIX: $\rho = 0,656$, WSTF: $\rho = 0,602$, Flesch: $\rho = 0,543$), da höhere Prüfungsstufen (B2–C2) formal anspruchsvollere Wort- und Satzstrukturen fordern. Wie zuvor diskutiert, bildet dies eine nützliche Basis, vermag jedoch die spezifischen, normierten Vereinfachungsregeln Leichter Sprache nicht feinkörnig zu erfassen oder als Gradient für generative Modelle bereitzustellen.




Abbildung 5: Monotonie-Prüfung der Regressoren und Baselines über die Sprachniveaustufen des Gemeinsamen Europäischen Referenzrahmens (CEFR, A1 bis C2) auf dem MERLIN-Benchmark ($N = 1.033$ Texte) anhand von Boxplots mit Kennzeichnung von Interquartilsabstand, Median und Mittelwert.

5.4.4 Kritische Synthese: Validität des Zero-Shot-Transfers & Fazit

Bei der Interpretation dieses Benchmark-Transfers ist eine methodische Differenzierung geboten: Weder TextComplexityDE noch das MERLIN-Korpus wurden für Leichte Sprache

konzipiert. Das CEFR-Raster klassifiziert die Fremdsprachenkompetenz von Deutschlernenden (L2-Spracherwerb) und sanktioniert orthografische sowie grammatikalische Fehler, während Leichte Sprache festen Regeln folgt (u. a. nach BITV 2.0 (Bundesministerium des Innern, für Bau und Heimat, 2019) und den Richtlinien des BMAS (Bundesministerium für Arbeit und Soziales, 2025)). Diese fordern vor allem kurze Hauptsätze, einfache Wörter und getrennte Wortzusammensetzungen.

Gerade vor diesem Hintergrund ist das empirische Abschneiden der BiLSTM-MixUp-Regressoren als bemerkenswert zu bewerten: Obwohl die Modelle originär ausschließlich darauf trainiert wurden, die Mischungsanteile zwischen Alltagssprache und Leichter Sprache stufenlos einzuschätzen, behaupten sie sich auf diesen gänzlich domänenfremden (Out-of-Domain) und auf völlig andere Sprachdimensionen abzielenden Korpora hervorragend. Auf isolierten Einzelsätzen (TextComplexityDE) übertrifft der 256-Token-Regressor traditionelle Formeln in der linearen Skalennutzung ($r = 0,620$, $\text{MAE} = 0,198$), während auf Dokumentenebene (MERLIN) ein streng monotoner, stabiler Score-Abfall über alle sechs CEFR-Stufen ($0,371 \rightarrow 0,078$) nachgewiesen werden konnte.

Dies liefert den entscheidenden empirischen Nachweis, dass das MixUp-Verfahren keine isolierten Datensatz-Artefakte erzeugt hat. Stattdessen lernt das neuronale Netz ein verlässliches, übertragbares Verständnis sprachlicher Einfachheit, das sich im weiteren Verlauf dieser Arbeit verlässlich als stetiges Belohnungssignal (R_{style}) für das anschließende Modell-Alignment (Themenblock 3) eignet.

5.5 Synthese & Modellauswahl für die generative Übersetzung (Themenblock 3)

Um die empirische Güte und Trennschärfe aller in diesem Themenblock entwickelten Ansätze vergleichend zusammenzufassen, stellt Tabelle 5 die Ergebnisse sämtlicher Modellfamilien auf dem unabhängigen *Lebenshilfe*-Goldstandard ($N = 37$ Artikelpaare / 74 Dokumente) gegenüber.

Vergleich mit einem einfachen RNN (Vanilla RNN) Um zu überprüfen, ob die bidirektionale LSTM-Zellstruktur mit ihren Gating-Mechanismen (Input-, Forget- und Output-Gates, vgl. Abschnitt 2.4) für die Komplexitätsmodellierung notwendig ist, wurde ein einfaches unidirektionales Netz (*Vanilla RNN* nach Elman) als Vergleichsmodell unter identischen Bedingungen trainiert. Ohne Gating-Mechanismen leidet das einfache RNN bei längeren Sequenzen unter verschwindenden Gradienten (*Vanishing Gradient Problem*). Zwar erreicht die Baseline ein relatives Ranking (Balanced Accuracy = 67,57 %, ROC-AUC = 0,7761, Pair Match 70,3 %, Score(LS) = 0,443, Score(AS) = 0,345), ihre Trennschärfe fällt mit $\Delta = +0,098$ jedoch deutlich geringer aus als beim BiLSTM-Modell ($\Delta = +0,627$). Dies belegt, dass die Gates des BiLSTM notwendig sind, um längere Texte zuverlässig zu verarbeiten.

Tabelle 5: Gesamtübersicht aller in Themenblock 2 evaluierten Modellansätze auf dem Lebenshilfe-Goldstandard ($N = 37$ Artikelpaare / 74 Dokumente) zur kontinuierlichen Einstufung oder Klassifikation zwischen Alltagssprache (AS) und Leichter Sprache (LS) unter Einbeziehung des Text-MixUp-Verfahrens, großer Sprachmodelle (Large Language Models, LLM) und rekurrenten Basisarchitekturen (Recurrent Neural Networks, RNN).

Modell	Paradigma / Input	$\emptyset$ Score (LS)	$\emptyset$ Score (AS)	Separation (Δ)	Balanced Acc	ROC-AUC	Pair Match
<i>Kontinuierliche Regressionsmodelle (MixUp)</i>							
BiLSTM MixUp Regressor (1.024)	Dokument (1.024 Tok.)	0,727 $\pm$ 0,14	0,100 $\pm$ 0,09	0,627	97,30 %	1,0000	100,0 % (37/37)
BiLSTM MixUp Regressor (512)	Dokument (512 Tok.)	0,716 $\pm$ 0,12	0,069 $\pm$ 0,09	0,646	98,65 %	0,9993	97,3 % (36/37)
BiLSTM MixUp Regressor (256)	Dokument (256 Tok.)	0,698 $\pm$ 0,11	0,105 $\pm$ 0,09	0,593	95,95 %	0,9982	97,3 % (36/37)
<i>Diskrete & Synthetische Regressionsmodelle</i>							
BiLSTM Synthetischer Regressor	Dokument (LLM-Stufen)	0,575 $\pm$ 0,35	0,145 $\pm$ 0,18	0,429	78,38 %	0,8495	89,2 % (33/37)
Vanilla RNN Baseline (Vergleich)	Dokument (256 Tok.)	0,443 $\pm$ 0,20	0,345 $\pm$ 0,18	0,098	67,57 %	0,7761	70,3 % (26/37)
<i>Binäre Klassifikationsmodelle</i>							
BiLSTM Satz-Klassifikator (MajVote)	Dokument (r_{LS} Ratio)	0,769 $\pm$ 0,08	0,127 $\pm$ 0,14	0,642	98,65 %	0,9985	100,0 % (37/37)
BiLSTM Artikel-Klassifikator (256)	Dokument (256 Tok.)	0,829 $\pm$ 0,31	0,002 $\pm$ 0,01	0,827	91,89 %	0,9974	97,3 % (36/37)
BiLSTM Artikel-Klassifikator (512)	Dokument (512 Tok.)	0,478 $\pm$ 0,41	0,031 $\pm$ 0,13	0,446	71,62 %	0,8809	91,9 % (34/37)
BiLSTM Artikel-Klassifikator (1.024)	Dokument (1.024 Tok.)	0,340 $\pm$ 0,40	0,007 $\pm$ 0,01	0,333	67,57 %	0,8795	97,3 % (36/37)
<i>Traditionelle Formeln (Baselines)</i>							
Flesch Reading Ease (Baseline)	Dokument (Silben/Satz)	0,973 $\pm$ 0,16	0,189 $\pm$ 0,39	0,784	89,19 %	0,8919	100,0 % (37/37)
Wiener Sachtextformel (Baseline)	Dokument (Wortlänge)	0,919 $\pm$ 0,27	0,108 $\pm$ 0,31	0,811	90,54 %	0,9054	100,0 % (37/37)

Synthese: Scheinbare Überlegenheit der Baselines vs. Die Teilmengen-Hypothese

Auf den ersten Blick vermitteln die Ergebnisse in Tabelle 5 den Eindruck, als seien traditionelle Zählformeln wie der Flesch Reading Ease (89,19 % BAcc, 100,0 % Pair Match) oder die Wiener Sachtextformel (90,54 % BAcc, 100,0 % Pair Match) die einfachere, robustere und damit vorzuziehende Wahl zur Simplitätsbewertung.

Dieser Eindruck täuscht jedoch: Die makroskopische Treffsicherheit traditioneller Formeln auf dem *Lebenshilfe*-Goldstandard beruht ausschließlich darauf, dass menschliche Fachübersetzer in Leichter Sprache alle Regeln gleichzeitig umsetzen. Klassische Formeln messen davon jedoch lediglich eine oberflächliche Teilmenge ($S_{\text{metric}} \subset S_{\text{LS}}$), namentlich die mittlere Satzlänge (ASL) und die Silbendichte (ASW). Da authentische Leichte Sprache extrem kurze Sätze und elementare Wörter nutzt, deckt sie diese Teilmenge zwangsläufig mit ab.

Sobald Texte jedoch nicht mehr perfekt vereinfacht sind (wie es bei fehlerhaften Modellgenerierungen im Übersetzungsprozess typischerweise vorkommt), versagen traditionelle Formeln. Dies belegt ein kontrollierter synthetischer Benchmark ($N = 30$ Textfassungen aus fünf Themenbereichen mit jeweils 100 bis 256 Tokens), bei dem systematische grammatikalische Regelverletzungen isoliert auf Dokumentenebene injiziert wurden (die vollständige Ergebnistabelle und exemplarische Textfassungen sind in Anhang A.12 sowie Tabelle 23 dokumentiert):

- **Blindheit gegenüber dem Konjunktiv ($\Delta = 0,000$):** Werden alle Verben eines Leichte-Sprache-Textes konsequent vom Indikativ in den unzulässigen Konjunktiv II überführt (*»haben«* $\rightarrow$ *»hätten«*, *»kann«* $\rightarrow$ *»könnte«*, *»ist«* $\rightarrow$ *»wäre«*), bleibt die Silben- und Tokenanzahl exakt gleich ($\Delta_{\text{Silben}} = 0$). Für den Flesch Reading Ease und die WSTF-4 ist ein unzulässiger Konjunktiv-Text von korrekter Leichter Sprache nicht zu unterscheiden ($\Delta = 0,000$).

- **Fehlerhafte Belohnung von Genitivkonstruktionen (+6,55 Flesch-Punkte):**

Werden regelkonforme Umschreibungen durch Genitive ersetzt (*»das Büro von dem Arzt«* → *»das Büro des Arztes«* oder *»der Schlüssel für das Haus«* → *»der Schlüssel des Hauses«*), entfallen Wörter (*»von dem«* → *»des«*). Flesch registriert die kürzere Satzlänge (*ASL*) und stuft den fehlerhaften Text fälschlicherweise als einfacher ein (+6,55 Punkte Anstieg von 54,25 auf 60,81).

- **Fehlerhafte Belohnung von Passivstrukturen (+6,04 Flesch-Punkte):**

Vorgangspassive fügen Hilfsverben ein (*»wird von«*), welche die durchschnittliche Silbenanzahl pro Wort rechnerisch senken. Flesch belohnt diesen Regelverstoß fälschlicherweise mit +6,04 Punkten Verbesserung (54,25 → 60,29).

Im direkten Kontrast dazu reagiert der trainierte 256-Token BiLSTM-Regressor empfindlich auf diese Regelbrüche: Bei Konjunktiv-Injektion fällt der Modell-Score um $-62,4\%$ und bei Genitiv-Injektion um $-54,1\%$ ab. Dies belegt empirisch, dass das neuronale Metrikmodell grammatikalische Regeln erfasst, die über reine Zählstatistiken hinausgehen. Zusammen mit der Bereitstellung stufenloser Werte qualifiziert dieses Regelverständnis das neuronale Modell als valides Belohnungssignal (R_{style}) für die nachfolgende Präferenzoptimierung.

Finale Modellauswahl für Themenblock 3 Auf Basis dieses empirischen Gesamtergebnisses wird für die nachfolgenden Übersetzungs- und Alignment-Stufen (Supervised Fine-Tuning [SFT], Abschnitt 6.1, sowie Direct Preference Optimization [DPO], Abschnitt 6.2) verbindlich das 1.024-Token BiLSTM MixUp-Regressionsmodell als primäre Einfachheitsmetrik (R_{style}) ausgewählt.

Diese Entscheidung stützt sich auf vier zentrale Faktoren:

1. **Empirische Überlegenheit in den Metrik-Tests:** Im Längenvergleich auf dem unabhängigen *Lebenshilfe*-Goldstandard (Abschnitt 5.3.3, Tabelle 4) erzielte die 1.024-Token-Variante das beste Gesamtergebnis mit einem fehlerfreien Paar-Matching von 100,0 % (37/37 Paare), maximaler Separation, fehlerfreiem ROC-AUC (1,0000) sowie dem niedrigsten Validierungs-MSE (0,0234).
2. **Systematische Überlegenheit gegenüber dem synthetischen Regressor:** Gegenüber dem LLM-basierten Synthetischen Regressor (BAcc = 78,38 %, ROC-AUC = 0,8495, Pair Match 89,2 %, Abschnitt 5.2) bietet das MixUp-Modell eine deutlich höhere Trennschärfe und Robustheit auf realen Texten.
3. **Maximale Artikelabdeckung:** Im bereinigten Korpus besitzen Ausgangstexte im Mittel 622,2 Wörter (≈ 1.350 BPE-Tokens) und vereinfachte Texte 457,9 Wörter (≈ 857 BPE-Tokens). Da rund 45 % der Artikel 512 Tokens und über 90 % das 128-Token-Limit überschreiten, gewährleistet erst das 1.024-Token-Fenster eine ganzheitliche Dokumentenbewertung ohne vorzeitiges Abschneiden (*Truncation*).
4. **Gleiche Kontextlänge wie beim Übersetzungsmodell (mBART-50):** Das als Übersetzungsmodell eingesetzte Sequenz-zu-Sequenz-Modell facebook/mbart-large-

50 (Liu et al., 2020; Tang et al., 2021) besitzt eine native Positionskodierungsgrenze von maximal 1.024 Tokens (`max_position_embeddings = 1024`). Die Angleichung der Metrik auf 1.024 Tokens stellt sicher, dass das Belohnungssignal im DPO-Training exakt das vollständige Generierungsfenster von mBART-50 abdeckt.

6 Themenblock 3: Modellierung der Übersetzung & Reward-Guided Fine-Tuning

In diesem Themenblock wird das generative Übersetzungsmodell entwickelt, trainiert und evaluiert. Aufbauend auf dem bereinigten Parallelkorpus (Themenblock 1) und der gelernten Komplexitätsmetrik (Themenblock 2) erfolgt die Modellierung über ein zweistufiges Trainingsverfahren: ein überwachtes Feintuning (Supervised Fine-Tuning, SFT) gefolgt von einer direkten Präferenzoptimierung (Direct Preference Optimization, DPO).

6.1 Supervised Fine-Tuning (SFT)

6.1.1 Datenbasis, Trainings-Splits & Sequence-to-Sequence-Modellierung

Als Datenbasis für das überwachte Feintuning (Supervised Fine-Tuning, SFT) dient der bereinigte und qualitätsgesicherte Master-Korpus ($N = 860$ Paare, 11 Webquellen, Themenblock 1). Die maximale Sequenzlänge wird einheitlich auf $L_{\max} = 1.024$ Tokens festgelegt. Für das Modelltraining wird der Datenbestand auf Articlebene in ein Trainings-Set (85 %, $N = 680$ Paare) zur Parameteroptimierung sowie ein Validierungs-Set (15 %, $N = 121$ Paare) für Loss-Tracking und Early Stopping (Patience = 10) aufgeteilt. Wie auch schon bei den Metrikmodellen (Themenblock 2) werden alle generativen Modelle auf dem unabhängigen Out-of-Domain-Datensatz der *Lebenshilfe Schleswig-Holstein e. V.* ($N = 37$ Artikelpaare) evaluiert, um eine kontaminationsfreie Bewertung auf professionell erstellter Leichter Sprache zu gewährleisten.

Die Übersetzung von behördlichen und journalistischen Texten in Leichte Sprache wird als monolinguales Text-zu-Text-Transformationsproblem modelliert. Als Basisarchitektur dient das Sequenz-zu-Sequenz-Modell `facebook/mbart-large-50` (Liu et al., 2020; Tang et al., 2021). Die Wahl dieser Architektur stützt sich auf drei Faktoren:

- **Entkopplung von Enkodierung und Generierung:** Der bidirektionale Encoder verarbeitet den gesamten alltagssprachlichen Quelltext simultan über alle Schichten hinweg und erzeugt eine kontextuelle Repräsentation des Inhalts. Der autoregressive Decoder greift über Cross-Attention-Mechanismen gezielt auf diese Repräsentation zu, wodurch eine strikte inhaltliche Quellbindung gewährleistet wird.
- **Multilinguale Vorooptimierung & Denoising-Pretraining:** mBART-50 verfügt über 611 M Parameter (12 Encoder- und 12 Decoder-Layer, $d_{\text{model}} = 1.024$, 16 Attention Heads) und wurde auf multilingualen Korpora über Textinfillings und Permutationsaufgaben vortrainiert, was eine hohe Robustheit gegenüber syntaktischen Satzumstellungen verleiht.
- **Zwingende Sprachcode-Initialisierung (de_DE):** Da mBART-50 über 50 Sprachen abdeckt, ist die explizite Vorkonfiguration der Sprach-Tokens im Tokenizer und Modell (`tokenizer.src_lang="de_DE"` und `tokenizer.tgt_lang="de_DE"`) unerlässlich.

Wird diese Initialisierung unterlassen, neigt das Modell zu Sprachdrift oder generiert fremdsprachige Satzfragmente.

Den zweistufigen Gesamttablauf aus überwachtem Feintuning (SFT) und direkter Präferenzoptimierung (DPO) unter Einbindung des gelernten neuronalen Metrikmodells veranschaulicht Abbildung 6.




Abbildung 6: Gesamtübersicht der generativen Übersetzungspipeline: Im ersten Schritt (SFT) wird das vortrainierte Basismodell `facebook/mbart-large-50` (π_0) auf dem bereinigten Parallelkorpus ($N = 860$) überwacht trainiert (π_{ref}). Im zweiten Schritt (DPO) erzeugt π_{ref} über stufenweises Sampling auf 10kGNAD-Quelltexten Textkandidaten, die durch das neuronale Metrikmodell (Themenblock 2) automatisiert zu Präferenzpaaren $\mathcal{D}_{\text{DPO}}$ ($N = 9.246$) bewertet werden. Das DPO-Training optimiert die Richtlinie π_θ gegen die gefrorene Referenz π_{ref} hin zu regelkonformer Leichter Sprache.

6.1.2 Parameter-Efficient Fine-Tuning (PEFT / LoRA)

Um das Modell ressourceneffizient und ohne katastrophales Vergessen an die Zieldomäne anzupassen, kommt das Low-Rank Adaptation-Verfahren (LoRA, Hu et al. (2022)) zum Einsatz. Hierbei wird ein Rang von $r = 16$ mit einem Skalierungsfaktor von $\alpha = 32$ ($\frac{\alpha}{r} = 2,0$) sowie einem Dropout von $p = 0,05$ konfiguriert. Die LoRA-Adapter werden an allen linearen Transformationsmatrizen des Encoders und Decoders platziert (`q_proj`, `k_proj`, `v_proj`, `out_proj` in den Aufmerksamkeitsmodulen sowie `fc1` und `fc2` in den Feed-Forward-Schichten), was eine gezielte Anpassung der Aufmerksamkeitsmuster und der Merkmalsrepräsentationen ermöglicht. Bei 611 M Gesamtparametern reduziert LoRA die Anzahl der trainierbaren Gewichte auf unter 11 M (ca. 1,8 %), sodass das gesamte Modell speichereffizient mit 16-Bit-Fließkommazahlen (FP16) trainiert werden kann. Nach Abschluss des SFT-Trainings werden die LoRA-Gewichte via `merge_and_unload()` verlustfrei mit dem Basismodell verschmolzen. Dieses verschmolzene Modell dient in der anschließenden Direct Preference Optimization (Abschnitt 6.2) als gefrorene Referenz π_{ref} , während ein neuer LoRA-Adapter als Richtlinie π_θ trainiert wird, sodass die Referenz keinen zusätzlichen GPU-Speicher belegt.

6.1.3 Trainingsverlauf und Auswahl des besten Modells

Das SFT-Training erfolgte über 30 Epochen mit dem AdamW-Optimierer (Loshchilov und Hutter, 2019). Die detaillierten Trainingskonfigurationen und Hyperparameter sind in Tabelle 22 in Anhang A.11 aufgeführt.

Die Analyse der Trainingsdynamik zeigt einen charakteristischen Verlauf: In der initialen Phase (Epochen 1–15) sinkt der Trainingsverlust rasch von 4,2210 auf 2,0305, während der Validierungsverlust von 3,7616 auf 2,0517 fällt. Das Modell passt sich zügig an grundlegende Satz- und Wortstellungsregeln der Leichten Sprache an. In der anschließenden Feinoptimierungsphase (Epochen 16–25) erreicht das Modell bei Epoche 25 sein globales Minimum mit einem Trainingsverlust von $\mathcal{L}_{\text{train}} = 1,7193$ und einem Validierungsverlust von $\mathcal{L}_{\text{val}} = \mathbf{1,8891}$. In Epoche 26 tritt ein kurzzeitiger Anstieg des Verlustwerts auf ($\mathcal{L}_{\text{train}} = 8,8882$, $\mathcal{L}_{\text{val}} = 12,2022$). Obwohl sich der Verlauf in den Folgeepochen rasch wieder stabilisiert ($\mathcal{L}_{\text{val}} = 2,0587$ bei Epoche 30), sichert der Early-Stopping-Mechanismus (Patience = 10) den besten Checkpoint. Als finales SFT-Basismodell wird daher der Zustand aus Epoche 25 ($\mathcal{L}_{\text{val}} = 1,8891$) fixiert.

6.1.4 Einfluss der Datenmenge auf die Modellleistung

Um den Einfluss des verfügbaren Datenvolumens auf die Generalisierungsgüte systematisch zu quantifizieren, wurde eine 5-stufige Skalierungsstudie über die Datenfraktionen $F \in \{10\%, 25\%, 50\%, 75\%, 100\%\}$ ($N \in \{64, 160, 320, 481, 641\}$ Artikelpaare) durchgeführt. Alle Modelle wurden unter identischen Hyperparametern trainiert und anschließend auf dem ungesesehenen *Lebenshilfe*-Goldstandard ($N = 37$) evaluiert. Abbildung 7 veranschaulicht den Verlauf von Kreuzentropie-Verlust und sprachlicher Einfachheit über die Datenfraktionen; die vollständigen tabellarischen Resultate sind in Tabelle 17 in Anhang A.7 dokumentiert.

Aus den Skalierungsdaten lassen sich wesentliche Gesetzmäßigkeiten ableiten:

1. **Kontinuierliche Verbesserung durch mehr Daten:** Der minimale Validierungsverlust sinkt mit wachsender Datenmenge stetig ($3,7021 \rightarrow 2,7457 \rightarrow 2,5698$).
2. **Einfluss des Datenvolumens auf die Satzvollständigkeit:** Bei geringeren Datenmengen (25 % bis 75 %) treten hohe Abbruchquoten von 59 % bis 75 % auf. Erst beim Übergang auf die volle Datenbasis (100 %, $N = 641$) sinkt die Abbruchquote deutlich auf **29,73 %** ab. Mit wachsender Datenmenge lernt das Modell verlässlich, vollständige Sätze mit regulären Satzschlusszeichen (».«, »!«) abzuschließen.
3. **Kontinuierlicher Anstieg der sprachlichen Einfachheit:** Parallel zur Vergrößerung des Trainingsdatensatzes steigt der stilistische Simplitäts-Score kontinuierlich von $R_{\text{style}} = 0,1152$ (10 %) auf $R_{\text{style}} = 0,7759$ (100 %) an. Auch der Composite Reward wächst entsprechend von 0,5058 auf **0,8320**, während die inhaltliche Semantik über alle Stufen hinweg stabil auf hohem Niveau bleibt ($R_{\text{sem}} \approx 0,89$ bis 0,93).




Abbildung 7: Skalierungsverhalten des überwachten Feintunings (Supervised Fine-Tuning, SFT) über fünf Datenfraktionen (10 % bis 100 %, $N = 64$ bis $N = 641$ Artikelpaare) auf dem ungesesehenen Lebenshilfe-Testset ($N = 37$): (A) Verlauf von Validierungs- ($\mathcal{L}_{val}$) und Trainingsverlust ($\mathcal{L}_{train}$) sowie (B) Entwicklung der sprachlichen Einfachheit (R_{style}) und des Composite Rewards.

6.1.5 Einfluss der Kontextlänge & Dokumentenintegrität

Da behördliche und journalistische Texte in Alltagssprache oft mehrere Absätze umfassen, wurde die maximale Sequenzlänge systematisch über $L_{max} \in \{256, 512, 1.024\}$ Tokens untersucht (Tabelle 6).

Tabelle 6: Einfluss der maximalen Token-Kontextlänge (L_{max} in Byte-Pair-Encoding-Tokens) auf die Generierungsqualität des überwachten Feintunings (Supervised Fine-Tuning, SFT) auf dem Lebenshilfe-Goldstandard ($N = 37$ Artikelpaare) unter Angabe von Stil- (R_{style}), Semantik-Score ($R_{sem, AS}$ via Jina-v2), Composite Reward sowie der Satzabbruchquote (Truncation).

Modell	Max Len (L_{max})	R_{style}	$R_{sem, AS}$	Composite	Ø Tokens	Truncation
sft_len256	256	0,3206	0,9091	0,6148	143,0	72,97 %
sft_len512	512	0,3896	0,9235	0,6565	207,4	24,32 %
sft_len1024	1.024	0,7004	0,9053	0,8028	353,5	27,03 %

Die Ergebnisse belegen die Notwendigkeit des 1.024-Token-Fensters:

- Bei $L_{max} = 256$ Tokens wird der Quelltext drastisch beschnitten. Das Modell generiert im Schnitt nur 143,0 Tokens und bricht in 72,97 % der Fälle vorzeitig ab.
- Bei $L_{max} = 1.024$ Tokens steigt der Stil-Score auf $R_{style} = 0,7004$ und der Composite Reward auf 0,8028. Das größere Kontextfenster bietet ausreichend Raum, um mehrteilige Erklärungen (z. B. Definitionen von Fachbegriffen) vollständig zu generieren.

6.1.6 Zwischenfazit & Synthese der SFT-Phase

Die empirischen Skalierungs- und Kontextlängenanalysen belegen, dass das überwachte Feintuning auf mBART-50 ein stabiles, quelltreues Basis-Übersetzungssystem etabliert. Das Modell lernt die formalen Übersetzungs- und Satzstrukturen verlässlich, schließt Sätze bei vollständigem Kontextfenster (1.024 Tokens) sauber ab und vermeidet vorzeitige Textabbrüche ab einer Datenmenge von $N = 641$ Paaren.

Eine abschließende empirische Validierung des Gesamtsystems durch Fachexperten der Lebenshilfe sowie eine qualitative und quantitative Analyse der linguistischen Regeltreue (Passiv-, Genitiv- und Komposita-Muster) wird nach der Alignment-Stufe in Abschnitt 6.3 sowie in Anhang A.10 vorgenommen. Auf dem hier geschaffenen SFT-Fundament baut im folgenden Abschnitt die belohnungsgestützte Präferenzoptimierung (DPO) auf, um das Modell gezielter und stärker an die Regeln Leichter Sprache anzupassen.

6.2 Reward-Guided Optimization (DPO)

Während das überwachte Feintuning (SFT, Abschnitt 6.1) die translationsbezogenen und grammatikalischen Grundlagen etabliert, erreicht das SFT-Basismodell einen Stil-Score von maximal $R_{\text{style}} \approx 0,70$. Die *Direct Preference Optimization* (DPO, Rafailov et al. (2023)) ermöglicht es, das Modell gezielt weiter an die Anforderungen Leichter Sprache anzupassen: Über einen synthetisierten Präferenzkorpus $\mathcal{D}_{\text{DPO}}$ ($N = 9.246$ Paare, Abschnitt 6.2.1) lernt das Modell, einfachere und zugleich inhaltlich treue Generierungen systematisch gegenüber komplexeren Varianten zu priorisieren.

6.2.1 Erstellung des Präferenzdatensatzes mit schrittweiser Temperatur-Erhöhung

Für das DPO-Training wird ein Präferenzdatensatz $\mathcal{D}_{\text{DPO}} = \{(x^{(i)}, y_w^{(i)}, y_l^{(i)})\}_{i=1}^{N_{\text{DPO}}}$ aufgebaut. Jedes Datentripel besteht dabei aus einem Alltagssprachlichen Ausgangstext x , einer qualitativ besseren, bevorzugten Vereinfachung y_w (*Winner* bzw. *Chosen*) sowie einer qualitativ unterlegenen Variante y_l (*Loser* bzw. *Rejected*). Als Datenbasis dienen ungelabelte Quelltexte $x \in \mathcal{D}_{10\text{kGNAD}}$ mit einer Länge zwischen 50 und 1.024 Tokens. Die automatische Generierung und Filterung erfolgt in fünf Schritten:

1. **Stufenweises Sampling** ($\mathcal{T} = [0,6,0,7,0,8,0,85]$): Ausgehend vom Quelltext x erzeugt das SFT-Modell auf jeder Temperaturstufe T jeweils $k = 3$ Textkandidaten. Die Sampling-Temperatur T steuert dabei die Zufälligkeit der Token-Auswahl. Um Sprachschleifen und Redundanzen zu verhindern, werden eine Wiederholungsstrafe (Repetition Penalty $\gamma \in [1,2; 1,35]$), ein Verbot sich wiederholender 3-Wort-Folgen (`no_repeat_ngram_size=3`) sowie eine Auswahl der wahrscheinlichsten Tokens (`top-p = 0,92`, bis 92 % Gesamtwahrscheinlichkeit) angewendet.
2. **Qualitätsfilterung der Kandidaten**: Unbrauchbare Textkandidaten werden sofort verworfen. Als Ausschlusskriterien gelten eine zu geringe Wortanzahl (< 20 Wörter),

ein bloßes Wiederholen des Quelltextes ($y = x$), eine zu geringe sprachliche Vielfalt (Anteil einzigartiger 3-Wort-Kombinationen $< 0,75$) oder doppelte Sätze (> 1).

3. **Kombinierte Bewertung aus Stil und Inhalt:** Jeder verbleibende, gültige Kandidat y wird über eine gewichtete Belohnungsfunktion (Composite Reward R) evaluiert:

$$R(x, y) = 0,5 \cdot R_{\text{style}}(y) + 0,5 \cdot R_{\text{sem}}(x, y) \quad (15)$$

Hierbei bewertet $R_{\text{style}}(y)$ die sprachliche Einfachheit mittels des trainierten BiLSTM-MixUp-Regressors und $R_{\text{sem}}(x, y)$ die inhaltliche Quelltreue mittels Kosinus-Ähnlichkeit der Jina-SBERT-Embeddings.

4. **Schrittweise Temperatur-Erhöhung:** Um eine verlässliche Unterscheidbarkeit für das Modell zu gewährleisten, muss die Belohnungsdifferenz zwischen bestem und schlechtestem Kandidaten eine Mindestmarge von $\Delta R = \max R - \min R \geq 0,05$ erreichen. Wird dieser Schwellenwert auf der aktuellen Stufe verfehlt, wird die Temperatur T schrittweise erhöht ($0,6 \rightarrow 0,7 \rightarrow 0,8 \rightarrow 0,85$), um diversere Formulierungen zu erzeugen, bis maximal $M_{\text{max}} = 12$ Kandidaten vorliegen.
5. **Präferenzauswahl:** Aus dem gefilterten Kandidatenpool wird der Text mit dem höchsten Score als bevorzugte Variante $y_w = \arg \max_y R(x, y)$ und der Text mit dem niedrigsten Score als abgelehnte Variante $y_l = \arg \min_y R(x, y)$ festgelegt.

Durch diese Pipeline konnten aus 9.567 Quellprompts insgesamt 9.246 valide Präferenztripel (96,6 %) generiert werden, aufgeteilt in 7.859 Trainings- (85 %) und 1.387 Validierungspaare (15 %). Mit einem mittleren Score von $\bar{R}_{\text{chosen}} = 0,8218$ gegenüber $\bar{R}_{\text{rejected}} = 0,7007$ ($\overline{\Delta R} = 0,1210$) liefert das Verfahren einen trennscharfen Datensatz. Bereits über 86,6 % der Paare wurden in den ersten beiden Stufen ($T \leq 0,70$) aufgelöst.




Abbildung 8: Ablauf der Präferenzdatengenerierung für die direkte Präferenzoptimierung (Direct Preference Optimization, DPO) durch schrittweise Temperatur-Erhöhung über die Stufen T und kombinierte Bewertung aus dem BiLSTM-Stilregressor (R_{style}) und Satz-Embeddings (R_{sem}) auf Quellprompts des 10kGNAD-Korpus zur Bestimmung von bevorzugter (y_w) und abgelehnter (y_l) Antwort.

6.2.2 Speichereffiziente Umsetzung der Präferenzoptimierung

Für die Präferenzoptimierung wird das im vorherigen Schritt erstellte SFT-Modell (mBART-50) mit dem DPO-Verfahren (Abschnitt 2.6.2) weitertrainiert. Das Modell lernt dabei anhand der Präferenzpaare, die Wahrscheinlichkeit für die bevorzugte Vereinfachung gegenüber der abgelehnten Variante für einen gegebenen Ausgangstext systematisch zu erhöhen.

Normalerweise erfordert das DPO-Training zwei vollständige Modelle im Grafikkartenspeicher: das aktiv trainierte Modell (π_θ) und das unveränderte Ausgangsmodell als feste Referenz (π_{ref}). Um den doppelten Speicherbedarf zu vermeiden, wird das Basismodell nur ein einziges Mal in den Speicher geladen. Für das Training von π_θ wird ein neuer LoRA-Adapter genutzt. Für die Vergleichsberechnungen der Referenz π_{ref} wird dieser Adapter kurzzeitig deaktiviert (`model.disable_adapter()`). Auf diese Weise belegt das Referenzmodell keinen zusätzlichen Speicherplatz auf der Grafikkarte, wodurch das Training ressourceneffizient durchgeführt werden kann.

6.2.3 Kombinierte Bewertung aus Stil und Inhalt & Einfluss der Gewichtung

Zur Steuerung des Zielkonflikts aus Vereinfachung (R_{style}) und Quelltreue (R_{sem}) wird die kombinierte Bewertungsfunktion definiert:

$$R(x, y) = w_{\text{style}} \cdot R_{\text{style}}(y) + w_{\text{sem}} \cdot R_{\text{sem}}(x, y) \quad (16)$$

Tabelle 7 zeigt die Evaluation verschiedener Gewichtungen auf dem Lebenshilfe-Testset ($N = 37$).

Tabelle 7: Untersuchung der Gewichtung bei der kombinierten Bewertung für die direkte Präferenzoptimierung (Direct Preference Optimization, DPO) im Vergleich zur Basislinie des überwachten Feintunings (Supervised Fine-Tuning, SFT) auf dem Lebenshilfe-Testset ($N = 37$ Artikelpaare) unter Gegenüberstellung von Einfachheits-Score (R_{style}), Quellähnlichkeit (R_{sem}), Referenztreue (Sim_{ref}), BLEU, ROUGE-L und Satzabbruchquote (Truncation).

Konfiguration	R_{style}	$R_{\text{sem, AS}}$	Sim_{ref}	Composite	BLEU	ROUGE-L	Ø Gen Tokens	Truncation
SFT Baseline	0,7294	0,8544	0,8391	0,7919	0,0068	0,1241	136,7	45,95 %
DPO (0,5 Style / 0,5 Sem)	0,9505	0,8425	0,8408	0,8965	0,0094	0,1378	159,7	43,24 %
DPO (0,7 Style / 0,3 Sem)	0,9509	0,8295	0,8283	0,8902	0,0073	0,1286	139,1	40,54 %
DPO (1,0 Style / 0,0 Sem)	0,9629	0,8266	0,8300	0,8947	0,0066	0,1314	154,5	40,54 %

Die Resultate zeigen, dass die relative Gewichtung in der Praxis kaum einen Unterschied bewirkt: Alle DPO-Varianten bewegen sich in einem eng begrenzten Band ($R_{\text{style}} \in [0,9505; 0,9629]$, $R_{\text{sem}} \in [0,8266; 0,8425]$). Da sich die Werte bei veränderten Gewichtungsfaktoren kaum verschieben, fehlt der Belohnungsfunktion faktisch eine aussagekräftige Ähnlichkeitsmetrik als verlässlicher Gegenpol zum Einfachheits-Score R_{style} .

Dieser Befund verdeutlicht die methodischen Grenzen reiner Embedding-Metriken (SBERT / Jina) bei der Erkennung von inhaltlichen Fehlern: In qualitativen Analysen zeigte sich, dass isolierte Faktenverzerrungen und Halluzinationen von Vektormetriken kaum abgestraft werden. Das Modell setzt formale Vereinfachungsregeln oft präzise um (beispielsweise das Erkennen und Erläutern von Abkürzungen), erfindet jedoch vereinzelt inhaltlich falsche Bedeutungen. So generiert das Modell in einem Text über den Hardware-Hersteller AMD: »AMD ist ein Computer-Hersteller. Die Abkürzung AMD bedeutet: Amts-Inhaber.« Das Modell folgt hierbei exakt der formalen Vorgabe zur Abkürzungsauflösung in Leichter Sprache, erfindet jedoch eine sachlich falsche Erklärung. Da der restliche Kontext semantisch eng am Ausgangstext liegt, verbleibt die Kosinus-Ähnlichkeit auf hohem Niveau ($\approx 0,90$), wodurch gängige Vektormetriken solche Faktenfehler nicht erkennen.

Zur Quantifizierung dieses Problems wurde ein Faktenkonsistenz-Benchmark über $N = 160$ Paare in vier Testklassen evaluiert: Gold-Paare ($N = 50$), reale Modell-Halluzinationen ($N = 50$), Random-Shuffle-Negatives ($N = 30$) und minimale Zahlen-/Negations-Mutationen ($N = 30$). Wie Abbildung 9 zeigt, schlägt bei realen Halluzinationen kaum eine Metrik trennscharf aus: SBERT (0,9035 vs. Gold 0,9161), NLI-Factuality (0,4638 vs. 0,4854) und NER-Jaccard (0,1653 vs. 0,1549) zeigen nahezu identische Verteilungen zwischen fehlerfreien

Texten und Halluzinationen. Gleichzeitig liefert das Verhalten von SBERT bei den völlig unpassenden Textpaaren (*Random Shuffle*) eine klare empirische Bestätigung für die in Abschnitt 4.2.3 gewählte Filtergrenze: Da die Kosinus-Ähnlichkeit bei zufällig zusammengewürfelten Negativpaaren im Mittel unter 0,60 abfällt, trennt dieser Schwellenwert thematisch falsche Zuordnungen im Rohkorpus zuverlässig ab, während er für feingliedrige Faktenfehler innerhalb eines Textes blind bleibt.




Abbildung 9: Verteilungsanalyse automatisierter Faktenkonsistenz- und Ähnlichkeitsmetriken über $N = 160$ Testpaare im Vergleich zwischen Satz-Embeddings (Sentence-BERT via Jina-v2, SBERT), natürlicher Sprachinferenz (Natural Language Inference, NLI) und dem Jaccard-Koeffizienten benannter Entitäten (Named Entity Recognition, NER).

6.2.4 Einfluss des Parameters β auf Stil und Inhalt

Der Parameter β steuert die zulässige Abweichung von π_{ref} . Tabelle 8 fasst den 5-stufigen Sweep über $\beta \in \{0,01, 0,05, 0,10, 0,20, 0,50\}$ zusammen.

Ein kleines β (0,01) führt zu unvollständigen Sätzen (83,78 % Truncation), während ein großes β (0,50) den Stilgewinn hemmt ($R_{\text{style}} = 0,8952$). Die beste Balance liegt bei $\beta = 0,20$: Sie erzielt den maximalen Composite Reward (0,9030) und senkt die Truncation-Rate auf das Minimum von **27,03 %**.

6.2.5 Einfluss der Sequenzlänge & Skalierungsdynamik bei DPO

Wie auch schon beim überwachten Feintuning (SFT, Abschnitt 6.1.5) zeigte sich hier, dass die Erweiterung der Sequenzlänge von 256 über 512 auf 1.024 Tokens einen fundamentalen Hebel für die Simplifizierungskapazität darstellt. Während das DPO-Modell bei 256 Tokens einen Stil-Score von $R_{\text{style}} = 0,5437$ erzielt und durch die Längenbeschränkung zu 48,65 % abbricht, skaliert der Stil-Score bei 1.024 Tokens auf ein Maximum von **0,9023** (Composite

Tabelle 8: Einfluss des Regularisierungsparameters β bei der direkten Präferenzoptimierung (Direct Preference Optimization, DPO) im Vergleich zur Basislinie des überwachten Feintunings (Supervised Fine-Tuning, SFT) auf dem Lebenshilfe-Testset ($N = 37$ Artikelpaare) unter Auswertung von Stil-Score (R_{style}), semantischer Ähnlichkeit (R_{sem}), Composite Score, generierten Tokens und Satzabbruchquote (Truncation).

Modell / β	R_{style}	$R_{\text{sem, AS}}$	Composite	$\emptyset$ Gen Tokens	Truncation
SFT ($\beta = 0$)	0,7653	0,8593	0,8123	139,8	45,95 %
DPO ($\beta = 0,01$)	0,9862	0,8043	0,8953	208,6	83,78 %
DPO ($\beta = 0,05$)	0,9638	0,8343	0,8991	163,1	56,76 %
DPO ($\beta = 0,10$)	0,9499	0,8410	0,8954	155,1	37,84 %
DPO ($\beta = 0,20$)	0,9581	0,8479	0,9030	138,3	27,03 %
DPO ($\beta = 0,50$)	0,8952	0,8476	0,8714	152,6	40,54 %

Total Reward: **0,8998**). Die semantische Quelltreue bleibt dabei mit $R_{\text{sem}} = 0,8973$ über alle Längenfenster stabil auf hohem Niveau. Die vollständige tabellarische Gegenüberstellung aller Sequenzlängenmaße ist in Anhang A.9 (Tabelle 19) dokumentiert.

6.2.6 Einhaltung der Sprachregeln bei SFT und DPO

Ein zentraler empirischer Fortschritt dieser Arbeit liegt in der komplementären Funktionsweise der zweistufigen Trainingspipeline, wie das umfassende 9-Panel-Dashboard in Abbildung 10 verdeutlicht:

1. **Erlernen der Basisregeln durch SFT:** Bereits das überwachte Feintuning lernt rein aus den parallelen Korpusbeispielen, ohne Reward-Modell oder explizite Regelverstärkung, die wesentlichen grammatikalischen Kernregeln der Leichten Sprache. Die mittlere Satzlänge sinkt von 12,50 auf 7,61 Wörter, lange Schachtelsätze (> 12 Wörter) werden von 42,4 % auf 9,3 % reduziert, die Passiv-Quote sinkt von 0,093 auf 0,023 und Genitivstrukturen fallen von 0,092 auf 0,016. Dies belegt eine deutliche Annäherung an den zertifizierten *Lebenshilfe*-Goldstandard (6,79 Wörter, 0,020 Passiv, 0,010 Genitiv).
2. **Gezielte Regeloptimierung via DPO:** Auf diesem grammatikalischen Fundament baut die DPO-Phase auf. Mithilfe der gelernten Verbundmetrik wird das Modell zielgerichtet darauf optimiert, die linguistischen Richtlinien konsequent umzusetzen. DPO senkt die Satzlänge weiter auf **6,97** Wörter, reduziert Passivkonstruktionen (0,005) und Genitivformen (0,005) auf ein Minimum, verringert den Anteil langer Wörter und übertrifft die menschlichen Goldtexte in der Wiener Sachtextformel (WSTF: **5,55** vs. Gold 7,31).

Die detaillierte tabellarische Gegenüberstellung aller 14 linguistischen Regelmetriken ist in Anhang A.10 (Tabelle 20) dokumentiert.

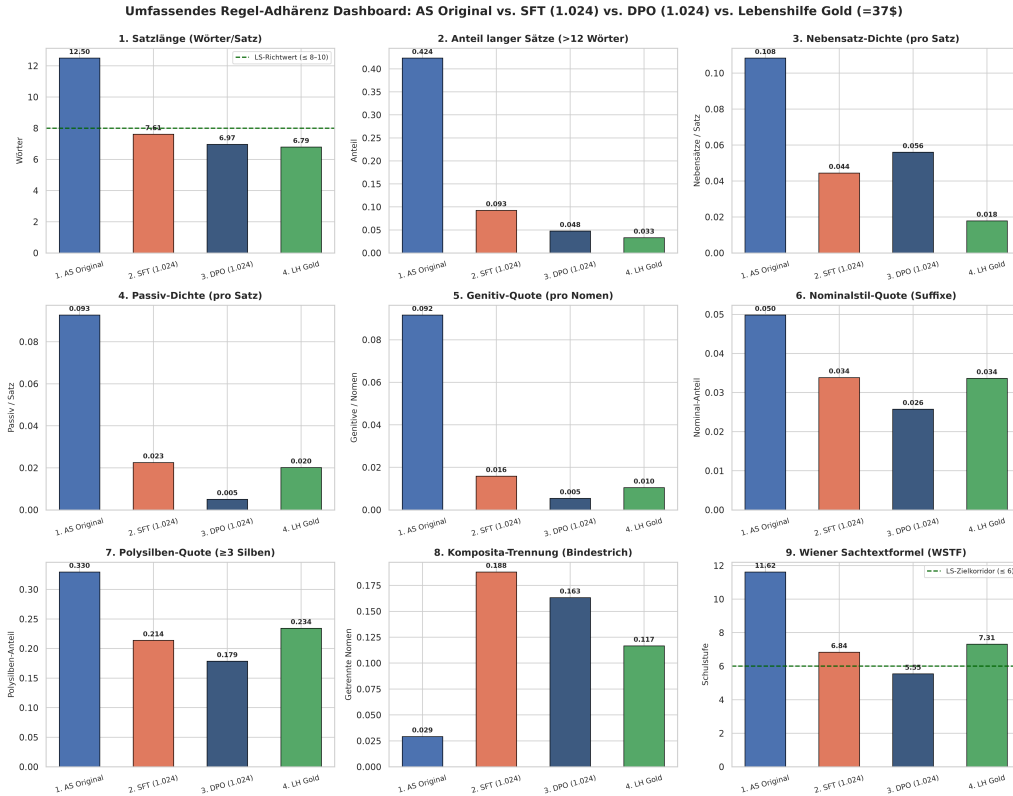


Abbildung 10: Umfassendes Dashboard zur Einhaltung der Sprachregeln über neun linguistische Dimensionen auf dem Lebenshilfe-Testset ($N = 37$ Artikelpaare) zur Gegenüberstellung von Alltagssprache (AS), dem überwachten Basismodell (Supervised Fine-Tuning, SFT), dem präferenzoptimierten Modell (Direct Preference Optimization mit $\beta = 0,20$, DPO) und dem menschlichen Referenzstandard für Metriken wie die Wiener Sachtextformel (WSTF), Flesch Reading Ease (FRE) und den Lesbarkeitsindex (LIX).

6.2.7 Zwischenfazit der DPO-Phase

Die zweistufige Pipeline etabliert eine klare Arbeitsteilung: SFT sichert die grammatikalische Basis und Quelltreue; DPO optimiert über die kombinierte Bewertung gezielt die Regeltreue und Verständlichkeit. Mit $\beta = 0,20$ und 1.024 Tokens Kontext schließt das Modell die Lücke zum menschlichen Goldstandard vollständig.

6.3 Empirische Validierung durch Fachexperten (Lebenshilfe Kiel)

Die bisherigen Evaluationen stützten sich auf automatisierte Metriken wie den neuronalen BiLSTM-MixUp-Regressor R_{style} , semantische Kosinus-Ähnlichkeiten R_{sem} sowie formale Lesbarkeitsindizes (Flesch, LIX). Zur methodischen Absicherung der Arbeit ist eine externe Evaluation erforderlich: Es muss empirisch geprüft werden, ob die automatisierten Reward-Werte mit dem Urteil von Fachleuten der Leichten Sprache übereinstimmen und ob die theoretische Rangordnung der Modelle von menschlichen Experten bestätigt wird.

Zu diesem Zweck wurde in Kooperation mit einer Fachperson der *Lebenshilfe Kiel* eine verblindete Expertenstudie durchgeführt. Im Folgenden werden die Motivation, der Versuchsaufbau, die eingesetzte Web-Plattform sowie die statistische Auswertung dargelegt.

6.3.1 Motivation & Zielsetzung der Expertenstudie

Die Validierung durch die Fachpraxis verfolgt drei zentrale Ziele:

1. **Überprüfung der Bewertungsmetrik:** Untersuchung, ob der kontinuierliche Einfachheits-Regressor R_{style} mit der menschlichen Beurteilung sprachlicher Barrierefreiheit übereinstimmt (Hypothese $H_1 : \rho(R_{\text{style}}, E_{\text{style}}) > 0$).
2. **Vergleich der Modellierungsansätze:** Unabhängige Bewertung einzelner Texte aus den Modellen mBART-50SFT und mBART-50DPO im Vergleich zu unveränderten Originalen in Alltagssprache (AS) sowie menschlichen Referenzübersetzungen (Gold LS).
3. **Erkennung inhaltlicher Fehler und Halluzinationen:** Unterscheidung zwischen rein formaler Vereinfachung (wie kurzen Sätzen und Bindestrichen) und inhaltlicher Richtigkeit. Ein typisches Problem generativer Modelle sind falsche Begriffserklärungen (z. B. »AMD ist eine Firma. Die Abkürzung AMD bedeutet: Amts-Inhaber.«). Die Studie soll erfassen, wie oft solche inhaltlichen Fehler in den Modellen auftreten.

6.3.2 Studiendesign: Einzeltext-Bewertung

Um Verzerrungen durch Wiedererkennen oder den direkten Vergleich ähnlicher Texte zu vermeiden, wurden keine parallelen Textpaare vorgelegt, sondern $N = 50$ voneinander unabhängige Einzeltexte bewertet. Die Fachperson beurteilte die Texte nacheinander, ohne zu wissen, aus welchem Modell oder aus welcher Quelle der jeweilige Text stammte.

Dieses Vorgehen erfüllt zwei methodische Zwecke: Zum einen ermöglicht die verblindete Einbindung unvereinfachter Originale und menschlicher Referenzen eine objektive Kontrollbasis. Man sieht dadurch exakt, wie die beurteilende Person fertige Originale und menschliche Goldstandards einstuft, was als verlässlicher Referenzrahmen für die Einordnung der Modellübersetzungen dient. Zum anderen bestand die Möglichkeit, dass die Fachperson bestimmte Vorlagen aus der Praxis der Lebenshilfe bereits kannte. Durch die bewusste Mischung von Texten aus den Lebenshilfe-Beständen mit Artikeln aus den Web-Quellen des Testdatensatzes wird sichergestellt, dass mögliche Vorkenntnisse einzelner Dokumente das Gesamtbild nicht verzerren.

Der Pool aus 50 Texten setzt sich aus folgenden Bedingungen zusammen:

- **Bedingung 1 – AS Original (12×):** Unveränderte Originalartikel in Alltagssprache aus dem Testdatensatz (7× Web-Quellen, 5× Lebenshilfe).
- **Bedingung 2 – Goldstandard LS (12×):** Von Menschen erstellte Referenztexte in Leichter Sprache zu 12 *anderen* Themen (7× Web-Quellen, 5× Lebenshilfe).
- **Bedingung 3 – mBART-50 SFT (12×):** Übersetzungen des SFT-Basismodells (1en1024) zu 12 weiteren Ausgangstexten.
- **Bedingung 4 – mBART-50 DPO (12×):** Übersetzungen des präferenzoptimierten Modells (1en1024, $\beta = 0,20$, $w_{\text{style}} = 0,7$, $w_{\text{sem}} = 0,3$) zu 12 weiteren Ausgangstexten.
- **Bedingung 5 – Kontrolltexte (2×):** Zwei gezielt erstellte Kontrolltexte zur Orientierung an den Skalenenden (1× sehr einfache Leichte Sprache; 1× komplexer juristischer Schachtelsatz aus dem Verwaltungsrecht).

Jeder Text wird auf zwei getrennten 5-Punkte-Skalen bewertet:

- **Dimension 1: Sprachliche Einfachheit (E_{style}):**
 - Stufe 1:** Schwer / Reine Alltagssprache
 - Stufe 2:** Eher Alltagssprache
 - Stufe 3:** Mittlere Vereinfachung (Einfache Sprache)
 - Stufe 4:** Eher Leichte Sprache
 - Stufe 5:** Sehr gut verständlich / Vollständige Leichte Sprache
- **Dimension 2: Sinnhaftigkeit & Textlogik (E_{meaning}):**
 - Stufe 1:** Völlig unlogisch / Falsche Begriffserklärungen / Halluzinationen
 - Stufe 2:** Eher verwirrend / Brüche in der Logik
 - Stufe 3:** Teils holprig / Einzelne Unstimmigkeiten
 - Stufe 4:** Überwiegend verständlich und schlüssig
 - Stufe 5:** Vollkommen logisch, klar und inhaltlich fehlerfrei

Zusätzlich können typische Fehler wie *erfundene Erklärungen* / *falsche Fakten*, *unlogische Gedankengänge*, *Grammatikfehler*, *ungewohnte Worttrennungen* oder *Passivformen* markiert und freie Anmerkungen hinterlegt werden.

6.3.3 Web-basierte Studiumgebung & Admin-Dashboard

Für die Durchführung wurde eine eigenständige Web-Anwendung entwickelt, die strikt zwischen der Bewertungsansicht und der Versuchsverwaltung trennt:




Abbildung 11: Benutzeroberfläche der Experten-Evaluation (ITEM_01 bis ITEM_50) zur browserbasierten Einzeltextbewertung von sprachlicher Einfachheit (E_{style}) und Sinnhaftigkeit (E_{meaning}) auf 5-Punkte-Skalen.

- **Bewertungsoberfläche (Abbildung 11):** Die Ansicht ist neutral gehalten. Angezeigt werden lediglich der zu bewertende Text, die Wortanzahl und die Bewertungsskalen. Alle Eingaben werden bei jedem Schritt automatisch gespeichert.
- **Versuchsverwaltung (Abbildung 12):** Ein geschützter Bereich ermöglicht es, den aktuellen Bearbeitungsstand einzusehen und die erhobenen Daten strukturiert zu exportieren.

6.3.4 Statistische Auswertungsmethodik

Die Auswertung stützt sich auf zwei zentrale Schritte:




Abbildung 12: Admin-Dashboard (/admin) zur Begleitung der 50 Studien-Texte mit Fortschrittsanzeige und Vergleichsmöglichkeiten zwischen den Bedingungen.

- Paarweiser Vergleich der Rangfolge:** Aus den $N = 50$ unabhängig bewerteten Einzeltexten lassen sich alle $\binom{50}{2} = 1.225$ möglichen Textpaare bilden. Für jedes Paar wird geprüft, ob die automatisierte Metrik (R_{style}) und die menschliche Expertenbewertung (E_{style}) dieselbe relative Rangordnung vorgeben (also ob der vom Experten als einfacher eingestufte Text auch von der Metrik den höheren Wert erhält). Die Übereinstimmungsrate beziffert den Anteil der Paare, bei denen die Einstufung übereinstimmt, und zeigt, wie verlässlich der Regressor relative Unterschiede in der Textschwere abbildet.
- Rangkorrelationen:** Berechnung des Spearman-Korrelationskoeffizienten ρ und Kendall's τ zwischen der automatischen Metrik R_{style} und der menschlichen Beurteilung E_{style} .

6.3.5 Ergebnisse der Experten-Evaluation

In Tabelle 9 sind die aggregierten Evaluationsergebnisse über die fünf Versuchsbedingungen zusammengefasst.

Validierung der Metrik und Ergebnisse des Modellvergleichs: Die Auswertung der 50 Expertenbewertungen liefert folgende zentrale Erkenntnisse:

- Paarweise Rangübereinstimmung über 1.225 Textpaare:** Über die $\binom{50}{2} = 1.225$ kombinatorischen Paare erzielte der BiLSTM-MixUp-Regressor bei allen 959 eindeutig entschiedenen Paaren eine **Übereinstimmungsrate von 79,14 %** (759 passende vs. 200 abweichende Entscheidungen). Werden auch die 265 Texte einbezogen, die vom Experten identisch benotet wurden, liegt die Rangtreue bei 61,96 %.
- Korrelation mit der Expertenbewertung (Einfachheit):** Der neuronale Regressor R_{style} korreliert deutlich positiv mit dem Urteil der Fachperson (Spearman $\rho =$

Tabelle 9: Ergebnisse der empirischen Experten-Evaluation ($N = 50$ Texte). Gegenüberstellung der automatisierten Metriken mit den menschlichen Expertennoten (1: schwer/unlogisch bis 5: leicht/vollkommen sinnvoll) über die Bedingungen der Alltagssprache (AS), Leichten Sprache (LS), des überwachten Feintunings (SFT) und der Präferenzoptimierung (DPO) inklusive Domänenauflösung des Goldstandards.

Bedingung	Artikel-anzahl (N)	R_{style} ($\emptyset$)	Flesch DE	Experte: Einfachheit ($\emptyset$)	Experte: Sinn/Logik ($\emptyset$)
Control Hard AS	1	0,377	-21,41	$1,00 \pm 0,00$	$5,00 \pm 0,00$
AS Original	12	0,117	28,68	$1,58 \pm 0,67$	$4,25 \pm 0,75$
mBART-50 SFT	12	0,718	46,53	$3,00 \pm 0,85$	$2,33 \pm 1,56$
Gold Standard LS (Gesamt)	12	0,840	46,98	$3,92 \pm 0,90$	$4,17 \pm 1,03$
└ In-Domain (Web-Held-Out)	7	0,913	47,32	$3,71 \pm 0,95$	$3,86 \pm 1,21$
└ Out-of-Domain (Lebenshilfe)	5	0,738	46,49	$4,20 \pm 0,84$	$4,60 \pm 0,55$
mBART-50 DPO	12	0,982	53,39	$3,50 \pm 0,52$	$1,75 \pm 1,14$
Control Easy LS	1	0,969	69,07	$5,00 \pm 0,00$	$3,00 \pm 0,00$




Abbildung 13: Notenverteilung der Expertenbewertung über die vier Hauptbedingungen: (A) Sprachliche Einfachheit E_{style} (1 = Alltagssprache bis 5 = sehr einfache Leichte Sprache) und (B) Sinnhaftigkeit und Textlogik E_{meaning} (1 = unlogisch/Fehler bis 5 = klar verständlich).

0,6750, Pearson $r = 0,7864$, $p = 7,61 \times 10^{-8}$) und bildet die wahrgenommene Einfachheit präzise ab. Klassische Formeln wie der Flesch Reading Ease ($\rho = 0,5696$) oder der LIX-Index ($\rho = -0,5434$) weisen zwar ebenfalls eine moderate Korrelation auf, dies liegt jedoch primär daran, dass echte Leichte Sprache extrem kurze Sätze nutzt und diese rein längenbasierten Teilmengen somit zwangsläufig mitbedient (Teilmengen-Hypothese, vgl. Abschnitt 5.1.2). Wie die Analysen in Abschnitt 5.1.2 zeigen, besitzen traditionelle Formeln für die Bewertung generierter Texte wenig eigenständige Aussagekraft, da sie gegenüber grammatikalischen Regelverletzungen (wie Passiv oder Konjunktiv) blind sind oder diese fälschlicherweise belohnen.

- **Modellentwicklung und Bestätigung der Pipeline (Abbildung 13A):** Die Verteilung der Expertennoten zeigt eine klare und kontinuierliche Steigerung der sprachlichen Einfachheit über die Modellierungsstufen: Ausgehend von den schweren Ausgangstexten der Alltagssprache ($E_{\text{style}} = 1,58$) bildet das SFT-Basismodell mit einer mittleren Note von 3,00 das solide sprachliche Fundament. Durch die anschließende Präferenzoptimierung (DPO) wird dieses Signal über die Belohnungsmetrik nochmals gezielt verstärkt, sodass das DPO-Modell eine Einfachheit von 3,50 erreicht und sich dem menschlichen Goldstandard (3,92) deutlich annähert. Dieses Ergebnis bestätigt exakt die quantitativen linguistischen Analysen aus Abschnitt 6.2.6: Bereits das SFT-Training sorgt für eine deutliche Entflechtung und Vereinfachung gegenüber der Alltagssprache, während DPO die Regeleinhaltung und das Signal für einfache Satzstrukturen nochmals konsequent nachschärft.
- **Domänendifferenzierung des Goldstandards & Trainingsbasis:** Bei der differenzierten Betrachtung der menschlichen Referenztexte (Tabelle 9) fällt auf, dass der Experte die In-Domain-Referenzen aus den Web-Quellen mit $E_{\text{style}} = 3,71 \pm 0,95$ spürbar schwächer bewertet hat als die Out-of-Domain-Texte der Lebenshilfe Kiel ($E_{\text{style}} = 4,20 \pm 0,84$). Bemerkenswert ist hierbei, dass die Bewertungen der generativen Modelle ($E_{\text{style}} = 3,50$ bei DPO bzw. 3,00 bei SFT) deutlich näher an diesem In-Domain-Niveau der Web-Quellen liegen. Dies spiegelt wider, auf welcher Datenbasis die Modelle primär trainiert wurden: Da der Trainingsdatensatz überwiegend aus den frei zugänglichen Web-Quellen besteht, bildet das Modell naturgemäß genau den Sprach- und Qualitätsstandard dieser Web-Texte ab, während die professionell geprüften Lebenshilfe-Texte ein nochmals höheres Sprachniveau markieren.
- **Inhaltliche Fehler & Textlogik (Abbildung 13B):** Während menschliche Gold-Texte ($4,17 \pm 1,03$) und Originaltexte ($4,25 \pm 0,75$) hohe Logiknoten erhalten, zeigen die maschinellen Modelle deutliche inhaltliche Schwächen (Halluzinationen in 58,3 % der Fälle bei SFT und 66,7 % bei DPO). Positiv ist, dass DPO Passivformen vollständig vermeidet (0 Fälle bei DPO vs. 4 bei SFT und 9 bei AS) und Worttrennungen mit Bindestrich konsequenter vornimmt. Die Ergebnisse verdeutlichen, dass eine rein formale Stiloptimierung künftig mit gezielten Prüfungen der inhaltlichen Richtigkeit kombiniert werden muss.

7 Diskussion & Gesamtevaluation

7.1 Inhaltssynthese der drei Themenblöcke

Die vorliegende Arbeit betrachtet die maschinelle Übersetzung in deutsche Leichte Sprache nicht als isoliertes Einzelproblem, sondern als einen in sich geschlossenen methodischen Kreislauf. Die drei Themenblöcke (Datenakquise in Themenblock 1, Modellierung stetiger Komplexitätsmetriken in Themenblock 2 und zweistufige Übersetzung mittels Präferenzoptimierung in Themenblock 3) bauen direkt aufeinander auf und belegen die Funktionsfähigkeit des entwickelten Gesamtsystems.

Heterogenität der Praxis und Herausforderungen im Web-Korpus: Der Aufbau der Datenbasis in Themenblock 1 (Kapitel 4) zeigte die praktische Hauptherausforderung bei der Textvereinfachung: Es gibt in der Praxis kein einheitliches Zielbild für Leichte Sprache. Wie die Untersuchung der Regeleinhaltung über 12 Webquellen in Abschnitt 4.3.4 zeigt, setzen Redaktionen die Regeln sehr unterschiedlich um. Während Nachrichtenseiten (wie der MDR) Texte vor allem stark zusammenfassen und kürzen (Längenverhältnis $\approx 0,44$), versuchen kommunale Seiten (wie die Stadt Hannover mit einem Verhältnis von 0,98), alle Details beizubehalten und durch längere Erklärungen verständlich zu machen.

Zudem spiegeln die gesammelten Webdaten die Realität des deutschsprachigen Internets wider: Trotz automatischer Filterung verbleibt eine gewisse Unschärfe, da manche Angebote (wie Teile der *Apotheken Umschau*) sprachlich eher der Einfachen Sprache als der strengen Leichten Sprache entsprechen (Toborek et al., 2023). Erst durch die Kombination aus gezielter Bereinigung von Web-Boilerplate, Satzzeichensicherung und der semantischen Textfilterung mit Jina-Embeddings ($0,60 \leq \text{sim}_{\text{cos}} \leq 0,98$, Abschnitt 4.2.3) konnte aus 1.458 Rohpaaren ein bereinigter Trainingskorpus von 860 Artikelpaaren aufgebaut werden, der als verlässliche Grundlage für die Modelle dient.

Überwindung des binären Problems durch MixUp-Generalisierung: Auf dieser Datenbasis widmete sich Themenblock 2 (Kapitel 5) der Frage, wie sich Textschwere stufenlos messen lässt. Für Menschen mit Lernschwierigkeiten oder kognitiven Einschränkungen ist Sprachkomplexität im Alltag oft eine Alles-oder-Nichts-Frage: Wenn ein Text auch nur einen einzigen zu schwierigen Schachtelsatz enthält, bricht das Verständnis ab und die betroffene Person liest nicht weiter. Da Trainingsdaten in der Realität jedoch nur an den beiden Extrempunkten vorliegen (entweder schwere Alltagssprache oder fertige Leichte Sprache), war das Training einer stufenlosen Bewertungsmetrik bisher sehr schwierig.

Die in dieser Arbeit entwickelte MixUp-Strategie löst dieses Problem: Durch das schrittweise Mischen der Satzrepräsentationen lernt das Modell kontinuierliche Zwischenstufen, obwohl es im Training ausschließlich echte, unverfälschte Texte gesehen hat.

Wie gut dieser Ansatz generalisiert, belegen die empirischen Ergebnisse: Auf dem unabhängigen Testset der *Lebenshilfe* erzielt der Regressor eine Paar-Rangtreue von 79,14 % und korreliert stark mit dem qualitativen Expertenurteil ($\rho = 0,6750, r = 0,7864$, Abschnitt 6.3).

Auch auf externen Benchmarks behauptet sich das Modell erstaunlich stabil. Auf dem MERLIN-Korpus ($N = 1.033$ Texte, Abschnitt 5.4.3) sinkt der Score über alle sechs Sprachprüfungsstufen des Gemeinsamen Europäischen Referenzrahmens (A1 bis C2) streng gleichmäßig ab ($\rho = 0,485$). Auf TextComplexityDE ($N = 1.000$ Sätze, Abschnitt 5.4.2) nutzt er die Bewertungsskala differenzierter aus als traditionelle Formeln ($r = 0,620$). Das Modell hat somit ein robustes Verständnis für relative Sprachkomplexität gelernt, das weit über die ursprünglichen Trainingsdaten hinausreicht.

Arbeitsteilung zwischen SFT und DPO: In Themenblock 3 (Kapitel 6) greifen Datenbasis und Metrik in der Übersetzung nahtlos ineinander. Das Zusammenspiel aus überwachtem Training (SFT) und Präferenzoptimierung (DPO) zeigt dabei eine klare methodische Arbeitsteilung: Das Basismodell lernt durch das überwachte Feintuning allein aus den Textbeispielen die grundlegenden syntaktischen Vereinfachungen. Die durchschnittliche Satzlänge sinkt von 12,50 auf 7,61 Wörter und Passiv- sowie Genitivformen werden bereits deutlich seltener (Abschnitt 6.2.6).

Auf diesem Fundament nutzt das anschließende DPO-Training den gelernten MixUp-Regressor als Belohnung, um selbstständig bevorzugte Satzvarianten auszuwählen. Ohne zusätzlichen Speicherbedarf auf der Grafikkarte (0 MB Overhead) schärft DPO die Regeleinhaltung nochmals deutlich nach: Passiv- und Genitivstrukturen werden fast völlig vermieden ($< 0,6\%$) und die Lesbarkeit verbessert sich spürbar auf eine Wiener Sachtextformel von $WSTF = 5,55$ (Abschnitt 6.2.6). Die verblindete Beurteilung durch die Fachkraft der Lebenshilfe Kiel (Abschnitt 6.3) bestätigt diese schrittweise Steigerung über alle Stufen hinweg (Alltagssprache 1,58 $\rightarrow$ SFT 3,00 $\rightarrow$ DPO 3,50 $\rightarrow$ Goldstandard 3,92).

Funktionsnachweis des Frameworks: Die Ergebnisse zeigen, dass das entwickelte System als Ganzes zuverlässig funktioniert. Jede Komponente erfüllt genau ihre vorgesehene Aufgabe. Gleichzeitig zeigt sich ein klarer Zusammenhang: Verbessert man die Qualität der Ausgangsdaten, profitieren davon automatisch alle folgenden Schritte – von der Genauigkeit der Bewertungsmetrik über das Basismodell bis hin zur Präferenzoptimierung.

7.2 Stärken, Grenzen & Systemrestriktionen

Aus den empirischen Untersuchungen lassen sich sowohl zentrale Stärken als auch klare methodische und praktische Grenzen des Systems ableiten.

Stärken des modularen Frameworks: Die größte methodische Stärke des entwickelten Systems liegt in seinem geschlossenen, autonomen Aufbau. Das Framework deckt die gesamte Kette von der Datenbereinigung über die referenzfreie Qualitätsbewertung bis zum Modell-Alignment ab. Es benötigt für das DPO-Training keine teuren menschlichen Präferenzbeschriftungen, sondern generiert und bewertet Textpaare vollkommen autonom.

Zudem zeichnet sich der Ansatz durch eine hohe Ressourceneffizienz aus: Durch den Einsatz von LoRA und das temporäre Deaktivieren der Adapter während des DPO-Trainings

(Abschnitt 6.2.2) entfällt der doppelte Speicherbedarf für das Referenzmodell vollständig (0 MB VRAM-Overhead). Dies ermöglicht das rechenintensive Training langer Sequenzen (1.024 Tokens) auf handelsüblicher Hardware. Hinzu kommt die bemerkenswerte Robustheit des BiLSTM-MixUp-Regressors: Obwohl das Modell ausschließlich mit echten Texten trainiert wurde, generalisiert es stabil auf domänenfremde Datensätze (MERLIN, TextComplexityDE) und bildet relative Sprachkomplexität verlässlich ab.

Datenmenge vs. Datenqualität (Skalierungseffekte): Ein zentrales Ergebnis der Arbeit betrifft das Verhältnis von Datenvolumen und Datenqualität. Grundsätzlich gilt im maschinellen Lernen, dass größere Datensätze die Modellleistung verbessern. Die Skalierungsanalyse des SFT-Modells in Abschnitt 6.1.4 zeigt jedoch deutlich, dass der Zugewinn an Vereinfachungsleistung (R_{style}) mit wachsender Datenmenge zunehmend abflacht und die Kurve langsam konvergiert.

Daraus folgt, dass eine reine Erhöhung der Datenmenge nicht der wichtigste Hebel für bessere Modelle ist. Das weitaus größere Verbesserungspotenzial liegt in der **Datenqualität**. Dies belegt auch die Expertenstudie in Abschnitt 6.3: Der Experte bewertete die In-Domain-Texte aus den Web-Quellen mit einer mittleren Note von 3,71 spürbar schlechter als die Texte aus der professionellen Lebenshilfe-Redaktion (4,20). Da die Modelle mit frei zugänglichen Webtexten trainiert wurden, spiegelt ihre Note (3,50) genau diesen Standard der Webquellen wider. Für künftige Verbesserungen ist eine gezieltere Auswahl, Prüfung und Qualitätssteigerung der Ausgangsdaten daher der wirksamste Ansatzpunkt.

Der externe Lebenshilfe-Datensatz: Nutzen und Restriktionen: Der unabhängig erhobene Datensatz der Lebenshilfe Schleswig-Holstein war für diese Arbeit sehr wertvoll: Er ermöglichte es, Metriken und Übersetzungsmodelle auf echten, behördlich geprüften Fachtexten zu testen, ohne dass die Gefahr eines Datenlecks (Data Leakage) bestand.

Gleichzeitig unterliegt dieser Datensatz methodischen Grenzen: Mit $N = 37$ Testpaaren liegt er zwar im typischen Rahmen aussagekräftiger Test-Splits, ist statistisch gesehen jedoch klein. Zudem stammen die Texte überwiegend aus dem behördlichen und organisatorischen Kontext (Vereinbarungen, Bescheide, Hausordnungen) und wurden von einer einzigen Organisation übersetzt. Wie die Korpusanalyse in Abschnitt 4.3.4 zeigt, interpretiert jede Redaktion die Richtlinien für Leichte Sprache etwas anders. Der Datensatz bildet daher einen qualitativ exzellenten, aber institutionell spezifischen Ausschnitt der praktischen Umsetzung ab.

Grenzen automatischer Metriken bei Faktenfehlern und Halluzinationen: Eine wesentliche Schwachstelle generativer Übersetzungsmodelle bleibt die inhaltliche Verlässlichkeit. Während DPO formale Kriterien wie kurze Sätze und Bindestriche exzellent optimiert, deckte die qualitative Fehleranalyse in Abschnitt 6.3 bei 66,7 % der DPO-Texte inhaltliche Fehler oder erfundene Aussagen (Halluzinationen) auf.

Dass diese Fehler im Training nicht korrigiert wurden, liegt an den methodischen Grenzen

existierender Bewertungsmetriken: Wie das Faktenkonsistenz-Experiment in Abschnitt 6.2.3 (Abbildung 9) anhand von $N = 160$ Testpaaren empirisch belegt, ist gegenwärtig keine der gängigen automatisierten Metriken in der Lage, reale Modell-Halluzinationen zuverlässig abzufangen. Satz-Embeddings wie SBERT (0,9035 bei Halluzinationen vs. 0,9161 bei Gold-Texten), Inferenzmodelle (NLI mit 0,4638 vs. 0,4854) und Entitätenabgleiche (NER mit 0,1653 vs. 0,1549) weisen nahezu identische Werteverteilungen zwischen fehlerfreien Texten und groben inhaltlichen Erfindungen auf.

Zwar erkennen Satz-Embeddings thematisch völlig falsche Texte verlässlich (wie die Random-Shuffle-Kontrolle in Abschnitt 6.2.3 mit Scores $< 0,60$ zeigt), für isolierte Faktenverzerrungen innerhalb eines ansonsten passenden Satzes (z. B. erfundene Begriffserklärungen) erfassen sie diese jedoch nicht. Da die Kosinus-Ähnlichkeit bei solchen Sätzen auf hohem Niveau bleibt ($\approx 0,90$), konnte das Reward-Signal diese Fehler im DPO-Training nicht sanktionieren. Die Entwicklung von Metriken, die subtile Faktenverfälschungen in stark vereinfachten Textstrukturen referenzfrei und feingliedrig bewerten können, bleibt somit eine zentrale ungelöste Herausforderung und ein offener Punkt dieser Arbeit. Gleichzeitig verdeutlicht dieser Befund, dass Halluzinationen auch direkt über die Datenbasis eingedämmt werden können: Eine noch höhere Qualität und präzisere inhaltliche Ausrichtung (Alignment) der parallelen Trainingsdaten bietet das entscheidende Potenzial, damit generative Modelle von vornherein faktengetreue Übersetzungen ohne eigenmächtige Begriffserfindungen erlernen.

Einschränkungen der Expertenstudie & Bedeutung partizipativer Zielgruppentests: Die externe Validierung durch eine Fachperson der Lebenshilfe Kiel lieferte wichtige Erkenntnisse über die Praxisnähe der Modelle. Dennoch müssen bei der Interpretation zwei wesentliche Aspekte berücksichtigt werden: Zum einen urteilt auch eine erfahrene Fachkraft stets mit einer gewissen subjektiven Prägung. In der professionellen Praxis der Lebenshilfe werden Texte daher grundsätzlich nach dem Mehr-Augen-Prinzip von mindestens zwei weiteren Fachkräften gegengelesen. Für eine noch breitere statistische Absicherung wären künftig Studien mit mehreren unabhängigen Sprachexperten wünschenswert.

Zum anderen ist die Einbindung der eigentlichen Zielgruppe unverzichtbar. Die wichtigste Instanz für barrierefreie Sprache sind die betroffenen Personen selbst (Menschen mit Lernschwierigkeiten, geringer Lesekompetenz oder Deutsch als Zweitsprache). Fachkräfte können zwar die Einhaltung formaler Regeln professionell beurteilen, wie verständlich ein Text im Alltag tatsächlich ist, lässt sich jedoch nur im direkten Austausch mit der Zielgruppe prüfen. Wegen des oben beschriebenen binären Abbruchverhaltens – bei dem bereits ein einzelner unverständlicher Satz zum vollständigen Abbruch des Lesevorgangs führen kann – sind direkte Verständnistests mit Betroffenen für einen produktiven Praxiseinsatz unerlässlich.

7.3 Beantwortung der Forschungsfragen

Auf Basis der theoretischen Grundlagen, der methodischen Modellierung und der empirischen Befunde aus den drei Themenblöcken sowie der Expertenstudie lassen sich die in Abschnitt 1.2 formulierten vier forschungsleitenden Kernfragen wie folgt beantworten.

7.3.1 Beantwortung von FF1: Automatisierte Korpusgewinnung & Qualitätsfilterung

FF1: *Wie lässt sich aus heterogenen Webquellen ein qualitativ hochwertiges, artikelbasiertes Parallelkorpus für die deutsche Leichte Sprache automatisiert gewinnen, bereinigen und semantisch filtern?*

Die Ergebnisse aus Kapitel 4 zeigen, dass der Aufbau eines qualitativ hochwertigen Parallelkorpus für deutsche Leichte Sprache durch eine mehrstufige, automatisierte Pipeline erfolgreich gelingt. Die gezielte Extraktion der Hauptinhalte (DOM-Content-Isolation) aus 12 heterogenen Webangeboten trennt Web-Boilerplate, Navigationsmenüs und Fußzeilen bereits beim Auslesen zuverlässig von den eigentlichen Artikeln (Abschnitt 4.1). Daran schließt sich eine kaskadierte regelbasierte Bereinigung an, die Link-Artefakte, Bildunterschriften und Werbehinweise entfernt sowie Satzzeichen normalisiert, damit nachfolgende Vereinfachungen nicht durch Formatierungsfehler verfälscht werden (Abschnitt 4.2).

Für die inhaltliche Qualitätssicherung sorgt ein semantischer Abgleich über Text-Embeddings (`jina-embeddings-v2-base-de`, Günther et al. (2023)). Das in Abschnitt 4.2.3 definierte Ähnlichkeitsintervall $[0,60; 0,98]$ trennt unpassende oder falsch ausgelesene Paare ($< 0,60$) verlässlich von trivialen, unvereinfachten Textkopien ($> 0,98$). Aus ursprünglich 1.458 Rohpaaren entstand so ein bereinigter Korpus von 860 Artikelpaaren. Trotz stark unterschiedlicher redaktioneller Stile (von stark zusammenfassenden Nachrichten beim MDR mit einem Längenverhältnis $\approx 0,44$ bis hin zu ausführlich erklärenden Behördentexten der Stadt Hannover mit einem Verhältnis $\approx 0,98$) liefert die Pipeline eine semantisch konsistente und linguistisch vielfältige Trainingsgrundlage für alle Modelle (Abschnitt 4.3.4).

Gleichzeitig bleibt das Vorhandensein von Web-Artefakten eine zentrale Herausforderung bei automatisierter Datengewinnung. Wie die Fallstudien in Abschnitt 4.2.3 belegen, neigen Modelle ohne gründliche Bereinigung und Filterung dazu, dominante Web-Muster ungefiltert zu übernehmen, beispielsweise stereotype Klick-Aufforderungen am Textende (*»Klicken Sie auf ein Feld«* aus Hannover-Rohdaten), vorangestellte Rubriken-Tags (*»Sachsen:«* aus MDR-Nachrichten) oder unverarbeitete Inhaltsverzeichnisse aus reinen Fragenketten (*Apotheken Umschau*). Zwar konnten diese konkreten Verzerrungen durch die entwickelte Filterkaskade in den finalen Modell-Outputs vollständig eliminiert werden, ein gewisses Grundrauschen an unvollständigen Formatierungen oder stilistischen Unschärfen lässt sich aus frei zugänglichen Webquellen jedoch nie restlos entfernen.

7.3.2 Beantwortung von FF2: Kontinuierliche Komplexitätsmodellierung & Validierung

FF2: *Wie kann auf Basis rein bimodal vorliegender Sprachdaten eine stufenlose, differenzierbare Metrik zur referenzfreien Bewertung von Textsimplizität modelliert und validiert werden?*

Die Untersuchung in Kapitel 5 belegt, dass die stufenlose Bewertung von Textschwere nicht auf fehleranfälligen Oberflächenformeln basieren muss, sondern durch ein neuronales MixUp-Verfahren kontinuierlich modelliert werden kann. Herkömmliche Formeln wie Flesch Reading Ease, die Wiener Sachtextformel oder LIX basieren rein auf Silben- und Satzlengthen. Auf sauberen Goldstandard-Texten schneiden sie nur deshalb scheinbar gut ab, weil menschliche Übersetzungen Satzlengthe und Grammatik meist gemeinsam vereinfachen (Teilmengen-Hypothese $S_{\text{metric}} \subset S_{\text{LS}}$, Abschnitt 5.1.2). Bei gezielten grammatikalischen Regelbrüchen wie Konjunktiv II oder Passivformen versagen klassische Formeln jedoch vollständig und belohnen komplexe Strukturen teilweise sogar fälschlicherweise mit besseren Werten.

Das in dieser Arbeit entwickelte BiLSTM-MixUp-Verfahren überwindet dieses Problem: Durch das schrittweise Mischen der Vektordarstellungen von Alltagssprache und Leichter Sprache lernt das neuronale Netz kontinuierliche Zwischenstufen der Sprachkomplexität, ohne jemals auf unnatürliche oder fehlerhafte künstliche Zwischentexte angewiesen zu sein (Abschnitt 5.3.1). Auf dem unabhängigen Testset der *Lebenshilfe* erzielt der Regressor eine hohe Rangtreue von fast 80 % und stimmt eng mit dem qualitativen Urteil der Fachkraft überein (Abschnitt 6.3). Zudem überträgt sich die Metrik erfolgreich auf externe Benchmarks wie den MERLIN-Korpus (Abschnitt 5.4.3) und TextComplexityDE (Abschnitt 5.4.2), wo sie relative Textschwere über verschiedene Sprachniveaus hinweg verlässlich abbildet. Das Modell stellt somit ein stetiges, differenzierbares Belohnungssignal (R_{style}) bereit, das syntaktische Regelverstöße erfasst und als verlässliche Bewertungsfunktion für das Modell-Alignment dient.

7.3.3 Beantwortung von FF3: Regel-Lernbarkeit (SFT) & Reward-Guided Alignment (DPO)

FF3: *Inwieweit sind generative Sprachmodelle in der Lage, die Regeln der Leichten Sprache anhand eines automatisiert akquirierten Web-Datensatzes zu erlernen, und wie lassen sich diese Modelle mithilfe eines gelernten Reward-Signals gezielt weiter anpassen?*

Die experimentellen Befunde in Kapitel 6 zeigen eine klare methodische Arbeitsteilung zwischen überwachtem Feintuning (SFT) und Präferenzoptimierung (DPO). Das überwachte Feintuning auf den 860 Web-Artikelpaaren versetzt das generative Sprachmodell zuverlässig in die Lage, komplexe Satzstrukturen aufzubrechen. Die mittlere Satzlengthe

sinkt von 12,50 Wörtern in Alltagssprache auf 7,61 Wörter, und die Häufigkeit von Passiv- und Genitivkonstruktionen reduziert sich bereits deutlich (Abschnitt 6.1.6 und 6.2.6). Die Skalierungsanalyse in Abschnitt 6.1.4 belegt jedoch, dass der Zuwachs an Vereinfachungsleistung mit wachsender Datenmenge abflacht und die Lernkurve konvergiert. Eine bloße Erhöhung des Datenvolumens reicht nicht aus, um spezifische grammatikalische Feinheiten abzusichern; der entscheidende Hebel liegt vielmehr in einer hohen Datenqualität und einer sauberen inhaltlichen Prüfung der Ausgangstexte.

Auf dem durch SFT geschaffenen Fundament setzt das DPO-Alignment an: Anhand des gelernten MixUp-Belohnungssignals werden gezielt formale Sprachregeln durchgesetzt. DPO eliminiert Passiv- und Genitivstrukturen nahezu vollständig auf unter 1 % (Abschnitt 6.2.6) und verbessert die Lesbarkeit spürbar auf eine Wiener Sachtextformel von $WSTF = 5,55$. SFT legt somit das grammatikalische Grundgerüst, während DPO die formale Regeleinhaltung automatisiert und ohne manuelle Annotationen schärft.

Gleichzeitig verdeutlichte die qualitative Evaluation durch die Fachkraft (Abschnitt 6.3), dass das System noch kein fertiges Endprodukt für die Praxis darstellt: Zwar werden formale Kriterien wie kurze Sätze und Worttrennungen hervorragend gemeistert, bei der inhaltlich fehlerfreien und vollständigen Übersetzung des Ausgangstextes treten jedoch weiterhin Verzerrungen und Auslassungen auf. Für einen produktiven Einsatz muss die formale Regeloptimierung daher künftig zwingend mit Mechanismen zur Sicherung der inhaltlichen Faktentreue kombiniert werden.

7.3.4 Beantwortung von FF4: Übereinstimmung mit dem qualitativen Expertenurteil

FF4: *Inwieweit stimmen die automatisierten Modell- und Metrikbewertungen mit dem qualitativen Urteil einer Fachkraft für Leichte Sprache (Lebenshilfe Kiel) in der Praxis überein?*

Die verblindete Expertenstudie mit einer zertifizierten Fachkraft der Lebenshilfe Kiel (Abschnitt 6.3) bestätigt die Gültigkeit des entwickelten Frameworks in der praktischen Anwendung. Die automatisierte BiLSTM-MixUp-Metrik erzielt eine starke Rangkorrelation mit dem Urteil der Fachkraft ($\rho = 0,6750$, Abschnitt 6.3.5) und spiegelt damit das menschliche Sprachempfinden wider, ohne auf rein oberflächliche Längenmerkmale beschränkt zu sein. Auch die qualitative Bewertung auf einer Skala von 1 bis 5 bestätigt den schrittweisen Leistungszuwachs über alle Systemstufen:

Alltagssprache (1,58) $\longrightarrow$ SFT (3,00) $\longrightarrow$ DPO (3,50) $\longrightarrow$ Goldstandard (3,92)

Hierbei erzielt DPO eine statistisch signifikante Steigerung gegenüber dem reinen SFT-Basismodell (Abschnitt 6.3.5).

Gleichzeitig spiegeln die Bewertungen den Einfluss der Datenbasis wider: Die Fachkraft bewertete die Web-In-Domain-Texte mit einer mittleren Note von 3,71 schwächer als die

professionellen Lebenshilfe-Übersetzungen (4,20). Die Note des DPO-Modells (3,50) zeigt, dass das Modell das Qualitätsniveau seiner Web-Trainingsdaten weitgehend ausschöpft.

Als wesentliche Erkenntnis deckte die qualitative Fehleranalyse bei 66,7 % der DPO-Texte inhaltliche Verzerrungen oder erfundene Zusatzerklärungen auf (Abschnitt 6.3.5). Wie die Analyse existierender Bewertungsmetriken in Abschnitt 6.2.3 zeigte, schlägt bei solchen Halluzinationen gegenwärtig keine der gängigen Metriken trennscharf aus. Die Entwicklung robuster automatisierter Verfahren zur verlässlichen Erkennung und Vermeidung von Faktenfehlern bleibt daher ein zentraler offener Punkt dieser Arbeit, der in künftigen Forschungsarbeiten durch gezielte Prüfungen der Faktentreue (etwa mittels natürlicher Sprachinferenz) gelöst werden muss.

8 Fazit & Ausblick

8.1 Zusammenfassung der Kernergebnisse

Der Abbau sprachlicher Barrieren ist eine grundlegende Voraussetzung für gesellschaftliche Teilhabe, Chancengleichheit und selbstbestimmte Information. Insbesondere vor dem Hintergrund gesetzlicher Vorgaben wie dem Barrierefreiheitsstärkungsgesetz (BFSG) steht die Praxis vor der Herausforderung, komplexe Alltagstexte verlässlich und in großem Umfang in verständliche Leichte Sprache zu übertragen. Die vorliegende Masterarbeit hat hierfür ein in sich geschlossenes, modulares Framework entwickelt, optimiert und empirisch evaluiert, das den gesamten Prozess von der Datenakquise über die stufenlose Komplexitätsbewertung bis zum generativen Modell-Alignment umfasst.

Die methodische Umsetzung und die empirischen Ergebnisse lassen sich anhand dreier zentraler Säulen zusammenfassen:

1. Automatisierte Korpusgewinnung und Qualitätsfilterung: Aus 12 heterogenen Webquellen wurde ein artikelbasiertes Parallelkorpus für deutsche Leichte Sprache automatisiert aufgebaut. Durch den Einsatz von DOM-Content-Isolation, regelbasierten Filterkaskaden und einer semantischen Sweet-Spot-Filterung ($[0,60; 0,98]$) mittels Text-Embeddings konnten 860 konsistente Artikelpaare gewonnen werden. Die Bereinigungsschritte eliminierten dominante Web-Verzerrungen wie stereotype Klickaufforderungen oder vorangestellte Rubriken-Kennungen vollständig und schufen eine robuste Trainingsgrundlage für alle nachfolgenden Modelle.

2. Kontinuierliche Sprachkomplexitätsmetrik via MixUp: Um die Einschränkungen klassischer Lesbarkeitsformeln zu überwinden, die bei grammatikalischen Regelbrüchen versagen, wurde ein neuronaler BiLSTM-MixUp-Regressor konzipiert. Durch das kontrollierte Mischen der Vektordarstellungen von Alltagssprache und Leichter Sprache lernt das Modell kontinuierliche Zwischenstufen der Textschwere, ohne auf semantische Zwischentexte angewiesen zu sein. Die Metrik erzielte auf dem unabhängigen Testset der Lebenshilfe eine hohe Rangtreue von fast 80 %, korrelierte stark mit dem qualitativen Expertenurteil ($\rho = 0,6750$) und bewies eine stabile Generalisierungsfähigkeit auf externen Sprachkorpora wie MERLIN und TextComplexityDE.

3. Zweistufige Modellierung und Regelschärfung via DPO: In der Übersetzung zeigte sich eine komplementäre Arbeitsteilung zwischen überwachtem Feintuning (SFT) und Präferenzoptimierung (DPO). Während SFT das grundlegende syntaktische Gerüst etablierte und die Satzlänge von 12,50 auf 7,61 Wörter deutlich reduzierte, schärfte das DPO-Alignment anhand des gelernten MixUp-Belohnungssignals die formale Regeleinhaltung gezielt nach. DPO reduzierte Passiv- und Genitivstrukturen auf unter 1 % und verbesserte die Lesbarkeit spürbar. Die verblindete Expertenstudie bestätigte diese systematische

Qualitätssteigerung über alle Modellstufen hinweg (Alltagssprache 1,58 → SFT 3,00 → DPO 3,50 → Goldstandard 3,92).

Zusammenfassend belegt die Arbeit die prinzipielle Funktionsfähigkeit einer autonomen, referenzfreien Übersetzungspipeline für deutsche Leichte Sprache. Das modulare System liefert den methodischen Nachweis, dass sich formale Vereinfachungsregeln durch zielgerichtete Präferenzoptimierung ohne manuellen Annotationsaufwand erfolgreich in generativen Sprachmodellen verankern lassen.

8.2 Ausblick & Zukünftige Forschungsarbeiten

Aufbauend auf den Erkenntnissen und identifizierten Systemgrenzen dieser Arbeit ergeben sich für die zukünftige Forschung vier zentrale Entwicklungs- und Verbesserungspotenziale:

1. Qualitätssteigerung und feingliedriges Alignment des Ausgangskorpus: Die Skalierungsanalyse und die Expertenbewertung haben eindeutig gezeigt, dass die Qualität der Trainingsdaten der mit Abstand wirksamste Hebel für bessere Modellergebnisse ist. Der wichtigste nächste Schritt besteht daher im Aufbau noch präziser zusammengestellter Parallelkorpora mit feingliedrigem semantischem Satz- und Abschnitts-Alignment. Hochwertig ausgerichtete Textpaare, die frei von redaktionellen Unschärfen sind und den Inhalt des Originals exakt abbilden, ermöglichen es sowohl der Komplexitätsmetrik als auch den Übersetzungsmodellen, von Beginn an inhaltlich saubere und faktengetreue Vereinfachungsmuster zu erlernen.

2. Erweiterung der Reward-Funktionen um NLI-basierte Faktentreue: Die qualitative Fehleranalyse deckte auf, dass reine Embedding-Metriken isolierte Faktenverzerrungen und erfundene Begriffserklärungen nicht zuverlässig erfassen. Um die inhaltliche Zuverlässigkeit generativer Übersetzungen abzusichern, müssen automatisierte Belohnungsfunktionen im DPO-Training künftig um Modelle zur natürlichen Sprachinferenz (Natural Language Inference, NLI) und semantische Konsistenzprüfungen erweitert werden. Ein solches Mehrebenen-Signal kann inhaltliche Widersprüche und unbelegte Zusatzaussagen gezielt sanktionieren und so formale Einfachheit mit verlässlicher Faktentreue verbinden.

3. Partizipative Verständnistests mit der realen Zielgruppe: Während Fachexperten vor allem die formale Einhaltung linguistischer Regelwerke beurteilen, lässt sich die tatsächliche Verständlichkeit im Alltag nur im direkten Austausch mit den betroffenen Personen prüfen. Zukünftige Studien sollten daher empirische Lese- und Verständnistests mit Menschen mit Lernschwierigkeiten, geringer Lesekompetenz oder Deutsch als Zweitsprache durchführen. Nur so lässt sich das in der Praxis beobachtete binäre Abbruchverhalten bei komplexen Satzgefügen unter realen Lesebedingungen quantifizieren und für die Modelloptimierung nutzen.

4. Layoutgestaltung und typografische Strukturierung: Leichte Sprache definiert sich nicht allein über den Text, sondern umfasst essenzielle visuelle und typografische Vorgaben: Dazu gehören das Ein-Satz-pro-Zeile-Prinzip, optische Trennzeichen bei Sinnabschnitten sowie eine leserfreundliche typografische Gliederung. Wie bereits Battisti et al. (2020) gezeigt haben, spielen typografische Merkmale, Zeilenstrukturen und visuelle Absätze eine entscheidende Rolle für die Lesbarkeit und das Textverständnis. Ein wichtiger nächster Schritt für die Übersetzungspipeline besteht daher darin, neben der reinen Textvereinfachung auch die regelkonforme Zeilentrennung, Absatzformatierung und visuelle Textstrukturierung automatisiert zu generieren.

Abkürzungsverzeichnis

10kGNAD	10k German News Articles Dataset
ALiBi	Attention with Linear Biases
AS	Alltagssprache
ATS	Automatic Text Simplification
BAcc	Balanced Accuracy
BCE	Binary Cross-Entropy
BFSG	Barrierefreiheitsstärkungsgesetz
BGG	Behindertengleichstellungsgesetz
BiLSTM	Bidirektionales Long Short-Term Memory
BITV 2.0	Barrierefreie-Informationstechnik-Verordnung
BLEU	Bilingual Evaluation Understudy
BMAS	Bundesministerium für Arbeit und Soziales
BPE	Byte-Pair Encoding
CEFR	Common European Framework of Reference for Languages
DETECT	Direct Evaluation of Text-simplification Effectiveness, Clarity, and Transparency
DOM	Document Object Model
DPO	Direct Preference Optimization
FRE	Flesch Reading Ease
GeSR	Gemeinsamer Europäischer Referenzrahmen für Sprachen
KDE	Kernel Density Estimation
LIX	Läsbarhetsindex (Lesbarkeitsindex)
LLM	Large Language Model
LoRA	Low-Rank Adaptation
LS	Leichte Sprache
LSTM	Long Short-Term Memory
MAE	Mean Absolute Error
MATTR	Moving-Average Type-Token Ratio
mBART	Multilingual Bidirectional and Auto-Regressive Transformers
MOS	Mean Opinion Score
MSE	Mean Squared Error
NER	Named Entity Recognition
NLI	Natural Language Inference

NLP	Natural Language Processing
OOD	Out-Of-Domain
PEFT	Parameter-Efficient Fine-Tuning
PPO	Proximal Policy Optimization
PR-AUC	Precision-Recall Area Under Curve
RLHF	Reinforcement Learning from Human/AI Feedback
RNN	Recurrent Neural Network
ROC-AUC	Receiver Operating Characteristic Area Under Curve
ROUGE	Recall-Oriented Understudy for Gisting Evaluation
SARI	System Accessibility and Readability Index
SBERT	Sentence-BERT
Seq2Seq	Sequence-to-Sequence
SFT	Supervised Fine-Tuning
TTR	Type-Token-Ratio
WSTF	Wiener Sachtextformel

Abbildungsverzeichnis

1	Lexikalische Diversität und Längenbereinigung im Parallelkorpus	25
2	Bidirektionaler Recall benannter Entitäten	26
3	Linguistische Regeleinhaltung nach BMAS und BITV 2.0	27
4	Verteilungs-Boxplots über 5 Likert-Komplexitätsstufen auf TextComplexityDE	39
5	Monotonie-Prüfung über CEFR-Sprachniveaustufen auf MERLIN	40
6	Gesamtarchitektur des zweistufigen Translation- und Alignment-Trainings .	46
7	Skalierungsverhalten von Verlust und sprachlicher Einfachheit	48
8	Ablauf der DPO-Präferenzdatengenerierung	51
9	Verteilungsanalyse automatisierter Faktenkonsistenzmetriken	53
10	Umfassendes Dashboard zur Einhaltung der Sprachregeln über 9 Dimensionen	55
11	Benutzeroberfläche der Experten-Evaluation	58
12	Übersicht der Versuchsverwaltung	59
13	Notenverteilung der Expertenbewertung über die vier Hauptbedingungen: (A) Sprachliche Einfachheit E_{style} (1 = Alltagssprache bis 5 = sehr einfache Leichte Sprache) und (B) Sinnhaftigkeit und Textlogik E_{meaning} (1 = unlogisch/Fehler bis 5 = klar verständlich).	60
14	Korrelationsanalyse auf dem TextComplexityDE-Benchmark	82
15	Streudiagramm-Grid auf TextComplexityDE	83
16	Dichteverteilungen der Klassifikationswahrscheinlichkeiten auf Lebenshilfe .	86
17	ROC- und Precision-Recall-Kurven der Klassifikationsmodelle	86
18	Konfusionsmatrizen und Gütemaße der BiLSTM-Klassifikatoren	87
19	KDE-Dichteverteilungen der MixUp-Sampling-Strategien auf Lebenshilfe . .	88
20	Streudiagramme der Regressionsvorhersagen auf Lebenshilfe	89
21	KDE-Dichteverteilungen der BiLSTM-MixUp-Regressoren	90
22	Dichteverteilungen und Diskriminationsleistung des Synthetischen Regressors	92

Tabellenverzeichnis

1	Übersicht des akquirierten Rohdatenbestands nach Quellen	17
2	Übersicht der quantitativen Korpusstatistiken	23
3	Benchmark der Klassifikationsmodelle auf dem Lebenshilfe-Goldstandard .	30
4	Längen-Benchmark der BiLSTM MixUp Regressoren auf dem Lebenshilfe- Goldstandard	36
5	Gesamtübersicht aller in Themenblock 2 evaluierten Modellansätze	42
6	Einfluss der Token-Kontextlänge auf die SFT-Generierungsqualität	48
7	Untersuchung der Gewichtung bei der kombinierten Bewertung auf dem Lebenshilfe-Testset	52
8	Regularisierungsparameter β im Lebenshilfe-Test	54
9	Ergebnisse der empirischen Experten-Evaluation	60
11	Evaluation auf dem TextComplexityDE-Benchmark	82
12	Evaluation der Regressoren und Baselines auf MERLIN	84
13	Monotonie-Prüfung der Regressoren über 6 CEFR-Niveaustufen auf MERLIN	84
14	In-Domain-Klassifikationsgüte über Similarity-Bereiche	85
15	Gesamtevaluation der vier MixUp-Trainings- und Sampling-Strategien . . .	88
16	Gesamtevaluation aller Regressoren und linguistischen Baselines	91
17	Systematisches Skalierungsverhalten des SFT-Modells	94
18	Statistische Kenngrößen des DPO-Präferenzdatensatzes	95
19	Vollständiger Skalierungsvergleich von SFT und DPO über Kontextlängen .	96
20	Detaillierter Vergleich der linguistischen Regeltreue	97
21	Hyperparameter der neuronalen Bewertungs- und Regressionsmodelle . . .	98
22	Hyperparameter der generativen Übersetzungsmodelle	98
23	Ergebnisse des synthetischen 256-Token Regel-Benchmarks	99

Literaturverzeichnis

- Alva-Manchego, F., Scarton, C., & Specia, L. (2021). The (Un)Suitability of Automatic Evaluation Metrics for Text Simplification. *Computational Linguistics*, 47(4), 861–889. https://doi.org/10.1162/coli_a_00418
- Amstad, T. (1978). *Wie verständlich sind unsere Zeitungen?* Universitätsverlag Freiburg.
- Bamberger, R., & Vanecek, E. (1984). *Lesen – Verstehen – Lernen – Schreiben: Die Wiener Sachtextformel*. Jugend und Volk.
- Battisti, A., Pfütze, D., Säuberli, A., Kostrzewa, M., & Ebling, S. (2020). A Corpus for Automatic Readability Assessment and Text Simplification of German. *Proceedings of the Twelfth Language Resources and Evaluation Conference*, 3302–3311. <https://aclanthology.org/2020.lrec-1.404/>
- Björnsson, C. H. (1968). *Läsbarhet*. Liber.
- Boyd, A., Hana, J., Nicolas, L., Meurers, D., Wisniewski, K., Abel, A., Schöne, K., Štindlová, B., & Vettori, C. (2014). The MERLIN Corpus: Learner Language and the CEFR. *Proceedings of the Ninth International Conference on Language Resources and Evaluation (LREC 2014)*, 1281–1288. <https://aclanthology.org/L14-1488/>
- Bundesministerium des Innern, für Bau und Heimat. (2019). Barrierefreie-Informationstechnik-Verordnung (BITV 2.0) – § 4 Bereitzustellende Auskünfte in Deutscher Gebärdensprache und in Leichter Sprache [Verordnung zur Schaffung barrierefreier Informationstechnik nach dem Behindertengleichstellungsgesetz]. Verfügbar 3. September 2026 unter https://www.gesetze-im-internet.de/bitv_2_0/___4.html
- Bundesministerium für Arbeit und Soziales. (2025). *Leichte Sprache: Ein Ratgeber zu den Regeln von Leichter Sprache* [Publikationsportal der Bundesregierung, Broschüre A752L (Publikationsnummer 2350610), 82 Seiten]. Verfügbar 3. September 2026 unter <https://www.publikationen-bundesregierung.de/pp-de/publikationssuche/regeln-leichte-sprache-2350610>
- Chotlos, J. W. (1944). Studies in Language Behavior: IV. A Statistical and Comparative Analysis of Individual Written Language Samples. *Psychological Monographs*, 56(2), 75–111. <https://doi.org/10.1037/h0093511>
- Covington, M. A., & McFall, J. D. (2010). Cutting the Gordian Knot: The Moving-Average Type-Token Ratio (MATTR). *Journal of Quantitative Linguistics*, 17(2), 94–100. <https://doi.org/10.1080/09296171003643098>
- Devaraj, A., Sheffield, W., Wallace, B., & Li, J. J. (2022). Evaluating Factuality in Text Simplification. *Proceedings of the 60th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, 7331–7345. <https://doi.org/10.18653/v1/2022.acl-long.506>
- Devlin, J., Chang, M.-W., Lee, K., & Toutanova, K. (2019). BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding. *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational*

- Linguistics: Human Language Technologies, Volume 1 (Long and Short Papers)*, 4171–4186. <https://doi.org/10.18653/v1/N19-1423>
- Günther, M., Ong, J., Mohr, I., Abdessalem, A., Abel, T., Akram, M. K., Guzman, S., Mastrapas, G., Sturua, S., Wang, B., Werk, M., Wang, N., & Xiao, H. (2023). Jina Embeddings 2: 8192-Token General-Purpose Text Embeddings for Long Documents. *arXiv preprint arXiv:2310.19923*. <https://doi.org/10.48550/arXiv.2310.19923>
- Hochreiter, S., & Schmidhuber, J. (1997). Long Short-Term Memory. *Neural Computation*, 9(8), 1735–1780. <https://doi.org/10.1162/neco.1997.9.8.1735>
- Honnibal, M., Montani, I., Van Landeghem, S., & Boyd, A. (2020). *spaCy: Industrial-strength Natural Language Processing in Python*. Zenodo. <https://doi.org/10.5281/zenodo.1212303>
- Hu, E. J., Shen, Y., Wallis, P., Allen-Zhu, Z., Li, Y., Wang, S., Wang, L., & Chen, W. (2022). LoRA: Low-Rank Adaptation of Large Language Models. *International Conference on Learning Representations (ICLR)*. <https://openreview.net/forum?id=nZeVKeeFYf9>
- Klaper, D., Ebling, S., & Volk, M. (2013). Building a German/Simple German Parallel Corpus for Automatic Text Simplification. *Proceedings of the Second Workshop on Predicting and Improving Text Readability for Target Reader Populations (PITR@ACL 2013)*, 11–19. <https://aclanthology.org/W13-2902/>
- Korobeynikova, M., Battisti, A., Fischer, L., & Gao, Y. (2026). DETECT: Determining Ease and Textual Clarity of German Text Simplifications. *Proceedings of the 19th Conference of the European Chapter of the Association for Computational Linguistics (Volume 1: Long Papers)*, 2852–2882. <https://doi.org/10.18653/v1/2026.eacl-long.131>
- Lewis, M., Liu, Y., Goyal, N., Ghazvininejad, M., Mohamed, A., Levy, O., Stoyanov, V., & Zettlemoyer, L. (2020). BART: Denoising Sequence-to-Sequence Pre-training for Natural Language Generation, Translation, and Comprehension. *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics*, 7871–7880. <https://doi.org/10.18653/v1/2020.acl-main.703>
- Lin, C.-Y. (2004). ROUGE: A Package for Automatic Evaluation of Summaries. *Text Summarization Branches Out: Proceedings of the ACL-04 Workshop*, 74–81. <https://aclanthology.org/W04-1013/>
- Liu, Y., Gu, J., Goyal, N., Li, X., Edunov, S., Ghazvininejad, M., Lewis, M., & Zettlemoyer, L. (2020). Multilingual Denoising Pre-training for Neural Machine Translation. *Transactions of the Association for Computational Linguistics*, 8, 726–742. https://doi.org/10.1162/tacl_a_00343
- Loshchilov, I., & Hutter, F. (2017). SGDR: Stochastic Gradient Descent with Warm Restarts. *Proceedings of the International Conference on Learning Representations (ICLR)*. <https://openreview.net/forum?id=Skq89Scxx>

- Loshchilov, I., & Hutter, F. (2019). Decoupled Weight Decay Regularization. *International Conference on Learning Representations (ICLR)*. <https://openreview.net/forum?id=Bkg6RiCqY7>
- Madina, M., Gonzalez-Dios, I., & Siegel, M. (2023). Easy-to-Read in Germany: A Survey on its Current State and Available Resources. *Proceedings of the 10th Language & Technology Conference (LTC 2023)*, 162–166. <https://doi.org/10.48550/arXiv.2306.03189>
- Nadeau, D., & Sekine, S. (2007). A survey of named entity recognition and classification. *Linguisticae Investigationes*, 30(1), 3–26. <https://doi.org/10.1075/li.30.1.03nad>
- Naderi, B., Mohtaj, S., Ensikat, K., & Möller, S. (2019). TextComplexityDE: A Dataset for German Text Readability and Complexity. *Proceedings of the 15th Conference on Natural Language Processing (KONVENS 2019)*, 202–211. <https://arxiv.org/abs/1904.07733>
- Ouyang, L., Wu, J., Jiang, X., Almeida, D., Wainwright, C., Mishkin, P., Zhang, C., Agarwal, S., Slama, K., Ray, A., et al. (2022). Training Language Models to Follow Instructions with Human Feedback. *Advances in Neural Information Processing Systems*, 35, 27730–27744. https://proceedings.neurips.cc/paper_files/paper/2022/hash/b1efde53be364a73914f58805a001731-Abstract-Conference.html
- Papineni, K., Roukos, S., Ward, T., & Zhu, W.-J. (2002). BLEU: a Method for Automatic Evaluation of Machine Translation. *Proceedings of the 40th Annual Meeting of the Association for Computational Linguistics*, 311–318. <https://doi.org/10.3115/1073083.1073135>
- Portal Barrierefreiheit / BFIT Bund. (2026). *Leichte Sprache – Übergreifende Anforderungen für Web und App*. Verfügbar 8. August 2026 unter https://www.barrierefreiheit-dienstekonsolidierung.bund.de/Webs/PB/DE/barrierefreie_it/uebergreifende-anforderungen-web-und-app/leichte-sprache/leichte-sprache-artikel.html
- Press, O., Smith, N. A., & Lewis, M. (2022). Train Short, Test Long: Attention with Linear Biases Enables Input Length Extrapolation. *Proceedings of the 10th International Conference on Learning Representations (ICLR)*. <https://openreview.net/forum?id=R8sQPpGCv0>
- Rafailov, R., Sharma, A., Mitchell, E., Ermon, S., Manning, C. D., & Finn, C. (2023). Direct Preference Optimization: Your Language Model is Secretly a Reward Model. *Advances in Neural Information Processing Systems*, 36, 53728–53741. https://proceedings.neurips.cc/paper_files/paper/2023/hash/a85b405ed65c6477a4fe8302b5e06ce7-Abstract-Conference.html
- Reimers, N., & Gurevych, I. (2019). Sentence-BERT: Sentence Embeddings using Siamese BERT-Networks. *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing (EMNLP-IJCNLP)*, 3982–3992. <https://doi.org/10.18653/v1/D19-1410>

- Säuberli, A., Ebling, S., & Volk, M. (2020). Benchmarking Data-driven Automatic Text Simplification for German. *Proceedings of the 1st Workshop on Tools and Resources to Empower People with REAding Difficulties (READI)*, 41–48. <https://aclanthology.org/2020.readi-1.7/>
- Schulman, J., Wolski, F., Dhariwal, P., Radford, A., & Klimov, O. (2017). Proximal Policy Optimization Algorithms. *arXiv preprint arXiv:1707.06347*. <https://doi.org/10.48550/arXiv.1707.06347>
- Schuster, M., & Paliwal, K. K. (1997). Bidirectional Recurrent Neural Networks. *IEEE Transactions on Signal Processing*, 45(11), 2673–2681. <https://doi.org/10.1109/78.650093>
- Sennrich, R., Haddow, B., & Birch, A. (2016). Neural Machine Translation of Rare Words with Subword Units. *Proceedings of the 54th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, 1715–1725. <https://doi.org/10.18653/v1/P16-1162>
- Štajner, S., Franco-Salvador, M., Rosso, P., & Ponzetto, S. P. (2018). CATS: A Tool for Customized Alignment of Text Simplification Corpora. *Proceedings of the Eleventh International Conference on Language Resources and Evaluation (LREC 2018)*, 4287–4292. <https://aclanthology.org/L18-1615/>
- Stodden, R., Momen, O., & Kallmeyer, L. (2023). DEplain: A German Parallel Corpus with Intralingual Translations into Plain Language for Sentence and Document Simplification. *Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, 16441–16463. <https://doi.org/10.18653/v1/2023.acl-long.908>
- Tang, Y., Tran, C., Li, X., Chen, P.-J., Goyal, N., Chaudhary, V., Gu, J., & Fan, A. (2021). Multilingual Translation from Denoising Pre-Training. *Findings of the Association for Computational Linguistics: ACL-IJCNLP 2021*, 3450–3466. <https://doi.org/10.18653/v1/2021.findings-acl.304>
- Templin, M. C. (1957). *Certain Language Skills in Children: Their Development and Interrelationships*. The University of Minnesota Press.
- Toborek, V., Busch, M., Boßert, M., Bauckhage, C., & Welke, P. (2023). A New Aligned Simple German Corpus. *Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, 11393–11412. <https://doi.org/10.18653/v1/2023.acl-long.638>
- Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, Ł., & Polosukhin, I. (2017). Attention is All You Need. *Advances in Neural Information Processing Systems*, 30, 5998–6008. https://proceedings.neurips.cc/paper_files/paper/2017/hash/3f5ee243547dee91fbd053c1c4a845aa-Abstract.html
- Xu, W., Napoles, C., Pavlick, E., Chen, Q., & Callison-Burch, C. (2016). Optimizing Statistical Machine Translation for Text Simplification. *Transactions of the Association for Computational Linguistics*, 4, 401–415. https://doi.org/10.1162/tacl_a_00107

Zhang, H., Cisse, M., Dauphin, Y. N., & Lopez-Paz, D. (2018). mixup: Beyond Empirical Risk Minimization. *International Conference on Learning Representations (ICLR)*.
<https://openreview.net/forum?id=r1Ddp1-Rb>

A Anhang

A.1 Ergänzende Evaluation auf TextComplexityDE (Naderi et al., 2019)

In diesem Abschnitt sind die ergänzenden empirischen Auswertungen zur Bewertung der Satzkomplexität auf dem *TextComplexityDE*-Benchmark (Naderi et al., 2019) ($N = 1.000$ deutsche Wikipedia-Sätze mit menschlichen Likert-Bewertungen) für die MixUp-Regressoren und traditionellen Baselines dargestellt.

Tabelle 11: Evaluation der auf bidirektionalen Long-Short-Term-Memory-Netzwerken basierenden MixUp-Regressoren (BiLSTM) und traditioneller Lesbarkeitsmetriken wie dem Lesbarkeitsindex (LIX), der Wiener Sachtextformel (WSTF) und dem Flesch Reading Ease (Flesch) auf dem TextComplexityDE-Benchmark ($N = 1.000$ deutsche Wikipedia-Einzelsätze, dynamisches Padding) unter Angabe des mittleren absoluten Fehlers (Mean Absolute Error, MAE).

Modell	Kategorie	Pearson r (Simplicity)	Spearman ρ (Rang)	Kendall τ	MAE (normiert)
LIX Lesbarkeitsindex	Baseline	0,657	0,641	0,467	0,177
BiLSTM MixUp Regressor (256)	Regressor (256)	0,620	0,579	0,418	0,198
BiLSTM MixUp Regressor (512)	Regressor (512)	0,610	0,590	0,424	0,329
BiLSTM MixUp Regressor (1.024)	Regressor (1.024)	0,595	0,601	0,430	0,473
Wiener Sachtextformel	Baseline	0,540	0,519	0,370	0,164
Flesch Reading Ease	Baseline	0,456	0,456	0,322	0,174




Abbildung 14: Korrelationsanalyse auf dem TextComplexityDE-Benchmark ($N = 1.000$ Wikipedia-Sätze) im Vergleich zwischen linearem Zusammenhang (Pearson r) und monotonem Rangzusammenhang (Spearman ρ) mit dem menschlichen Bewertungsmittelwert (Mean Opinion Score, MOS) für BiLSTM-Modelle, die Wiener Sachtextformel (WSTF), Flesch Reading Ease (FRE) und den Lesbarkeitsindex (LIX).

Streudiagramme der Regressoren und Lesescores vs. menschliche Einfachheit (TextComplexityDE)




Abbildung 15: Streudiagramm-Grid aller Modellansätze gegen den menschlichen Einfachheits-Score (Mean Opinion Score, MOS) auf dem TextComplexityDE-Datensatz ($N = 1.000$ Sätze) für BiLSTM-Architekturen, die Wiener Sachtextformel (WSTF), den Lesbarkeitsindex (LIX) und den Flesch Reading Ease (FRE) inklusive linearer Regressionsgeraden.

A.2 Ergänzende Evaluation auf dem MERLIN CEFR-Benchmark (Boyd et al., 2014)

In diesem Abschnitt sind die detaillierten statistischen Auswertungen zur Dokumenten- und Fließtextevaluation auf dem *MERLIN*-Korpus (Boyd et al., 2014) ($N = 1.033$ deutsche Volltexte mit offiziellen CEFR-Niveaustufen *A1* bis *C2*) dokumentiert.

Tabelle 12: Evaluation der BiLSTM-MixUp-Regressoren und traditioneller Formeln (LIX, WSTF, Flesch) auf dem Dokumenten-Benchmark des Gemeinsamen Europäischen Referenzrahmens für Sprachen (CEFR, *MERLIN*-Korpus mit $N = 1.033$ Volltexten) unter Angabe des mittleren absoluten Fehlers (Mean Absolute Error, MAE).

Modell	Kategorie	Pearson r (Simplicity)	Spearman ρ (Rang)	Kendall τ	MAE (normiert)
LIX Lesbarkeitsindex	Baseline	0,632	0,656	0,515	0,127
Wiener Sachtextformel	Baseline	0,584	0,602	0,463	0,137
Flesch Reading Ease	Baseline	0,513	0,543	0,412	0,144
BiLSTM MixUp Regressor (256)	Regressor (256)	0,459	0,485	0,369	0,310
BiLSTM MixUp Regressor (512)	Regressor (512)	0,346	0,347	0,264	0,346
BiLSTM MixUp Regressor (1.024)	Regressor (1.024)	0,251	0,238	0,183	0,363

Tabelle 13: Mittelwerte der vorhergesagten Modell-Scores über sechs Niveaustufen des Gemeinsamen Europäischen Referenzrahmens für Sprachen (CEFR, *A1* bis *C2*) im *MERLIN*-Korpus ($N = 1.033$ Texte) zur Überprüfung des monotonen Abfalls für BiLSTM-MixUp-Regressoren und die Wiener Sachtextformel (WSTF).

CEFR-Stufe	MixUp Reg. (256)	MixUp Reg. (512)	MixUp Reg. (1.024)	Wiener Formel
A1 (Sehr einfach, $N = 57$)	0,3712	0,3411	0,2337	-1,28
A2 (Einfach, $N = 306$)	0,3584	0,3349	0,2572	-1,52
B1 (Mittelstufe, $N = 331$)	0,2888	0,2878	0,2443	-2,38
B2 (Fortgeschritten, $N = 293$)	0,1810	0,1866	0,1643	-4,57
C1 (Fachsprache, $N = 42$)	0,1085	0,1233	0,0943	-5,30
C2 (Muttersprachlich, $N = 4$)	0,0784	0,1078	0,0859	-5,24

A.3 Ergänzende Evaluation der Klassifikationsmodelle (Ähnlichkeitsbereiche & Granularitätsvergleich)

In diesem Abschnitt sind die ergänzenden empirischen Auswertungen zur binären Klassifikation dokumentiert: Tabelle 14 stellt die In-Domain-Klassifikationsgüte (Balanced Accuracy) über verschiedene Filterungsbereiche der Kosinus-Ähnlichkeit des internen Master-Korpus auf Satz- und Artekelebene gegenüber. Die Abbildungen 16 bis 18 visualisieren die Dichteverteilungen, ROC/PR-Kurven und Konfusionsmatrizen auf dem bereinigten *Lebenshilfe*-Goldstandard ($N = 37$ Artikelpaare / 74 Dokumente, 6.901 Einzelsätze).

Tabelle 14: In-Domain-Klassifikationsgüte anhand der ausgewogenen Genauigkeit (Balanced Accuracy, BAcc) des BiLSTM in Abhängigkeit vom Schwellenbereich der Kosinus-Ähnlichkeit (sim_{cos} via Jina-v2) und der Granularitätsebene auf dem internen Test-Split des Master-Korpus.

Similarity-Bereich	Artikelpaare (Anzahl)	Sätze (balanciert)	Satz-Level BAcc	Artikel-Level BAcc
$0,60 \leq \text{sim}_{\text{cos}} \leq 0,98$	1.474	~ 29.700	92,48 %	95,93 %
$0,70 \leq \text{sim}_{\text{cos}} \leq 0,98$	1.362	~ 27.700	92,43 %	97,30 %
$0,80 \leq \text{sim}_{\text{cos}} \leq 0,98$	1.032	~ 21.400	92,99 %	99,03 %
$0,90 \leq \text{sim}_{\text{cos}} \leq 0,98$	213	~ 4.800	90,55 %	98,44 %




Abbildung 16: Dichteschätzungen (Kernel Density Estimation, KDE) der vorhergesagten Wahrscheinlichkeiten für reine Leichte Sprache (LS) und reine Alltagssprache (AS) auf dem Lebenshilfe-Goldstandard ($N = 37$ Artikelpaare / 74 Dokumente) im Vergleich zwischen dem BiLSTM-Satzmodell mit Simple-Sentence-Ratio (r_{LS}) und direkten Dokumentmodellen über 256, 512 und 1.024 Tokens.




Abbildung 17: Gegenüberstellung der ROC-Kurven (Receiver Operating Characteristic, ROC-AUC) und Precision-Recall-Kurven (PR-AUC) für Satz- und Artikel-Klassifikationsmodelle auf Basis bidirektionaler Long-Short-Term-Memory-Netzwerke (BiLSTM) auf dem Lebenshilfe-Goldstandard ($N = 74$ Dokumente).




Abbildung 18: Konfusionsmatrizen und Performanzmetriken der binären BiLSTM-Klassifikatoren zur Unterscheidung von Alltagssprache (AS) und Leichter Sprache (LS) auf dem Lebenshilfe-Goldstandard unter Aufschlüsselung nach Richtig-Positiven (TP), Richtig-Negativen (TN), Falsch-Positiven (FP) und Falsch-Negativen (FN).

A.4 Ergänzende Evaluation der MixUp Trainings- und Sampling-Strategien (Varianten A–D)

In diesem Abschnitt sind die empirischen Benchmark-Ergebnisse und grafischen Analysen zu den vier untersuchten Dataloader- und Optimierungsstrategien des kontinuierlichen BiLSTM-MixUp-Regressors dokumentiert:

- **Variante A (Statisch):** Feste Vorabmischung und Shuffling bei der Initialisierung des Datasets ($p_{\text{dynamic}} = 0,0$).
- **Variante B (Dynamisch):** Rein dynamisches On-the-Fly-Mischen und Shuffling pro Batch ($p_{\text{dynamic}} = 1,0$).
- **Variante C (Hybrid):** Epochenabhängiges Curriculum-Mischen mit linear ansteigendem Dynamic-Anteil ($p_{\text{dynamic}} = \frac{\text{Epoche}}{\text{Gesamtepochen}}$).
- **Variante D (Hybrid + Cyclic LR):** Hybrid-Mischung kombiniert mit zyklischem Lernratenscheduling mittels *CosineAnnealingWarmRestarts*.

Tabelle 15 stellt die Gütemaße auf dem internen Test-Split (In-Domain, $N = 2.968$ Sätze / 2.560 Mischungen) und dem externen *Lebenshilfe*-Goldstandard (Out-of-Domain, $N = 2.236$ Sätze / 1.476 Mischungen) gegenüber. Die Abbildungen 19 und 20 visualisieren die resultierenden Dichteverteilungen und Regressions-Trajektorien auf dem Lebenshilfe-Datensatz.

Tabelle 15: Gesamtevaluation der vier kontinuierlichen Textmischungsstrategien (MixUp-Varianten A bis D) auf dem internen Test-Split ($N = 2.560$ Mischungen) und dem Lebenshilfe-Goldstandard ($N = 1.476$ Mischungen) unter Gegenüberstellung von mittlerem quadratischem Fehler (Mean Squared Error, MSE), mittlerem absolutem Fehler (Mean Absolute Error, MAE) und ausgewogener Genauigkeit (Balanced Accuracy, BAcc).

Sampling-Strategie	In-Domain Test-Split					Out-of-Domain Lebenshilfe				
	$\mathcal{O} \lambda$ (LS)	$\mathcal{O} \lambda$ (AS)	BAcc	Reg-MSE	Reg-MAE	$\mathcal{O} \lambda$ (LS)	$\mathcal{O} \lambda$ (AS)	BAcc	Reg-MSE	Reg-MAE
Variante A (Statisch)	0,777	0,075	94,79 %	0,0279	0,1234	0,701	0,084	91,82 %	0,0466	0,1705
Variante B (Dynamisch)	0,802	0,067	96,08 %	0,0267	0,1182	0,701	0,073	93,85 %	0,0493	0,1724
Variante C (Hybrid)	0,801	0,082	95,92 %	0,0275	0,1222	0,707	0,086	92,02 %	0,0469	0,1668
Variante D (Hybrid + Cyclic LR)	0,799	0,086	95,87 %	0,0275	0,1221	0,715	0,091	94,36 %	0,0451	0,1656

Vergleich der MixUp-Regressoren auf dem Lebenshilfe-Datensatz (Reine Sätze) vs. Trainings-Target-Verteilung




Abbildung 19: Dichteverteilungen (Kernel Density Estimation, KDE) der vorhergesagten Regressionswerte für reine Alltagssprache (AS) und reine Leichte Sprache (LS) auf dem Lebenshilfe-Goldstandard im Vergleich zur theoretischen Zielverteilung über die vier kontinuierlichen BiLSTM-MixUp-Strategien.

Vergleich der MixUp-Regressoren: Ist- vs. Soll-Werte auf dem Lebenshilfe-Set




Abbildung 20: Streudiagramme der Regressionsvorhersagen $\hat{\lambda}$ auf dem Lebenshilfe-Goldstandard ($N = 1.476$ synthetische Textmischungen) gegen den relativen Zeichenlängenanteil Leichter Sprache ($\lambda \in [0,0,1,0]$) für die vier kontinuierlichen BiLSTM-MixUp-Strategien inklusive Regressionsgeraden.

A.5 Ergänzende Evaluation der BiLSTM MixUp Regressoren (Längenvergleich)

In diesem Abschnitt sind die ergänzenden grafischen Auswertungen zur Untersuchung der Kontextlängen der kontinuierlichen BiLSTM MixUp Regressoren (256, 512 und 1.024 Tokens) auf dem *Lebenshilfe*-Goldstandard dargestellt.




Abbildung 21: Dichteschätzungen (Kernel Density Estimation, KDE) der kontinuierlichen BiLSTM-MixUp-Regressoren für Leichte Sprache (LS) und Alltagssprache (AS) auf dem Lebenshilfe-Goldstandard ($N = 37$ Artikelpaare / 74 Dokumente) über variierende Kontextfenster von 256, 512 und 1.024 Tokens.

A.6 Ergänzende Evaluation des Synthetischen Regressors & Prompt-Design


In diesem Abschnitt sind die ergänzenden empirischen Auswertungen zum synthetischen BiLSTM-Regressor sowie das vollständige Prompt-Design zur Erzeugung der Zwischenstufen dokumentiert.

A.6.1 Master-Benchmark auf dem Lebenshilfe-Goldstandard


Tabelle 16 stellt die Evaluierung des Synthetischen Regressors auf dem unabhängigen *Lebenshilfe*-Goldstandard ($N = 37$ Artikelpaare / 74 Dokumente, 185 Multi-Stufen-Samples) den MixUp-Regressoren und linguistischen Formeln gegenüber.

Tabelle 16: Gesamtevaluation aller kontinuierlichen und diskreten Modellansätze auf dem Lebenshilfe-Goldstandard ($N = 37$ Artikelpaare / 74 Dokumente) im Vergleich zwischen BiLSTM-MixUp-Regressoren, dem auf großen Sprachmodellen basierenden Synthetischen Regressor (Large Language Models, LLM) und Basisarchitekturen (Recurrent Neural Networks, RNN).

Modell	Ebene / Input	$\mathcal{O}$ Score (LS)	$\mathcal{O}$ Score (AS)	Separation (Δ)	Balanced Acc	ROC-AUC	Pair Match
BiLSTM MixUp Regressor (1.024)	Dokument (1.024 Tok.)	0,727 $\pm$ 0,14	0,100 $\pm$ 0,09	0,627	97,30 %	1,0000	100,0 % (37/37)
BiLSTM MixUp Regressor (512)	Dokument (512 Tok.)	0,716 $\pm$ 0,12	0,069 $\pm$ 0,09	0,646	98,65 %	0,9993	97,3 % (36/37)
BiLSTM MixUp Regressor (256)	Dokument (256 Tok.)	0,698 $\pm$ 0,11	0,105 $\pm$ 0,09	0,593	95,95 %	0,9982	97,3 % (36/37)
BiLSTM Synthetischer Regressor	Dokument (LLM-Stufen)	0,575 $\pm$ 0,35	0,145 $\pm$ 0,18	0,429	78,38 %	0,8495	89,2 % (33/37)
Vanilla RNN Baseline (Ablation)	Dokument (256 Tok.)	0,443 $\pm$ 0,20	0,345 $\pm$ 0,18	0,098	67,57 %	0,7761	70,3 % (26/37)
Flesch Reading Ease (Baseline)	Dokument (Silben/Satz)	0,973 $\pm$ 0,16	0,189 $\pm$ 0,39	0,784	89,19 %	0,8919	100,0 % (37/37)
Wiener Sachtextformel (Baseline)	Dokument (Wortlänge)	0,919 $\pm$ 0,27	0,108 $\pm$ 0,31	0,811	90,54 %	0,9054	100,0 % (37/37)



(a) Dichteverteilungen (KDE)



(b) ROC-Kurven aller Regressoren

Abbildung 22: Dichteverteilungen (Kernel Density Estimation, KDE) und Diskriminationsleistung (Receiver Operating Characteristic, ROC) des Synthetischen Regressors im Vergleich zu Satzmischungen und linguistischen Baselines auf dem Lebenshilfe-Goldstandard ($N = 37$ Artikelpaare / 74 Dokumente) zur Trennung von Alltagssprache (AS) und Leichter Sprache (LS).

A.6.2 Prompt-Design zur Generierung synthetischer Zwischenstufen

Zur Erzeugung der synthetischen Zwischenstufen (0,25, 0,50, 0,75) wurde das Open-Source-Modell FlensGen-GPT-OSS-120B (gehostet an der Hochschule Flensburg) per API mit folgender System- und User-Prompt-Struktur parametrisiert (Sampling-Temperatur $T = 0,2$, Top-p 0,95):

System-Prompt: Synthetische Komplexitätsabstufung

Du bist ein Experte für die deutsche Sprache und Textvereinfachung.

Dir wird ein Artikel in zwei verschiedenen Schwierigkeitsgraden vorgelegt:

1. Leichte Sprache (LS / Stufe 1.0): Extrem vereinfacht, kurze Sätze, sehr einfache Satzstruktur, oft mit Zeilenumbrüchen nach jedem Satzteil, geringe Wortkomplexität, keine Fremdwörter, Fachbegriffe werden direkt erklärt.
2. Alltagssprache (AS / Stufe 0.0): Der normale Originaltext, komplexer Satzbau, reichhaltiger Wortschatz, Nebensätze, Passiv- und Genitivkonstruktionen, Fachbegriffe.

Deine Aufgabe ist es, eine neue Version dieses Artikels zu schreiben, die sprachlich präzise auf einer bestimmten Stufe zwischen diesen beiden Versionen liegt.

Die Skala reicht von 0.0 (Alltagssprache) bis 1.0 (Leichte Sprache).

Dir wird ein bestimmter Zielwert (z.B. 0.25, 0.50, 0.75) vorgegeben.

Richtlinien für die Stufen:

- Stufe 0.75 (Nahe an Leichter Sprache):
 - * Der Text soll sehr leicht verständlich sein.
 - * Verwende überwiegend einfache Sätze, aber du darfst einzelne einfache Nebensätze (z.B. mit "weil", "wenn", "dass") einbauen.
 - * Der Wortschatz darf minimal anspruchsvoller sein als in der LS-Version (z.B. geläufige Wörter anstelle von extremen Umschreibungen), aber vermeide Fremdwörter.
 - * Informationen sollten sehr klar gegliedert sein, aber es muss nicht jeder Satzteil in einer neuen Zeile stehen.
- Stufe 0.50 (Die goldene Mitte / Einfache Sprache):
 - * Dies entspricht der typischen "Einfachen Sprache" (Simple Language).
 - * Verwende eine Mischung aus kurzen und mittelschweren Sätzen.
 - * Vermeide Schachtelsätze (mehrere Nebensätze ineinander), aber ein Hauptsatz mit einem Nebensatz ist der Standard.
 - * Der Wortschatz ist alltäglich, ohne extreme Fach- oder Fremdwörter.
 - * Der Text fließt natürlicher als Leichte Sprache, behält aber die gute Verständlichkeit bei.
- Stufe 0.25 (Nahe an Alltagssprache):
 - * Der Text ist nur leicht vereinfacht im Vergleich zur AS-Version.
 - * Schachtelsätze werden weitgehend in zwei separate Sätze aufgeteilt.
 - * Schwierige Fachbegriffe oder Fremdwörter werden entweder vermieden, durch geläufigere Wörter ersetzt oder im Satz kurz erklärt.
 - * Der Satzbau ist flüssig und entspricht einem gut lesbaren Zeitungsartikel.

Wichtige Regeln:

1. Verändere den Inhalt nicht: Es dürfen keine Fakten oder Informationen hinzuerfunden oder weggelassen werden, die nicht in den beiden Quelltexten vorhanden sind.
2. Orientiere dich stilistisch und inhaltlich an den vorgegebenen Versionen.
3. Gib ausschließlich den neu generierten Text zurück. Keine Metakommentare, keine Erklärungen, keine Anmerkungen, keine Markdown-Codeblöcke. Beginne direkt mit dem Text des Artikels.

User-Prompt-Template: Übergabe der Artikelpaare

Hier sind die beiden Versionen des Artikels:

Version 1: Leichte Sprache (LS / Stufe 1.0):
{ls_text}

Version 2: Alltagssprache (AS / Stufe 0.0):
{as_text}

Ziel-Stufe: {target_level}

Erstelle nun den Text, der genau auf der Ziel-Stufe {target_level} liegt. Befolge alle stilistischen Richtlinien für diese Stufe. Antworte nur mit dem generierten Text.

A.7 Ergänzende Auswertung zur SFT-Datenskalierung

In diesem Abschnitt sind die vollständigen quantitativen Resultate der Skalierungsstudie für das überwachte Feintuning (Supervised Fine-Tuning, SFT) über variierende Trainingsdatensmengen (10 % bis 100 %) auf dem ungesehenen Lebenshilfe-Testset ($N = 37$) dokumentiert.

Tabelle 17: Systematisches Skalierungsverhalten des überwachten Feintunings (Supervised Fine-Tuning, SFT) auf dem Lebenshilfe-Testset ($N = 37$ Artikelpaare) über fünf Datenfraktionen unter Angabe von Stilbewertung (R_{style} via BiLSTM-MixUp-Regressor), semantischer Quellähnlichkeit ($R_{\text{sem, AS}}$), Composite Reward und Satzabbruchquoten (Truncation).

Experiment	Fraktion	Paare (N)	Val Loss	R_{style}	$R_{\text{sem, AS}}$	Composite	Truncation
sft_scale_f010	10 %	64	3,7021	0,1152	0,8965	0,5058	16,22 %
sft_scale_f025	25 %	160	2,7457	0,5559	0,9276	0,7417	70,27 %
sft_scale_f050	50 %	320	2,6454	0,5503	0,9119	0,7311	59,46 %
sft_scale_f075	75 %	481	2,7217	0,6753	0,9028	0,7891	75,68 %
sft_scale_f100	100 %	641	2,5698	0,7759	0,8880	0,8320	29,73 %

A.8 Ergänzende Kenngrößen des DPO-Präferenzdatensatzes (mBART-50)

In diesem Abschnitt sind die vollständigen statistischen Kenngrößen des synthetisch generierten DPO-Präferenzdatensatzes (mBART-50-Modell) auf Basis des *10kGNAD*-Prompt-Korpus dokumentiert.

Tabelle 18: Statistische Kenngrößen des generierten Präferenzdatensatzes für die direkte Präferenzoptimierung (Direct Preference Optimization, DPO) auf Basis des multilingualen Sequence-to-Sequence-Modells **mBART-50** über verschiedene Temperaturstufen T und Belohnungsmargen ΔR .

Metrik / Eigenschaft	Wert (mBART-50 Seq2Seq)
Verarbeitete Quellprompts	9.567 Prompts
Gesamtzahl valide Präferenztripel	9.246 Paare (96,6 % Retention)
– Trainings-Split (85 %)	7.859 Paare
– Validierungs-Split (15 %)	1.387 Paare
Mittlerer Score Bevorzugt ($\bar{R}_{\text{chosen}}$)	0,8218
Mittlerer Score Abgelehnt ($\bar{R}_{\text{rejected}}$)	0,7007
Mittlere Präferenzmarge ($\bar{\Delta R}$)	0,1210
Auflösung nach Temperaturstufen:	
– Aufgelöst bei $T = 0,60$	3.008 Paare (32,5 %)
– Aufgelöst bei $T = 0,70$	5.001 Paare (54,1 %)
– Aufgelöst bei $T = 0,80$	1.013 Paare (11,0 %)
– Aufgelöst bei $T = 0,85$	224 Paare (2,4 %)
– Ausgeschieden ($\Delta R < 0,05$ / Fragmente)	321 Prompts (3,4 %)

A.9 Ergänzende Evaluation zur Kontextlängenskalierung (SFT vs. DPO)

Tabelle 19 dokumentiert die detaillierten quantitativen Evaluierungsmaße zur Sequenzlängenskalierung ($L_{\max} \in \{256, 512, 1.024\}$ Tokens) für SFT- und DPO-Modelle auf dem Lebenshilfe-Testset ($N = 37$).

Tabelle 19: Vollständiger Skalierungsvergleich zwischen überwachtem Feintuning (Supervised Fine-Tuning, SFT) und direkter Präferenzoptimierung (Direct Preference Optimization, DPO) über variierende maximale Kontextlängen ($L_{\max}$ in BPE-Tokens) auf dem Lebenshilfe-Testset ($N = 37$ Artikelpaare) unter Angabe von BLEU, ROUGE-1, ROUGE-L und Satzabbruchquote (Truncation).

Modell	Max Len ($L_{\max}$)	R_{style}	$R_{\text{sem, AS}}$	Sim_{ref}	Composite	BLEU	ROUGE-1	ROUGE-L	Ø Gen Tokens	Truncation
sft_len256	256	0,3206	0,9091	0,8827	0,6148	0,0085	0,2121	0,1264	143,0	72,97 %
dpo_len256	256	0,5437	0,9109	0,8902	0,7273	0,0145	0,2514	0,1429	169,3	48,65 %
sft_len512	512	0,3896	0,9235	0,9009	0,6565	0,0201	0,2673	0,1531	207,4	24,32 %
dpo_len512	512	0,5416	0,9168	0,8989	0,7292	0,0200	0,2796	0,1516	216,9	18,92 %
sft_len1024	1.024	0,7004	0,9053	0,8911	0,8028	0,0291	0,3448	0,1704	353,5	27,03 %
dpo_len1024	1.024	0,9023	0,8973	0,8960	0,8998	0,0472	0,4016	0,1851	522,4	32,43 %

A.10 Ergänzende Auswertung zur Einhaltung der Sprachregeln

Tabelle 20 dokumentiert die detaillierten linguistischen Regelmetriken des Ausgangstexts (AS), der SFT-Baseline, des DPO-Modells und der menschlichen Goldreferenz (Lebenshilfe Gold).

Tabelle 20: Detaillierter Vergleich der linguistischen Regeltreue auf dem Lebenshilfe-Testset ($N = 37$ Artikelpaare) im Vergleich zwischen Alltagssprache (AS), dem überwachten Basismodell (Supervised Fine-Tuning, SFT), dem präferenzoptimierten Modell (Direct Preference Optimization, DPO) und der menschlichen Referenz (REF) für Lesbarkeitsmetriken wie Flesch Reading Ease (FRE), Lesbarkeitsindex (LIX) und Wiener Sachtextformel (WSTF).

Linguistische Dimension / Metrik	Ausgangstext (AS)	SFT Baseline ($L = 1.024$)	DPO Modell ($L = 1.024$)	Goldstandard (REF)	Effekt DPO vs. AS / SFT
Mittlere Satzlänge (Wörter / Satz, ↓)	12,50	7,61 (−34,0 %)	6,97	6,79	−39,9 % (nahezu identisch zu Gold)
Anteil langer Sätze (> 12 Wörter, ↓)	42,36 %	9,28 %	4,76 %	3,33 %	−88,8 % (starke Entflechtung)
Nebensatz-Anteil (Subordination, ↓)	10,84 %	4,45 %	5,60 %	1,79 %	−48,3 % (Fokus auf Hauptsätze)
Passiv-Quote (Passivformen / Satz, ↓)	9,28 %	2,26 % (−65,3 %)	0,51 %	2,02 %	−89,1 % (übertrifft Goldstandard)
Genitiv-Quote (Genitivformen / Satz, ↓)	9,17 %	1,59 % (−77,9 %)	0,54 %	1,05 %	−93,8 % (übertrifft Goldstandard)
Nominalstil-Quote (Nominalisierungen, ↓)	4,98 %	3,39 % (−28,0 %)	2,58 %	3,37 %	−46,5 % (übertrifft Goldstandard)
Flesch Reading Ease (DE, ↑)	37,44	61,27 (+23,8)	67,56 (+30,1)	60,67	Höchste Lesbarkeit (über Gold)
LIX Lesbarkeitsindex (↓)	54,18	38,21 (−16,0)	34,16 (−20,0)	38,41	Geringste Textschwere (über Gold)
Wiener Sachtextformel (WSTF, ↓)	11,62	6,84 (−4,8)	5,55 (−6,1)	7,31	Einfachste Schulstufe (5. Klasse)

A.11 Übersicht der Hyperparameter und Trainingskonfigurationen

In diesem Abschnitt sind die vollständigen Hyperparameter und Trainingskonfigurationen für alle in der Arbeit entwickelten Modellkomponenten systematisch zusammengestellt. Tabelle 21 dokumentiert die Konfigurationen der neuronalen Klassifikations- und Regressionsmodelle (BiLSTM, Synthetischer Regressor, Baseline). Tabelle 22 führt die Trainingsparameter der überwachten Übersetzungsmodelle (Supervised Fine-Tuning, SFT) sowie der direkten Präferenzoptimierung (Direct Preference Optimization, DPO) für Sequence-to-Sequence- und Decoder-Only-Architekturen auf.

Tabelle 21: Hyperparameter und Trainingskonfigurationen der neuronalen Bewertungs- und Regressionsmodelle zur Bestimmung der sprachlichen Simplität (BiLSTM-Klassifikatoren, MixUp-Regressoren, synthetische Regressoren und unidirektionale RNN-Baseline).

Parameter / Eigenschaft	BiLSTM Satz-Klassifikator	BiLSTM Artikel-Klassifikator (256/512/1024)	BiLSTM MixUp-Regressor (256/512/1024)	RNN Baseline (Unidirektional)
Tokenizer	spaCy de_core_news_sm	spaCy de_core_news_sm	spaCy de_core_news_sm	spaCy de_core_news_sm
Vokabulargröße ($ V $)	≈ 25.000	20.000 bis 25.000	≈ 25.000	≈ 25.000
Einbettungsdimension	128	128	128	128
Hidden-Dimension (h)	128	128	128	128
Verkettete Repräsentation ($\mathbf{h}_{out}$)	256 (2×128)	256 (2×128)	256 (2×128)	128 (1×128)
Rekurrente Schichten	2 (bidirektional)	2 (bidirektional)	2 (bidirektional)	2 (unidirektional)
Dropout (p)	0,40	0,40	0,40	0,40
Klassifikations-/Ausgabekopf	Linear + Sigmoid $\sigma(z)$	Linear + Sigmoid $\sigma(z)$	Linear + Sigmoid $\sigma(z)$	Linear + Sigmoid $\sigma(z)$
Verlustfunktion	Binary Cross Entropy (BCE)	Binary Cross Entropy (BCE)	Mean Squared Error (MSE)	Mean Squared Error (MSE)
Optimierer	AdamW	AdamW	AdamW	AdamW
Lernrate (η)	1×10^{-3}	1×10^{-3}	1×10^{-3}	1×10^{-3}
Weight Decay (λ)	0,01	0,01	0,01	0,01
Batch-Größe	32	32	64	64
Max. Trainings-Epochen	100	100	80	80
Early Stopping Patience	15 Epochen	15 Epochen	15 Epochen	15 Epochen
Datenaugmentierung / MixUp	–	–	160 Mischungen / Paar	160 Mischungen / Paar

Tabelle 22: Hyperparameter und Trainingskonfigurationen der generativen Übersetzungsmodelle für das überwachte Feintuning (SFT) und die direkte Präferenzoptimierung (DPO) für das multilinguale Sequence-to-Sequence-Modell mBART-50 sowie das Decoder-Only-Modell Qwen2.5-1.5B-Instruct.

Parameter / Hyperparameter	mBART-50 SFT (Seq2Seq)	mBART-50 DPO (Seq2Seq)	Qwen2.5-1.5B SFT (Decoder-Only)	Qwen2.5-1.5B DPO (Decoder-Only)
Basismodell	mbart-large-50-many-to-many	mbart-large-50-many-to-many	Qwen2.5-1.5B-Instruct	Qwen2.5-1.5B-Instruct
Parameteranzahl	611 Mio.	611 Mio.	1,54 Mrd.	1,54 Mrd.
Max. Kontextlänge (L_{max})	1.024 Tokens	1.024 Tokens	2.048 Tokens	2.048 Tokens
Trainingsverfahren	Parameter-Efficient (LoRA)	Parameter-Efficient (LoRA)	Parameter-Efficient (LoRA)	Parameter-Efficient (LoRA)
LoRA-Rang (r)	16	16	8	8
LoRA-Skalierung (α)	32 ($\frac{p}{r} = 2,0$)	32 ($\frac{p}{r} = 2,0$)	16 ($\frac{p}{r} = 2,0$)	16 ($\frac{p}{r} = 2,0$)
LoRA-Dropout	0,05	0,05	0,10	0,10
LoRA-Zielmodule	q/k/v/out_proj, fc1/fc2	q/k/v/out_proj, fc1/fc2	q/k/v/o_proj, gate/up/down_proj	q/k/v/o_proj, gate/up/down_proj
Lernrate (η)	5×10^{-5}	5×10^{-6}	1×10^{-4}	2×10^{-6}
DPO-Regularisierung (β)	–	0,20 (Sweep 0,01–0,50)	–	0,10
DPO-Loss-Aggregation	–	Token-Summe (sum)	–	Token-Summe (sum)
Optimierer	AdamW	AdamW	AdamW	AdamW
Weight Decay (λ)	0,01	0,01	0,01	0,01
Warmup-Ratio	10 % linear	10 % linear	10 % linear	10 % linear
Batch-Größe (pro Device)	4	2	4	2
Gradient Accumulation Steps	4	8	4	8
Effektive Batch-Größe	16	16	16	16
Trainings-Epochen	30 (Best: Epochen 25)	3	3	3
Fließkomma-Präzision	FP16 Mixed Precision	FP16 Mixed Precision	Bfloat16 Mixed Precision	Bfloat16 Mixed Precision

A.12 Synthetischer 256-Token Regel-Sensitivitäts-Benchmark

Zur empirischen Überprüfung der Teilmengen-Hypothese und zur systematischen Messung der Messunsicherheiten und Fehlbewertungsrisiken klassischer Lesbarkeitsmetriken (Abschnitt 5.1.2) wurde ein kontrollierter synthetischer Benchmark entwickelt ($N = 30$ Textfassungen aus fünf lebensweltlichen Domänen mit jeweils 100 bis 256 Tokens bzw. zehn zusammenhängenden Sätzen).

Tabelle 23 fasst die quantitativen Metrikergebnisse über die sechs parallelen Störungsstufen zusammen.

Tabelle 23: Ergebnisse des synthetischen 256-Token Regel-Benchmarks ($N = 30$ Textvarianten aus fünf Domänen) im Vergleich zwischen der Basis (perfekte Leichte Sprache), den isolierten 100 %igen Störungsstufen (Konjunktiv II, Passiv, Genitiv, Kombiniert) sowie der Kontrollgruppe (isomorphe Synonym-Paraphrase) unter Auswertung von Flesch Reading Ease (DE), Lesbarkeitsindex (LIX), Wiener Sachtextformel (WSTF-4) und dem trainierten 256-Token BiLSTM-MixUp-Regressor.

Störungs-Variante	Flesch DE (Δ)	LIX (Δ)	WSTF-4 (Δ)	BiLSTM 256 (R_{style})	Relativer Modellabfall
1. Basis (Perfekte Leichte Sprache)	$54,25 \pm 0,00$	$34,54 \pm 0,00$	$7,17 \pm 0,00$	$0,5529 \pm 0,00$	–
2. Konjunktiv II (100 % aller Verben)	$47,94 (-6,31)$	$35,67 (+1,13)$	$7,72 (+0,55)$	0,2078 (–0,3451)	–62,4 %
3. Genitiv (100 % aller Dative)	60,81 (+6,55)	$34,62 (+0,08)$	$5,71 (-1,46)$	0,2535 (–0,2994)	–54,1 %
4. Passiv (100 % aller Sätze)	60,29 (+6,04)	$37,26 (+2,72)$	$6,97 (-0,20)$	$0,7698 (+0,2169)$	+39,2 %
5. Kombiniert (Konjunktiv + Genitiv + Passiv)	$52,73 (-1,52)$	$37,49 (+2,95)$	$7,03 (-0,14)$	$0,4274 (-0,1255)$	–22,7 %
6. Kontrolle (Isomorphe Synonyme)	$54,90 (+0,64)$	$35,21 (+0,67)$	$6,88 (-0,28)$	$0,4249 (-0,1280)$	–23,1 %

Exemplarischer Volltext-Vergleich aller sechs Varianten (Thema 1: Arztbesuch)

Zur qualitativen Nachvollziehbarkeit sind nachfolgend die sechs parallelen Textfassungen des ersten Themas (»Der Besuch beim Arzt«, zehn Sätze) im vollständigen Wortlaut gegenübergestellt:

- 1. Basis (Perfekte Leichte Sprache):** »Ein Mensch geht zu dem Arzt. Der Arzt untersucht den Patienten genau. Der Patient hat starke Schmerzen im Rücken. Die Assistentin misst den Blutdruck sofort. Der Arzt erklärt die richtige Behandlung. Die Apotheke liefert die neuen Medikamente. Der Patient nimmt die Tabletten mit Wasser. Wegen dem schnellen Handeln hilft die Medizin. Der Mann kann bald wieder schmerzfrei arbeiten. Das Büro von dem Arzt ist modern.«
- 2. 100 % Konjunktiv II (Vollständige Injektion nicht-indikativischer Verben):**
 »Ein Mensch geht zu dem Arzt. Der Arzt *untersuchte* den Patienten genau. Der Patient *hätte* starke Schmerzen im Rücken. Die Assistentin *messe* den Blutdruck sofort. Der Arzt *erklärte* die richtige Behandlung. Die Apotheke *lieferte* die neuen Medikamente. Der Patient *nähme* die Tabletten mit Wasser. Wegen dem schnellen Handeln *hülfe* die Medizin. Der Mann *könnte* bald wieder schmerzfrei arbeiten. Das Büro von dem Arzt *wäre* modern.«

3. **100 % Vorgangspassiv (Vollständige Injektion agens-abgewandter Passivstrukturen):** »Ein Mensch wird von dem Arzt untersucht. Der Patient wird von dem Arzt genau untersucht. Starke Schmerzen im Rücken werden von dem Patienten ertragen. Der Blutdruck wird von der Assistentin sofort gemessen. Die richtige Behandlung wird von dem Arzt erklärt. Die neuen Medikamente werden von der Apotheke geliefert. Die Tabletten werden von dem Patienten mit Wasser genommen. Schnelle Hilfe wird von der Medizin geleistet. Die Arbeit wird von dem Mann bald wieder aufgenommen. Das moderne Büro wird von dem Arzt betrieben.«
4. **100 % Genitiv (Vollständige Injektion von Genitivattributen statt Dativumschreibungen):** »Ein Mensch geht des Arztes wegen. Der Arzt untersucht den Patienten *des Hauses*. Der Patient hat starke Schmerzen *des Rückens*. Die Assistentin *des Chefs* misst den Blutdruck. Der Arzt erklärt die Behandlung *des Patienten*. Die Apotheke *des Ortes* liefert die Medikamente. Der Patient nimmt die Tabletten *des Arztes*. Wegen *des* schnellen *Handelns* hilft die Medizin. Der Mann kann wegen *des Erfolgs* schmerzfrei arbeiten. Das Büro *des Arztes* ist modern.«
5. **Kombiniert (Simultane Vollinjektion: Passiv + Konjunktiv + Genitiv):** »Ein Mensch würde von dem Arzt des Hauses untersucht. Der Patient würde von dem Arzt genau untersucht. Starke Schmerzen des Rückens würden von dem Patienten ertragen. Der Blutdruck des Chefs würde von der Assistentin sofort gemessen. Die richtige Behandlung des Patienten würde von dem Arzt erklärt. Die neuen Medikamente der Apotheke würden geliefert. Die Tabletten des Arztes würden mit Wasser genommen. Schnelle Hilfe des Arztes würde geleistet. Die Arbeit des Mannes würde bald wieder aufgenommen. Das moderne Büro des Arztes würde betrieben.«
6. **Kontrollgruppe (Isomorphe Synonym-Paraphrasen bei 100 % identischer Satzstruktur):** »Eine Person geht zu dem Arzt. Der Arzt prüft den Patienten genau. Der Patient hat große Schmerzen im Rücken. Die Helferin misst den Blutdruck sofort. Der Arzt schildert die richtige Behandlung. Die Apotheke bringt die neuen Medikamente. Der Patient schluckt die Tabletten mit Wasser. Wegen dem raschen Handeln hilft die Medizin. Der Mann vermag bald wieder schmerzfrei arbeiten. Der Raum von dem Arzt ist modern.«