

Hochschule Flensburg
University of Applied Sciences
Master of Science Angewandte Informatik

M A S T E R - T H E S I S

**Entwicklung domänenspezifischer Datensätze und
automatisierter Evaluation für ein Framework zur
neuronalen Textvereinfachung in leichte Sprache**

Fiete Scheel
Matrikel-Nr.:
Erstprüfer: Max Mustermann
Zweitprüfer: Manuela Musterfrau
Abgabe: xx.xx.xxxx

Hochschule Flensburg

M A S T E R - T H E S I S

Thema: Entwicklung domänenspezifischer Datensätze und automatisierter Evaluation
für ein Framework zur neuronalen Textvereinfachung in leichte Sprache

von: Fiete Scheel

Matrikel-Nr.:

Studiengang: Master of Science Angewandte Informatik

Betreuer/in und

Erstbewerter/in: Prof. Dr.-Ing. Marc Aubreville

Zweitbewerter/in: Prof. Dr. Peter John

Ausgabedatum: 21.05.2026

Abgabedatum: 10.09.2026

Erklärung zur Nutzung generativer Künstlicher Intelligenz

Generative KI wurde im Verlauf dieser Masterarbeit regelmäßig als unterstützendes Werkzeug eingesetzt. Sie wurde als standardmäßiger Bestandteil moderner Arbeitsabläufe betrachtet – in gleicher Weise, wie eine integrierte Entwicklungsumgebung oder eine Rechtschreibprüfung ein Standardbestandteil beim Schreiben von Programmcode und Fließtext ist. Der Einsatz erfolgte stets unterstützend und zu keinem Zeitpunkt als passive Abgabe von Aufgaben. Jede Ausgabe unterlag einer engen manuellen Überwachung, wurde wiederholt überarbeitet und durch den Autor verifiziert.

Die folgenden Werkzeuge kamen zum Einsatz:

- **DeepL Write** wurde für das sprachliche Lektorat und das grammatikalische Korrekturlesen verwendet.
- **Gemini (Google)** wurde zur Unterstützung beim Brainstorming, zur Klärung technischer Konzepte und zur Generierung von Formulierungsvorschlägen für nicht-technische Erklärungstexte genutzt. Zudem diente es als erster Schritt bei der Informationssuche anstelle einer konventionellen Suchmaschine.
- **Antigravity (Google)** wurde als agentische Entwicklungsumgebung und über die Befehlszeilenschnittstelle (CLI) für Programmieraufgaben, technische Beratung, Code-Reviews sowie das Korrekturlesen der Abschlussarbeit eingesetzt (u. a. zur automatisierten Überprüfung auf argumentative Konsistenz, präzise Wortwahl sowie Rechtschreibung und Grammatik).

Die KI-Werkzeuge dienten zudem als Diskussions- und Sparringspartner sowie zum »Rubber Ducking«. Das strukturierte Formulieren eines Problems gegenüber dem System trug oft bereits vor Erhalt einer Antwort zur Klärung bei. Sämtliche methodischen Vorgehensweisen und erarbeiteten Lösungsansätze wurden darüber hinaus fortlaufend in den wöchentlichen Master-Meetings mit dem betreuenden Professor, den Doktoranden und weiteren Masterstudierenden gegengeprüft, diskutiert und entweder bestätigt, verworfen oder gezielt weiterentwickelt.

Alle durch KI-Werkzeuge generierten Inhalte wurden vom Autor kritisch geprüft, editiert und verifiziert. Kein generatives KI-System wurde zur Erzeugung originärer wissenschaftlicher Resultate, experimenteller Messdaten, Beweise oder der finalen Implementierungen der Algorithmen herangezogen. Das Forschungsdesign, die Analyse sowie die Interpretation der Ergebnisse sind originäre Leistungen des Autors. Der Autor übernimmt die uneingeschränkte Verantwortung für den Inhalt, die Richtigkeit und die Eigenständigkeit dieser Arbeit.

Ich versichere, dass ich meine Arbeit selbstständig und ohne fremde Hilfe verfasst, keine anderen als die angegebenen Quellen und Hilfsmittel benutzt, alle wörtlich oder sinngemäß übernommenen Stellen einschließlich generierter Texte in der Arbeit gekennzeichnet habe, und dass die Arbeit in gleicher oder ähnlicher Form in noch keiner anderen Prüfung vorgelegen hat. Ich stimme der Überprüfung der Arbeit durch eine Plagiatssoftware zu.

Ort, Datum

Unterschrift

Inhaltsverzeichnis

1	Einleitung	1
1.1	Problemstellung & Motivation	1
1.2	Zielsetzung & Forschungsfragen	2
1.3	Aufbau der Arbeit	3
2	Theoretischer Hintergrund	5
2.1	Das Konzept der Leichten Sprache	5
2.2	Grundlagen der automatischen Textvereinfachung	5
2.2.1	Textrepräsentationen & Einbettungen	6
2.2.2	Herausforderungen der automatischen Evaluation	7
2.3	Architekturen moderner neuronaler Sprachmodelle	7
2.3.1	Der Attention-Mechanismus	7
2.3.2	Modellfamilien im NLP	8
3	Stand der Forschung	9
3.1	Verfügbare Datenbasis und Korpora (Themenblock 1)	9
3.2	Evaluierungsmetriken für die Vereinfachung (Themenblock 2) . .	10
3.3	Maschinelle Übersetzung und Optimierungsverfahren (Themenblock 3)	12
4	Themenblock 1: Datenbasis & Korpus-Erstellung	14
4.1	Multi-Quellen-Crawling & Datenakquise	17
4.1.1	Domänen- und Quellenabdeckung	18
4.1.2	Technische Extraktions- & Verknüpfungsmechanismen . .	19
4.1.3	Ergebnis der Datenakquise (Roh-Korpus)	20
4.2	Alignment & Das 1:n-Problem	21
4.3	Quality Assurance & Similarity Sweet-Spot	22
4.4	Datenbereinigung & Normalisierung	22
4.5	Korpus-Statistiken & Lexikalische Diversität	22
5	Themenblock 2: Metrik & Bewerten von Sprachkomplexität	24
5.1	Klassifikationsmodelle (BiLSTM vs. Baselines)	24
5.2	Out-of-Domain-Generalisierung & Empirische Bias-Kontrolle . .	24
5.3	Continuous MixUp Regression	25
5.4	Evaluierung synthetischer Sprachstufen	25

6 Themenblock 3: Modellierung der Übersetzung & Reward-Guided Fine-Tuning	26
6.1 Datenvorbereitung & Trainings-Splits	26
6.2 Supervised Fine-Tuning (SFT)	26
6.3 Reward-Guided Optimization (RLHF / DPO)	27
6.4 Mehrdimensionale Evaluierung & Demonstrator-App	27
7 Diskussion & Gesamtevaluation	28
7.1 Inhaltssynthese der drei Themenblöcke	28
7.2 Stärken, Grenzen & Systemrestriktionen	28
7.3 Beantwortung der Forschungsfragen	28
8 Fazit & Ausblick	29
8.1 Zusammenfassung der Kernergebnisse	29
8.2 Ausblick & Zukünftige Forschungsarbeiten	29
9 Anhang	30
Glossar	31
Abbildungsverzeichnis	32
Tabellenverzeichnis	33
Literaturverzeichnis	34
10 Anhang	37

1 Einleitung

1.1 Problemstellung & Motivation

Für manche eine optionale Lesehilfe, für andere der einzige Zugang zu gesellschaftlicher Teilhabe.

Beim Thema Barrierefreiheit denken viele an physische Barrieren wie Rampen, Aufzüge oder automatische Türen. Durch die Digitalisierung und die Verlagerung von Dienstleistungen und Informationen ins Internet ist es damit jedoch nicht mehr getan. Barrierefreie Gestaltung betrifft zunehmend digitale Räume und insbesondere die Sprache, in der Informationen bereitgestellt werden.

Menschen mit kognitiven Einschränkungen, Lernschwierigkeiten, geringer Lese- und Schreibkompetenz oder Deutsch als Zweitsprache werden durch komplexe Texte, bürokratische Fachsprache und verschachtelte Satzstrukturen vom Zugang zu grundlegenden Informationen und Dienstleistungen ausgeschlossen. Das Konzept der *Leichten Sprache* (LS) bietet hierfür ein klar reglementiertes Regelwerk, um Texte durch Vereinfachung des Vokabulars und der Syntax verständlich zu machen.

Mit dem Inkrafttreten des Barrierefreiheitsstärkungsgesetzes (BFSG) in Deutschland sowie europäischen Richtlinien (wie der Web-Accessibility-Directive) wächst der rechtliche Druck auf öffentliche und private Akteure, Informationen auch in Leichter Sprache anzubieten. Die manuelle Übersetzung von Alltagssprache (AS) in Leichte Sprache (LS) durch menschliche Übersetzer ist jedoch extrem zeitintensiv, kostspielig und durch einen Mangel an Fachkräften limitiert.

Hieraus ergibt sich ein dringender Forschungs- und Entwicklungsbedarf im Bereich der maschinellen Textvereinfachung. Bisherige neuronale Übersetzungsmodelle scheitern jedoch häufig an den spezifischen syntaktischen und strukturellen Besonderheiten der Leichten Sprache oder leiden unter dem Mangel an qualitativ hochwertigen, parallelen Trainingsdaten. Es bedarf daher systematischer Ansätze zur automatisierten Erstellung paralleler Korpora, robuster Metriken zur Komplexitätsbewertung und optimierter Trainingsstrategien.

1.2 Zielsetzung & Forschungsfragen

Ziel dieser Arbeit ist die Entwicklung, Optimierung und Evaluierung eines methodischen Frameworks zur automatisierten Übersetzung deutscher Alltagssprache in Leichte Sprache. Dies umfasst den gesamten Prozess von der automatisierten Datenakquise über die Bewertung von Sprachkomplexität bis hin zum Training und der Optimierung generativer Sprachmodelle.

Im Zentrum dieser Arbeit steht die folgende übergreifende Leitfrage:

Wie lässt sich die automatische Übersetzung in Leichte Sprache (LS) durch die Kombination aus semantisch optimierten Korpora, strukturellen Klassifikatoren und zielgerichteten Trainingsstrategien systematisch verbessern und evaluieren?

Zur Beantwortung dieser Leitfrage werden drei zentrale Forschungsbereiche (Themenblöcke) untersucht:

1. Datenbasis & Alignment (Themenblock 1):

- *FF 2.1*: Wie stark beeinträchtigt das 1:n-Satzalignment das Training von Sequenz-zu-Sequenz-Modellen und kann ein absatzweises Alignment semantische Einheiten besser wahren?
- *FF 2.2 & 2.3*: Welcher Filterbereich der Kosinus-Ähnlichkeit bei parallelen Textpaaren liefert den qualitativen „Sweet Spot“ für das Modelltraining und inwiefern helfen Long-Context Embeddings bei der Rauschreduktion?

2. Klassifikation & Sprachkomplexität (Themenblock 2):

- *FF 3.1 & 3.2*: Lässt sich Sprachkomplexität besser auf Satz- oder Dokumentenebene klassifizieren und wie gut generalisieren diese Klassifikatoren auf unabhängige, proprietäre Testdaten?
- *FF 3.3*: Wie lassen sich systematische Shortcuts (Längen-, Layout- und typografische Biases) in den Klassifikationsmodellen empirisch ausschließen?

3. Übersetzung & Reward-Guided Fine-Tuning (Themenblock 3):

- *FF 5.3 & 5.4*: Inwiefern verbessert ein mit Reinforcement Learning (DPO) optimiertes Übersetzungsmodell unter Nutzung eines Komplexitätsklassifikators als Reward-Funktion die Einhaltung formaler Regeln im Vergleich zu reinem Supervised Fine-Tuning (SFT)?

1.3 Aufbau der Arbeit

Die vorliegende Arbeit folgt einer logischen Struktur, die sich an den drei Säulen des entwickelten Übersetzungssystems orientiert:

- **Kapitel 2 (Theoretischer Hintergrund)** legt das theoretische und linguistische Fundament. Es definiert das Konzept der Leichten Sprache und grenzt dieses formal sowie rechtlich von der Einfachen Sprache ab.
- **Kapitel 3 (Stand der Forschung)** stellt den aktuellen wissenschaftlichen Stand strukturiert entlang der drei Säulen Datenbasis, Komplexitätsmetriken und maschinelle Übersetzungsverfahren dar und leitet die bestehenden Forschungslücken ab.
- **Kapitel 4 (Themenblock 1: Datenbasis & Korpus-Erstellung)** beschreibt die erste Stufe der Pipeline. Im Fokus steht das Crawling paralleler Texte, die Behandlung des 1:n-Alignment-Problems und die qualitative Filterung mittels semantischer Embeddings.
- **Kapitel 5 (Themenblock 2: Metrik & Bewerten von Sprachkomplexität)** widmet sich der zweiten Stufe: der Entwicklung von Klassifikationsmodellen (BiLSTM vs. SBERT) und dem Entwurf einer *Continuous MixUp Regression* zur stufenlosen Komplexitätsbewertung.
- **Kapitel 6 (Themenblock 3: Modellierung der Übersetzung & Reward-Guided Fine-Tuning)** stellt das eigentliche Übersetzungsmodell vor. Hierbei werden die Implementierung des Supervised Fine-Tunings (SFT) sowie das Reward-Guided Fine-Tuning (DPO) zur Regeleinhaltung evaluiert.
- **Kapitel 7 (Diskussion & Gesamtevaluation)** führt die Ergebnisse der drei Stufen zusammen, beantwortet systematisch die aufgeworfenen Forschungsfragen und beleuchtet kritisch die Systemrestriktionen sowie Fragen zur Faktentreue.

- **Kapitel 8 (Fazit & Ausblick)** fasst die Kernergebnisse der Arbeit zusammen und gibt einen Ausblick auf zukünftige Forschungsarbeiten und praktische Anwendungsfelder.

2 Theoretischer Hintergrund

2.1 Das Konzept der Leichten Sprache

Das Konzept der Leichten Sprache (LS) stellt eine stark reglementierte Sprachvariante der deutschen Standardsprache dar, die primär darauf abzielt, Barrierefreiheit in der schriftlichen Kommunikation für Menschen mit kognitiven Einschränkungen, Lernschwierigkeiten oder geringer Lese- und Schreibkompetenz zu gewährleisten. Syntaktisch zeichnet sich LS unter anderem durch kurze Hauptsätze (Subjekt-Prädikat-Objekt), den Verzicht auf Nebensätze, Passivkonstruktionen, den Genitiv sowie den Konjunktiv aus. Auf lexikalischer Ebene werden abstrakte Begriffe durch konkrete Beispiele ersetzt, und lange zusammengesetzte Wörter werden mittels typografischer Hilfsmittel wie Bindestrichen oder dem Mediopunkt (z. B. *Bundestags-Wahl* oder *Bundestags-wahl*) segmentiert.

Vom Konzept der Leichten Sprache ist die sogenannte *Einfache Sprache* (Plain German) abzugrenzen. Während die Leichte Sprache als hochspezialisierte Sprachvariante mit strengen, normierten Richtlinien konzipiert ist und in Deutschland rechtlich durch die Barrierefreie-Informationstechnik-Verordnung (BITV 2.0) für öffentliche Stellen vorgeschrieben wird (Überwachungsstelle des Bundes für Barrierefreiheit von Informationstechnik, 2026), besitzt die Einfache Sprache ein weitaus weniger restriktives Regelwerk. Letztere richtet sich an eine breitere Zielgruppe (wie Menschen mit Deutsch als Zweitsprache oder funktionale Alphabeten) und lässt komplexere Satzstrukturen sowie einen größeren Wortschatz zu. Ein weiterer kritischer Unterschied liegt im Qualitätssicherungsprozess: Texte in Leichter Sprache müssen zwingend von Personen aus der primären Zielgruppe auf ihre Verständlichkeit hin geprüft werden, was bei Texten in Einfacher Sprache nicht vorgeschrieben ist.

2.2 Grundlagen der automatischen Textvereinfachung

Die automatische Textvereinfachung (*Automatic Text Simplification*, ATS) zielt darauf ab, die syntaktische und lexikalische Komplexität eines Textes zu reduzieren, während die semantische Kernbotschaft erhalten bleibt. Aus maschineller Sicht lässt sich ATS formal als monolinguale maschinelle Übersetzung (*Mono-lingual Machine Translation*) modellieren. Im Gegensatz zur klassischen bilin-

gualen Übersetzung (z. B. Deutsch nach Englisch) erfordert ATS tiefgreifende asymmetrische Strukturtransformationen:

- **Satzteilung (Sentence Splitting):** Lange, hypotaktische Satzgefüge müssen in mehrere koordinierte Hauptsätze zerlegt werden.
- **Streichung & Kompression (Deletion/Compression):** Redundante oder nebensächliche Füllinformationen müssen getilgt werden, um die kognitive Belastung des Lesers zu reduzieren.
- **Lexikalische Substitution & Explikation:** Schwierige Fachtermini müssen durch frequente Synonyme ersetzt oder um definitorische Nebensätze erweitert werden.

2.2.1 Textrepräsentationen & Einbettungen

Moderne Algorithmen des Natural Language Processing (NLP) verarbeiten Text über numerische Repräsentationen. Der Prozess gliedert sich in Tokenisierung und Einbettung (*Embedding*):

1. **Tokenisierung:** Vor der mathematischen Modellierung wird der Text in atomare Einheiten (Tokens) zerlegt. Neben wortbasierten Verfahren kommen in neuronalen Modellen überwiegend Subword-Tokenisierer wie Byte-Pair Encoding (BPE) nach Sennrich et al. (2016) oder SentencePiece zum Einsatz. Diese ermöglichen es, ein geschlossenes Vokabular fester Größe zu definieren und gleichzeitig seltene oder unbekannte Wörter (*Out-of-Vocabulary*, OOV) in morphologische Subkomponenten aufzuspalten.
2. **Dichte Vektoreinbettungen (Dense Embeddings):** Tokens oder ganze Sequenzen werden auf kontinuierliche Vektoren $\mathbf{e} \in \mathbb{R}^d$ im latenten semantischen Raum abgebildet. Sentence-Embedding-Modelle wie Sentence-BERT (SBERT) nach Reimers und Gurevych (2019) erzeugen über siamesische Netzwerke kontextsensitive Sequenzrepräsentationen.
3. **Semantische Ähnlichkeit:** Die inhaltliche Verwandtschaft zweier Textsequenzen x und y mit den Einbettungen $\mathbf{e}_x, \mathbf{e}_y$ wird üblicherweise über die Kosinus-Ähnlichkeit im Vektorraum quantifiziert:

$$\text{sim}_{\cos}(\mathbf{e}_x, \mathbf{e}_y) = \frac{\mathbf{e}_x \cdot \mathbf{e}_y}{\|\mathbf{e}_x\|_2 \|\mathbf{e}_y\|_2} \in [-1, 1] \quad (1)$$

welche für Normalisierungszwecke oft linear auf das Intervall $[0, 1]$ skaliert wird: $\text{sim}_{\text{norm}} = \frac{\text{sim}_{\text{cos}} + 1}{2}$.

2.2.2 Herausforderungen der automatischen Evaluation

Die Evaluation von ATS-Systemen unterscheidet sich fundamental von der Standard-Übersetzung. Klassische referenzbasierte N-Gramm-Metriken wie BLEU (Papineni et al., 2002) und ROUGE (Lin, 2004) messen primär die wörtliche Übereinstimmung mit einem Referenztext. Wie Alva-Manchego et al. (2021) empirisch belegen, korreliert BLEU im ATS-Kontext jedoch häufig negativ mit der menschlichen Beurteilung: Ein System, das den komplexen Ausgangstext unverändert kopiert, erzielt oft hohe BLEU-Werte, leistet jedoch keine Vereinfachung.

Aus diesem Grund etablierte sich die Metrik SARI (Xu et al., 2016), welche eingefügte (*add*), beibehaltene (*keep*) und gelöschte N-Gramme (*delete*) explizit getrennt gegenüber der Quelle und den Referenzen bewertet und somit Vereinfachungsoperationen honoriert.

2.3 Architekturen moderner neuronaler Sprachmodelle

Neuronale Sprachmodelle haben sich als führendes Paradigma für Sequence-to-Sequence-Aufgaben etabliert. Das Fundament bildet die von Vaswani et al. (2017) eingeführte **Transformer-Architektur**, welche vollständig auf rekurrente Schleifen verzichtet und stattdessen auf dem Konzept der *Self-Attention* (Selbstaufmerksamkeit) aufbaut.

2.3.1 Der Attention-Mechanismus

Der skalierten Skalarprodukt-Aufmerksamkeit (*Scaled Dot-Product Attention*) liegen drei Vektormatrizen zugrunde: Queries **Q**, Keys **K** und Values **V**, welche durch lineare Projektionen der Eingangsrepräsentationen entstehen. Die Aufmerksamkeitsmatrix wird formal berechnet durch:

$$\text{Attention}(\mathbf{Q}, \mathbf{K}, \mathbf{V}) = \text{softmax} \left(\frac{\mathbf{Q}\mathbf{K}^T}{\sqrt{d_k}} \right) \mathbf{V} \quad (2)$$

wobei d_k die Dimension der Key-Vektoren darstellt. Mittels *Multi-Head Attention* wird dieser Prozess mehrfach parallel mit unterschiedlichen Projektionsmatrizen durchgeführt, wodurch das Modell simultan Beziehungen auf unterschiedlichen semantischen und syntaktischen Abstraktionsebenen erfassen kann.

2.3.2 Modellfamilien im NLP

Je nach Aufbau der Transformer-Schichten werden drei primäre Architekturtypen unterschieden:

1. **Encoder-Decoder-Modelle (Sequence-to-Sequence):** Diese Architektur (wie mBART von Lewis et al. (2020) und Tang et al. (2020) oder mT5) besteht aus einem bidirektionalen Encoder zur Repräsentation des Eingabetextes und einem autoregressiven Decoder, der mittels *Cross-Attention* konditioniert auf die Encoder-Ausgaben den Zieltext Token für Token generiert. Sie eignet sich hervorragend für klassische Transformations- und Übersetzungsaufgaben.
2. **Decoder-Only-Modelle (Kausale Sprachmodelle):** Modelle wie die LLaMA- oder Mistral-Familie nutzen ausschließlich kausal maskierte Decoder-Schichten (*Causal Masking*). Jedes Token darf nur auf vorherige Token aufmerksam werden. Sie werden auf die Vorhersage des nächsten Tokens (*Next-Token Prediction*) vortrainiert und über Prompting oder Instruction Fine-Tuning gesteuert.
3. **Encoder-Only-Modelle:** Modelle wie BERT (Devlin et al., 2019) oder das deutschsprachige GBERT verarbeiten Eingabesequenzen vollständig bidirektional. Sie eignen sich primär für Sequenz- und Token-Klassifikationsaufgaben sowie für Einbettungsmodelle, nicht jedoch zur autoregressiven Textgenerierung.

3 Stand der Forschung

3.1 Verfügbare Datenbasis und Korpora (Themenblock 1)

Einen guten Überblick über den aktuellen Stand und die verfügbaren Ressourcen für Leichte und Einfache Sprache in Deutschland geben Madina et al. (2023). Sie zeigen dabei vor allem auf, wie unterschiedlich die bestehenden Datensätze strukturiert sind und dass es an standardisierten Werkzeugen zur automatischen Bewertung der Texte fehlt.

Die Erforschung datengetriebener, maschineller Übersetzungsverfahren (Automatic Text Simplification, ATS) für das Deutsche litt historisch unter einer eklatanten Datenknappheit. Erste Versuche, ein paralleles Korpus aufzubauen, gehen auf Klaper et al. (2013) mit dem *KLAPER*-Korpus zurück, das jedoch mit ca. 250 parallelen Textpaaren (rund 7.000 Sätze und 70.000 Tokens) für moderne Deep-Learning-Ansätze deutlich zu klein war.

Einen Meilenstein stellte die Arbeit von Battisti et al. (2020) dar, die ein umfangreiches, multimodales Korpus für das Deutsche zusammentrug. Die AutorInnen entwickelten Web-Scraper, um Texte in Leichter und Einfacher Sprache von verschiedenen deutschsprachigen Webportalen und Institutionen der Behindertenhilfe (wie etwa gesundheitlichen Informationsdiensten, öffentlich-rechtlichen Nachrichtenportalen und sozialen Trägern) zu extrahieren. Insgesamt umfasst das Korpus 6.217 Dokumente bzw. fast 211.000 Sätze mit rund 5,5 Millionen geschriebenen Tokens. Ein zentrales Merkmal der Arbeit ist die Aufteilung des Korpus: Es besteht zu einem großen Teil aus 5.461 monolingualen Dokumenten in vereinfachter Sprache, während der parallele Teil mit lediglich 378 parallelen Dokumentenpaaren (jeweils 378 Ausgangs- und Zieltexte) im Vergleich dazu sehr klein ausfällt. Neben den reinen Texten erfassten die AutorInnen systematisch typografische Metadaten (Schriftart, -größe und -stil), Absatz- und Zeilenstrukturen sowie Informationen zu eingebetteten Bildern (Vorhandensein, Dimensionen und Positionierung). Sie wiesen nach, dass diese visuellen Layout-Features die automatische Bewertung der Lesbarkeit (Readability Assessment) stark verbessern.

Für den Bereich der „Einfachen Sprache“ (Plain German) präsentierten Stodden et al. (2023) mit *DEplain* ein professionell erstelltes paralleles Korpus. Dieses teilt sich auf in einen Nachrichtenbereich (DEplain-APA) mit ca. 500 Dokumentenpaaren (rund 13.000 manuell ausgerichteten Satzpaaren) und einen

Webbereich mit ca. 150 manuell ausgerichteten Dokumenten (ca. 2.000 Satzpaaren). Um die Datenknappheit weiter zu reduzieren, stellt das Framework zusätzlich einen Web-Harvester zur automatischen Extraktion und Ausrichtung bereit, wodurch der Webbereich auf ca. 750 Dokumentenpaare (ca. 3.500 automatisch ausgerichtete Satzpaare) vergrößert werden kann. Die Autoren zeigten, dass Modelle, die auf Dokumentenebene trainiert werden, oft Probleme haben, die feinkörnigen semantischen Übergänge beizubehalten, weshalb präzise Alignments eine kritische Ressource für das Training von Seq2Seq-Modellen darstellen. An dieser Stelle ist jedoch hervorzuheben, dass eine direkte Vergleichbarkeit mit Systemen zur Übersetzung in Leichte Sprache erschwert ist: Obwohl das DEplain-Framework methodisch wertvolle Ansätze liefert, bezieht es sich durch den Fokus auf Einfache Sprache auf eine andere linguistische Ziel- und Datendomäne.

Einen weiteren Beitrag zur Generierung paralleler Ressourcen leisteten Toborek et al. (2023) mit der Vorstellung des *New Aligned Simple German Corpus*. Ihr Datensatz besteht aus ca. 700 Dokumentenpaaren auf Dokumentenebene und über 10.000 Satzpaaren auf Satzebene, die teils manuell annotiert und teils automatisch berechnet wurden. Das Korpus kombiniert dabei das systematische Scraping paralleler Webinhalte mit automatischer Satz-Ausrichtung. Allerdings fasst die Arbeit Texte sowohl der Leichten als auch der Einfachen Sprache unter einem gemeinsamen Vereinfachungsbegriff zusammen, was eine feine Unterscheidung der spezifischen syntaktischen und semantischen Richtlinien von Leichter Sprache erschwert. Dieser Kompromiss verdeutlicht jedoch auch ein grundlegendes Problem der aktuellen Forschung: Ein Korpusaufbau, der sich ausschließlich auf reine Leichte Sprache beschränkt, ist Stand jetzt kaum in großem Umfang realisierbar, da es im deutschsprachigen Web schlichtweg an einer ausreichenden Anzahl frei zugänglicher, paralleler Quellen fehlt.

3.2 Evaluierungsmetriken für die Vereinfachung (Themenblock 2)

Die automatische Evaluierung von Textvereinfachungssystemen stellt eine große methodische Hürde dar. Traditionelle Metriken der maschinellen Übersetzung wie BLEU, die primär auf n-Gramm-Präzision im Vergleich zu einer Referenzübersetzung basieren, erweisen sich für die Vereinfachung oft als ungeeignet. Wie Alva-Manchego et al. (2021) empirisch belegen, korreliert BLEU nur schwach

mit dem menschlichen Urteil über Einfachheit und Textqualität. Der Grund liegt darin, dass BLEU lexikalische Variationen und strukturelle Modifikationen (wie Satzteilung und Umformulierung) als Fehler abstrahlt, obwohl genau diese für eine gute Vereinfachung essenziell sind.

Als Alternative etablierte sich die Metrik *SARI* (System Accessibility and Readability Index), eingeführt von Xu et al. (2016). SARI vergleicht die Systemausgabe sowohl mit dem komplexen Ausgangstext als auch mit den Referenzübersetzungen. Dabei berechnet SARI separat die Präzision und den Recall für eingefügte (add), gelöschte (delete) und beibehaltene (keep) Wörter:

$$\text{SARI} = \frac{F_{\text{add}} + F_{\text{keep}} + P_{\text{del}}}{3} \quad (3)$$

Dadurch belohnt SARI explizit Vereinfachungsoperationen, die sich vom komplexen Ausgangstext wegbewegen.

Im Laufe der Entstehungszeit dieser Arbeit wurde mit *DETECT* von Kobeynikova et al. (2024) eine neuartige, erlernbare Evaluierungsmetrik speziell für die deutsche Textvereinfachung vorgestellt. DETECT adaptiert das englischsprachige LENS-Framework für den deutschsprachigen Raum und zielt darauf ab, die Qualität automatischer Vereinfachungen ganzheitlich über drei Dimensionen abzubilden: Verständlichkeit (*Simplicity / Ease*), semantische Inhaltsbewahrung (*Meaning Preservation*) sowie grammatikalische Korrektheit und Sprachfluss (*Fluency / Textual Clarity*). Um den Mangel an manuell annotierten Trainingsdaten zu überwinden, wird das Regressionsmodell vollständig auf synthetisch durch Large Language Models generierten Qualitätsurteilen trainiert. In empirischen Validierungen auf einem eigens erhobenen menschlichen Testdatensatz wiesen die AutorInnen nach, dass DETECT deutlich stärkere Korrelationen mit menschlichen Qualitätsbewertungen erzielt als traditionelle Maße wie BLEU, SARI oder BERTScore.

Gleichzeitig verdeutlicht dieser Ansatz zentrale verbleibende Forschungslücken: Da der zugrundeliegende Evaluierungsdatensatz (*SimpEvalDE*) primär auf Korpora der Einfachen Sprache (DEplain-APA und LHA-APA) aufbaut, sind spezifische, normierte Richtlinien der Leichten Sprache — wie das strikte Vermeiden von Passiv- und Genitivkonstruktionen oder die typografische Gliederung von Komposita — nicht explizit als Kriterien modelliert. Zudem sind rein referenzbasierte Satz-Metriken nur bedingt geeignet, um die Komplexität längerer Dokumente ganzheitlich und referenzfrei zu bewerten oder als kontinu-

ierliches Steuerungssignal während des Modelltrainings eingesetzt zu werden.

Obwohl das Thema Leichte Sprache in der deutschsprachigen NLP-Forschung über viele Jahre hinweg nur wenig Beachtung gefunden hat, zeigt das jüngste Erscheinen solcher Arbeiten, dass das Forschungsfeld derzeit stark an Dynamik gewinnt, was die wissenschaftliche und gesellschaftliche Relevanz dieses Themenbereichs zusätzlich unterstreicht.

3.3 Maschinelle Übersetzung und Optimierungsverfahren (Themenblock 3)

Die maschinelle Übersetzung von Alltagssprache (AS) in Leichte Sprache (LS) lässt sich formal als monolinguale maschinelle Übersetzung (*Monolingual Machine Translation*) begreifen. Im Gegensatz zur klassischen bilingualen Übersetzung (z. B. Deutsch–Englisch) erfordert dieser Transformationsprozess tiefgreifende asymmetrische Strukturänderungen: Komplexe Satzgefüge müssen aufgespalten (*Sentence Splitting*), Passiv- in Aktivkonstruktionen überführt, irrelevante Textpassagen gekürzt (*Compression*) und abstrakte Begrifflichkeiten explizierend umschrieben werden.

Die empirische Erforschung datengetriebener Übersetzungsmodelle für die deutsche Leichte Sprache ist bislang stark limitiert. Erste systematische Benchmarks zur neuronalen maschinellen Übersetzung (NMT) für das Deutsche wurden von Säuberli et al. (2020) vorgelegt. Auf Basis eines kleinen parallelen Nachrichtenkorpus wiesen die Autoren nach, dass Transformer-basierte Sequence-to-Sequence-Modelle grundlegende lexikalische Substitutionen und Satzkürzungen erlernen können. Allerdings zeigten sich deutliche qualitative Grenzen bei komplexeren syntaktischen Transformationen sowie eine hohe Anfälligkeit für die zugrundeliegende Datenknappheit.

Mit dem Aufkommen moderner Large Language Models (LLMs) verlagerte sich der Schwerpunkt zunehmend auf vortrainierte generative Sprachmodelle (wie die LLaMA- oder Mistral-Familie). Während rein Prompt-basierte Ansätze genereller Modelle häufig dazu neigen, Texte lediglich in ein moderates Sprachniveau (Einfache Sprache) zu überführen und formale Negativbeschränkungen der Leichten Sprache (wie den strikten Ausschluss von Genitiven oder Nebensätzen) zu verletzen, ermöglicht das zielgerichtete Fine-Tuning (z. B. Parameter-Efficient Fine-Tuning mittels LoRA/QLoRA) eine präzisere stilistische Anpassung.

Da qualitativ hochwertige parallele Datenpaare in der Praxis stark limitiert sind, stößt reines Supervised Fine-Tuning (SFT) schnell an eine quantitative Obergrenze. In diesem Kontext bietet die Präferenzoptimierung (*Preference Optimization*) einen vielversprechenden Ansatz zur weiteren Modellverbesserung: Mit dem initial trainierten SFT-Basismodell können für neue oder unalignierte Ausgangstexte mehrere Übersetzungskandidaten generiert werden. Werden diese Ausgaben anschließend anhand von Qualitäts- oder Komplexitätskriterien in bevorzugte (*chosen*, y_w) und abgelehnte (*rejected*, y_l) Antworten unterteilt, lässt sich das Modell auf diesen neu erzeugten Präferenzpaaren gezielt weiter trainieren und an die spezifischen Stil- und Verständlichkeitsanforderungen anpassen.

Um generative Modelle mathematisch stabil und ohne den aufwendigen Overhead von klassischem Reinforcement Learning (RLHF/PPO) auf spezifische Qualitäts- und Formatierungsrichtlinien auszurichten, führten Rafailov et al. (2023) die *Direct Preference Optimization* (DPO) ein. DPO optimiert die Policy direkt auf Präferenzdaten der Form (x, y_w, y_l) — bestehend aus einem Prompt x , einer bevorzugten Antwort y_w (winning) und einer abgelehnten Antwort y_l (losing) — über eine geschlossene Verlustfunktion:

$$\mathcal{L}_{\text{DPO}}(\theta; \pi_{\text{ref}}) = -\mathbb{E}_{(x, y_w, y_l)} \left[\log \sigma \left(\beta \log \frac{\pi_{\theta}(y_w|x)}{\pi_{\text{ref}}(y_w|x)} - \beta \log \frac{\pi_{\theta}(y_l|x)}{\pi_{\text{ref}}(y_l|x)} \right) \right] \quad (4)$$

wobei π_{ref} die SFT-Referenz-Policy darstellt, β ein Regularisierungsparameter ist und σ die Sigmoidfunktion bezeichnet.

Die Wirksamkeit von DPO für die deutsche Textvereinfachung wurde kürzlich von Anonymized (2025) anhand des *HF4ATS*-Datensatzes untersucht. Die Autoren zeigten empirisch, dass DPO-optimierte Modelle im Vergleich zu reinem SFT nicht nur eine signifikant höhere Verständlichkeit für die Zielgruppe erzielen, sondern vor allem formale Kriterien der Leichten Sprache (wie das Vermeiden von Genitiven und Nebensätzen) drastisch stabiler einhalten.

Hieraus leitet sich eine zentrale **Forschungslücke** ab: Bisherige Übersetzungsansätze für das Deutsche operieren fast ausnahmslos auf isolierter Satzebene und sind auf statische, manuell erstellte Präferenzdaten angewiesen. Es fehlt an domänenübergreifenden Übersetzungssystemen, die Texte kohärent auf Dokumenten- und Artikelebene transformieren und deren Präferenzoptimierung automatisiert über erlernte Komplexitätsmetriken als kontinuierliche Reward-Instanz gesteuert werden kann.

4 Themenblock 1: Datenbasis & Korpus-Erstellung

Die Erstellung eines qualitativ hochwertigen, repräsentativen und ausreichend großen parallelen Korpus bildet das Fundament für jedes datengetriebene Übersetzungssystem. Wie im vorangegangenen Kapitel dargelegt, leidet die maschinelle Textvereinfachung (ATS) für die deutsche Leichte Sprache unter einer eklatanten Datenknappheit. Während bestehende Ressourcen wie das Korpus von Battisti et al. (2020) einen wertvollen Grundstein legten, weisen sie für das Training moderner Seq2Seq- und Präferenzoptimierungsmodelle (wie DPO) entscheidende Limitierungen auf: Entweder ist ihr paralleler Anteil mit wenigen hundert Dokumenten zu gering, oder sie fokussieren sich, wie das DEplain-Korpus von Stodden et al. (2023), primär auf Einfache Sprache (Plain German), was sich linguistisch und regulatorisch signifikant von der Leichten Sprache unterscheidet. Einen wichtigen methodischen Impuls zur automatisierten Datengewinnung lieferten Toborek et al. (2023) mit dem *New Aligned Simple German Corpus*. Ihr Ansatz demonstrierte, wie parallele Webinhalte über seiten-spezifische Selektoren und Sprachumschalter im Internet automatisiert identifiziert und gescraped werden können. Diese Vorgehensweise bildete den primären Ausgangspunkt für die in dieser Arbeit entwickelte Crawling- und Extraktions-Pipeline. Allerdings fokussieren Toborek et al. primär auf ein inhärent fehleranfälliges Satz-Alignment und differenzieren nicht strikt zwischen Leichter und Einfacher Sprache.

Um diese Forschungslücke zu schließen, wurde im Rahmen dieser Arbeit eine eigene, automatisierte Pipeline zur Akquise und Aufbereitung von Trainingsdaten entwickelt, welche die Scraping-Prinzipien von Toborek et al. (2023) als methodisches Fundament aufgreift, auf 11 heterogene Domänen ausweitet und zu einer artikelbasierten, qualitätsgesicherten Korpus-Pipeline weiterentwickelt. Da diese Vorarbeit mittlerweile rund drei Jahre zurückliegt und im deutschsprachigen Web in diesem Zeitraum zahlreiche neue Informationsangebote sowie redaktionelle Portale in Leichter Sprache entstanden sind, wurde die Entscheidung getroffen, einen vollständig neuen, zeitgemäßen und breiter aufgestellten Korpus aufzubauen.

Ein zentrales methodisches Charakteristikum der in dieser Arbeit entwickelten Pipeline und der nachfolgenden Modellierung ist die bewusste Entscheidung für ein **artikelbasiertes** (bzw. dokumentenweites) Training sowohl der Kom-

plexitätsmetrik als auch des Übersetzungsmodells. In der bisherigen Forschung wurden Vereinfachungssysteme primär auf Satzebene trainiert und evaluiert, was jedoch erhebliche Defizite aufweist:

1. **Kontext- und Kohärenzverlust:** Satzbasierte Ansätze isolieren Sätze aus ihrem diskursiven Zusammenhang. Dadurch gehen anaphorische Bezüge, der rote Faden sowie die globale Kohärenz verloren. Zudem können makrostrukturelle Vereinfachungen wie die Umstrukturierung ganzer Absätze oder das Einfügen von erklärenden Hintergrundinformationen – welche im Konzept der Leichten Sprache essenziell sind – auf Satzebene nicht gelernt werden.
2. **Verrauschte Satz-Alignments:** Die Modellierung auf Satzebene setzt voraus, dass präzise Alignments vorliegen. Wie Stodden et al. (2023) und Štajner et al. (2018) zeigen, führt die asymmetrische Natur der Vereinfachung (z. B. n:m-Alignments und Satzteilungen) dazu, dass automatische Satz-Aligner entweder stark fehlerhafte Paare erzeugen oder einen massiven Informationsverlust durch das Verwerfen nicht-linearer Übergänge in Kauf nehmen müssen.
3. **Verlust struktureller Metadaten:** Wie Battisti et al. (2020) nachwiesen, spielen visuelle Layoutmerkmale, Absatzstrukturen und die Gliederung auf Dokumentenebene eine entscheidende Rolle für das Verständnis von Leichter Sprache. Ein satzbasiertes Alignment eliminiert diese Strukturen vollständig.

Indem wir den gesamten Artikel als Basiseinheit wählen, kann das Übersetzungsmodell lernen, globale Kürzungen vorzunehmen und Texte kohärent umzuformulieren. Gleichzeitig erlaubt dies der Komplexitätsmetrik, die Verständlichkeit eines Textes im Kontext des gesamten Dokuments statt isolierter Sätze zu bewerten. Die methodischen Entscheidungen dieser Pipeline spiegeln dabei direkt die in Abschnitt 3.3 und 3.2 diskutierten Herausforderungen des Forschungsstandes wider:

- **Multi-Quellen-Crawling & Datenakquise (Abschnitt 3.1):** Aufbauend auf den Scraping- und Alignment-Heuristiken des *New Aligned Simple German Corpus* (Toborek et al., 2023) als Ausgangspunkt wurde ein modularer Scraper für eine Vielzahl deutschsprachiger Webportale implementiert. Dies stellt sicher, dass sowohl behördliche Texte (im Kontext

der BITV 2.0) als auch journalistische Beiträge und Alltagstexte über 11 heterogene Quellen hinweg automatisiert erfasst werden.

- **Alignment & Das 1:n-Problem (Abschnitt 3.2):** Wie in Abschnitt 3.3 erläutert, übersetzen menschliche Übersetzer Leichte Sprache selten in Form von 1:1-Satzentsprechungen. Häufiger sind Satzaufspaltungen (Sentence Splitting) und starke Komprimierungen. Daher wird eine dynamische Alignment-Strategie benötigt, die über klassische Satzähnlichkeiten hinausgeht und semantische Einbettungen nutzt, um asymmetrische Satzbeziehungen (1:n) zuverlässig abzubilden.
- **Quality Assurance & Similarity Sweet-Spot (Abschnitt 3.3):** Um das von Štajner et al. (2018) beschriebene Rauschen in den ausgerichteten Daten zu minimieren, wird eine filterbasierte Qualitätssicherung eingeführt. Diese zielt darauf ab, den „Similarity Sweet-Spot“ zu identifizieren: Einerseits müssen zu unähnliche Satzpaare (die auf fehlerhaften Alignments beruhen) ausgeschlossen werden; andererseits müssen auch identische oder nahezu identische Satzpaare (die keinen Vereinfachungseffekt aufweisen) herausgefiltert werden, um dem Modell das Erlernen trivialer Kopieroperationen zu erschweren.
- **Datenbereinigung & Normalisierung (Abschnitt 3.4):** Da Texte aus unterschiedlichen Quellen stark variierende HTML-Strukturen, typografische Besonderheiten (z. B. die Verwendung von Bindestrichen oder Mediopunkten zur Worttrennung) und Layout-Elemente aufweisen, ist eine sorgfältige Vorverarbeitung essenziell.
- **Korpus-Statistiken & Lexikalische Diversität (Abschnitt 3.5):** Abschließend wird das resultierende Korpus quantitativ und qualitativ evaluiert. Hierbei wird analysiert, inwiefern die bereinigten und ausgerichteten Daten die theoretischen Anforderungen der Leichten Sprache erfüllen und welche lexikalische Vielfalt sie aufweisen.

Dieses Kapitel beschreibt den detaillierten Ablauf dieser Schritte und dokumentiert die Designentscheidungen bei der Konstruktion des finalen Datensatzes.

4.1 Multi-Quellen-Crawling & Datenakquise

Die automatisierte Akquise paralleler Textdaten für die deutsche Leichte Sprache stellt aufgrund der heterogenen Weblandschaft und des Fehlens zentraler Repositorien eine erhebliche methodische Herausforderung dar. Während im englischsprachigen Raum Plattformen wie die *Simple English Wikipedia* als quasi-standardisierte Datenquelle dienen, existiert im deutschsprachigen Raum kein vergleichbares, monolithisches Korpus. Parallele Sprachversionen verteilen sich stattdessen über behördliche Portale, öffentlich-rechtliche Rundfunkanstalten, Verbände der Behindertenhilfe und journalistische Magazine.

Um diesen heterogenen Datenbestand automatisiert und reproduzierbar zu erschließen, greift die in dieser Arbeit entwickelte Pipeline die grundlegenden Scraping-Heuristiken des *New Aligned Simple German Corpus* von Toborek et al. (2023) als methodischen Ausgangspunkt auf. Während Toborek et al. ihr Verfahren jedoch primär auf die Extraktion unzusammenhängender Satzfragmente ausrichteten, wird der Ansatz hier zu einer modularen, zweistufigen Dokumenten-Crawling-Architektur erweitert. Diese trennt die logische URL-Identifikation strikt von der inhaltlichen DOM-Extraktion:

1. **Stufe 1: URL-Discovery & Alignment-Heuristiken** (`scripts/data_collection/crawl_scraper/`): In diesem Schritt navigieren spezialisierte Crawler durch die Zielportale, identifizieren Artikel in Leichter Sprache (LS) und ermitteln über seitenspezifische Verknüpfungsmechanismen die korrespondierende URL der Alltagssprache (AS). Das Ergebnis jeder Quelle wird als JSON-Struktur standardisierter URL-Paare abgelegt.
2. **Stufe 2: Selektive DOM-Content-Extraktion** (`scripts/data_collection/corpus_scrapers/`): Aufbauend auf den identifizierten URL-Paaren lädt die zweite Stufe die HTML-Dokumente asynchron herunter. Anstatt den gesamten Seiteninhalt ungefiltert zu erfassen, extrahiert ein zielgerichteter DOM-Parser ausschließlich den redaktionellen Fließtext über semantische HTML5-Container (`<main>`, `<article>`, `div.paragraph`). Navigationsleisten, Kopf- und Fußzeilen, Cookie-Banner sowie interaktive Schaltflächen werden dadurch bereits auf Extraktionsebene systematisch eliminiert.

4.1.1 Domänen- und Quellenabdeckung

Um eine breite stilistische und thematische Varianz zu gewährleisten und eine Überanpassung an ein einzelnes redaktionelles Regelwerk zu verhindern, wurden 12 frei zugängliche deutschsprachige Webquellen aus drei gesellschaftlich relevanten Domänen erschlossen:

- **Öffentliche Verwaltung & Kommunalportale:** Dieser Sektor besitzt besondere rechtliche Relevanz, da öffentliche Stellen gemäß der Barrierefreie-Informationstechnik-Verordnung (BITV 2.0) gesetzlich verpflichtet sind, wesentliche Informationen in Leichter Sprache bereitzustellen (Überwachungsstelle des Bundes für Barrierefreiheit von Informationstechnik, 2026). Erfasst wurden die Stadtportale *Hannover.de* (welches aufgrund seines Umfangs als Referenzkorpus dient), *Hamburg.de*, *Koeln.de*, *Stuttgart.de*, *Wiesbaden.de* sowie das Portal des *Main-Taunus-Kreises*.
- **Medien & Journalismus:** Zur Abdeckung tagesaktueller Berichterstattung und nachrichtlicher Diskursformen umfasst das Korpus die Angebote des Mitteldeutschen Rundfunks (*MDR Nachrichten in Leichter Sprache*), der tageszeitung (*taz*) sowie des Wirtschaftsmagazins *brand eins*.
- **Gesundheit, Soziales & Politik:** Zur Erfassung medizinischer und sozialrechtlicher Fachtexte wurden das Portal der *Apotheken Umschau* (Einfache Sprache), die Veröffentlichungen des *Beauftragten der Bundesregierung für die Belange von Menschen mit Behinderungen* sowie das Bildungsportal *Sozialpolitik.com* integriert.

Ergänzend zu den Webquellen wurde ein unabhängiger **Out-of-Domain-Testdatensatz (OOD)** auf Basis realer Dokumente der *Lebenshilfe Schleswig-Holstein e. V.* aufgebaut. Dieser Datensatz umfasst behördliche Bescheide, Hausordnungen, Vereinbarungen und Prüfberichte, die von professionellen Übersetzungsbüros übertragen und von zertifizierten Prüfgruppen aus Menschen mit Lernschwierigkeiten validiert wurden. Die Extraktion erfolgte über ein spezialisiertes Parsing-Skript (`scripts/preprocessing/create_lebenshilfe_dataset.py`), welches proprietäre Dateiformate (`.docx`, `.rtf`, `.odt`) verarbeitet und für die spätere modellunabhängige Generalisierungsevaluation bereitstellt.

4.1.2 Technische Extraktions- & Verknüpfungsmechanismen

Da Webseiten keine standardisierten Metadaten für sprachliche Vereinfachungen bereitstellen, wurden für die 12 Webquellen fünf distinkte Verknüpfungsmechanismen implementiert:

1. **Canonical Link Header Exploration:** Die Stadt Hannover implementiert eine technisch vorbildliche Verknüpfung. Jeder LS-Artikel besitzt im HTML-Kopf ein Canonical-Tag (`<link rel="canonical" href="...">`), welches direkt auf den ursprünglichen Volltext in Alltagssprache verweist. Der Scraper durchsucht ausgehend von der Übersichtsseite rekursiv alle internen Pfade und bildet über diese Referenz deterministische Paare.
2. **DOM Language Switcher Detection:** Bei Quellen wie dem *Behinderungenbeauftragten* (`.c-language-switch__1-as`), *Hamburg.de* (`.km1-icon-original-language`) oder *Sozialpolitik.com* (`.underline.easy` mit `hreflang="de-DE"`) existieren dedizierte Umschalt-Schaltflächen im DOM. Der Crawler parst die LS-Seite, liest das Link-Ziel des Sprachumschalters aus und verknüpft die Dokumente.
3. **URL-Parameter- & Routing-Heuristiken:** Einige kommunale Content-Management-Systeme routen Sprachvarianten über URL-Query-Parameter. Bei *Stuttgart.de* wird die Zielsprache über den Parameter `?sp:out=easy` gesteuert; bei *Wiesbaden.de* erfolgt die Auslieferung über `?sp:easylanguage=1`. Das Alignment erfolgt hierbei durch gezieltes Setzen bzw. Entfernen des Parameters bei identischem URL-Stamm.
4. **Kontextuelle Backlinks & Text-Trigger:** Redaktionelle Angebote betten Links zur Ausgangssprache häufig direkt in den Fließtext oder Teaser-Boxen ein. Beim *MDR* sucht der Scraper nach dem standardisierten Block »Hier können Sie diese Nachricht auch in schwerer Sprache lesen.«; die *taz* verlinkt den Originalartikel im Satzsatz innerhalb kursiver Elemente (`<em>`), während die *Apotheken Umschau* Links mit dem Titelattribut »mehr Informationen« außerhalb des vereinfachten Verzeichnispfads auswertet.
5. **Intra-Page CSS- & Layout-Dissektion:** Das Magazin *brand eins* publiziert beide Sprachfassungen gemeinsam auf einer einzigen Webseite innerhalb desselben Textcontainers (`section.textblock`). Das Alignment

erfordert hier eine Stil-Dissektion: Absätze in Leichter Sprache sind im Inline-CSS rot formatiert (color: #fa4600 bzw. #ff4948), während der schwarze Standardtext der Alltagssprache entspricht.

Für historische oder umstrukturierte Webseiten (*Stadt Köln, Lebenshilfe Main-Taunus, brand eins*) wurde das Scraping über die *Wayback Machine* des Internet Archive realisiert. Um Verbindungsabbrüche durch serverseitige Rate-Limits zu verhindern, implementieren die Scraper eine robuste Retry-Logik mit exponentiellem Backoff (Intervall 2 s $\rightarrow$ 4 s $\rightarrow$ 8 s).

4.1.3 Ergebnis der Datenakquise (Roh-Korpus)

Durch den Einsatz dieser zielgerichteten Scraper-Infrastruktur konnten in der ersten Pipelinestufe insgesamt **1.533 parallele Artikelpaare** über alle 12 Webquellen hinweg akquiriert werden. Tabelle 1 fasst den Rohdatenbestand nach Quellen zusammen.

Tabelle 1: Übersicht des akquirierten Rohdatenbestands (Stufe 1 der Pipeline) nach Quellen.

Quelle	Artikelpaare	AS-Tokens	LS-Tokens	Token-Ratio (LS/AS)
Hannover.de	808	871.042	872.115	1,00
MDR Nachrichten	235	173.210	98.432	0,57
Apotheken Umschau	161	451.290	241.108	0,53
Behindertenbeauftragter	60	51.820	40.612	0,78
Hamburg.de	57	67.614	68.012	1,01
Stuttgart.de	42	124.918	64.310	0,51
Wiesbaden.de	41	30.012	21.240	0,71
Koeln.de	39	60.320	92.015	1,53
Main-Taunus-Kreis	36	17.514	18.910	1,08
brand eins	32	22.140	21.218	0,96
Sozialpolitik.com	15	14.415	6.390	0,44
taz (die tageszeitung)	7	4.699	3.993	0,85
Gesamt (Rohdaten)	1.533	1.868.994	1.468.345	0,79

Insgesamt umfasst der Rohdatenbestand rund **1,87 Millionen Tokens** in der Ausgangssprache und rund **1,47 Millionen Tokens** in Leichter Sprache

(gemessen mit dem Tokenisierer `cl100k_base`). Wie die Token-Ratios in Tabelle 1 verdeutlichen, unterscheidet sich das Längenverhalten zwischen den Quellen erheblich: Während journalistische und medizinische Quellen (MDR, Apotheken Umschau, Sozialpolitik) stark komprimieren (Ratio $\approx 0,44$ bis $0,57$), weisen kommunale Quellen (Hannover, Hamburg, Köln) ausgeglichene oder expandierende Längenverhältnisse auf (Ratio $> 1,00$, bei Köln bis zu $1,53$).

Diese deutliche Diskrepanz in der Token-Ratio spiegelt wider, wie unterschiedlich das Regelwerk und das Zielbild von Leichter Sprache in der Praxis interpretiert und redaktionell umgesetzt werden. Während im nachrichtlichen und journalistischen Kontext die radikale inhaltliche Reduktion sowie Verdichtung auf Kernbotschaften im Vordergrund stehen, verfolgen insbesondere behördliche und kommunale Portale einen explizierenden Ansatz. Hierbei wird versucht, die vollständige administrative Information beizubehalten, wodurch kurze Fachbegriffe, formale Abläufe und juristische Sachverhalte durch detaillierte, mehrsätzliche Erläuterungen und Kontextbeschreibungen aufgeschlüsselt werden. Die Token-Ratio verdeutlicht somit nicht nur statistische Längenunterschiede, sondern illustriert die Bandbreite zwischen inhaltsfilternder Zusammenfassung und vollumfänglicher syntaktisch-semantischer Erläuterung im Spektrum der Leichten Sprache.

Gleichzeitig weist der Rohdatenbestand noch erhebliche Qualitätsunterschiede auf, da fehlerhafte Verlinkungen, leere Teaser-Seiten sowie verbleibendes Web-Boilerplate enthalten sind. Die nachfolgenden Abschnitte beschreiben daher die methodischen Schritte zur Qualitätssicherung und Bereinigung.

4.2 Alignment & Das 1:n-Problem

- **Ebenen des Alignments:** Gegenüberstellung von Satz- vs. Absatz- vs. Dokument-Alignment.
- **Asymmetrische Abbildungen (1:n und n:m):** Analyse von Satzaufteilungen (*Sentence Splitting*) und syntaktischer Restrukturierung in Leichter Sprache.
- **Wahrung des Diskurskontextes:** Vermeidung von Kontextverlust und anaphorischen Brüchen durch dokumentenweites Pairing.

4.3 Quality Assurance & Similarity Sweet-Spot

- **Long-Context Embeddings:** Einsatz von *Jina Embeddings v2* (8192 Tokens Kontextfenster) zur lückenlosen Vektorisierung langer Artikel ohne Truncation-Artefakte klassischer SBERT-Modelle.
- **Der Similarity Sweet-Spot (Filtration):** Definition des optimalen Ähnlichkeitskorridors ($0,60 \leq \text{sim}_{\cos} \leq 0,98$).
 - Ausschluss von Fehl-Alignments und irrelevanten Metadaten-Seiten ($\text{sim} < 0,60$).
 - Ausschluss identischer Kopien und unvollständiger Übersetzungen ohne Vereinfachungseffekt ($\text{sim} > 0,98$).

4.4 Datenbereinigung & Normalisierung

- **Web-Boilerplate-Bereinigung:** Chirurgische Entfernung von Navigationsfragmenten, Teasern, Bildunterschriften und Radio-/Audio-Metadaten.
- **Typografische Normalisierung:** Behandlung von Mediopunkten ($\cdot$), Bindestrich-Komposita und Unicode-Sonderzeichen.
- **Glossar-Anreicherung (*Enrichment*):** Extraktion und strukturierte Integration von Begriffserläuterungen aus dem *Hurraki*-Wörterbuch für Leichte Sprache.

4.5 Korpus-Statistiken & Lexikalische Diversität

- **Quantitative Korpusmaße:** Artikelpaare, Token- und Satzanzahlen sowie Längenverhältnisse nach Quellen.
- **Lexikalische Diversität:** Vergleichende Analyse mittels Type-Token-Ratio (TTR) und Moving-Average Type-Token-Ratio (MATTR) zur Kontrolle des Längeneinflusses.
- **Traditionelle Lesbarkeitsindizes:** Auswertung nach Wiener Sachtextformel (WSTF 1–4), Flesch-Reading-Ease (FRE) und LIX.
- **Faktenerhalt & Informationsverlust:** Bidirektionaler Named Entity Recall (NER mit spaCy `de_core_news_lg`) zur Identifikation von Auslassungen und Paraphrasen.

- **Syntaktische Shifts:** Verteilung der Wortarten (Part-of-Speech / POS) und Quantifizierung des Rückgangs von Subordinationen und Passivstrukturen.

5 Themenblock 2: Metrik & Bewerten von Sprachkomplexität

Die automatisierte, referenzfreie Bewertung von Sprachkomplexität stellt eine Kernkomponente dieser Arbeit dar. Um Textvereinfachungen objektiv zu bewerten und ein steuerbares Belohnungssignal (*Reward*) für das spätere Modelltraining bereitzustellen, wird in diesem Themenblock eine eigene Metrik-Pipeline entwickelt und systematisch untersucht.

5.1 Klassifikationsmodelle (BiLSTM vs. Baselines)

- **Modellarchitektur:** Bidirektionales Long Short-Term Memory (BiLSTM) mit Word-Embedding-Layer, Dropout-Regularisierung und Klassifikationskopf (Linear + Sigmoid).
- **Vergleichsbaselines:** Vanilla RNN, Standard-LSTM und vortrainierte Transformer-Klassifikatoren (GBERT).
- **Granularitätsebenen:**
 - *Satz-Klassifikator:* Training und Inferenz auf isolierten Einzelsätzen.
 - *Artikel-Klassifikator:* Dokumentenweites Training (bis 512 Tokens).
 - *Majority Voting:* Aggregierte Dokumenten-Klassifikation durch Mehrheitsentscheid über alle Sätze eines Textes.
- **In-Domain-Evaluation:** Leistungsvergleich anhand von Balanced Accuracy (BAcc) und F1-Score auf dem internen Test-Split.

5.2 Out-of-Domain-Generalisierung & Empirische Bias-Kontrolle

- **Out-of-Domain-Validierung:** Evaluation auf einem unabhängigen, externen Testdatensatz der *Lebenshilfe Schleswig-Holstein e. V.*
- **Shortcut- und Bias-Kontrollen:**
 - *Dummy-Content-Test (Längen-Bias):* Maskierung aller Wörter durch identische Satzzeichen (‘.’) bei unveränderter Tokenanzahl zur Kontrolle von Längen-Shortcuts.

- *Layout-Bias-Test*: Vollständige Entfernung von Absätzen und Zeilenumbrüchen zur Überprüfung von typografischen Heuristiken.

5.3 Continuous MixUp Regression

- **Das Konzept des textuellen MixUp**: Erzeugung kontinuierlicher Schwierigkeitsgrade $\lambda \in [0,0,1,0]$ durch satzweise Mischungen paralleler Artikel.
- **Dynamische Target-Berechnung**: Gewichtung anhand des relativen Zeichenlängenanteils:

$$\lambda = \frac{\text{CharLen}(LS)}{\text{CharLen}(LS) + \text{CharLen}(AS)} \quad (5)$$

- **Vergleich der Trainings- und Dataloader-Varianten**:
 - *Variante A (Statisch)*: Feste Vorabmischung des Trainingskorpus.
 - *Variante B (Dynamisch)*: On-the-Fly Shuffling (Analyse des *Prediction Collapse*).
 - *Variante C (Hybrid)*: Epochenabhängiges Curriculum-Shuffling.
 - *Variante D (Hybrid + Cyclic Learning Rate)*: Optimierung mittels *CosineAnnealingWarmRestarts* zur Vermeidung lokaler Minima.
- **Kontextlängen-Ablationsstudie**: Empirische Bestimmung der optimalen Eingabesequenzlänge (128, 256, 500, 1000 Tokens).
- **Regressions-Metriken**: Mean Squared Error (MSE), Mean Absolute Error (MAE), Pearson- und Spearman-Korrelation sowie KDE-Dichteverteilungsanalysen.

5.4 Evaluierung synthetischer Sprachstufen

- **LLM-basierte Stufengenerierung**: Synthetische Erzeugung diskreter Zwischenstufen (0,25, 0,50, 0,75) mittels Instruction Prompting großer Sprachmodelle (FlensGen-GPT / OpenAI).
- **Kreuz-Evaluation**: Gegenüberstellung des MixUp-Regressors und des synthetisch trainierten Regressors auf dem Lebenshilfe-Datensatz.
- **Monotonie- und Reliabilitätsprüfung**: Analyse von Fehlertrends, Boxplots und stilistischen Artefakten (*Chatty Prefixes*, Formatierungsverluste).

6 Themenblock 3: Modellierung der Übersetzung & Reward-Guided Fine-Tuning

In diesem Themenblock wird das generative Übersetzungsmodell entwickelt, trainiert und optimiert. Aufbauend auf dem bereinigten Parallelkorpus (Themenblock 1) und der gelernten Komplexitätsmetrik (Themenblock 2) erfolgt die Modellierung über ein zweistufiges Trainingsverfahren aus Supervised Fine-Tuning (SFT) und anschließender Präferenzoptimierung mittels Direct Preference Optimization (DPO).

6.1 Datenvorbereitung & Trainings-Splits

- **Datensatzfilterung:** Bereitstellung der Trainingspaare aus dem Sweet-Spot-Korpus ($0,60 \leq \text{sim}_{\text{cos}} \leq 0,98$).
- **Split-Konfiguration:** Aufteilung in Trainings- (80 %), Validierungs- (10 %) und Test-Sets (10 %) unter Vermeidung von Datenlecks (*Data Contamination*).
- **Präferenzdatensatz-Konstruktion:** Offline-Generierung von (x, y_w, y_l) -Tripeln (Prompt, präferierte Antwort, dispräferierte Antwort) mittels SFT-Sampling und automatischer Reward-Bewertung.

6.2 Supervised Fine-Tuning (SFT)

- **Modellauswahl & Architektur:** Sequence-to-Sequence Modellierung mit facebook/mbart-large-50 inklusive korrekter Sprachcode-Initialisierung (de_DE) sowie Gegenüberstellung mit Decoder-Only-Modellen (Mistral, LLaMA).
- **Parameter-Efficient Fine-Tuning (PEFT / LoRA):** Konfiguration der Niedrigrang-Adaption ($r = 16$, $\alpha = 32$, Dropout 0,05) auf allen Aufmerksamkeits- und Feed-Forward-Projektionen.
- **Trainingsdynamik & Overfitting-Kontrolle:** Analyse von Lernkurven, Early Stopping mit Patience und Rollback-Mechanismen bei Spät-Divergenz.

6.3 Reward-Guided Optimization (RLHF / DPO)

- **DPO-Implementierung:** Native PyTorch-Engine für Seq2Seq-Architekturen mit Zero-VRAM Referenzmodell über PEFT-Adapterdeaktivierung (`disable_adapter()`).
- **Verbund-Reward-Design (*Composite Reward*):** Steuerung des Zielkonflikts aus syntaktischer Einfachheit und semantischer Faktentreue:

$$R(x, y) = w_{\text{style}} \cdot R_{\text{style}}(y) + w_{\text{sem}} \cdot R_{\text{sem, norm}}(x, y) \quad (6)$$

unter Nutzung des BiLSTM-MixUp-Regressors (R_{style}) und der SBERT-Ähnlichkeit (R_{sem}).

- **Ablation der Reward-Gewichte:** Systematische Untersuchung von $w_{\text{style}}/w_{\text{sem}}$ (0,5/0,5, 0,7/0,3, 1,0/0,0) zur Identifikation der optimalen Pareto-Grenze.
- **Loss-Aggregation (Sum vs. Mean):** Mathematische Analyse und experimentelle Behebung der Kürzungsfälle (*Length Exploitation*) durch län-gennormalisiertes Per-Token-DPO (**mean**).
- **Einfluss der Glossar-Anreicherung:** Vergleich von Modellen auf Standard-vs. Enriched-Korpora.

6.4 Mehrdimensionale Evaluierung & Demonstrator-App

- **Out-of-Domain-Benchmark:** Evaluation der Übersetzungsmodelle auf dem unabhängigen *Lebenshilfe*-Testset.
- **Decoding-Parameter & Halluzinationskontrolle:** Kalibrierung von Beam Search, Repetition Penalty und N-Gramm-Sperren (`no_repeat_ngram_size`) zur Unterbindung von Wiederholungsschleifen.
- **Qualitative Analyse:** Linguistische Detailuntersuchung von Modellgenerierungen (Satzkürzungen, Passiv-Aktiv-Wandlung, Wortkomposita-Trennung).
- **Full-Stack Web-Demonstrator:** Implementierung einer interaktiven Anwendung (Next.js Frontend + Flask Inferenz-Backend) mit dynamischer Einfachheits-Skala für Endanwender.

7 Diskussion & Gesamtevaluation

7.1 Inhaltssynthese der drei Themenblöcke

7.2 Stärken, Grenzen & Systemrestriktionen

7.3 Beantwortung der Forschungsfragen

8 Fazit & Ausblick

8.1 Zusammenfassung der Kernergebnisse

8.2 Ausblick & Zukünftige Forschungsarbeiten

9 Anhang

Glossar

Abbildungsverzeichnis

Tabellenverzeichnis

1	Übersicht des akquirierten Rohdatenbestands (Stufe 1 der Pipeline) nach Quellen.	20
---	--	----

Literaturverzeichnis

- Alva-Manchego, F., Scarton, C., & Specia, L. (2021). The (Un)Suitability of Automatic Evaluation Metrics for Text Simplification. *Computational Linguistics*, 47(4), 861–889.
- Anonymized, A. (2025). Evaluating the Effectiveness of Direct Preference Optimization for Personalizing German Automatic Text Simplifications for Persons with Intellectual Disabilities. *Proceedings of the 2025 Conference on Empirical Methods in Natural Language Processing*.
- Battisti, A., Pfütze, D., Säuberli, A., Kostrzewa, M., & Ebling, S. (2020). A Corpus for Automatic Readability Assessment and Text Simplification of German. *Proceedings of the 12th Language Resources and Evaluation Conference*, 3302–3311.
- Devlin, J., Chang, M.-W., Lee, K., & Toutanova, K. (2019). BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding. *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies*, 4171–4186.
- Klaper, D., Ebling, S., & Volk, M. (2013). KLAPER: A German/Simplified German Parallel Corpus. *Proceedings of the 17th International Conference on System Theory, Control and Computing*.
- Korobeynikova, M., Battisti, A., Fischer, L., & Gao, Y. (2024). DETECT: Determining Ease and Textual Clarity of German Text Simplifications. *Proceedings of the 18th Conference of the European Chapter of the Association for Computational Linguistics (Volume 1: Long Papers)*, 2215–2230.
- Lewis, M., Liu, Y., Goyal, N., Ghazvininejad, M., Mohamed, A., Levy, O., Stoyanov, V., & Zettlemoyer, L. (2020). BART: Denoising Sequence-to-Sequence Pre-training for Natural Language Generation, Translation, and Comprehension. *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics*, 7871–7880.
- Lin, C.-Y. (2004). ROUGE: A Package for Automatic Evaluation of Summaries. *Text Summarization Branches Out*, 74–81.

- Madina, M., Gonzalez-Dios, I., & Siegel, M. (2023). Easy-to-Read in Germany: A Survey on its Current State and Available Resources. *arXiv preprint arXiv:2306.03189*.
- Papineni, K., Roukos, S., Ward, T., & Zhu, W.-J. (2002). BLEU: a Method for Automatic Evaluation of Machine Translation. *Proceedings of the 40th Annual Meeting of the Association for Computational Linguistics*, 311–318.
- Rafailov, R., Sharma, A., Mitchell, E., Ermon, S., Manning, C. D., & Finn, C. (2023). Direct Preference Optimization: Your Language Model is Secretly a Reward Model. *Advances in Neural Information Processing Systems*.
- Reimers, N., & Gurevych, I. (2019). Sentence-BERT: Sentence Embeddings using Siamese BERT-Networks. *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing (EMNLP-IJCNLP)*, 3982–3992.
- Säuberli, A., Ebling, S., & Volk, M. (2020). Benchmarking Data-driven Automatic Text Simplification for German. *Proceedings of the 1st Workshop on Tools and Resources to Empower People with READING Difficulties (READI)*, 41–48.
- Sennrich, R., Haddow, B., & Birch, A. (2016). Neural Machine Translation of Rare Words with Subword Units. *Proceedings of the 54th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, 1715–1725.
- Štajner, S., Franco-Salvador, M., Rosso, P., & Ponzetto, S. P. (2018). CATS: A Tool for Customized Alignment of Text Simplification Corpora. *Proceedings of the 11th Language Resources and Evaluation Conference*.
- Stodden, R., Momen, O., & Kallmeyer, L. (2023). DEplain: A German Parallel Corpus with Intralingual Translations into Plain Language for Sentence and Document Simplification. *Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, 8391–8412.
- Tang, Y., Tran, C., Li, X., Chen, P.-J., Goyal, N., Chaudhary, V., Gu, J., & Fan, A. (2020). Multilingual Translation with Extensible Multilingual Pre-training and Finetuning. *arXiv preprint arXiv:2008.00401*.

- Toborek, V., Busch, M., Boßert, M., Bauckhage, C., & Welke, P. (2023). A New Aligned Simple German Corpus. *Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, 11416–11432.
- Überwachungsstelle des Bundes für Barrierefreiheit von Informationstechnik. (2026). *Leichte Sprache – Übergreifende Anforderungen für Web und App*. Verfügbar 8. August 2026 unter https://www.barrierefreiheit-dienstekonsolidierung.bund.de/Webs/PB/DE/barrierefreie_it/uebergreifende-anforderungen-web-und-app/leichte-sprache/leichte-sprache-artikel.html
- Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, Ł., & Polosukhin, I. (2017). Attention is All You Need. *Advances in Neural Information Processing Systems*, 30, 5998–6008.
- Xu, W., Napoles, C., Pavlick, E., Chen, Q., & Callison-Burch, C. (2016). Optimizing Statistical Machine Translation for Text Simplification. *Transactions of the Association for Computational Linguistics*, 4, 401–415.

10 Anhang