

Hochschule Flensburg
University of Applied Sciences
Master of Science Angewandte Informatik

M A S T E R - T H E S I S

**Entwicklung domänenspezifischer Datensätze und
automatisierter Evaluation für ein Framework zur
neuronalen Textvereinfachung in leichte Sprache**

Fiete Scheel
Matrikel-Nr.:
Erstprüfer: Max Mustermann
Zweitprüfer: Manuela Musterfrau
Abgabe: xx.xx.xxxx

Hochschule Flensburg

M A S T E R - T H E S I S

Thema: Entwicklung domänenspezifischer Datensätze und automatisierter Evaluation
für ein Framework zur neuronalen Textvereinfachung in leichte Sprache

von: Fiete Scheel

Matrikel-Nr.:

Studiengang: Master of Science Angewandte Informatik

Betreuer/in und

Erstbewerter/in: Prof. Dr.-Ing. Marc Aubreville

Zweitbewerter/in: Prof. Dr. Peter John

Ausgabedatum: 21.05.2026

Abgabedatum: 10.09.2026

Erklärung zur Nutzung generativer Künstlicher Intelligenz

Generative KI wurde im Verlauf dieser Masterarbeit regelmäßig als unterstützendes Werkzeug eingesetzt. Sie wurde als standardmäßiger Bestandteil moderner Arbeitsabläufe betrachtet – in gleicher Weise, wie eine integrierte Entwicklungsumgebung oder eine Rechtschreibprüfung ein Standardbestandteil beim Schreiben von Programmcode und Fließtext ist. Der Einsatz erfolgte stets unterstützend und zu keinem Zeitpunkt als passive Abgabe von Aufgaben. Jede Ausgabe unterlag einer engen manuellen Überwachung, wurde wiederholt überarbeitet und durch den Autor verifiziert.

Die folgenden Werkzeuge kamen zum Einsatz:

- **DeepL Write** wurde für das sprachliche Lektorat und das grammatikalische Korrekturlesen verwendet.
- **Gemini (Google)** wurde zur Unterstützung beim Brainstorming, zur Klärung technischer Konzepte und zur Generierung von Formulierungsvorschlägen für nicht-technische Erklärungstexte genutzt. Zudem diente es als erster Schritt bei der Informationssuche anstelle einer konventionellen Suchmaschine.
- **Antigravity (Google)** wurde als agentische Entwicklungsumgebung und über die Befehlszeilenschnittstelle (CLI) für Programmieraufgaben, technische Beratung, Code-Reviews sowie das Korrekturlesen der Abschlussarbeit eingesetzt (u. a. zur automatisierten Überprüfung auf argumentative Konsistenz, präzise Wortwahl sowie Rechtschreibung und Grammatik).

Die KI-Werkzeuge dienten zudem als Diskussions- und Sparringspartner sowie zum »Rubber Ducking«. Das strukturierte Formulieren eines Problems gegenüber dem System trug oft bereits vor Erhalt einer Antwort zur Klärung bei. Sämtliche methodischen Vorgehensweisen und erarbeiteten Lösungsansätze wurden darüber hinaus fortlaufend in den wöchentlichen Master-Meetings mit dem betreuenden Professor, den Doktoranden und weiteren Masterstudierenden gegengeprüft, diskutiert und entweder bestätigt, verworfen oder gezielt weiterentwickelt.

Alle durch KI-Werkzeuge generierten Inhalte wurden vom Autor kritisch geprüft, editiert und verifiziert. Kein generatives KI-System wurde zur Erzeugung

originärer wissenschaftlicher Resultate, experimenteller Messdaten, Beweise oder der finalen Implementierungen der Algorithmen herangezogen. Das Forschungsdesign, die Analyse sowie die Interpretation der Ergebnisse sind originäre Leistungen des Autors. Der Autor übernimmt die uneingeschränkte Verantwortung für den Inhalt, die Richtigkeit und die Eigenständigkeit dieser Arbeit.

Ich versichere, dass ich meine Arbeit selbstständig und ohne fremde Hilfe verfasst, keine anderen als die angegebenen Quellen und Hilfsmittel benutzt, alle wörtlich oder sinngemäß übernommenen Stellen einschließlich generierter Texte in der Arbeit gekennzeichnet habe, und dass die Arbeit in gleicher oder ähnlicher Form in noch keiner anderen Prüfung vorgelegen hat. Ich stimme der Überprüfung der Arbeit durch eine Plagiatsoftware zu.

Ort, Datum

Unterschrift

Inhaltsverzeichnis

1	Einleitung	1
1.1	Problemstellung & Motivation	1
1.2	Zielsetzung & Forschungsfragen	2
1.3	Aufbau der Arbeit	3
2	Theoretischer Hintergrund	5
2.1	Das Konzept der Leichten Sprache	5
2.2	Grundlagen der automatischen Textvereinfachung	5
2.2.1	Textrepräsentationen & Einbettungen	6
2.2.2	Herausforderungen der automatischen Evaluation	7
2.3	Architekturen moderner neuronaler Sprachmodelle	7
2.3.1	Der Attention-Mechanismus	7
2.3.2	Modellfamilien im NLP	8
3	Stand der Forschung	9
3.1	Verfügbare Datenbasis und Korpora (Themenblock 1)	9
3.2	Evaluierungsmetriken für die Vereinfachung (Themenblock 2) . .	10
3.3	Maschinelle Übersetzung und Optimierungsverfahren (Themenblock 3)	12
4	Themenblock 1: Datenbasis & Korpus-Erstellung	14
4.1	Multi-Quellen-Crawling & Datenakquise	16
4.1.1	Domänen- und Quellenabdeckung	17
4.1.2	Technische Extraktions- & Verknüpfungsmechanismen . .	18
4.1.3	Ergebnis der Datenakquise (Roh-Korpus)	20
4.2	Datenbereinigung & Normalisierung	21
4.2.1	Web-Boilerplate-Bereinigung & Tag-Punctuation-Guard .	22
4.2.2	Typografische Normalisierung & Listen-Transformation .	23
4.2.3	Quantitative Korpusevaluation: Pipeline-Funnel & Retention	24
4.2.4	Empirische Fallstudien zur Bias- & Halluzinations-Prävention	26
4.3	Quality Assurance & Similarity Sweet-Spot	27
4.3.1	Long-Context-Vektorisierung mittels Jina Embeddings v2	27
4.3.2	Der Similarity Sweet-Spot: Filtration & Grenzdefinition .	28
4.4	Korpus-Statistiken & Lexikalische Diversität	29
4.4.1	Quantitative Korpusmaße & Quellcharakteristika	30

4.4.2	Lexikalische Diversität: TTR vs. MATTR & Längen-Bias	31
4.4.3	Faktenerhalt vs. Faktentreue: Grenzen von NER als Metrik	32
4.4.4	Regel-Adhärenz & Regeleinhaltung nach BMAS-Richtlinien	34
4.4.5	Synthese der Korpuseigenschaften	36
5	Themenblock 2: Metrik & Bewerten von Sprachkomplexität	37
5.1	Klassifikationsmodelle (BiLSTM vs. Baselines)	37
5.2	Out-of-Domain-Generalisierung & Empirische Bias-Kontrolle . .	38
5.3	Continuous MixUp Regression	39
5.4	Evaluierung synthetischer Sprachstufen	40
6	Themenblock 3: Modellierung der Übersetzung & Reward-Guided Fine-Tuning	41
6.1	Datenvorbereitung & Trainings-Splits	41
6.2	Supervised Fine-Tuning (SFT)	42
6.3	Reward-Guided Optimization (RLHF / DPO)	43
6.4	Mehrdimensionale Evaluierung & Demonstrator-App	44
7	Diskussion & Gesamtevaluation	45
7.1	Inhaltssynthese der drei Themenblöcke	45
7.2	Stärken, Grenzen & Systemrestriktionen	45
7.3	Beantwortung der Forschungsfragen	45
8	Fazit & Ausblick	46
8.1	Zusammenfassung der Kernergebnisse	46
8.2	Ausblick & Zukünftige Forschungsarbeiten	46
9	Anhang	47
	Glossar	48
	Abbildungsverzeichnis	49
	Tabellenverzeichnis	50
	Literaturverzeichnis	51
10	Anhang	54

1 Einleitung

1.1 Problemstellung & Motivation

Für manche eine optionale Lesehilfe, für andere der einzige Zugang zu gesellschaftlicher Teilhabe.

Beim Thema Barrierefreiheit denken viele an physische Barrieren wie Rampen, Aufzüge oder automatische Türen. Durch die Digitalisierung und die Verlagerung von Dienstleistungen und Informationen ins Internet ist es damit jedoch nicht mehr getan. Barrierefreie Gestaltung betrifft zunehmend digitale Räume und insbesondere die Sprache, in der Informationen bereitgestellt werden.

Menschen mit kognitiven Einschränkungen, Lernschwierigkeiten, geringer Lese- und Schreibkompetenz oder Deutsch als Zweitsprache werden durch komplexe Texte, bürokratische Fachsprache und verschachtelte Satzstrukturen vom Zugang zu grundlegenden Informationen und Dienstleistungen ausgeschlossen. Das Konzept der *Leichten Sprache* (LS) bietet hierfür ein klar reglementiertes Regelwerk, um Texte durch Vereinfachung des Vokabulars und der Syntax verständlich zu machen.

Mit dem Inkrafttreten des Barrierefreiheitsstärkungsgesetzes (BFSG) in Deutschland sowie europäischen Richtlinien (wie der Web-Accessibility-Directive) wächst der rechtliche Druck auf öffentliche und private Akteure, Informationen auch in Leichter Sprache anzubieten. Die manuelle Übersetzung von Alltagssprache (AS) in Leichte Sprache (LS) durch menschliche Übersetzer ist jedoch extrem zeitintensiv, kostspielig und durch einen Mangel an Fachkräften limitiert.

Hieraus ergibt sich ein dringender Forschungs- und Entwicklungsbedarf im Bereich der maschinellen Textvereinfachung. Bisherige neuronale Übersetzungsmodelle scheitern jedoch häufig an den spezifischen syntaktischen und strukturellen Besonderheiten der Leichten Sprache oder leiden unter dem Mangel an qualitativ hochwertigen, parallelen Trainingsdaten. Es bedarf daher systematischer Ansätze zur automatisierten Erstellung paralleler Korpora, robuster Metriken zur Komplexitätsbewertung und optimierter Trainingsstrategien.

1.2 Zielsetzung & Forschungsfragen

Ziel dieser Arbeit ist die Entwicklung, Optimierung und empirische Evaluierung eines methodischen Frameworks zur automatisierten Übersetzung deutscher Alltagssprache in Leichte Sprache. Dies umfasst die gesamte Pipeline: von der Akquise und Bereinigung paralleler Web-Korpora über die kontinuierliche, referenzfreie Modellierung von Textsimplizität bis hin zur dateneffizienten Modelladaption (LoRA) und dem Präferenz-Alignment (DPO).

Im Zentrum dieser Arbeit steht die folgende übergreifende Leitfrage:

Wie lässt sich die automatische Übersetzung in Leichte Sprache (LS) durch die Kombination aus rauschbereinigten Korpora, kontinuierlichen Simplitätsmetriken und zielgerichteten Alignment-Strategien (DPO) systematisch optimieren und validieren?

Zur systematischen Beantwortung dieser Leitfrage werden sechs forschungsleitende Kernfragen (**FF1** bis **FF6**) formuliert, die den logischen Bogen über die drei methodischen Hauptsäulen der Arbeit spannen:

1. Datenbasis & Korpusqualität (Themenblock 1):

- **FF1 (Quellenheterogenität & Web-Rauschen):** *Inwieweit existiert im deutschsprachigen Web eine hinreichende und qualitativ konsistente Datenbasis für Leichte Sprache, und welche Vorverarbeitungsschritte sind erforderlich, um domänenspezifisches Web-Rauschen (Boilerplate, Teaser, maschinelle Vorübersetzungen) zu eliminieren?*
- **FF2 (Artikel- vs. Satzebene & Informationsverlust):** *Welche Vor- und Nachteile bietet eine artikelbasierte Modellierung gegenüber satzweiser Segmentierung für das Übersetzen in Leichte Sprache, und wie lässt sich der inhärente Konflikt zwischen syntaktischer Simplifikation und semantischem Informationsverlust (Faktenerhalt) quantifizieren?*

2. Metrik & Kontinuierliche Simplitäts-Modellierung (Themenblock 2):

- **FF3 (Kontinuierliche Regression ohne Zwischenkorpora):** *Wie kann ein kontinuierliches Regressionsmodell zur Messung des Vereinfachungsgrads trainiert werden, wenn in realen Korpora ausschließlich binäre Extremzustände (Standardsprache vs. Leichte Sprache) ohne natürliche Zwischenstufen vorliegen?*

3. Übersetzung, Alignment & Expertenvalidierung (Themenblock 3 & Diskussion):

- **FF4 (Dateneffizienz & PEFT/LoRA):** *In welchem Maße können vortrainierte Sequenz-zu-Sequenz-Modelle bei extrem begrenzter Datenmenge (800–1.000 Artikelpaare) die komplexen syntaktischen und lexikalischen Regeln der Leichten Sprache erlernen, ohne in Memorization und Overfitting zu verfallen?*
- **FF5 (Reward-Guided Alignment via DPO):** *Inwiefern kann das Signal eines kontinuierlich trainierten Simplizitäts-Regressors genutzt werden, um ein vortrainiertes Übersetzungsmodell über Direct Preference Optimization (DPO) gezielt auf die Eigenheiten Leichter Sprache auszurichten, ohne die semantische Faktentreue zu kompromittieren?*
- **FF6 (Expertenvalidierung & Ökologische Validität):** *Wie valide korrelieren automatisierte Bewertungsmetriken mit dem qualitativen Urteil von Fachkräften für Leichte Sprache (Lebenshilfe Kiel), und in welchem Maße sind Modellübersetzungen von professionellen Humanübersetzungen unterscheidbar?*

1.3 Aufbau der Arbeit

Die vorliegende Arbeit folgt einer logischen Struktur, die sich an den drei Säulen des entwickelten Übersetzungssystems orientiert:

- **Kapitel 2 (Theoretischer Hintergrund)** legt das theoretische und linguistische Fundament. Es definiert das Konzept der Leichten Sprache und grenzt dieses formal sowie rechtlich von der Einfachen Sprache ab.
- **Kapitel 3 (Stand der Forschung)** stellt den aktuellen wissenschaftlichen Stand strukturiert entlang der drei Säulen Datenbasis, Komplexitätsmetriken und maschinelle Übersetzungsverfahren dar und leitet die bestehenden Forschungslücken ab.

- **Kapitel 4 (Themenblock 1: Datenbasis & Korpus-Erstellung)** beschreibt die erste Stufe der Pipeline. Im Fokus steht das Crawling paralleler Webtexte, die domänenspezifische Datenbereinigung und die qualitative Filterung mittels semantischer Embeddings.
- **Kapitel 5 (Themenblock 2: Metrik & Bewerten von Sprachkomplexität)** widmet sich der zweiten Stufe: der Entwicklung von Klassifikationsmodellen (BiLSTM vs. SBERT) und dem Entwurf einer *Continuous MixUp Regression* zur stufenlosen Komplexitätsbewertung.
- **Kapitel 6 (Themenblock 3: Modellierung der Übersetzung & Reward-Guided Fine-Tuning)** stellt das eigentliche Übersetzungsmodell vor. Hierbei werden die Implementierung des Supervised Fine-Tunings (SFT) sowie das Reward-Guided Fine-Tuning (DPO) zur Regeleinhaltung evaluiert.
- **Kapitel 7 (Diskussion & Gesamtevaluation)** führt die Ergebnisse der drei Stufen zusammen, beantwortet systematisch die aufgeworfenen Forschungsfragen und beleuchtet kritisch die Systemrestriktionen sowie Fragen zur Faktentreue.
- **Kapitel 8 (Fazit & Ausblick)** fasst die Kernergebnisse der Arbeit zusammen und gibt einen Ausblick auf zukünftige Forschungsarbeiten und praktische Anwendungsfelder.

2 Theoretischer Hintergrund

2.1 Das Konzept der Leichten Sprache

Das Konzept der Leichten Sprache (LS) stellt eine stark reglementierte Sprachvariante der deutschen Standardsprache dar, die primär darauf abzielt, Barrierefreiheit in der schriftlichen Kommunikation für Menschen mit kognitiven Einschränkungen, Lernschwierigkeiten oder geringer Lese- und Schreibkompetenz zu gewährleisten. Syntaktisch zeichnet sich LS unter anderem durch kurze Hauptsätze (Subjekt-Prädikat-Objekt), den Verzicht auf Nebensätze, Passivkonstruktionen, den Genitiv sowie den Konjunktiv aus. Auf lexikalischer Ebene werden abstrakte Begriffe durch konkrete Beispiele ersetzt, und lange zusammengesetzte Wörter werden mittels typografischer Hilfsmittel wie Bindestrichen oder dem Mediopunkt (z. B. *Bundestags-Wahl* oder *Bundestags·wahl*) segmentiert.

Vom Konzept der Leichten Sprache ist die sogenannte *Einfache Sprache* (Plain German) abzugrenzen. Während die Leichte Sprache als hochspezialisierte Sprachvariante mit strengen, normierten Richtlinien konzipiert ist und in Deutschland rechtlich durch die Barrierefreie-Informationstechnik-Verordnung (BITV 2.0) für öffentliche Stellen vorgeschrieben wird (Überwachungsstelle des Bundes für Barrierefreiheit von Informationstechnik, 2026), besitzt die Einfache Sprache ein weitaus weniger restriktives Regelwerk. Letztere richtet sich an eine breitere Zielgruppe (wie Menschen mit Deutsch als Zweitsprache oder funktionale Alphabeten) und lässt komplexere Satzstrukturen sowie einen größeren Wortschatz zu. Ein weiterer kritischer Unterschied liegt im Qualitätssicherungsprozess: Texte in Leichter Sprache müssen zwingend von Personen aus der primären Zielgruppe auf ihre Verständlichkeit hin geprüft werden, was bei Texten in Einfacher Sprache nicht vorgeschrieben ist.

2.2 Grundlagen der automatischen Textvereinfachung

Die automatische Textvereinfachung (*Automatic Text Simplification*, ATS) zielt darauf ab, die syntaktische und lexikalische Komplexität eines Textes zu reduzieren, während die semantische Kernbotschaft erhalten bleibt. Aus maschineller Sicht lässt sich ATS formal als monolinguale maschinelle Übersetzung (*Monolingual Machine Translation*) modellieren. Im Gegensatz zur klassischen bilingualen Übersetzung (z. B. Deutsch nach Englisch) erfordert ATS tiefgreifende asymme-

trische Strukturtransformationen:

- **Satzteilung (Sentence Splitting):** Lange, hypotaktische Satzgefüge müssen in mehrere koordinierte Hauptsätze zerlegt werden.
- **Streichung & Kompression (Deletion/Compression):** Redundante oder nebensächliche Füllinformationen müssen getilgt werden, um die kognitive Belastung des Lesers zu reduzieren.
- **Lexikalische Substitution & Explikation:** Schwierige Fachtermini müssen durch frequente Synonyme ersetzt oder um definitorische Nebensätze erweitert werden.

2.2.1 Textrepräsentationen & Einbettungen

Moderne Algorithmen des Natural Language Processing (NLP) verarbeiten Text über numerische Repräsentationen. Der Prozess gliedert sich in Tokenisierung und Einbettung (*Embedding*):

1. **Tokenisierung:** Vor der mathematischen Modellierung wird der Text in atomare Einheiten (Tokens) zerlegt. Neben wortbasierten Verfahren kommen in neuronalen Modellen überwiegend Subword-Tokenisierer wie Byte-Pair Encoding (BPE) nach Sennrich et al. (2016) oder SentencePiece zum Einsatz. Diese ermöglichen es, ein geschlossenes Vokabular fester Größe zu definieren und gleichzeitig seltene oder unbekannte Wörter (*Out-of-Vocabulary*, OOV) in morphologische Subkomponenten aufzuspalten.
2. **Dichte Vektoreinbettungen (Dense Embeddings):** Tokens oder ganze Sequenzen werden auf kontinuierliche Vektoren $\mathbf{e} \in \mathbb{R}^d$ im latenten semantischen Raum abgebildet. Sentence-Embedding-Modelle wie Sentence-BERT (SBERT) nach Reimers und Gurevych (2019) erzeugen über siamesische Netzwerke kontextsensitive Sequenzrepräsentationen.
3. **Semantische Ähnlichkeit:** Die inhaltliche Verwandtschaft zweier Textsequenzen x und y mit den Einbettungen $\mathbf{e}_x, \mathbf{e}_y$ wird üblicherweise über die Kosinus-Ähnlichkeit im Vektorraum quantifiziert:

$$\text{sim}_{\cos}(\mathbf{e}_x, \mathbf{e}_y) = \frac{\mathbf{e}_x \cdot \mathbf{e}_y}{\|\mathbf{e}_x\|_2 \|\mathbf{e}_y\|_2} \in [-1, 1] \quad (1)$$

welche für Normalisierungszwecke oft linear auf das Intervall $[0, 1]$ skaliert wird: $\text{sim}_{\text{norm}} = \frac{\text{sim}_{\cos} + 1}{2}$.

2.2.2 Herausforderungen der automatischen Evaluation

Die Evaluation von ATS-Systemen unterscheidet sich fundamental von der Standard-Übersetzung. Klassische referenzbasierte N-Gramm-Metriken wie BLEU (Papineni et al., 2002) und ROUGE (Lin, 2004) messen primär die wörtliche Übereinstimmung mit einem Referenztext. Wie Alva-Manchego et al. (2021) empirisch belegen, korreliert BLEU im ATS-Kontext jedoch häufig negativ mit der menschlichen Beurteilung: Ein System, das den komplexen Ausgangstext unverändert kopiert, erzielt oft hohe BLEU-Werte, leistet jedoch keine Vereinfachung.

Aus diesem Grund etablierte sich die Metrik SARI (Xu et al., 2016), welche eingefügte (*add*), beibehaltene (*keep*) und gelöschte N-Gramme (*delete*) explizit getrennt gegenüber der Quelle und den Referenzen bewertet und somit Vereinfachungsoperationen honoriert.

2.3 Architekturen moderner neuronaler Sprachmodelle

Neuronale Sprachmodelle haben sich als führendes Paradigma für Sequence-to-Sequence-Aufgaben etabliert. Das Fundament bildet die von Vaswani et al. (2017) eingeführte **Transformer-Architektur**, welche vollständig auf rekurrente Schleifen verzichtet und stattdessen auf dem Konzept der *Self-Attention* (Selbstaufmerksamkeit) aufbaut.

2.3.1 Der Attention-Mechanismus

Der skalierten Skalarprodukt-Aufmerksamkeit (*Scaled Dot-Product Attention*) liegen drei Vektormatrizen zugrunde: Queries **Q**, Keys **K** und Values **V**, welche durch lineare Projektionen der Eingangsrepräsentationen entstehen. Die Aufmerksamkeitsmatrix wird formal berechnet durch:

$$\text{Attention}(\mathbf{Q}, \mathbf{K}, \mathbf{V}) = \text{softmax} \left(\frac{\mathbf{Q}\mathbf{K}^T}{\sqrt{d_k}} \right) \mathbf{V} \quad (2)$$

wobei d_k die Dimension der Key-Vektoren darstellt. Mittels *Multi-Head Attention* wird dieser Prozess mehrfach parallel mit unterschiedlichen Projektionsmatrizen durchgeführt, wodurch das Modell simultan Beziehungen auf unterschiedlichen semantischen und syntaktischen Abstraktionsebenen erfassen kann.

2.3.2 Modellfamilien im NLP

Je nach Aufbau der Transformer-Schichten werden drei primäre Architekturtypen unterschieden:

1. **Encoder-Decoder-Modelle (Sequence-to-Sequence):** Diese Architektur (wie mBART von Lewis et al. (2020) und Tang et al. (2020) oder mT5) besteht aus einem bidirektionalen Encoder zur Repräsentation des Eingabetextes und einem autoregressiven Decoder, der mittels *Cross-Attention* konditioniert auf die Encoder-Ausgaben den Zieltext Token für Token generiert. Sie eignet sich hervorragend für klassische Transformations- und Übersetzungsaufgaben.
2. **Decoder-Only-Modelle (Kausale Sprachmodelle):** Modelle wie die LLaMA- oder Mistral-Familie nutzen ausschließlich kausal maskierte Decoder-Schichten (*Causal Masking*). Jedes Token darf nur auf vorherige Token aufmerksam werden. Sie werden auf die Vorhersage des nächsten Tokens (*Next-Token Prediction*) vortrainiert und über Prompting oder Instruction Fine-Tuning gesteuert.
3. **Encoder-Only-Modelle:** Modelle wie BERT (Devlin et al., 2019) oder das deutschsprachige GBERT verarbeiten Eingabesequenzen vollständig bidirektional. Sie eignen sich primär für Sequenz- und Token-Klassifikationsaufgaben sowie für Einbettungsmodelle, nicht jedoch zur autoregressiven Textgenerierung.

3 Stand der Forschung

3.1 Verfügbare Datenbasis und Korpora (Themenblock 1)

Einen guten Überblick über den aktuellen Stand und die verfügbaren Ressourcen für Leichte und Einfache Sprache in Deutschland geben Madina et al. (2023). Sie zeigen dabei vor allem auf, wie unterschiedlich die bestehenden Datensätze strukturiert sind und dass es an standardisierten Werkzeugen zur automatischen Bewertung der Texte fehlt.

Die Erforschung datengetriebener, maschineller Übersetzungsverfahren (Automatic Text Simplification, ATS) für das Deutsche litt historisch unter einer eklatanten Datenknappheit. Erste Versuche, ein paralleles Korpus aufzubauen, gehen auf Klaper et al. (2013) mit dem *KLAPER*-Korpus zurück, das jedoch mit ca. 250 parallelen Textpaaren (rund 7.000 Sätze und 70.000 Tokens) für moderne Deep-Learning-Ansätze deutlich zu klein war.

Einen Meilenstein stellte die Arbeit von Battisti et al. (2020) dar, die ein umfangreiches, multimodales Korpus für das Deutsche zusammentrug. Die AutorInnen entwickelten Web-Scraper, um Texte in Leichter und Einfacher Sprache von verschiedenen deutschsprachigen Webportalen und Institutionen der Behindertenhilfe (wie etwa gesundheitlichen Informationsdiensten, öffentlich-rechtlichen Nachrichtenportalen und sozialen Trägern) zu extrahieren. Insgesamt umfasst das Korpus 6.217 Dokumente bzw. fast 211.000 Sätze mit rund 5,5 Millionen geschriebenen Tokens. Ein zentrales Merkmal der Arbeit ist die Aufteilung des Korpus: Es besteht zu einem großen Teil aus 5.461 monolingualen Dokumenten in vereinfachter Sprache, während der parallele Teil mit lediglich 378 parallelen Dokumentenpaaren (jeweils 378 Ausgangs- und Zieltexte) im Vergleich dazu sehr klein ausfällt. Neben den reinen Texten erfassten die AutorInnen systematisch typografische Metadaten (Schriftart, -größe und -stil), Absatz- und Zeilenstrukturen sowie Informationen zu eingebetteten Bildern (Vorhandensein, Dimensionen und Positionierung). Sie wiesen nach, dass diese visuellen Layout-Features die automatische Bewertung der Lesbarkeit (Readability Assessment) stark verbessern.

Für den Bereich der „Einfachen Sprache“ (Plain German) präsentierten Stodden et al. (2023) mit *DEplain* ein professionell erstelltes paralleles Korpus. Dieses teilt sich auf in einen Nachrichtenbereich (DEplain-APA) mit ca. 500 Dokumentenpaaren (rund 13.000 manuell ausgerichteten Satzpaaren) und einen

Webbereich mit ca. 150 manuell ausgerichteten Dokumenten (ca. 2.000 Satzpaaren). Um die Datenknappheit weiter zu reduzieren, stellt das Framework zusätzlich einen Web-Harvester zur automatischen Extraktion und Ausrichtung bereit, wodurch der Webbereich auf ca. 750 Dokumentenpaare (ca. 3.500 automatisch ausgerichtete Satzpaare) vergrößert werden kann. Die Autoren zeigten, dass Modelle, die auf Dokumentenebene trainiert werden, oft Probleme haben, die feinkörnigen semantischen Übergänge beizubehalten, weshalb präzise Alignments eine kritische Ressource für das Training von Seq2Seq-Modellen darstellen. An dieser Stelle ist jedoch hervorzuheben, dass eine direkte Vergleichbarkeit mit Systemen zur Übersetzung in Leichte Sprache erschwert ist: Obwohl das DEplain-Framework methodisch wertvolle Ansätze liefert, bezieht es sich durch den Fokus auf Einfache Sprache auf eine andere linguistische Ziel- und Datendomäne.

Einen weiteren Beitrag zur Generierung paralleler Ressourcen leisteten Toborek et al. (2023) mit der Vorstellung des *New Aligned Simple German Corpus*. Ihr Datensatz besteht aus ca. 700 Dokumentenpaaren auf Dokumentenebene und über 10.000 Satzpaaren auf Satzebene, die teils manuell annotiert und teils automatisch berechnet wurden. Das Korpus kombiniert dabei das systematische Scraping paralleler Webinhalte mit automatischer Satz-Ausrichtung. Allerdings fasst die Arbeit Texte sowohl der Leichten als auch der Einfachen Sprache unter einem gemeinsamen Vereinfachungsbegriff zusammen, was eine feine Unterscheidung der spezifischen syntaktischen und semantischen Richtlinien von Leichter Sprache erschwert. Dieser Kompromiss verdeutlicht jedoch auch ein grundlegendes Problem der aktuellen Forschung: Ein Korpusaufbau, der sich ausschließlich auf reine Leichte Sprache beschränkt, ist Stand jetzt kaum in großem Umfang realisierbar, da es im deutschsprachigen Web schlichtweg an einer ausreichenden Anzahl frei zugänglicher, paralleler Quellen fehlt.

3.2 Evaluierungsmetriken für die Vereinfachung (Themenblock 2)

Die automatische Evaluierung von Textvereinfachungssystemen stellt eine große methodische Hürde dar. Traditionelle Metriken der maschinellen Übersetzung wie BLEU, die primär auf n-Gramm-Präzision im Vergleich zu einer Referenzübersetzung basieren, erweisen sich für die Vereinfachung oft als ungeeignet. Wie Alva-Manchego et al. (2021) empirisch belegen, korreliert BLEU nur schwach mit dem menschlichen Urteil über Einfachheit und Textqualität. Der Grund liegt

darin, dass BLEU lexikalische Variationen und strukturelle Modifikationen (wie Satzteilung und Umformulierung) als Fehler abstrahlt, obwohl genau diese für eine gute Vereinfachung essenziell sind.

Als Alternative etablierte sich die Metrik *SARI* (System Accessibility and Readability Index), eingeführt von Xu et al. (2016). SARI vergleicht die Systemausgabe sowohl mit dem komplexen Ausgangstext als auch mit den Referenzübersetzungen. Dabei berechnet SARI separat die Präzision und den Recall für eingefügte (add), gelöschte (delete) und beibehaltene (keep) Wörter:

$$\text{SARI} = \frac{F_{\text{add}} + F_{\text{keep}} + P_{\text{del}}}{3} \quad (3)$$

Dadurch belohnt SARI explizit Vereinfachungsoperationen, die sich vom komplexen Ausgangstext wegbewegen.

Im Laufe der Entstehungszeit dieser Arbeit wurde mit *DETECT* von Kobeynikova et al. (2024) eine neuartige, erlernbare Evaluierungsmetrik speziell für die deutsche Textvereinfachung vorgestellt. DETECT adaptiert das englischsprachige LENS-Framework für den deutschsprachigen Raum und zielt darauf ab, die Qualität automatischer Vereinfachungen ganzheitlich über drei Dimensionen abzubilden: Verständlichkeit (*Simplicity / Ease*), semantische Inhaltsbewahrung (*Meaning Preservation*) sowie grammatikalische Korrektheit und Sprachfluss (*Fluency / Textual Clarity*). Um den Mangel an manuell annotierten Trainingsdaten zu überwinden, wird das Regressionsmodell vollständig auf synthetisch durch Large Language Models generierten Qualitätsurteilen trainiert. In empirischen Validierungen auf einem eigens erhobenen menschlichen Testdatensatz wiesen die AutorInnen nach, dass DETECT deutlich stärkere Korrelationen mit menschlichen Qualitätsbewertungen erzielt als traditionelle Maße wie BLEU, SARI oder BERTScore.

Gleichzeitig verdeutlicht dieser Ansatz zentrale verbleibende Forschungslücken: Da der zugrundeliegende Evaluierungsdatensatz (*SimpEvalDE*) primär auf Korpora der Einfachen Sprache (DEplain-APA und LHA-APA) aufbaut, sind spezifische, normierte Richtlinien der Leichten Sprache — wie das strikte Vermeiden von Passiv- und Genitivkonstruktionen oder die typografische Gliederung von Komposita — nicht explizit als Kriterien modelliert. Zudem sind rein referenzbasierte Satz-Metriken nur bedingt geeignet, um die Komplexität längerer Dokumente ganzheitlich und referenzfrei zu bewerten oder als kontinuierliches Steuerungssignal während des Modelltrainings eingesetzt zu werden.

Obwohl das Thema Leichte Sprache in der deutschsprachigen NLP-Forschung über viele Jahre hinweg nur wenig Beachtung gefunden hat, zeigt das jüngste Erscheinen solcher Arbeiten, dass das Forschungsfeld derzeit stark an Dynamik gewinnt, was die wissenschaftliche und gesellschaftliche Relevanz dieses Themenbereichs zusätzlich unterstreicht.

3.3 Maschinelle Übersetzung und Optimierungsverfahren (Themenblock 3)

Die maschinelle Übersetzung von Alltagssprache (AS) in Leichte Sprache (LS) lässt sich formal als monolinguale maschinelle Übersetzung (*Monolingual Machine Translation*) begreifen. Im Gegensatz zur klassischen bilingualen Übersetzung (z. B. Deutsch–Englisch) erfordert dieser Transformationsprozess tiefgreifende asymmetrische Strukturänderungen: Komplexe Satzgefüge müssen aufgespalten (*Sentence Splitting*), Passiv- in Aktivkonstruktionen überführt, irrelevante Textpassagen gekürzt (*Compression*) und abstrakte Begrifflichkeiten explizierend umschrieben werden.

Die empirische Erforschung datengetriebener Übersetzungsmodelle für die deutsche Leichte Sprache ist bislang stark limitiert. Erste systematische Benchmarks zur neuronalen maschinellen Übersetzung (NMT) für das Deutsche wurden von Säuberli et al. (2020) vorgelegt. Auf Basis eines kleinen parallelen Nachrichtenkorpus wiesen die Autoren nach, dass Transformer-basierte Sequence-to-Sequence-Modelle grundlegende lexikalische Substitutionen und Satzkürzungen erlernen können. Allerdings zeigten sich deutliche qualitative Grenzen bei komplexeren syntaktischen Transformationen sowie eine hohe Anfälligkeit für die zugrundeliegende Datenknappheit.

Mit dem Aufkommen moderner Large Language Models (LLMs) verlagerte sich der Schwerpunkt zunehmend auf vortrainierte generative Sprachmodelle (wie die LLaMA- oder Mistral-Familie). Während rein Prompt-basierte Ansätze genereller Modelle häufig dazu neigen, Texte lediglich in ein moderates Sprachniveau (Einfache Sprache) zu überführen und formale Negativbeschränkungen der Leichten Sprache (wie den strikten Ausschluss von Genitiven oder Nebensätzen) zu verletzen, ermöglicht das zielgerichtete Fine-Tuning (z. B. Parameter-Efficient Fine-Tuning mittels LoRA/QLoRA) eine präzisere stilistische Anpassung.

Da qualitativ hochwertige parallele Datenpaare in der Praxis stark limitiert sind, stößt reines Supervised Fine-Tuning (SFT) schnell an eine quantitative

Obergrenze. In diesem Kontext bietet die Präferenzoptimierung (*Preference Optimization*) einen vielversprechenden Ansatz zur weiteren Modellverbesserung: Mit dem initial trainierten SFT-Basismodell können für neue oder unalignierte Ausgangstexte mehrere Übersetzungskandidaten generiert werden. Werden diese Ausgaben anschließend anhand von Qualitäts- oder Komplexitätskriterien in bevorzugte (*chosen*, y_w) und abgelehnte (*rejected*, y_l) Antworten unterteilt, lässt sich das Modell auf diesen neu erzeugten Präferenzpaaren gezielt weiter trainieren und an die spezifischen Stil- und Verständlichkeitsanforderungen anpassen.

Um generative Modelle mathematisch stabil und ohne den aufwendigen Overhead von klassischem Reinforcement Learning (RLHF/PPO) auf spezifische Qualitäts- und Formatierungsrichtlinien auszurichten, führten Rafailov et al. (2023) die *Direct Preference Optimization* (DPO) ein. DPO optimiert die Policy direkt auf Präferenzdaten der Form (x, y_w, y_l) — bestehend aus einem Prompt x , einer bevorzugten Antwort y_w (winning) und einer abgelehnten Antwort y_l (losing) — über eine geschlossene Verlustfunktion:

$$\mathcal{L}_{\text{DPO}}(\theta; \pi_{\text{ref}}) = -\mathbb{E}_{(x, y_w, y_l)} \left[\log \sigma \left(\beta \log \frac{\pi_{\theta}(y_w|x)}{\pi_{\text{ref}}(y_w|x)} - \beta \log \frac{\pi_{\theta}(y_l|x)}{\pi_{\text{ref}}(y_l|x)} \right) \right] \quad (4)$$

wobei π_{ref} die SFT-Referenz-Policy darstellt, β ein Regularisierungsparameter ist und σ die Sigmoidfunktion bezeichnet.

Die Wirksamkeit von DPO für die deutsche Textvereinfachung wurde kürzlich von Anonymized (2025) anhand des *HF4ATS*-Datensatzes untersucht. Die Autoren zeigten empirisch, dass DPO-optimierte Modelle im Vergleich zu reinem SFT nicht nur eine signifikant höhere Verständlichkeit für die Zielgruppe erzielen, sondern vor allem formale Kriterien der Leichten Sprache (wie das Vermeiden von Genitiven und Nebensätzen) drastisch stabiler einhalten.

Hieraus leitet sich eine zentrale **Forschungslücke** ab: Bisherige Übersetzungsansätze für das Deutsche operieren fast ausnahmslos auf isolierter Satzebene und sind auf statische, manuell erstellte Präferenzdaten angewiesen. Es fehlt an domänenübergreifenden Übersetzungssystemen, die Texte kohärent auf Dokumenten- und Articlebene transformieren und deren Präferenzoptimierung automatisiert über erlernte Komplexitätsmetriken als kontinuierliche Reward-Instanz gesteuert werden kann.

4 Themenblock 1: Datenbasis & Korpus-Erstellung

Die Erstellung eines qualitativ hochwertigen, repräsentativen und ausreichend großen parallelen Korpus bildet das Fundament für jedes datengetriebene Übersetzungssystem. Wie im vorangegangenen Kapitel dargelegt, leidet die maschinelle Textvereinfachung (ATS) für die deutsche Leichte Sprache unter einer eklatanten Datenknappheit. Während bestehende Ressourcen wie das Korpus von Battisti et al. (2020) einen wertvollen Grundstein legten, weisen sie für das Training moderner Seq2Seq- und Präferenzoptimierungsmodelle (wie DPO) entscheidende Limitierungen auf: Entweder ist ihr paralleler Anteil mit wenigen hundert Dokumenten zu gering, oder sie fokussieren sich, wie das DEplain-Korpus von Stodden et al. (2023), primär auf Einfache Sprache (Plain German), was sich linguistisch und regulatorisch signifikant von der Leichten Sprache unterscheidet. Einen wichtigen methodischen Impuls zur automatisierten Datengewinnung lieferten Toborek et al. (2023) mit dem *New Aligned Simple German Corpus*. Ihr Ansatz demonstrierte, wie parallele Webinhalte über seitenspezifische Selektoren und Sprachumschalter im Internet automatisiert identifiziert und gescraped werden können. Diese Vorgehensweise bildete den primären Ausgangspunkt für die in dieser Arbeit entwickelte Crawling- und Extraktions-Pipeline. Allerdings fokussieren Toborek et al. primär auf ein inhärent fehleranfälliges Satz-Alignment und differenzieren nicht strikt zwischen Leichter und Einfacher Sprache.

Um diese Forschungslücke zu schließen, wurde im Rahmen dieser Arbeit eine eigene, automatisierte Pipeline zur Akquise und Aufbereitung von Trainingsdaten entwickelt, welche die Scraping-Prinzipien von Toborek et al. (2023) als methodisches Fundament aufgreift, auf 11 heterogene Domänen ausweitet und zu einer artikelbasierten, qualitätsgesicherten Korpus-Pipeline weiterentwickelt. Da diese Vorarbeit mittlerweile rund drei Jahre zurückliegt und im deutschsprachigen Web in diesem Zeitraum zahlreiche neue Informationsangebote sowie redaktionelle Portale in Leichter Sprache entstanden sind, wurde die Entscheidung getroffen, einen vollständig neuen, zeitgemäßen und breiter aufgestellten Korpus aufzubauen.

Ein zentrales methodisches Charakteristikum der in dieser Arbeit entwickelten Pipeline und der nachfolgenden Modellierung ist die bewusste Entscheidung für ein **artikelbasiertes** (bzw. dokumentenweites) Training sowohl der Komplexitätsmetrik als auch des Übersetzungsmodells. In der bisherigen Forschung

wurden Vereinfachungssysteme primär auf Satzebene trainiert und evaluiert, was jedoch erhebliche Defizite aufweist:

1. **Kontext- und Kohärenzverlust:** Satzbasierte Ansätze trennen Sätze von dem, was sie im Kontext bedeuten. Dadurch gehen Anspielungen, der rote Faden und die Verbindung zwischen den einzelnen Elementen verloren. Zudem können makrostrukturelle Vereinfachungen wie die Umstrukturierung ganzer Absätze oder das Einfügen von erklärenden Hintergrundinformationen – welche im Konzept der Leichten Sprache essenziell sind – auf Satzebene nicht gelernt werden.
2. **Verrauschte Satz-Alignments:** Die Modellierung auf Satzebene setzt voraus, dass präzise Alignments vorliegen. Wie Stodden et al. (2023) und Štajner et al. (2018) zeigen, führt die asymmetrische Natur der Vereinfachung (z. B. n:m-Alignments und Satzteilungen) dazu, dass automatische Satz-Aligner entweder stark fehlerhafte Paare erzeugen oder einen massiven Informationsverlust durch das Verwerfen nicht-linearer Übergänge in Kauf nehmen müssen.
3. **Verlust struktureller Metadaten:** Wie Battisti et al. (2020) nachwiesen, spielen visuelle Layoutmerkmale, Absatzstrukturen und die Gliederung auf Dokumentenebene eine entscheidende Rolle für das Verständnis von Leichter Sprache. Ein satzbasiertes Alignment eliminiert diese Strukturen vollständig.

Indem wir den gesamten Artikel als Basiseinheit wählen, kann das Übersetzungsmodell lernen, globale Kürzungen vorzunehmen und Texte kohärent umzuformulieren. Gleichzeitig erlaubt dies der Komplexitätsmetrik, die Verständlichkeit eines Textes im Kontext des gesamten Dokuments statt isolierter Sätze zu bewerten. Die methodischen Entscheidungen dieser Pipeline spiegeln dabei direkt die in Abschnitt 3.3 und 3.2 diskutierten Herausforderungen des Forschungsstandes wider:

- **Multi-Quellen-Crawling & Datenakquise (Abschnitt 4.1):** Aufbauend auf den Scraping-Heuristiken des *New Aligned Simple German Corpus* (Toborek et al., 2023) als Ausgangspunkt wurde ein modularer Scraper für eine Vielzahl deutschsprachiger Webportale implementiert. Dies stellt sicher, dass sowohl behördliche Texte (im Kontext der BITV

2.0) als auch journalistische Beiträge und Alltagstexte über 11 heterogene Quellen hinweg automatisiert erfasst werden.

- **Datenbereinigung & Normalisierung (Abschnitt 4.2):** Da Rohdaten aus Webquellen stark variierende HTML-Strukturen, typografische Besonderheiten (z. B. die Verwendung von Bindestrichen oder Mediopunkten zur Worttrennung) und Layout-Elemente aufweisen, erfolgt zunächst eine zielgerichtete, regelbasierte Bereinigung und linguistische Vorverarbeitung.
- **Quality Assurance & Similarity Sweet-Spot (Abschnitt 4.3):** Um das von Štajner et al. (2018) beschriebene Rauschen in den ausgerichteten Daten zu minimieren, wird eine filterbasierte Qualitätssicherung auf Basis langer Vektoreinbettungen eingeführt. Diese identifiziert den optimalen Ähnlichkeitskorridor (den sogenannten „Similarity Sweet-Spot“), um sowohl thematisch divergierende Fehlverlinkungen als auch redundante Kopien ohne Vereinfachungseffekt auszuschließen.
- **Korpus-Statistiken & Lexikalische Diversität (Abschnitt 4.4):** Abschließend wird das resultierende Korpus quantitativ und qualitativ evaluiert. Hierbei wird analysiert, inwiefern die bereinigten und gefilterten Daten die theoretischen Anforderungen der Leichten Sprache erfüllen und welche lexikalische Vielfalt sowie syntaktischen Vereinfachungen sie aufweisen.

Dieses Kapitel beschreibt den detaillierten Ablauf dieser Schritte und dokumentiert die Designentscheidungen bei der Konstruktion des finalen Datensatzes.

4.1 Multi-Quellen-Crawling & Datenakquise

Die automatisierte Akquise paralleler Textdaten für die deutsche Leichte Sprache stellt aufgrund der heterogenen Weblandschaft und des Fehlens zentraler Repositorien eine erhebliche methodische Herausforderung dar. Während im englischsprachigen Raum Plattformen wie die *Simple English Wikipedia* als quasi-standardisierte Datenquelle dienen, existiert im deutschsprachigen Raum kein vergleichbares, monolithisches Korpus. Parallele Sprachversionen verteilen sich stattdessen über behördliche Portale, öffentlich-rechtliche Rundfunkanstalten, Verbände der Behindertenhilfe und journalistische Magazine.

Um diesen heterogenen Datenbestand automatisiert und reproduzierbar zu erschließen, greift die in dieser Arbeit entwickelte Pipeline die grundlegenden Scraping-Heuristiken des *New Aligned Simple German Corpus* von Toborek et al. (2023) als methodischen Ausgangspunkt auf. Während Toborek et al. ihr Verfahren jedoch primär auf die Extraktion unzusammenhängender Satzfragmente ausrichteten, wird der Ansatz hier zu einer modularen, zweistufigen Dokumenten-Crawling-Architektur erweitert. Diese trennt die logische URL-Identifikation strikt von der inhaltlichen DOM-Extraktion:

1. **Stufe 1: URL-Discovery & Alignment-Heuristiken** (`scripts/data_collection/crawl_scraper/`): In diesem Schritt navigieren spezialisierte Crawler durch die Zielportale, identifizieren Artikel in Leichter Sprache (LS) und ermitteln über seitenspezifische Verknüpfungsmechanismen die korrespondierende URL der Alltagssprache (AS). Das Ergebnis jeder Quelle wird als JSON-Struktur standardisierter URL-Paare abgelegt.
2. **Stufe 2: Selektive DOM-Content-Extraktion** (`scripts/data_collection/corpus_scrapers/`): Aufbauend auf den identifizierten URL-Paaren lädt die zweite Stufe die HTML-Dokumente asynchron herunter. Anstatt den gesamten Seiteninhalt ungefiltert zu erfassen, extrahiert ein zielgerichteter DOM-Parser ausschließlich den redaktionellen Fließtext über semantische HTML5-Container (`<main>`, `<article>`, `div.paragraph`). Navigationsleisten, Kopf- und Fußzeilen, Cookie-Banner sowie interaktive Schaltflächen werden dadurch bereits auf Extraktionsebene systematisch eliminiert.

4.1.1 Domänen- und Quellenabdeckung

Um eine breite stilistische und thematische Varianz zu gewährleisten und eine Überanpassung an ein einzelnes redaktionelles Regelwerk zu verhindern, wurden 11 frei zugängliche deutschsprachige Webquellen aus drei gesellschaftlich relevanten Domänen erschlossen:

- **Öffentliche Verwaltung & Kommunalportale:** Dieser Sektor besitzt besondere rechtliche Relevanz, da öffentliche Stellen gemäß der Barrierefreie-Informationstechnik-Verordnung (BITV 2.0) gesetzlich verpflichtet sind, wesentliche Informationen in Leichter Sprache bereitzustellen (Überwachungsstelle des Bundes für Barrierefreiheit von Informationstechnik, 2026).

Erfasst wurden die Stadt- und Kommunalportale *Hannover.de* (welches aufgrund seines Umfangs als quantitativer Schwerpunkt dient), *Hamburg.de*, *Koeln.de*, *Stuttgart.de* und *Wiesbaden.de*.

- **Medien & Journalismus:** Zur Abdeckung tagesaktueller Berichterstattung und nachrichtlicher Diskursformen umfasst das Korpus die Angebote des Mitteldeutschen Rundfunks (*MDR Nachrichten in Leichter Sprache*), der tageszeitung (*taz*) sowie des Wirtschaftsmagazins *brand eins*.
- **Gesundheit, Soziales & Politik:** Zur Erfassung medizinischer und sozialrechtlicher Fachtexte wurden das Portal der *Apotheken Umschau* (Einfache Sprache), die Veröffentlichungen des *Beauftragten der Bundesregierung für die Belange von Menschen mit Behinderten* sowie das Bildungsportal *Sozialpolitik.com* integriert.

Ergänzend zu den Webquellen wurde ein unabhängiger **Out-of-Domain-Testdatensatz (OOD)** auf Basis realer Dokumente der *Lebenshilfe Schleswig-Holstein e. V.* aufgebaut. Dieser Datensatz umfasst behördliche Bescheide, Hausordnungen, Vereinbarungen und Prüfberichte, die von professionellen Übersetzungsbüros übertragen und von zertifizierten Prüfgruppen aus Menschen mit Lernschwierigkeiten validiert wurden. Die Extraktion erfolgte über ein spezialisiertes Parsing-Skript (`scripts/preprocessing/create_lebenshilfe_datasets.py`), welches proprietäre Dateiformate (`.docx`, `.rtf`, `.odt`) verarbeitet und für die spätere modellunabhängige Generalisierungsevaluation bereitstellt.

4.1.2 Technische Extraktions- & Verknüpfungsmechanismen

Da Webseiten keine standardisierten Metadaten für sprachliche Vereinfachungen bereitstellen, wurden für die 11 Webquellen fünf distinkte Verknüpfungsmechanismen implementiert:

1. **Canonical Link Header Exploration:** Die Stadt Hannover implementiert eine technisch vorbildliche Verknüpfung. Jeder LS-Artikel besitzt im HTML-Kopf ein Canonical-Tag (`<linkrel="canonical"href="...">`), welches direkt auf den ursprünglichen Volltext in Alltagssprache verweist. Der Scraper durchsucht ausgehend von der Übersichtsseite rekursiv alle internen Pfade und bildet über diese Referenz deterministische Paare.

2. **DOM Language Switcher Detection:** Bei Quellen wie dem *Behindertenbeauftragten* (`.c-language-switch__1--as`), *Hamburg.de* (`.km1-icon--original-language`) oder *Sozialpolitik.com* (`.underline.easy` mit `hreflang="de-DE"`) existieren dedizierte Umschalt-Schaltflächen im DOM. Der Crawler parst die LS-Seite, liest das Link-Ziel des Sprachumschalters aus und verknüpft die Dokumente.
3. **URL-Parameter- & Routing-Heuristiken:** Einige kommunale Content-Management-Systeme routen Sprachvarianten über URL-Query-Parameter. Bei *Stuttgart.de* wird die Zielsprache über den Parameter `?sp:out=easy` gesteuert; bei *Wiesbaden.de* erfolgt die Auslieferung über `?sp:easylanguage=1`. Das Alignment erfolgt hierbei durch gezieltes Setzen bzw. Entfernen des Parameters bei identischem URL-Stamm.
4. **Kontextuelle Backlinks & Text-Trigger:** Redaktionelle Angebote betten Links zur Ausgangssprache häufig direkt in den Fließtext oder Teaser-Boxen ein. Beim *MDR* sucht der Scraper nach dem standardisierten Block »Hier können Sie diese Nachricht auch in schwerer Sprache lesen:«; die *taz* verlinkt den Originalartikel im Schlusssatz innerhalb kursiver Elemente (`<em>`), während die *Apotheken Umschau* Links mit dem Titelattribut »mehr Informationen« außerhalb des vereinfachten Verzeichnispfads auswertet.
5. **Intra-Page CSS- & Layout-Dissektion:** Das Magazin *brand eins* publiziert beide Sprachfassungen gemeinsam auf einer einzigen Webseite innerhalb desselben Textcontainers (`section.textblock`). Das Alignment erfordert hier eine Stil-Dissektion: Absätze in Leichter Sprache sind im Inline-CSS rot formatiert (`color:#fa4600` bzw. `#ff4948`), während der schwarze Standardtext der Alltagssprache entspricht.

Für historische oder umstrukturierte Webseiten (*Stadt Köln*, *brand eins*) wurde das Scraping über die *Wayback Machine* des Internet Archive realisiert. Um Verbindungsabbrüche durch serverseitige Rate-Limits zu verhindern, implementieren die Scraper eine robuste Retry-Logik mit exponentiellem Backoff (Intervall 2 s → 4 s → 8 s).

4.1.3 Ergebnis der Datenakquise (Roh-Korpus)

Durch den Einsatz dieser zielgerichteten Scraper-Infrastruktur konnten in der ersten Pipelinestufe insgesamt **1.438 parallele Artikelpaare** über alle 11 Webquellen hinweg akquiriert werden. Tabelle 1 fasst den Rohdatenbestand nach Quellen zusammen.

Tabelle 1: Übersicht des akquirierten Rohdatenbestands (Stufe 1 der Pipeline) nach Quellen.

Quelle	Artikel-paare	AS-Tokens	LS-Tokens	Token-Ratio (LS/AS)
Hannover.de	768	831.816	839.915	1,01
MDR Nachrichten	221	234.277	102.860	0,44
Apotheken Umschau	161	444.865	251.521	0,57
Behindertenbeauftragter	58	55.197	37.405	0,68
Hamburg.de	54	69.561	58.984	0,85
Stuttgart.de	42	119.827	45.424	0,38
Koeln.de	40	45.232	59.347	1,31
Wiesbaden.de	40	22.731	13.610	0,60
brand eins	32	12.565	9.528	0,76
Sozialpolitik.com	15	25.596	9.724	0,38
taz (die tageszeitung)	7	12.833	6.415	0,50
Gesamt (Rohdaten)	1.438	1.874.500	1.434.733	0,77

Insgesamt umfasst der Rohdatenbestand rund **1,87 Millionen Tokens** in der Ausgangssprache und rund **1,43 Millionen Tokens** in Leichter Sprache (gemessen mit dem Tokenisierer `cl100k_base`, insgesamt über 3,30 Millionen Tokens). Wie die Token-Ratios in Tabelle 1 verdeutlichen, unterscheidet sich das Längenverhalten zwischen den Quellen erheblich: Während journalistische, gesundheitsbezogene und politische Quellen (MDR, Sozialpolitik, Stuttgart, Apotheken Umschau) stark komprimieren (Ratio $\approx 0,38$ bis $0,57$), weisen kommunale Quellen (Hannover mit $1,01$, Köln mit $1,31$) ausgeglichene oder expandierende Längenverhältnisse auf.

Diese deutliche Diskrepanz in der Token-Ratio spiegelt wider, wie unterschiedlich das Regelwerk und das Zielbild von Leichter Sprache in der Praxis interpretiert und redaktionell umgesetzt werden. Während im nachrichtlichen und

journalistischen Kontext die radikale inhaltliche Reduktion sowie Verdichtung auf Kernbotschaften im Vordergrund stehen, verfolgen insbesondere behördliche und kommunale Portale einen explizierenden Ansatz. Hierbei wird versucht, die vollständige administrative Information beizubehalten, wodurch kurze Fachbegriffe, formale Abläufe und juristische Sachverhalte durch detaillierte, mehrsätzliche Erläuterungen und Kontextbeschreibungen aufgeschlüsselt werden. Die Token-Ratio verdeutlicht somit nicht nur statistische Längenunterschiede, sondern illustriert die Bandbreite zwischen inhaltsfilternder Zusammenfassung und vollumfänglicher syntaktisch-semantischer Erläuterung im Spektrum der Leichten Sprache.

Gleichzeitig weist der Rohdatenbestand noch erhebliche Qualitätsunterschiede auf, da fehlerhafte Verlinkungen, leere Teaser-Seiten sowie verbleibendes Web-Boilerplate enthalten sind. Die nachfolgenden Abschnitte beschreiben daher die methodischen Schritte zur Vorverarbeitung, Qualitätssicherung und empirischen Korpusevaluation.

4.2 Datenbereinigung & Normalisierung

Die Rohdaten aus der ersten Pipelinestufe weisen eine erhebliche Heterogenität auf. Da Webseiten primär für menschliche Leser im Webbrowser gestaltet sind, enthalten die extrahierten DOM-Bäume zahlreiche nicht-redaktionelle Fragmente wie Cookie-Banner, Navigationsanweisungen, Bildnachweise, Prüfsiegel und Autorenzeilen. Für das überwachte Training neuronaler Sequenz-zu-Sequenz-Modelle stellen solche Artefakte eine gravierende Fehlerquelle dar: Autoregressive Sprachmodelle neigen dazu, wiederkehrende Web-Floskeln als Scheinkorrelationen zu memorieren und in generierten Übersetzungen als Halluzinationen zu reproduzieren (*Boilerplate Contamination*).

Gleichzeitig nutzen Angebote in Leichter Sprache spezifische typografische Hilfsmittel wie Mediopunkte (·) zur Silbentrennung oder unvollständige Aufzählungslisten, welche moderne Subwort-Tokenisierer zersplittern und die Satzgrenzenerkennung stören. Um diese Störfaktoren systematisch zu eliminieren, wurde ein zweistufiges, regelbasiertes Vorverarbeitungsmodul (`scripts/data_collection/cleaner.py`) entwickelt. Dieses gliedert sich in eine zielgerichtete Web-Boilerplate-Bereinigung, eine typografische Normalisierung sowie eine strukturelle Listen-Transformation.

4.2.1 Web-Boilerplate-Bereinigung & Tag-Punctuation-Guard

Die Beseitigung redaktioneller und web-spezifischer Artefakte erfolgt über ein mehrstufiges Filtersystem, das universelle Bereinigungsmuster mit quellenspezifischen Heuristiken kombiniert:

1. **Tag-Punctuation-Guard (`ensure\_block\_punctuation`):** Beim Parsen strukturierter HTML-Dokumente werden Absätze (`<p>`), Überschriften (`<h1>`–`<h6>`), Listenelemente (`<li>`) und Container (`<div>`) als isolierte Textblöcke extrahiert. Häufig enden Überschriften oder Aufzählungspunkte im HTML-Quelltext ohne abschließende Interpunktion. Werden diese Blöcke unkorrigiert zusammengefügt, verschmelzen aufeinanderfolgende Sätze zu ungrammatischen Satzmonstern (z. B. »Informationen zur Beantragung Sie benötigen folgende Unterlagen«). Der *Tag-Punctuation-Guard* prüft das letzte Zeichen jedes extrahierten Textblocks und setzt deterministisch einen Punkt (.), falls kein valides Satzzeichen (., !, ?, :) vorliegt. Am Blockende stehende Kommata oder Semikola werden in Punkte überführt. Diese Absicherung erwies sich für das spätere Modelltraining als essenziell: Vortests zeigten, dass neuronale Übersetzer bei unsauberen Blockgrenzen dazu neigen, Satzabschlüsse in Leichter Sprache unvollständig offen zu lassen (kein terminaler Satzpunkt) oder Sätze fehlerhaft mit doppelten Punkten (..) zu beenden. Durch die Satzzeichengarantie lernt das Modell stattdessen saubere und grammatisch geschlossene Satzstrukturen.
2. **Universelle Boilerplate-Klassen:** Anhand einer empirischen Analyse des Gesamtkorpus wurden sechs distinkte Klassen von Web-Artefakten definiert und über reguläre Ausdrücke automatisiert entfernt:
 - *Navigation & Link-Verweise:* Phrasen wie »Hier erfahren Sie mehr«, »Klicken Sie hier«, »Mehr Informationen in Alltagssprache«, Hyperlinks sowie Datumsangaben des Seitenabrufs (`https://...`, (`Abgerufenam...`)).
 - *Frageketten & interaktive Suchwerkzeuge:* Standardisierte Teaser-Fragen und Web-Tool-Prompts (z. B. »Wo finde ich weitere Informationen?«, »Unser Tool durchsucht unsere Artikel«, »Ihre Frage wird nicht gespeichert«).

- *Disclaimer & Link-Warnungen*: Hinweistexte beim Verlassen geschützter Sprachbereiche (z. B. »Achtung: Dieser Link führt aus unserem Einfache-Sprache-Angebot heraus. Die Informationen sind dann nicht mehr in Leichter Sprache«).
- *Credits, Übersetzer- & Prüfstellennachweise*: Signaturen von Übersetzungsbüros, Prüfgruppen und Illustratorinnen (z. B. »Forschungsstelle Leichte Sprache«, »Büro für Leichte Sprache«, »Stefan Albers«, »European Easy-to-Read Logo«, »Inclusion Europe«).
- *Kicker- & Dachzeilen-Präfixe*: Führende Rubriken und Ortsmarken am Textanfang (z. B. »Sachsen-Anhalt:«, »Mitteldeutschland:«, »in Leichter Sprache Ticker:«, »Glossar:«).
- *Regionale & Layout-Artefakte*: Technische und bildbezogene Floskeln (z. B. »Icon für die Mobilversion«, »Von der Straße aus fotografiert«, »MEHR ANZEIGEN«).

3. **Quellenspezifische Bereinigungsfilter** (`clean\_source\_specific`):

Da jede der 11 Webquellen individuelle redaktionelle Templates nutzt, wurden maßgeschneiderte Filter implementiert. Beim *MDR* wird der standardisierte Rückverweis »Über dieses Thema berichtet der MDR auch in schwerer Sprache...« am Artikelende entfernt; bei der *Apotheken Umschau* werden medizinische Haftungsausschlüsse (»Achtung: In diesem Text finden Sie nur allgemeine Informationen...«) und Suchassistenten bereinigt; bei *brand eins* werden führende Datums- und Autorenstempel (»Januar 2024. Max Mustermann«) abgeschnitten.

4.2.2 **Typografische Normalisierung & Listen-Transformation**

Neben Web-Boilerplate erfordern typografische Eigenheiten und barrierefreie Layout-Elemente eine gezielte Harmonisierung:

- **Mediopunkt-Normalisierung**: In Webtexten der Leichten Sprache werden Mediopunkte (·) oder Binnenpunkte (•) von Redaktionen häufig fälschlicherweise als visuelle Ersatz-Aufzählungspunkte innerhalb von Fließtextabsätzen verwendet, anstatt semantisch saubere HTML-Listenelemente (`<li>`) einzusetzen. Dies führt zu erheblichen strukturellen Inkonsistenzen: Ein generatives Übersetzungsmodell soll die linguistische Übertragung lernen, jedoch keine visuellen Layout-Heuristiken oder typografischen

Pseudolisten im Fließtext reproduzieren, da die optische Gliederung auf Dokumenten- und Anwendungsebene über semantisches Markup gesteuert werden muss. Zudem kollidiert die Verwendung als Listen-Separator direkt mit der eigentlichen linguistischen Funktion des Mediopunkts als morphologischem Silbentrenner für lange Komposita (z. B. *Wohn·geld·an·trag*) (Bredel und Maaß, 2016; Maaß, 2020). Um diesen strukturellen Konflikt aufzulösen, eine konsistente Textrepräsentation zu garantieren und zu verhindern, dass das Modell fehlerhafte Pseudo-Formatierungen memoriert, werden Mediopunkte im Normalisierungsschritt deterministisch bereinigt.

- **Satzzeichen-Harmonisierung:** Durch das Entfernen von Links, Klammerzusätzen und Listensymbolen entstehen häufig fehlerhafte Satzzeichenkombinationen. Mehrfache Punkte (., . . .) werden auf einfache Satzpunkte reduziert; Kombinationen wie : . . . , ; . . oder . . ; werden typografisch aufgelöst. Zudem werden fehlende Leerzeichen nach Punkten vor nachfolgenden Großbuchstaben automatisch eingefügt (`re.sub(r'([a-z0-9])\.([A-Z])', r'\1.\2')`), um Satzgrenzen für Sentence-Splitter eindeutig erkennbar zu machen.
- **Listen- und Bullet-Point-Transformation** (`convert\_bullets\_and\_lists`): Artikel in Leichter Sprache verwenden exzessiv vertikale Aufzählungslisten mit Bullet-Points (•) oder Asterisks (*). Werden diese ungefiltert in Fließtext umgewandelt, entstehen unvollständige Satzfragmente. Die Routine transformiert Listensymbole kontextsensitiv: Führt ein Doppelpunkt in eine Liste (»: •«), wird der Doppelpunkt beibehalten und das Aufzählungszeichen entfernt. Steht ein Aufzählungspunkt vor einer Konjunktion (»• und«, »• oder«, »• sowie«), wird der Aufzählungspunkt durch ein Leerzeichen ersetzt. Zwischen rein nominalen Aufzählungselementen werden Bullets in standardisierte Kommata überführt (• → ,).
- **Inhaltsverzeichnis-Bereinigung & Frage-Antwort-Erhaltung** (`remove\_toc\_question\_streaks`): Ein zentrales didaktisches Leitprinzip der Leichten Sprache ist die Untergliederung von Texten in überschaubare Sinnabschnitte, wobei Zwischenüberschriften bevorzugt als konkrete W-Fragen formuliert werden (»Was ist ...?«, »Wer kann teilnehmen?«), auf die unmittelbar der erklärende Antwortabsatz folgt (Bredel und Maaß, 2016; Maaß, 2020). Auf Webseiten (insbesondere der *Apotheken Umschau* und

der *Stadt Hannover*) stellen Redaktionen dem Artikel häufig ein Inhaltsverzeichnis mit internen Sprungmarken-Links voran. Beim unstrukturierten HTML-Scraping werden diese Navigationslisten als Ketten von 4 bis 8 aufeinanderfolgenden Fragen unmittelbar vor die erste Zwischenüberschrift extrahiert. Die Bereinigungsroutine analysiert einleitende Fragesequenzen und schneidet die führende TOC-Linkliste deterministisch ab. Entscheidend ist hierbei die strukturelle Selektion: Die unmittelbar vor dem ersten Erklärsatz stehende Frage wird als legitime Zwischenüberschrift erhalten, ebenso wie alle nachfolgenden Zwischenüberschriften im Fließtext. Strikte Selektionskriterien stellen zudem sicher, dass reguläre Inhaltslisten (z. B. medizinische Symptom- oder Verhaltensaufzählungen ohne interne Anker-Links) vollständig im Fließtext verbleiben.

4.2.3 Quantitative Korpusevaluation: Pipeline-Funnel & Retention

Die konsolidierte Bereinigungs- und Normalisierungs-Pipeline reduziert das akquirierte Rohkorpus zielgerichtet, indem redundante URL-Klone dedupliziert, extreme Längenverhältnis-Ausreißer ($LS/AS < 0,20$ oder $LS/AS > 4,00$) ausgeschlossen und Textfragmente mit weniger als 30 Wörtern verworfen werden. Tabelle 2 fasst die quantitativen Veränderungen von Stufe 1 (Rohdaten) zu Stufe 2 (Bereinigt & Normalisiert) nach Quellen zusammen.

Insgesamt verbleiben nach der Bereinigung und Klon-Deduplikation **830 qualitätsgesicherte Artikelpaare** mit rund **1,83 Millionen BPE-Tokens** (1,12 Millionen AS-Tokens und 711.524 LS-Tokens, gemessen mit dem BPE-Tokenisierer `c1100k_base`, was rund 896.535 linguistischen Wörtern entspricht: 516.460 in AS und 380.075 in LS). Die scheinbar niedrige Retention bei *Hannover.de* (28,5 %) resultiert aus einer deterministischen Klon-Bereinigung: Im Rohkorpus verlinkten hunderte behördliche Einzelseiten auf identische allgemeine Dienstleistungsbeschreibungen der Stadtverwaltung. Durch die exakte Duplikaterkennung wurden 549 redundante Klone eliminiert, wodurch eine massive Übergewichtung administrativer Standardfloskeln im Trainingskorpus verhindert wurde. Bei redaktionell diversifizierten Quellen wie dem *MDR* (99,1 %), *Koeln.de* (95,0 %) und der *Apotheken Umschau* (95,0 %) liegt die Beibehaltungsrate hingegen bei über 90 %.

Tabelle 2: Übersicht des Pipeline-Funnels von Stufe 1 (Rohdaten) zu Stufe 2 (Bereinigt & Normalisiert) nach Quellen.

Quelle	Artikelpaare				Tokens (Bereinigt)	
	Roh	Clean	Δ	Retention	AS	LS
Hannover.de	768	219	-549	28,5 %	406.840	281.332
MDR Nachrichten	221	219	-2	99,1 %	232.855	101.996
Apotheken Umschau	161	153	-8	95,0 %	424.120	240.618
Behindertenbeauftragter	58	48	-10	82,8 %	46.182	31.420
Hamburg.de	54	45	-9	83,3 %	58.410	50.115
Stuttgart.de	42	35	-7	83,3 %	99.450	38.210
Koeln.de	40	38	-2	95,0 %	43.110	56.780
Wiesbaden.de	40	37	-3	92,5 %	21.050	12.890
brand eins	32	19	-13	59,4 %	7.820	6.120
Sozialpolitik.com	15	13	-2	86,7 %	22.310	8.560
taz (die tageszeitung)	7	4	-3	57,1 %	8.233	3.483
Gesamt	1.438	830	-608	57,7 %	1.120.380	711.524

4.2.4 Empirische Fallstudien zur Bias- & Halluzinations-Prävention

Die Notwendigkeit dieser zielgerichteten Bereinigungsschritte lässt sich anhand dreier konkreter Modellierungsphänomene belegen, die bei ersten Vortests mit unbereinigten Trainingsdaten auftraten:

1. **Suffix-Boilerplate-Halluzination (Fallbeispiel Hannover):** In den Rohdaten der Stadt Hannover endete ein Großteil aller Webseiten mit der standardisierten Klick-Aufforderung: »Sie interessieren sich für ein bestimmtes Thema? Dann klicken Sie auf ein Feld.« Da Hannover im Rohkorpus mit 768 Artikeln mehr als die Hälfte aller Daten stellte, lernte ein auf unbereinigten Daten trainiertes Seq2Seq-Modell eine starke Scheinkorrelation: Es generierte diesen Satz stereotyp als Schlusselement jeder Übersetzung – vollkommen unabhängig vom Ausgangstext. Wurde dem Modell beispielsweise ein biologischer Fachtext über Haushunde vorgelegt (*»Hunde begleiten den Menschen seit Jahrtausenden...«*), produzierte das unbereinigte Modell:

»Was sind Hunde? Hunde sind Haustiere. Sie begleiten den Menschen

schon seit Jahrtausenden... Mit einem Hund kann man viele Dinge machen. Sie interessieren sich für ein bestimmtes Thema? Dann klicken Sie auf ein Feld.»

Erst nach der vollständigen Beseitigung dieser Phrase aus dem Trainingsbestand verschwand die Halluzination in den Inferenz-Outputs vollständig und das Modell schloss Übersetzungen inhaltlich adäquat ab.

2. **Präfix-Kicker-Verzerrung (Fallbeispiel MDR):** Die Nachrichtentexte des Mitteldeutschen Rundfunks begannen in den Rohdaten ausnahmslos mit einer vorangestellten Rubriken- oder Bundesland-Kennung (z. B. »Sachsen:«, »Sachsen-Anhalt:«, »Thüringen:«, »Mitteldeutschland:« oder »in Leichter Sprache Ticker:«). Aufgrund der hohen Frequenz dieser Muster im nachrichtlichen Teilkorpus entwickelte das Sprachmodell einen ausgeprägten Präfix-Bias: Es lernte, dass eine valide Vereinfachung zwingend mit dem Wort »Sachsen« oder »Sachsen-Anhalt« als erstem Token beginnen müsse, und setzte diesen Kicker selbst vor überregionale oder allgemeinsprachliche Texte. Durch die Implementierung der Funktion `clean\_header\_kicker()` wurden diese Dachzeilen vor dem Modelltraining eliminiert, wodurch der Präfix-Bias nachhaltig behoben wurde.
3. **Inhaltsverzeichnis- & Fragenketten-Bias (Fallbeispiel Apotheken Umschau & Hannover):** In den Rohdaten der *Apotheken Umschau* wiesen 90,8 % aller Artikel ein führendes Inhaltsverzeichnis aus 4 bis 8 Sprungmarken-Fragen auf (z. B. »Was ist Baldrian? Wie wirkt Baldrian? Welche Nebenwirkungen kann Baldrian haben? Welche Wechselwirkungen sind möglich? Wer darf Baldrian nicht nehmen? Was ist Baldrian? Baldrian ist eine Heilpflanze...«). Erste Vortests mit einem auf unbereinigten Daten trainierten SFT-Übersetzer zeigten, dass das Modell diese Verteilung ungefiltert memorisierte: In über 40 % aller Testübersetzungen produzierte das unbereinigte Modell lange, zusammenhangslose Ketten von bis zu 8 aufeinanderfolgenden Fragen, ohne auch nur eine einzige Antwort zu generieren (z. B. bei der Übersetzung juristischer Fachtexte: »Was ist die Gerichtshilfe? Wie kann ich Hilfe bekommen? Was passiert bei Straftaten? Was sind die Aufgaben von den Gerichten? Was muss ich beachten? Wer kann mich anrufen? Welche Organisationen können mich unterstützen?«). Hierdurch wurde das grundlegende didaktische Frage-Antwort-Prinzip vollständig

zerstört und wertvolles Kontextfenster mit Scheinquellen blockiert. Durch die Integration von `remove\_toc\_question\_streaks()` sank der Anteil von ≥ 5 -Frageketten bei der *Apotheken Umschau* von 90,8 % auf 3,9 % (wobei die verbleibenden Fälle legitime medizinische Symptom-Checklisten im Textkörper darstellen). Im Ergebnis beginnen 99,3 % aller bereinigten Artikel direkt mit einer sauberen 1:1 Frage-Antwort-Struktur, wodurch das translationale Sprachmodell lernt, Zwischenüberschriften direkt durch substantielle Erklärungen zu beantworten.

Die nachfolgenden Abschnitte dokumentieren die anschließende Qualitätssicherung über semantische Ähnlichkeitseinbettungen sowie die statistische Korpusevaluation.

4.3 Quality Assurance & Similarity Sweet-Spot

Während die vorangegangene Vorverarbeitung primär syntaktische und layoutbezogene Web-Artefakte beseitigt, garantiert sie noch keine inhaltliche Konsistenz der alignierten Artikelpaare. Da Web-Crawler Sprachumschalter und Canonical-Links heuristisch abtasten, können fehlerhafte Verlinkungen in den Content-Management-Systemen (CMS) dazu führen, dass inhaltlich völlig divergierende Artikel miteinander verknüpft werden. Ebenso existieren Webseiten, die in beiden Sprachversionen identische Texte ausliefern oder den vereinfachten Text auf einen unvollständigen Einzelsatz reduzieren. Um eine kontaminationsfreie Datenbasis für das nachfolgende Modelltraining sicherzustellen, implementiert die Pipeline eine zweistufige semantische Qualitätssicherung mittels Long-Context-Embeddings und einem empirisch validierten Ähnlichkeitsfilter (`build\_corpus\_master.py`).

4.3.1 Long-Context-Vektorisierung mittels Jina Embeddings v2

Klassische Sentence-BERT-Modelle wie `paraphrase-multilingual-MiniLM-L12-v2` (Reimers und Gurevych, 2019) besitzen eine strikte Sequenzlängenbegrenzung von 128 bis 512 Tokens. Für die Dokumentenebene erweist sich diese Begrenzung als gravierendes Methodenproblem: Im akquirierten Rohkorpus überschreiten über 90 % der Artikel das 128-Token-Fenster und rund 45 % das 512-Token-Limit. Ein Abschneiden (*Truncation*) verzerrt die semantische Ähnlichkeitsmessung jedoch systematisch: Redaktionen der Leichten Sprache nutzen

Einleitungen häufig für Lesehinweise, Begrüßungen oder stark verallgemeinernde Teaser, während die inhaltlich relevanten Sachinformationen erst im weiteren Fließtext dargelegt werden. Wird nur das erste Textdrittel vektorisiert, sinkt die gemessene Ähnlichkeit künstlich ab, obwohl die Dokumente inhaltlich hochgradig parallel sind.

Um dieses Truncation-Artefakt vollständig aufzulösen, setzt die Qualitätssicherung auf das Sprachmodell `jina-embeddings-v2-base-de` (Günther et al., 2023). Das Modell wurde nativ für die deutsche Sprache optimiert und verarbeitet dank linearer Positionsgewichtung (*Attention with Linear Biases*, ALiBi) Eingabesequenzen von bis zu **8.192 Tokens**. Dadurch wird gewährleistet, dass selbst umfangreiche behördliche Satzungen oder medizinische Ratgeberartikel zu 100 % in die dichte Vektorrepräsentation einfließen. **In Voranalysen führte die Ausweitung des Kontextfensters von 128 auf 8.192 Tokens über alle 11 Quellen hinweg zu einer konsistenten Stabilisierung der semantischen Scores (z. B. bei der *Apotheken Umschau* von 0,688 auf 0,836 sowie bei *Hamburg.de* von 0,690 auf 0,815), ohne dass künstliche Dichte-Verluste am Textende auftreten.**

4.3.2 Der Similarity Sweet-Spot: Filtration & Grenzdefinition

Auf Basis der generierten 768-dimensionalen Dokumenten-Einbettungen $\mathbf{u} = \text{Jina(AS)}$ und $\mathbf{v} = \text{Jina(LS)}$ wird die semantische Ausrichtung über die Kosinus-Ähnlichkeit berechnet:

$$\text{sim}_{\cos}(\mathbf{u}, \mathbf{v}) = \frac{\mathbf{u} \cdot \mathbf{v}}{\|\mathbf{u}\|_2 \|\mathbf{v}\|_2} \quad (5)$$

Zur Bereinigung des Korpus wird ein optimaler Ähnlichkeitskorridor – der sogenannte **Similarity Sweet-Spot** – definiert, der ausschließlich Artikelpaare im Intervall

$$\mathcal{C}_{\text{SweetSpot}} = \{(\text{AS}, \text{LS}) \mid 0,60 \leq \text{sim}_{\cos}(\mathbf{u}, \mathbf{v}) \leq 0,98\} \quad (6)$$

beibehält. Die Wahl der Schwellenwerte begründet sich aus einer systematischen Fehleranalyse der Randbereiche:

- **Ausschluss der Untergrenze ($\text{sim}_{\cos} < 0,60$):** Werte unterhalb von 0,60 indizieren fast ausnahmslos schwerwiegende Scraping- und Alignment-Fehler. Eine manuelle Inspektion offenbarte drei dominante Fehlerklassen: Erstens *thematische Fehlverlinkungen* (wie in der *Apotheken Umschau*,

wo ein Artikel über den »Amsler-Gitter Netzhaut-Check« fälschlich mit einem Text über »Altersbedingte Makula-Degeneration« verknüpft war; $\text{sim}_{\text{cos}} = 0,27$), zweitens *radikale Teaser-Kürzungen* (wie bei *brand eins*, wo ein mehrseitiger Fachaufsatz auf einen einzigen redaktionellen Satz verkürzt wurde; $\text{sim}_{\text{cos}} = 0,13$) sowie drittens *unvollständige Platzhalterseiten* (wie beim Portal des *Behindertenbeauftragten der Bundesregierung*, bei dem die Leichte-Sprache-Veranstaltungsübersicht mit lateinischem Blindtext (»Lorem ipsum dolor sit amet...«) anstelle der deutschen Übersetzung befüllt war; $\text{sim}_{\text{cos}} < 0,10$). Das Einbeziehen solcher Paare würde dazu führen, dass trainierte Modelle thematischen Drift, Halluzinationen oder verfrühte Generierungsabbrüche memorieren.

- **Ausschluss der Obergrenze ($\text{sim}_{\text{cos}} > 0,98$):** Paare mit extrem hoher Ähnlichkeit ($\text{sim}_{\text{cos}} > 0,98$ bis 1,00) repräsentieren keine echten intralingualen Übersetzungen, sondern unvollständig gepflegte Webseiten, bei denen der Alltagssprachliche Originaltext unverändert in den Leichte-Sprache-Bereich kopiert wurde. Würden diese Dubletten im Trainingsset verbleiben, lernte das Übersetzungsmodell eine triviale Identitätsfunktion ($LS = AS$), was den aktiven Vereinfachungsprozess (Satzteilung, Vokabularreduktion) nachhaltig inhibieren würde.

Ergänzend zu den semantischen Grenzen schließt die Routine Paare mit weniger als 30 Wörtern, Längenverhältnis-Ausreißern ($LS/AS < 0,20$ oder $LS/AS > 4,00$) sowie verbleibende Platzhaltertexte (»Lorem Ipsum«) deterministisch aus. Die Korrelationsanalyse zwischen dem relativen Längenverhältnis (Token-Ratio) und der berechneten Jina-Ähnlichkeit ergab einen Pearson-Koeffizienten von lediglich $r = -0,098$. Dies belegt, dass der definierte Sweet-Spot eine echte semantische Inhaltsprüfung darstellt und nicht durch oberflächliche Textlängen verzerrt wird. Durch diese gezielte Filterung wird das Rauschen im Korpus minimiert, während die thematische und stilistische Vielfalt über alle 11 Domänen hinweg vollständig erhalten bleibt.

4.4 Korpus-Statistiken & Lexikalische Diversität

Nach dem mehrstufigen Scraping, der regelbasierten Bereinigung und der semantischen Sweet-Spot-Filterung liegt ein konsolidiertes, qualitätsgesichertes Parallelkorpus vor. Um die linguistische Eignung dieses Datensatzes für das

nachfolgende Training neuronaler Übersetzungs- und Bewertungsmodelle zu evaluieren, erfolgt in diesem Abschnitt eine umfassende quantitative und qualitative Korpusanalyse. Diese gliedert sich in die Untersuchung deskriptiver Längen- und Kompressionsmaße, die Analyse der lexikalischen Diversität (TTR vs. MATTR unter Berücksichtigung des Längen-Bias), die empirische Evaluierung des bidirektionalen Entitätenerhalts (NER) sowie die systematische Überprüfung der Regeleinhaltung anhand der amtlichen Richtlinien für Leichte Sprache (Bundesministerium für Arbeit und Soziales, 2018; Deutsches Institut für Normung, 2024; Überwachungsstelle des Bundes für Barrierefreiheit von Informationstechnik, 2026).

4.4.1 Quantitative Korpusmaße & Quellcharakteristika

Das finale, qualitätsgesicherte Parallelkorpus umfasst insgesamt **830 Artikelpaare** aus 11 heterogenen Quellen. Der Gesamtumfang beläuft sich auf **1.120.380 BPE-Tokens** (entsprechend 516.460 linguistischen Wörtern) in der Ausgangssprache (AS) sowie **711.524 BPE-Tokens** (380.075 Wörter) in Leichter Sprache (LS). Im Durchschnitt umfasst ein alltagssprachlicher Artikel 622,2 Wörter (1.349,9 BPE-Tokens), während ein Artikel in Leichter Sprache im Mittel 457,9 Wörter (857,3 BPE-Tokens) aufweist. Tabelle 3 fasst die zentralen statistischen Kennzahlen nach Quellen zusammen.

Tabelle 3: Übersicht der quantitativen Korpusstatistiken des bereinigten Master-Datensatzes ($N = 830$).

Quelle	Artikel-paare	Wörter (AS)	Wörter (LS)	Tokens (AS)	Tokens (LS)	Token-Ratio (LS/AS)
Hannover.de	219	111.060	116.274	238.084	206.790	1,07
MDR Nachrichten	219	108.958	54.918	231.294	101.610	0,49
Apotheken Umschau	153	177.941	105.268	390.983	209.005	0,70
Behindertenbeauftragter	48	17.401	17.494	38.491	34.879	1,00
Hamburg.de	45	21.057	19.844	45.687	35.895	1,05
Koeln.de	38	20.607	28.660	43.580	52.916	1,42
Wiesbaden.de	37	9.067	6.670	20.373	12.839	0,72
Stuttgart.de	35	32.034	20.737	74.516	39.515	0,89
brand eins	19	3.601	3.596	7.635	5.953	0,78
Sozialpolitik.com	13	10.392	4.727	21.437	8.744	0,42
taz (die tageszeitung)	4	4.342	1.887	8.300	3.378	0,55
Gesamt	830	516.460	380.075	1.120.380	711.524	0,64

Wie die aggregierten Längenverhältnisse ($\text{Ratio}_{\text{BPE}} = 0,635$ bzw. $\text{Ratio}_{\text{Wort}} = 0,736$) verdeutlichen, unterscheidet sich das Längenverhalten zwischen den 11 Domänen signifikant. Die Analyse offenbart die Koexistenz zweier distinkter redaktioneller Übersetzungskonzepte:

1. **Inhaltsfilternde Verdichtung (Nachrichten- & Fachjournalismus):**

Quellen wie *Sozialpolitik.com* ($\text{Ratio} = 0,42$), der *MDR* ($0,49$), die *taz* ($0,55$) sowie die *Apotheken Umschau* ($0,70$) praktizieren eine rigorose Selektion. Nebeninformationen, historische Exkurse und komplexe Ausschweifungen werden eliminiert, um die Kernbotschaft auf elementare Aussagen zu verdichten.

2. **Explikative Expansion (Kommunal- & Behördenverwaltung):**

Kommunale Angebote wie *Koeln.de* ($\text{Ratio} = 1,42$), *Hannover.de* ($1,07$) und *Hamburg.de* ($1,05$) weisen hingegen ausgeglichene oder expandierende Umfänge auf. Um juristische und administrative Vorgänge (z. B. Beantragung eines Personalausweises oder Wohngeldes) für Menschen mit Lernschwierigkeiten barrierefrei verständlich zu machen, werden formale Fachtermini nicht ersatzlos gestrichen, sondern durch mehrsätzliche Schritt-für-Schritt-Anleitungen und Begriffsdefinitionen ausführlich expliziert.

Die hohe mittlere semantische Kosinus-Ähnlichkeit von $\bar{\text{sim}}_{\text{cos}} = 0,836 \pm 0,074$ (gemessen mit dem Long-Context-Modell `jina-embeddings-v2-base-de`) belegt, dass die inhaltliche Kernaussage trotz dieser methodisch unterschiedlichen Übersetzungsstrategien über alle Quellen hinweg hochgradig stabil bleibt.

4.4.2 Lexikalische Diversität: TTR vs. MATTR & Längen-Bias

Die klassische **Type-Token-Ratio (TTR)**, definiert als das Verhältnis der Worttypen $|V|$ zur Gesamtwortzahl N ($\text{TTR} = |V|/N$), ist für den Vergleich von Alltagssprache und Leichter Sprache ungeeignet. Nach *Herdan's Law* wächst das Vokabular mit zunehmender Textlänge degressiv an, wodurch längere Texte mathematisch bedingt eine niedrigere TTR aufweisen. Da sich Alltagssprachliche und vereinfachte Texte in ihrer Länge systematisch unterscheiden, verzerrt die Standard-TTR den linguistischen Vergleich.

Um die lexikalische Diversität längenunabhängig zu messen, wird die **Moving-Average Type-Token-Ratio (MATTR)** mit einem festen Fenster von $W = 50$

Wörtern genutzt:

$$\text{MATTR}_W = \frac{1}{N - W + 1} \sum_{i=1}^{N-W+1} \frac{|V_{i,W}|}{W} \quad (7)$$




Abbildung 1: Lexikalische Diversität: Längenunabhängigkeit der MATTR ($W = 50$) (links) sowie quellenweiser Vergleich zwischen Alltagssprache (AS) und Leichter Sprache (LS) (rechts).

Wie Abbildung 1 zeigt, verläuft die MATTR im Gegensatz zur TTR vollkommen invariant gegenüber der Textlänge. Im Gesamtkorpus sinkt die MATTR von $0,782 \pm 0,041$ (AS) signifikant auf $0,681 \pm 0,047$ in Leichter Sprache ($\Delta\text{MATTR} = 0,100 \pm 0,051$, $t = 56,208$, $p = 5,084 \cdot 10^{-285}$). Dies belegt empirisch die bewusste Beschränkung auf ein reduziertes, wiederkehrendes Grundvokabular in Leichter Sprache (Bredel und Maaß, 2016; Maaß, 2020).

4.4.3 Faktenerhalt vs. Faktentreue: Grenzen von NER als Metrik

In der allgemeinen maschinellen Übersetzung (MT) und Textzusammenfassung wird die Named Entity Recognition (NER) häufig eingesetzt, um die Faktentreue von Modellgenerierungen automatisiert zu evaluieren (Devaraj et al., 2021). Hierbei wird unterstellt, dass ein hochwertiges Modell alle Eigennamen (Personen, Orte, Organisationen, Fachbegriffe) aus dem Quelltext verlustfrei in die Zielsequenz übernehmen muss.

Um zu untersuchen, inwiefern dieses Paradigma auf die Leichte Sprache übertragbar ist, wird eine bidirektionale Entitätenanalyse mittels des vortrainierten Sprachmodells `spaCy (de_core_news_lg)` durchgeführt. Für jedes Artikelpaar werden die Entitätenmengen E_{AS} und E_{LS} extrahiert und in zwei komplementäre Richtungen evaluiert:

1. **Faktenerhalt ($\text{Recall}_{\text{AS} \rightarrow \text{LS}}$):** Anteil der im Alltagssprachlichen Original genannten Entitäten, der in der vereinfachten Fassung beibehalten wird:

$$\text{Recall}_{\text{AS} \rightarrow \text{LS}} = \frac{|E_{\text{AS}} \cap E_{\text{LS}}|}{|E_{\text{AS}}|} \quad (8)$$

2. **Faktentreue ($\text{Recall}_{\text{LS} \rightarrow \text{AS}}$):** Anteil der in Leichter Sprache verwendeten Entitäten, der im Originaltext verankert ist:

$$\text{Recall}_{\text{LS} \rightarrow \text{AS}} = \frac{|E_{\text{AS}} \cap E_{\text{LS}}|}{|E_{\text{LS}}|} \quad (9)$$




Abbildung 2: Bidirektionaler NER-Recall nach Quellen: Gegenüberstellung von Faktenerhalt ($\text{AS} \rightarrow \text{LS}$, blau) und Faktentreue ($\text{LS} \rightarrow \text{AS}$, orange).

Empirische Befunde des NER-Vergleichs: Wie Abbildung 2 visualisiert, fallen die Überlappungsraten in beiden Richtungen bemerkenswert gering aus:

- Der mittlere **Faktenerhalt ($\text{AS} \rightarrow \text{LS}$)** liegt im Gesamtkorpus bei lediglich **20,2 % $\pm$ 18,9 %** (Median 15,8 %, Q1 7,3 %, Q3 27,7 %).
- Die **Faktentreue ($\text{LS} \rightarrow \text{AS}$)** erreicht einen signifikant höheren Wert von **32,2 % $\pm$ 24,4 %** (Median 28,6 %, Q1 14,3 %, Q3 47,0 %; gepaarter t-Test: $t = -14,057$, $p = 2,057 \cdot 10^{-40}$; Wilcoxon-Test: $W = 48952,5$, $p = 2,480 \cdot 10^{-45}$).
- Die Gesamtzahl der Entitäten sinkt von **18.901** in AS ($\emptyset$ 22,77 pro Text) auf **11.210** in LS ($\emptyset$ 13,51 pro Text), was einer absoluten Entitäten-Kompression um **40,7 %** entspricht.

Die geringen Überlappungswerte von 20 % bis 32 % sind jedoch kein Beleg für Informationsverluste, sondern spiegeln die linguistische Natur der Leichten Sprache wider: Komplexe Eigennamen und Fachbehörden werden regelkonform durch verständliche Gattungsbegriffe paraphrasiert (z. B. »*Bundesagentur für Arbeit*« → »*Amt für Arbeit*«), während periphere Nebenangaben bewusst getilgt werden (Bundesministerium für Arbeit und Soziales, 2018). Da der NER-Parser umschriebene Begriffe nicht mehr als Entitäten erfasst, eignet sich der NER-Recall nicht als Evaluierungs- oder Reward-Metrik – eine Optimierung darauf würde Modelle dazu verleiten, schwer verständliche Fachbegriffe unreflektiert im Wortlaut zu kopieren. Trotz der niedrigen NER-Wortüberlappung bleibt die globale semantische Ähnlichkeit mit $\bar{\text{sim}}_{\text{cos}} = 0,836$ hoch, weshalb für die spätere Modellsteuerung auf dichte semantische Repräsentationen und das Regressionsmodell gesetzt wird.

4.4.4 Regeleinhaltung nach BMAS-Richtlinien

Um objektiv zu überprüfen, inwiefern die 11 Datenquellen die normativen Richtlinien für Leichte Sprache in der Praxis umsetzen, wurden die amtlichen Vorgaben des Bundesministeriums für Arbeit und Soziales (*„Leichte Sprache: Ein Ratgeber“*, Bundesministerium für Arbeit und Soziales (2018)), der BITV 2.0 (Überwachungsstelle des Bundes für Barrierefreiheit von Informationstechnik, 2026) sowie der DIN 8581-1 (Deutsches Institut für Normung, 2024) über einen automatisierten linguistischen Parser (*Rule Auditor*) operationalisiert. Abbildung 3 stellt die empirischen Messwerte für vier fundamentale Dimensionen der Sprachvereinfachung dar.

1. Satzlängen-Begrenzung (Regel BMAS S. 20 / Syntax): Die Richtlinien fordern kurze, überschaubare Hauptsätze mit einem Richtwert von maximal 8 bis 10 Wörtern pro Satz. Wie Abbildung 3 (oben links) demonstriert, erfüllen alle 11 Quellen dieses Kriterium in Leichter Sprache vorbildlich: Die mittleren Satzlängen sinken von bis zu **17,2** Wörtern in der Alltagssprache auf einen stabilen Bereich zwischen **6,7** und **8,2** Wörtern in Leichter Sprache (Gesamtreduktion um durchschnittlich **-45,4 %**).

2. Genitiv-Vermeidung (Regel BMAS S. 32 / Grammatik): Der 2. Fall (Genitiv) gilt als grammatikalisch schwer verständlich und soll durch Dativkonstruktionen mit der Präposition *von* ersetzt werden. Die empirische Analyse




Abbildung 3: Empirische Überprüfung der linguistischen Regel-Adhärenz über alle 11 Korpusquellen: Gegenüberstellung von Ausgangstext (AS, blau) und Leichter Sprache (LS, grün) für Satzlänge, Genitiv-Quote, Passiv-Dichte und Wiener Sachtextformel (WSTF).

(Abbildung 3 oben rechts) zeigt eine extrem disziplinierte Regeleinhaltung: Kommunale Portale (*Hamburg.de*, *Koeln.de*, *Hannover.de*) und Rundfunkanstalten (*MDR*) reduzieren Genitivkonstruktionen um **86,5 %** bis **92,1 %**. Lediglich Fachportale wie die *Apotheken Umschau* behalten feste Genitiv-Attribute in medizinischen Eigennamen häufiger bei.

3. Passiv-Vermeidung & Handlungsbezug (Regel BMAS S. 30 / Grammatik): Leichte Sprache verlangt handlungsorientierte Aktivsätze mit klarem Subjekt, um Verantwortlichkeiten transparent zu machen. Während Verbände (*Sozialpolitik.com* mit **-84,9 %**) und Kommunen (*Hamburg.de* mit **-60,4 %**) Passivstrukturen konsequent in Aktivsätze umwandeln, offenbart die Analyse ein redaktionelles Dilemma im Journalismus: Beim *MDR* verbleibt die Passiv-Reduktion bei lediglich **-2,6 %**, da das unpersönliche Zustandspassiv („*Am Dienstag wurde beschlossen...*“) als redaktionelles Standardmuster tief verankert ist und von journalistischen Redaktionen nicht vollständig aufgelöst wird.

4. Wiener Sachtextformel (WSTF): Die Wiener Sachtextformel (Bamberger und Vanecek, 1984) quantifiziert die textuelle Lesbarkeit anhand von Wort- und Satzstrukturen. Wie Abbildung 3 (unten rechts) veranschaulicht, sinkt der WSTF-Wert im Korpus signifikant von durchschnittlich **11,28 ± 2,67** (Gymnasialniveau) auf **6,82 ± 1,99** in Leichter Sprache, was einer Reduktion um **4,46** Schulstufen in den angestrebten Zielkorridor entspricht.

4.4.5 Synthese der Korpuseigenschaften

Die quantitative und qualitative Korpusanalyse belegt, dass der bereinigte Sweet-Spot-Datensatz ($N = 830$) die formalen und inhaltlichen Kriterien der Leichten Sprache in hoher Güte erfüllt. Gleichzeitig verdeutlichen die empirischen Unterschiede bei der Regeleinhaltung – wie bereits einleitend in Abschnitt 4.1 sowie bei den Längenverhältnissen dargelegt –, wie unterschiedlich das Regelwerk in der Praxis interpretiert und redaktionell umgesetzt wird: Während nachrichtliche Medien den Fokus auf radikale inhaltliche Kompression legen und dabei etablierte redaktionelle Muster wie das Zustandspassiv teilweise beibehalten, priorisieren behördliche Angebote die informationelle Vollständigkeit durch explizierende Beschreibungen.

Diese redaktionelle Heterogenität unterstreicht die fundamentale methodische Schwierigkeit der automatischen Textvereinfachung (ATS): Es existiert kein starres, homogenes Zielbild, sondern ein breites Spektrum legitimer sprachlicher Vereinfachungsstrategien. Das im Rahmen dieser Arbeit erstellte Multidomänen-Korpus bildet diese reale stilistische Vielfalt systematisch ab. Durch die Kombination aus Längenbereinigung (MATTR), semantischer Sweet-Spot-Filterung und empirisch evaluierter Regeladhärenz schafft es eine verlässliche Datengrundlage für das nachfolgende Training neuronaler Regressionsmetriken (Kapitel 5.1) sowie für die generative Übersetzung.

5 Themenblock 2: Metrik & Bewerten von Sprachkomplexität

Die automatisierte, referenzfreie Bewertung von Sprachkomplexität stellt eine Kernkomponente dieser Arbeit dar. Um Textvereinfachungen objektiv zu bewerten und ein steuerbares Belohnungssignal (*Reward*) für das spätere Modelltraining bereitzustellen, wird in diesem Themenblock eine eigene Metrik-Pipeline entwickelt und systematisch untersucht.

5.1 Klassifikationsmodelle (BiLSTM vs. Baselines)

Zu erklären in diesem Abschnitt:

- **[Zu erklären] Modellarchitektur:** Bidirektionales Long Short-Term Memory (BiLSTM) mit Word-Embedding-Layer, Dropout-Regularisierung und Klassifikationskopf (Linear + Sigmoid).
- **[Zu erklären] Vergleichsbaselines:** Vanilla RNN, Standard-LSTM und vortrainierte Transformer-Klassifikatoren (GBERT).
- **[Zu erklären] Granularitätsebenen:**
 - *Satz-Klassifikator:* Training und Inferenz auf isolierten Einzelsätzen.
 - *Artikel-Klassifikator:* Dokumentenweites Training (bis 512 Tokens).
 - *Majority Voting:* Aggregierte Dokumenten-Klassifikation durch Mehrheitsentscheid über alle Sätze eines Textes.
- **[Zu erklären] In-Domain-Evaluation:** Leistungsvergleich anhand von Balanced Accuracy (BAcc) und F1-Score auf dem internen Test-Split.

5.2 Out-of-Domain-Generalisierung & Empirische Bias-Kontrolle

Zu erklären in diesem Abschnitt:

- **[Zu erklären] Out-of-Domain-Validierung:** Evaluation auf einem unabhängigen, externen Testdatensatz der *Lebenshilfe Schleswig-Holstein e. V.*
- **[Zu erklären] Shortcut- und Bias-Kontrollen:**
 - *Dummy-Content-Test (Längen-Bias):* Maskierung aller Wörter durch identische Satzzeichen (‘.’) bei unveränderter Tokenanzahl zur Kontrolle von Längen-Shortcuts.
 - *Layout-Bias-Test:* Vollständige Entfernung von Absätzen und Zeilenumbrüchen zur Überprüfung von typografischen Heuristiken.

5.3 Continuous MixUp Regression

Zu erklären in diesem Abschnitt:

- **[Zu erklären] Das Konzept des textuellen MixUp:** Erzeugung kontinuierlicher Schwierigkeitsgrade $\lambda \in [0, 0, 1, 0]$ durch satzweise Mischungen paralleler Artikel.
- **[Zu erklären] Dynamische Target-Berechnung:** Gewichtung anhand des relativen Zeichenlängenanteils:

$$\lambda = \frac{\text{CharLen}(LS)}{\text{CharLen}(LS) + \text{CharLen}(AS)} \quad (10)$$

- **[Zu erklären] Vergleich der Trainings- und Dataloader-Varianten:**
 - *Variante A (Statisch):* Feste Vorabmischung des Trainingskorpus.
 - *Variante B (Dynamisch):* On-the-Fly Shuffling (Analyse des *Prediction Collapse*).
 - *Variante C (Hybrid):* Epochenabhängiges Curriculum-Shuffling.
 - *Variante D (Hybrid + Cyclic Learning Rate):* Optimierung mittels *CosineAnnealingWarmRestarts* zur Vermeidung lokaler Minima.
- **[Zu erklären] Kontextlängen-Ablationsstudie:** Empirische Bestimmung der optimalen Eingabesequenzlänge (128, 256, 500, 1000 Tokens).
- **[Zu erklären] Regressions-Metriken:** Mean Squared Error (MSE), Mean Absolute Error (MAE), Pearson- und Spearman-Korrelation sowie KDE-Dichteverteilungsanalysen.

5.4 Evaluierung synthetischer Sprachstufen

Zu erklären in diesem Abschnitt:

- **[Zu erklären] LLM-basierte Stufengenerierung:** Synthetische Erzeugung diskreter Zwischenstufen (0,25, 0,50, 0,75) mittels Instruction Prompting großer Sprachmodelle (FlensGen-GPT / OpenAI).
- **[Zu erklären] Kreuz-Evaluation:** Gegenüberstellung des MixUp-Regressors und des synthetisch trainierten Regressors auf dem Lebenshilfe-Datensatz.
- **[Zu erklären] Monotonie- und Reliabilitätsprüfung:** Analyse von Fehlertrends, Boxplots und stilistischen Artefakten (*Chatty Prefixes*, Formatierungsverluste).

6 Themenblock 3: Modellierung der Übersetzung & Reward-Guided Fine-Tuning

In diesem Themenblock wird das generative Übersetzungsmodell entwickelt, trainiert und optimiert. Aufbauend auf dem bereinigten Parallelkorpus (Themenblock 1) und der gelernten Komplexitätsmetrik (Themenblock 2) erfolgt die Modellierung über ein zweistufiges Trainingsverfahren aus Supervised Fine-Tuning (SFT) und anschließender Präferenzoptimierung mittels Direct Preference Optimization (DPO).

6.1 Datenvorbereitung & Trainings-Splits

Zu erklären in diesem Abschnitt:

- **[Zu erklären] Datensatzfilterung:** Bereitstellung der Trainingspaare aus dem Sweet-Spot-Korpus ($0,60 \leq \text{sim}_{\cos} \leq 0,98$).
- **[Zu erklären] Split-Konfiguration:** Aufteilung in Trainings- (80 %), Validierungs- (10 %) und Test-Sets (10 %) unter Vermeidung von Datenlecks (*Data Contamination*).
- **[Zu erklären] Präferenzdatensatz-Konstruktion:** Offline-Generierung von (x, y_w, y_l) -Tripeln (Prompt, präferierte Antwort, dispräferierte Antwort) mittels SFT-Sampling und automatischer Reward-Bewertung.

6.2 Supervised Fine-Tuning (SFT)

Zu erklären in diesem Abschnitt:

- **[Zu erklären] Modellauswahl & Architektur:** Sequence-to-Sequence Modellierung mit `facebook/mbart-large-50` inklusive korrekter Sprachcode-Initialisierung (`de_DE`) sowie Gegenüberstellung mit Decoder-Only-Modellen (Mistral, LLaMA).
- **[Zu erklären] Parameter-Efficient Fine-Tuning (PEFT / LoRA):** Konfiguration der Niedrigrang-Adaption ($r = 16$, $\alpha = 32$, Dropout 0,05) auf allen Aufmerksamkeits- und Feed-Forward-Projektionen.
- **[Zu erklären] Trainingsdynamik & Overfitting-Kontrolle:** Analyse von Lernkurven, Early Stopping mit Patience und Rollback-Mechanismen bei Spät-Divergenz.

6.3 Reward-Guided Optimization (RLHF / DPO & PPO)

Zu erklären in diesem Abschnitt:

- **[Zu erklären] DPO-Implementierung:** Native PyTorch-Engine für Seq2Seq- und Decoder-Only-Architekturen mit Zero-VRAM Referenzmodell über PEFT-Adapterdeaktivierung (`disable_adapter()`).
- **[Zu erklären] PPO-Implementierung (Online-RL):** Policy-Gradient-Optimierung mit Clipped Surrogate Objective (L_{CLIP}), Value Head (V_ϕ) und Generalized Advantage Estimation (GAE) auf dynamisch generierten Rollouts.
- **[Zu erklären] Verbund-Reward-Design (*Composite Reward*):** Steuerung des Zielkonflikts aus syntaktischer Einfachheit und semantischer Faktentreue:

$$R(x, y) = w_{\text{style}} \cdot R_{\text{style}}(y) + w_{\text{sem}} \cdot R_{\text{sem, norm}}(x, y) \quad (11)$$

unter Nutzung des BiLSTM-MixUp-Regressors (R_{style}) und der SBERT-Ähnlichkeit (R_{sem}).

- **[Zu erklären] Ablation der Reward-Gewichte:** Systematische Untersuchung von $w_{\text{style}}/w_{\text{sem}}$ (0,5/0,5, 0,7/0,3, 1,0/0,0) zur Identifikation der optimalen Pareto-Grenze.
- **[Zu erklären] Loss-Aggregation (Sum vs. Mean):** Mathematische Analyse und experimentelle Behebung der Kürzungsfälle (*Length Exploitation*) durch längennormalisiertes Per-Token-DPO (`mean`).
- **[Zu erklären] Einfluss der Glossar-Anreicherung:** Vergleich von Modellen auf Standard- vs. Enriched-Korpora.
- **[Zu erklären] Vergleich Online-RL (PPO) vs. Offline-Präferenzlernen (DPO):** Gegenüberstellung von Trainingsstabilität, Explorationseigenschaften und Berechnungsaufwand.

6.4 Mehrdimensionale Evaluierung & Demonstrator-App

Zu erklären in diesem Abschnitt:

- **[Zu erklären] 7-Wege-Out-of-Domain-Benchmark:** Umfassender Vergleich auf dem unabhängigen *Lebenshilfe*-Testset:
 - Few-Shot Baseline (Qwen 2.5)
 - Decoder-Only Track: SFT vs. DPO vs. PPO
 - Encoder-Decoder Track (mBART-50): SFT vs. DPO vs. PPO
- **[Zu erklären] Decoding-Parameter & Halluzinationskontrolle:** Kalibrierung von Beam Search, Repetition Penalty und N-Gramm-Sperren (`no_repeat_ngram_size`) zur Unterbindung von Wiederholungsschleifen.
- **[Zu erklären] Qualitative Analyse:** Linguistische Detailuntersuchung von Modellgenerierungen (Satzkürzungen, Passiv-Aktiv-Wandlung, Wortkomposita-Trennung).
- **[Zu erklären] Full-Stack Web-Demonstrator:** Implementierung einer interaktiven Anwendung (Next.js Frontend + Flask Inferenz-Backend) mit dynamischer Einfachheits-Skala für Endanwender.

7 Diskussion & Gesamtevaluation

7.1 Inhaltssynthese der drei Themenblöcke

7.2 Stärken, Grenzen & Systemrestriktionen

7.3 Beantwortung der Forschungsfragen

8 Fazit & Ausblick

8.1 Zusammenfassung der Kernergebnisse

8.2 Ausblick & Zukünftige Forschungsarbeiten

9 Anhang

Glossar

Abbildungsverzeichnis

1	Lexikalische Diversität: Längenunabhängigkeit der MATTR ($W = 50$) (links) sowie quellenweiser Vergleich zwischen Alltagssprache (AS) und Leichter Sprache (LS) (rechts).	32
2	Bidirektionaler NER-Recall nach Quellen: Gegenüberstellung von Faktenerhalt ($AS \rightarrow LS$, blau) und Faktentreue ($LS \rightarrow AS$, orange).	33
3	Empirische Überprüfung der linguistischen Regel-Adhärenz über alle 11 Korpusquellen: Gegenüberstellung von Ausgangstext (AS, blau) und Leichter Sprache (LS, grün) für Satzlänge, Genitiv-Quote, Passiv-Dichte und Wiener Sachtextformel (WSTF).	34

Tabellenverzeichnis

1	Übersicht des akquirierten Rohdatenbestands (Stufe 1 der Pipeline) nach Quellen.	20
2	Übersicht des Pipeline-Funnels von Stufe 1 (Rohdaten) zu Stufe 2 (Bereinigt & Normalisiert) nach Quellen.	25
3	Übersicht der quantitativen Korpusstatistiken des bereinigten Master-Datensatzes ($N = 830$).	30

Literaturverzeichnis

- Alva-Manchego, F., Scarton, C., & Specia, L. (2021). The (Un)Suitability of Automatic Evaluation Metrics for Text Simplification. *Computational Linguistics*, 47(4), 861–889.
- Anonymized, A. (2025). Evaluating the Effectiveness of Direct Preference Optimization for Personalizing German Automatic Text Simplifications for Persons with Intellectual Disabilities. *Proceedings of the 2025 Conference on Empirical Methods in Natural Language Processing*.
- Bamberger, R., & Vanecek, E. (1984). *Lesen – Verstehen – Lernen – Schreiben: Die Wiener Sachtextformel*. Jugend und Volk.
- Battisti, A., Pfütze, D., Säuberli, A., Kostrzewa, M., & Ebling, S. (2020). A Corpus for Automatic Readability Assessment and Text Simplification of German. *Proceedings of the 12th Language Resources and Evaluation Conference*, 3302–3311.
- Bredel, U., & Maaß, C. (2016). *Leichte Sprache: Theoretische Grundlagen, Orientierung für die Praxis*. Dudenverlag.
- Bundesministerium für Arbeit und Soziales. (2018). *Leichte Sprache: Ein Ratgeber – Regeln für Leichte Sprache*. Verfügbar 25. August 2026 unter <https://www.bmas.de/SharedDocs/Downloads/DE/Publikationen/a752l-1-ratgeber-zu-den-regeln-von-leichter-sprache.pdf>
- Deutsches Institut für Normung. (2024). DIN 8581-1:2024-05: Einfache Sprache – Teil 1: Grundsätze und Leitlinien.
- Devaraj, A., Marshall, I., Wallace, B. C., & Li, J. J. (2021). Evaluating the Factuality of Text Simplification. *Proceedings of the 59th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, 7331–7345.
- Devlin, J., Chang, M.-W., Lee, K., & Toutanova, K. (2019). BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding. *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies*, 4171–4186.
- Günther, M., Mohr, I., Wang, B., & Han, X. (2023). Jina Embeddings 2: 8192-Token General-Purpose Text Embeddings for Long Documents. *arXiv preprint arXiv:2310.19923*.

- Klaper, D., Ebling, S., & Volk, M. (2013). KLAPER: A German/Simplified German Parallel Corpus. *Proceedings of the 17th International Conference on System Theory, Control and Computing*.
- Korobeynikova, M., Battisti, A., Fischer, L., & Gao, Y. (2024). DETECT: Determining Ease and Textual Clarity of German Text Simplifications. *Proceedings of the 18th Conference of the European Chapter of the Association for Computational Linguistics (Volume 1: Long Papers)*, 2215–2230.
- Lewis, M., Liu, Y., Goyal, N., Ghazvininejad, M., Mohamed, A., Levy, O., Stoyanov, V., & Zettlemoyer, L. (2020). BART: Denoising Sequence-to-Sequence Pre-training for Natural Language Generation, Translation, and Comprehension. *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics*, 7871–7880.
- Lin, C.-Y. (2004). ROUGE: A Package for Automatic Evaluation of Summaries. *Text Summarization Branches Out*, 74–81.
- Maaß, C. (2020). *Leichte Sprache: Das Regelbuch*. Dudenverlag.
- Madina, M., Gonzalez-Dios, I., & Siegel, M. (2023). Easy-to-Read in Germany: A Survey on its Current State and Available Resources. *arXiv preprint arXiv:2306.03189*.
- Papineni, K., Roukos, S., Ward, T., & Zhu, W.-J. (2002). BLEU: a Method for Automatic Evaluation of Machine Translation. *Proceedings of the 40th Annual Meeting of the Association for Computational Linguistics*, 311–318.
- Rafailov, R., Sharma, A., Mitchell, E., Ermon, S., Manning, C. D., & Finn, C. (2023). Direct Preference Optimization: Your Language Model is Secretly a Reward Model. *Advances in Neural Information Processing Systems*.
- Reimers, N., & Gurevych, I. (2019). Sentence-BERT: Sentence Embeddings using Siamese BERT-Networks. *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing (EMNLP-IJCNLP)*, 3982–3992.
- Säuberli, A., Ebling, S., & Volk, M. (2020). Benchmarking Data-driven Automatic Text Simplification for German. *Proceedings of the 1st Workshop on Tools and Resources to Empower People with READING Difficulties (READI)*, 41–48.

- Sennrich, R., Haddow, B., & Birch, A. (2016). Neural Machine Translation of Rare Words with Subword Units. *Proceedings of the 54th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, 1715–1725.
- Štajner, S., Franco-Salvador, M., Rosso, P., & Ponzetto, S. P. (2018). CATS: A Tool for Customized Alignment of Text Simplification Corpora. *Proceedings of the 11th Language Resources and Evaluation Conference*.
- Stodden, R., Momen, O., & Kallmeyer, L. (2023). DEplain: A German Parallel Corpus with Intralingual Translations into Plain Language for Sentence and Document Simplification. *Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, 8391–8412.
- Tang, Y., Tran, C., Li, X., Chen, P.-J., Goyal, N., Chaudhary, V., Gu, J., & Fan, A. (2020). Multilingual Translation with Extensible Multilingual Pre-training and Finetuning. *arXiv preprint arXiv:2008.00401*.
- Toborek, V., Busch, M., Boßert, M., Bauckhage, C., & Welke, P. (2023). A New Aligned Simple German Corpus. *Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, 11416–11432.
- Überwachungsstelle des Bundes für Barrierefreiheit von Informationstechnik. (2026). *Leichte Sprache – Übergreifende Anforderungen für Web und App*. Verfügbar 8. August 2026 unter https://www.barrierefreiheit-dienstekonsolidierung.bund.de/Webs/PB/DE/barrierefreie_it/uebergreifende-anforderungen-web-und-app/leichte-sprache/leichte-sprache-artikel.html
- Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, Ł., & Polosukhin, I. (2017). Attention is All You Need. *Advances in Neural Information Processing Systems*, 30, 5998–6008.
- Xu, W., Napoles, C., Pavlick, E., Chen, Q., & Callison-Burch, C. (2016). Optimizing Statistical Machine Translation for Text Simplification. *Transactions of the Association for Computational Linguistics*, 4, 401–415.

10 Anhang