

Hochschule Flensburg  
University of Applied Sciences  
Master of Science Angewandte Informatik

# M A S T E R - T H E S I S

**Entwicklung domänenspezifischer Datensätze und  
automatisierter Evaluation für ein Framework zur  
neuronalen Textvereinfachung in leichte Sprache**

Fiete Scheel  
Matrikel-Nr.:  
Erstprüfer: Max Mustermann  
Zweitprüfer: Manuela Musterfrau  
Abgabe: xx.xx.xxxx

**Hochschule Flensburg**

# **M A S T E R - T H E S I S**

Thema: Entwicklung domänenspezifischer Datensätze und automatisierter Evaluation  
für ein Framework zur neuronalen Textvereinfachung in leichte Sprache

von: Fiete Scheel

Matrikel-Nr.:

Studiengang: Master of Science Angewandte Informatik

Betreuer/in und

Erstbewerter/in: Prof. Dr.-Ing. Marc Aubreville

Zweitbewerter/in: Prof. Dr. Peter John

Ausgabedatum: 21.05.2026

Abgabedatum: 10.09.2026

# Erklärung zur Nutzung generativer Künstlicher Intelligenz

Generative KI wurde im Verlauf dieser Masterarbeit regelmäßig als unterstützendes Werkzeug eingesetzt. Sie wurde als standardmäßiger Bestandteil moderner Arbeitsabläufe betrachtet – in gleicher Weise, wie eine integrierte Entwicklungsumgebung oder eine Rechtschreibprüfung ein Standardbestandteil beim Schreiben von Programmcode und Fließtext ist. Der Einsatz erfolgte stets unterstützend und zu keinem Zeitpunkt als passive Abgabe von Aufgaben. Jede Ausgabe unterlag einer engen manuellen Überwachung, wurde wiederholt überarbeitet und durch den Autor verifiziert.

Die folgenden Werkzeuge kamen zum Einsatz:

- **DeepL Write** wurde für das sprachliche Lektorat und das grammatikalische Korrekturlesen verwendet.
- **Gemini (Google)** wurde zur Unterstützung beim Brainstorming, zur Klärung technischer Konzepte und zur Generierung von Formulierungsvorschlägen für nicht-technische Erklärungstexte genutzt. Zudem diente es als erster Schritt bei der Informationssuche anstelle einer konventionellen Suchmaschine.
- **Antigravity (Google)** wurde als agentische Entwicklungsumgebung und über die Befehlszeilenschnittstelle (CLI) für Programmieraufgaben, technische Beratung, Code-Reviews sowie das Korrekturlesen der Abschlussarbeit eingesetzt (u. a. zur automatisierten Überprüfung auf argumentative Konsistenz, präzise Wortwahl sowie Rechtschreibung und Grammatik).

Die KI-Werkzeuge dienten zudem als Diskussions- und Sparringspartner sowie zum »Rubber Ducking«. Das strukturierte Formulieren eines Problems gegenüber dem System trug oft bereits vor Erhalt einer Antwort zur Klärung bei. Sämtliche methodischen Vorgehensweisen und erarbeiteten Lösungsansätze wurden darüber hinaus fortlaufend in den wöchentlichen Master-Meetings mit dem betreuenden Professor, den Doktoranden und weiteren Masterstudierenden gegengeprüft, diskutiert und entweder bestätigt, verworfen oder gezielt weiterentwickelt.

Alle durch KI-Werkzeuge generierten Inhalte wurden vom Autor kritisch geprüft, editiert und verifiziert. Kein generatives KI-System wurde zur Erzeugung

originärer wissenschaftlicher Resultate, experimenteller Messdaten, Beweise oder der finalen Implementierungen der Algorithmen herangezogen. Das Forschungsdesign, die Analyse sowie die Interpretation der Ergebnisse sind originäre Leistungen des Autors. Der Autor übernimmt die uneingeschränkte Verantwortung für den Inhalt, die Richtigkeit und die Eigenständigkeit dieser Arbeit.



Ich versichere, dass ich meine Arbeit selbstständig und ohne fremde Hilfe verfasst, keine anderen als die angegebenen Quellen und Hilfsmittel benutzt, alle wörtlich oder sinngemäß übernommenen Stellen einschließlich generierter Texte in der Arbeit gekennzeichnet habe, und dass die Arbeit in gleicher oder ähnlicher Form in noch keiner anderen Prüfung vorgelegen hat. Ich stimme der Überprüfung der Arbeit durch eine Plagiatsoftware zu.

---

Ort, Datum

---

Unterschrift

# Inhaltsverzeichnis

|          |                                                                             |           |
|----------|-----------------------------------------------------------------------------|-----------|
| <b>1</b> | <b>Einleitung</b>                                                           | <b>1</b>  |
| 1.1      | Problemstellung & Motivation . . . . .                                      | 1         |
| 1.2      | Zielsetzung & Forschungsfragen . . . . .                                    | 2         |
| 1.3      | Aufbau der Arbeit . . . . .                                                 | 3         |
| <b>2</b> | <b>Theoretischer Hintergrund</b>                                            | <b>5</b>  |
| 2.1      | Das Konzept der Leichten Sprache . . . . .                                  | 5         |
| 2.2      | Grundlagen der automatischen Textvereinfachung . . . . .                    | 5         |
| 2.2.1    | Textrepräsentationen & Einbettungen . . . . .                               | 6         |
| 2.2.2    | Herausforderungen der automatischen Evaluation . . . . .                    | 7         |
| 2.3      | Architekturen moderner neuronaler Sprachmodelle . . . . .                   | 7         |
| 2.3.1    | Der Attention-Mechanismus . . . . .                                         | 7         |
| 2.3.2    | Modellfamilien im NLP . . . . .                                             | 8         |
| <b>3</b> | <b>Stand der Forschung</b>                                                  | <b>9</b>  |
| 3.1      | Verfügbare Datenbasis und Korpora (Themenblock 1) . . . . .                 | 9         |
| 3.2      | Evaluierungsmetriken für die Vereinfachung (Themenblock 2) . .              | 10        |
| 3.3      | Maschinelle Übersetzung und Optimierungsverfahren (Themenblock 3) . . . . . | 12        |
| <b>4</b> | <b>Themenblock 1: Datenbasis &amp; Korpus-Erstellung</b>                    | <b>15</b> |
| 4.1      | Multi-Quellen-Crawling & Datenakquise . . . . .                             | 17        |
| 4.1.1    | Domänen- und Quellenabdeckung . . . . .                                     | 18        |
| 4.1.2    | Technische Extraktions- & Verknüpfungsmechanismen . .                       | 19        |
| 4.1.3    | Ergebnis der Datenakquise (Roh-Korpus) . . . . .                            | 21        |
| 4.2      | Datenbereinigung & Normalisierung . . . . .                                 | 22        |
| 4.2.1    | Web-Boilerplate-Bereinigung & Tag-Punctuation-Guard .                       | 23        |
| 4.2.2    | Typografische Normalisierung & Listen-Transformation .                      | 24        |
| 4.2.3    | Quantitative Korpusevaluation: Pipeline-Funnel & Retention                  | 26        |
| 4.2.4    | Empirische Fallstudien zur Bias- & Halluzinations-Prävention                | 27        |
| 4.3      | Quality Assurance & Similarity Sweet-Spot . . . . .                         | 29        |
| 4.3.1    | Long-Context-Vektorisierung mittels Jina Embeddings v2                      | 29        |
| 4.3.2    | Der Similarity Sweet-Spot: Filtration & Grenzdefinition .                   | 30        |
| 4.4      | Korpus-Statistiken & Lexikalische Diversität . . . . .                      | 31        |
| 4.4.1    | Quantitative Korpusmaße & Quellcharakteristika . . . . .                    | 32        |

|          |                                                                                                                    |           |
|----------|--------------------------------------------------------------------------------------------------------------------|-----------|
| 4.4.2    | Lexikalische Diversität: TTR vs. MATTR & Längen-Bias                                                               | 33        |
| 4.4.3    | Faktenerhalt vs. Faktentreue: Grenzen von NER als Metrik                                                           | 34        |
| 4.4.4    | Regeleinhaltung nach BMAS-Richtlinien . . . . .                                                                    | 36        |
| 4.4.5    | Synthese der Korpusseigenschaften . . . . .                                                                        | 38        |
| <b>5</b> | <b>Themenblock 2: Metrik &amp; Bewerten von Sprachkomplexität</b>                                                  | <b>40</b> |
| 5.1      | Vorstufe: Binäre Klassifikation als Machbarkeitsnachweis & Architektur-Baseline . . . . .                          | 40        |
| 5.1.1    | Motivation, Lesbarkeitsmetriken & BiLSTM-Architektur .                                                             | 40        |
| 5.1.2    | Granularitäts-Ablation: Majority Voting vs. Dilution-Effekt                                                        | 42        |
| 5.1.3    | Ausschluss von Längen- und Layout-Biases (Kontrollexperimente) . . . . .                                           | 44        |
| 5.1.4    | Synthese: Erlernbarkeit des Signals & Überleitung zur MixUp-Regression . . . . .                                   | 45        |
| 5.2      | Continuous MixUp Regression . . . . .                                                                              | 46        |
| 5.2.1    | Ablationsstudie: Einfluss der Kontextlänge auf die MixUp-Regression . . . . .                                      | 47        |
| 5.3      | Validierung der kontinuierlichen Abstufungsfähigkeit auf externen Benchmarks (TextComplexityDE & MERLIN) . . . . . | 50        |
| 5.3.1    | Das fundamentale Dilemma: Diskrete Klassifikation vs. kontinuierlicher Reward . . . . .                            | 50        |
| 5.3.2    | Satzebene: Evaluation auf TextComplexityDE & Analyse des Floor-Effekts . . . . .                                   | 51        |
| 5.3.3    | Dokumentebene: Evaluation auf dem MERLIN CEFR-Benchmark . . . . .                                                  | 52        |
| 5.3.4    | Kritische Synthese: Validität des Zero-Shot-Transfers & Fazit . . . . .                                            | 53        |
| 5.4      | Evaluierung synthetischer Sprachstufen (LLM-basierter Regressor) 54                                                |           |
| 5.4.1    | Konzeption, Prompt-Design & Generierung mit FlensGen-GPT . . . . .                                                 | 54        |
| 5.4.2    | Empirische Ergebnisse & Vergleich mit dem MixUp-Paradigma                                                          | 55        |
| 5.4.3    | Methodische Grenzen & Begründung der Ausmusterung .                                                                | 55        |
| 5.5      | Synthese & Modellauswahl für die generative Übersetzung (Themenblock 3) . . . . .                                  | 56        |

|                                                                                                                   |           |
|-------------------------------------------------------------------------------------------------------------------|-----------|
| <b>6 Themenblock 3: Modellierung der Übersetzung &amp; Reward-Guided Fine-Tuning</b>                              | <b>59</b> |
| 6.1 Datenvorbereitung & Trainings-Splits . . . . .                                                                | 59        |
| 6.2 Supervised Fine-Tuning (SFT) . . . . .                                                                        | 60        |
| 6.3 Reward-Guided Optimization (RLHF / DPO & PPO) . . . . .                                                       | 61        |
| 6.4 Mehrdimensionale Evaluierung & Demonstrator-App . . . . .                                                     | 62        |
| <b>7 Diskussion &amp; Gesamtevaluation</b>                                                                        | <b>63</b> |
| 7.1 Inhaltssynthese der drei Themenblöcke . . . . .                                                               | 63        |
| 7.2 Stärken, Grenzen & Systemrestriktionen . . . . .                                                              | 63        |
| 7.3 Beantwortung der Forschungsfragen . . . . .                                                                   | 63        |
| <b>8 Fazit &amp; Ausblick</b>                                                                                     | <b>64</b> |
| 8.1 Zusammenfassung der Kernergebnisse . . . . .                                                                  | 64        |
| 8.2 Ausblick & Zukünftige Forschungsarbeiten . . . . .                                                            | 64        |
| <b>9 Anhang</b>                                                                                                   | <b>65</b> |
| <b>Glossar</b>                                                                                                    | <b>66</b> |
| <b>Abbildungsverzeichnis</b>                                                                                      | <b>67</b> |
| <b>Tabellenverzeichnis</b>                                                                                        | <b>70</b> |
| <b>Literaturverzeichnis</b>                                                                                       | <b>72</b> |
| 9.1 Ergänzende Evaluation auf TextComplexityDE (Naderi et al., 2019)                                              | 76        |
| 9.2 Ergänzende Evaluation auf dem MERLIN CEFR-Benchmark<br>(Boyd et al., 2014) . . . . .                          | 79        |
| 9.3 Ergänzende Evaluation der Klassifikationsmodelle (In-Domain<br>Sweet-Spot & Granularitätsvergleich) . . . . . | 80        |
| 9.4 Ergänzende Evaluation der MixUp Trainings- und Sampling-<br>Strategien (Varianten A–D) . . . . .              | 86        |
| 9.5 Ergänzende Evaluation der BiLSTM MixUp Regressoren (Län-<br>genvergleich & Trajektorien) . . . . .            | 89        |
| 9.6 Ergänzende Evaluation des Synthetischen Regressors & Prompt-<br>Design . . . . .                              | 91        |
| 9.6.1 Master-Benchmark auf dem Lebenshilfe-Goldstandard . .                                                       | 91        |

|       |                                                       |    |
|-------|-------------------------------------------------------|----|
| 9.6.2 | Prompt-Design zur Generierung synthetischer Zwischen- |    |
|       | stufen . . . . .                                      | 92 |

# 1 Einleitung

## 1.1 Problemstellung & Motivation

**Für manche eine optionale Lesehilfe, für andere der einzige Zugang zu gesellschaftlicher Teilhabe.**

Beim Thema Barrierefreiheit denken viele an physische Barrieren wie Rampen, Aufzüge oder automatische Türen. Durch die Digitalisierung und die Verlagerung von Dienstleistungen und Informationen ins Internet ist es damit jedoch nicht mehr getan. Barrierefreie Gestaltung betrifft zunehmend digitale Räume und insbesondere die Sprache, in der Informationen bereitgestellt werden.

Menschen mit kognitiven Einschränkungen, Lernschwierigkeiten, geringer Lese- und Schreibkompetenz oder Deutsch als Zweitsprache werden durch komplexe Texte, bürokratische Fachsprache und verschachtelte Satzstrukturen vom Zugang zu grundlegenden Informationen und Dienstleistungen ausgeschlossen. Das Konzept der *Leichten Sprache* (LS) bietet hierfür ein klar reglementiertes Regelwerk, um Texte durch Vereinfachung des Vokabulars und der Syntax verständlich zu machen.

Mit dem Inkrafttreten des Barrierefreiheitsstärkungsgesetzes (BFSG) in Deutschland sowie europäischen Richtlinien (wie der Web-Accessibility-Directive) wächst der rechtliche Druck auf öffentliche und private Akteure, Informationen auch in Leichter Sprache anzubieten. Die manuelle Übersetzung von Alltagssprache (AS) in Leichte Sprache (LS) durch menschliche Übersetzer ist jedoch extrem zeitintensiv, kostspielig und durch einen Mangel an Fachkräften limitiert.

Hieraus ergibt sich ein dringender Forschungs- und Entwicklungsbedarf im Bereich der maschinellen Textvereinfachung. Bisherige neuronale Übersetzungsmodelle scheitern jedoch häufig an den spezifischen syntaktischen und strukturellen Besonderheiten der Leichten Sprache oder leiden unter dem Mangel an qualitativ hochwertigen, parallelen Trainingsdaten. Es bedarf daher systematischer Ansätze zur automatisierten Erstellung paralleler Korpora, robuster Metriken zur Komplexitätsbewertung und optimierter Trainingsstrategien.

## 1.2 Zielsetzung & Forschungsfragen

Ziel dieser Arbeit ist die Entwicklung, Optimierung und empirische Evaluierung eines methodischen Frameworks zur automatisierten Übersetzung deutscher Alltagssprache in Leichte Sprache. Dies umfasst die gesamte Pipeline: von der Akquise und Bereinigung paralleler Web-Korpora über die kontinuierliche, referenzfreie Modellierung von Textsimplizität bis hin zur dateneffizienten Modelladaption (LoRA) und dem Präferenz-Alignment (DPO).

Im Zentrum dieser Arbeit steht die folgende übergreifende Leitfrage:

**Wie lässt sich die automatische Übersetzung in Leichte Sprache (LS) durch die Kombination aus rauschbereinigten Korpora, kontinuierlichen Simplitätsmetriken und zielgerichteten Alignment-Strategien (DPO) systematisch optimieren und validieren?**

Zur systematischen Beantwortung dieser Leitfrage werden sechs forschungsleitende Kernfragen (FF1 bis FF6) formuliert, die den logischen Bogen über die drei methodischen Hauptsäulen der Arbeit spannen:

### 1. Datenbasis & Korpusqualität (Themenblock 1):

- **FF1 (Quellenheterogenität & Web-Rauschen):** *Inwieweit existiert im deutschsprachigen Web eine hinreichende und qualitativ konsistente Datenbasis für Leichte Sprache, und welche Vorverarbeitungsschritte sind erforderlich, um domänenspezifisches Web-Rauschen (Boilerplate, Teaser, maschinelle Vorübersetzungen) zu eliminieren?*
- **FF2 (Artikel- vs. Satzebene & Informationsverlust):** *Welche Vor- und Nachteile bietet eine artikelbasierte Modellierung gegenüber satzweiser Segmentierung für das Übersetzen in Leichte Sprache, und wie lässt sich der inhärente Konflikt zwischen syntaktischer Simplifikation und semantischem Informationsverlust (Faktenerhalt) quantifizieren?*

### 2. Metrik & Kontinuierliche Simplitäts-Modellierung (Themenblock 2):

- **FF3 (Kontinuierliche Regression ohne Zwischenkorpora):** *Wie kann ein kontinuierliches Regressionsmodell zur Messung des Vereinfachungsgrads trainiert werden, wenn in realen Korpora ausschließlich binäre Extremzustände (Standardsprache vs. Leichte Sprache) ohne natürliche Zwischenstufen vorliegen?*

### 3. Übersetzung, Alignment & Expertenvalidierung (Themenblock 3 & Diskussion):

- **FF4 (Dateneffizienz & PEFT/LoRA):** *In welchem Maße können vortrainierte Sequenz-zu-Sequenz-Modelle bei extrem begrenzter Datenmenge ( 800–1.000 Artikelpaare) die komplexen syntaktischen und lexikalischen Regeln der Leichten Sprache erlernen, ohne in Memorization und Overfitting zu verfallen?*
- **FF5 (Reward-Guided Alignment via DPO):** *Inwiefern kann das Signal eines kontinuierlich trainierten Simplizitäts-Regressors genutzt werden, um ein vortrainiertes Übersetzungsmodell über Direct Preference Optimization (DPO) gezielt auf die Eigenheiten Leichter Sprache auszurichten, ohne die semantische Faktentreue zu kompromittieren?*
- **FF6 (Expertenvalidierung & Ökologische Validität):** *Wie valide korrelieren automatisierte Bewertungsmetriken mit dem qualitativen Urteil von Fachkräften für Leichte Sprache (Lebenshilfe Kiel), und in welchem Maße sind Modellübersetzungen von professionellen Humanübersetzungen unterscheidbar?*

## 1.3 Aufbau der Arbeit

Die vorliegende Arbeit folgt einer logischen Struktur, die sich an den drei Säulen des entwickelten Übersetzungssystems orientiert:

- **Kapitel 2 (Theoretischer Hintergrund)** legt das theoretische und linguistische Fundament. Es definiert das Konzept der Leichten Sprache und grenzt dieses formal sowie rechtlich von der Einfachen Sprache ab.
- **Kapitel 3 (Stand der Forschung)** stellt den aktuellen wissenschaftlichen Stand strukturiert entlang der drei Säulen Datenbasis, Komplexitätsmetriken und maschinelle Übersetzungsverfahren dar und leitet die bestehenden Forschungslücken ab.



- **Kapitel 4 (Themenblock 1: Datenbasis & Korpus-Erstellung)** beschreibt die erste Stufe der Pipeline. Im Fokus steht das Crawling paralleler Webtexte, die domänenspezifische Datenbereinigung und die qualitative Filterung mittels semantischer Embeddings.
- **Kapitel 5 (Themenblock 2: Metrik & Bewerten von Sprachkomplexität)** widmet sich der zweiten Stufe: der Entwicklung von Klassifikationsmodellen (BiLSTM vs. SBERT) und dem Entwurf einer *Continuous MixUp Regression* zur stufenlosen Komplexitätsbewertung.
- **Kapitel 6 (Themenblock 3: Modellierung der Übersetzung & Reward-Guided Fine-Tuning)** stellt das eigentliche Übersetzungsmodell vor. Hierbei werden die Implementierung des Supervised Fine-Tunings (SFT) sowie das Reward-Guided Fine-Tuning (DPO) zur Regeleinhaltung evaluiert.
- **Kapitel 7 (Diskussion & Gesamtevaluation)** führt die Ergebnisse der drei Stufen zusammen, beantwortet systematisch die aufgeworfenen Forschungsfragen und beleuchtet kritisch die Systemrestriktionen sowie Fragen zur Faktentreue.
- **Kapitel 8 (Fazit & Ausblick)** fasst die Kernergebnisse der Arbeit zusammen und gibt einen Ausblick auf zukünftige Forschungsarbeiten und praktische Anwendungsfelder.

## 2 Theoretischer Hintergrund

### 2.1 Das Konzept der Leichten Sprache

Das Konzept der Leichten Sprache (LS) stellt eine stark reglementierte Sprachvariante der deutschen Standardsprache dar, die primär darauf abzielt, Barrierefreiheit in der schriftlichen Kommunikation für Menschen mit kognitiven Einschränkungen, Lernschwierigkeiten oder geringer Lese- und Schreibkompetenz zu gewährleisten. Syntaktisch zeichnet sich LS unter anderem durch kurze Hauptsätze (Subjekt-Prädikat-Objekt), den Verzicht auf Nebensätze, Passivkonstruktionen, den Genitiv sowie den Konjunktiv aus. Auf lexikalischer Ebene werden abstrakte Begriffe durch konkrete Beispiele ersetzt, und lange zusammengesetzte Wörter werden mittels typografischer Hilfsmittel wie Bindestrichen oder dem Mediopunkt (z. B. *Bundestags-Wahl* oder *Bundestags·wahl*) segmentiert.

Vom Konzept der Leichten Sprache ist die sogenannte *Einfache Sprache* (Plain German) abzugrenzen. Während die Leichte Sprache als hochspezialisierte Sprachvariante mit strengen, normierten Richtlinien konzipiert ist und in Deutschland rechtlich durch die Barrierefreie-Informationstechnik-Verordnung (BITV 2.0) für öffentliche Stellen vorgeschrieben wird (Überwachungsstelle des Bundes für Barrierefreiheit von Informationstechnik, 2026), besitzt die Einfache Sprache ein weitaus weniger restriktives Regelwerk. Letztere richtet sich an eine breitere Zielgruppe (wie Menschen mit Deutsch als Zweitsprache oder funktionale Alphabeten) und lässt komplexere Satzstrukturen sowie einen größeren Wortschatz zu. Ein weiterer kritischer Unterschied liegt im Qualitätssicherungsprozess: Texte in Leichter Sprache müssen zwingend von Personen aus der primären Zielgruppe auf ihre Verständlichkeit hin geprüft werden, was bei Texten in Einfacher Sprache nicht vorgeschrieben ist.

### 2.2 Grundlagen der automatischen Textvereinfachung

Die automatische Textvereinfachung (*Automatic Text Simplification*, ATS) zielt darauf ab, die syntaktische und lexikalische Komplexität eines Textes zu reduzieren, während die semantische Kernbotschaft erhalten bleibt. Aus maschineller Sicht lässt sich ATS formal als monolinguale maschinelle Übersetzung (*Monolingual Machine Translation*) modellieren. Im Gegensatz zur klassischen bilingualen Übersetzung (z. B. Deutsch nach Englisch) erfordert ATS tiefgreifende asymme-

trische Strukturtransformationen:

- **Satzteilung (Sentence Splitting):** Lange, hypotaktische Satzgefüge müssen in mehrere koordinierte Hauptsätze zerlegt werden.
- **Streichung & Kompression (Deletion/Compression):** Redundante oder nebensächliche Füllinformationen müssen getilgt werden, um die kognitive Belastung des Lesers zu reduzieren.
- **Lexikalische Substitution & Explikation:** Schwierige Fachtermini müssen durch frequente Synonyme ersetzt oder um definitorische Nebensätze erweitert werden.

### 2.2.1 Textrepräsentationen & Einbettungen

Moderne Algorithmen des Natural Language Processing (NLP) verarbeiten Text über numerische Repräsentationen. Der Prozess gliedert sich in Tokenisierung und Einbettung (*Embedding*):

1. **Tokenisierung:** Vor der mathematischen Modellierung wird der Text in atomare Einheiten (Tokens) zerlegt. Neben wortbasierten Verfahren kommen in neuronalen Modellen überwiegend Subword-Tokenisierer wie Byte-Pair Encoding (BPE) nach Sennrich et al. (2016) oder SentencePiece zum Einsatz. Diese ermöglichen es, ein geschlossenes Vokabular fester Größe zu definieren und gleichzeitig seltene oder unbekannte Wörter (*Out-of-Vocabulary*, OOV) in morphologische Subkomponenten aufzuspalten.
2. **Dichte Vektoreinbettungen (Dense Embeddings):** Tokens oder ganze Sequenzen werden auf kontinuierliche Vektoren  $\mathbf{e} \in \mathbb{R}^d$  im latenten semantischen Raum abgebildet. Sentence-Embedding-Modelle wie Sentence-BERT (SBERT) nach Reimers und Gurevych (2019) erzeugen über siamesische Netzwerke kontextsensitive Sequenzrepräsentationen.
3. **Semantische Ähnlichkeit:** Die inhaltliche Verwandtschaft zweier Textsequenzen  $x$  und  $y$  mit den Einbettungen  $\mathbf{e}_x, \mathbf{e}_y$  wird üblicherweise über die Kosinus-Ähnlichkeit im Vektorraum quantifiziert:

$$\text{sim}_{\cos}(\mathbf{e}_x, \mathbf{e}_y) = \frac{\mathbf{e}_x \cdot \mathbf{e}_y}{\|\mathbf{e}_x\|_2 \|\mathbf{e}_y\|_2} \in [-1, 1] \quad (1)$$

welche für Normalisierungszwecke oft linear auf das Intervall  $[0, 1]$  skaliert wird:  $\text{sim}_{\text{norm}} = \frac{\text{sim}_{\cos} + 1}{2}$ .

### 2.2.2 Herausforderungen der automatischen Evaluation

Die Evaluation von ATS-Systemen unterscheidet sich fundamental von der Standard-Übersetzung. Klassische referenzbasierte N-Gramm-Metriken wie BLEU (Papineni et al., 2002) und ROUGE (Lin, 2004) messen primär die wörtliche Übereinstimmung mit einem Referenztext. Wie Alva-Manchego et al. (2021) empirisch belegen, korreliert BLEU im ATS-Kontext jedoch häufig negativ mit der menschlichen Beurteilung: Ein System, das den komplexen Ausgangstext unverändert kopiert, erzielt oft hohe BLEU-Werte, leistet jedoch keine Vereinfachung.

Aus diesem Grund etablierte sich die Metrik SARI (Xu et al., 2016), welche eingefügte (*add*), beibehaltene (*keep*) und gelöschte N-Gramme (*delete*) explizit getrennt gegenüber der Quelle und den Referenzen bewertet und somit Vereinfachungsoperationen honoriert.

## 2.3 Architekturen moderner neuronaler Sprachmodelle

Neuronale Sprachmodelle haben sich als führendes Paradigma für Sequence-to-Sequence-Aufgaben etabliert. Das Fundament bildet die von Vaswani et al. (2017) eingeführte Transformer-Architektur, welche vollständig auf rekurrenten Schleifen verzichtet und stattdessen auf dem Konzept der *Self-Attention* (Selbstaufmerksamkeit) aufbaut.

### 2.3.1 Der Attention-Mechanismus

Der skalierten Skalarprodukt-Aufmerksamkeit (*Scaled Dot-Product Attention*) liegen drei Vektormatrizen zugrunde: Queries  $\mathbf{Q}$ , Keys  $\mathbf{K}$  und Values  $\mathbf{V}$ , welche durch lineare Projektionen der Eingangsrepräsentationen entstehen. Die Aufmerksamkeitsmatrix wird formal berechnet durch:

$$\text{Attention}(\mathbf{Q}, \mathbf{K}, \mathbf{V}) = \text{softmax} \left( \frac{\mathbf{Q}\mathbf{K}^T}{\sqrt{d_k}} \right) \mathbf{V} \quad (2)$$

wobei  $d_k$  die Dimension der Key-Vektoren darstellt. Mittels *Multi-Head Attention* wird dieser Prozess mehrfach parallel mit unterschiedlichen Projektionsmatrizen durchgeführt, wodurch das Modell simultan Beziehungen auf unterschiedlichen semantischen und syntaktischen Abstraktionsebenen erfassen kann.

### 2.3.2 Modellfamilien im NLP

Je nach Aufbau der Transformer-Schichten werden drei primäre Architekturtypen unterschieden:

1. **Encoder-Decoder-Modelle (Sequence-to-Sequence):** Diese Architektur (wie mBART von Lewis et al. (2020) und Tang et al. (2020) oder mT5) besteht aus einem bidirektionalen Encoder zur Repräsentation des Eingabetextes und einem autoregressiven Decoder, der mittels *Cross-Attention* konditioniert auf die Encoder-Ausgaben den Zieltext Token für Token generiert. Sie eignet sich hervorragend für klassische Transformations- und Übersetzungsaufgaben.
2. **Decoder-Only-Modelle (Kausale Sprachmodelle):** Modelle wie die LLaMA- oder Mistral-Familie nutzen ausschließlich kausal maskierte Decoder-Schichten (*Causal Masking*). Jedes Token darf nur auf vorherige Token aufmerksam werden. Sie werden auf die Vorhersage des nächsten Tokens (*Next-Token Prediction*) vortrainiert und über Prompting oder Instruction Fine-Tuning gesteuert.
3. **Encoder-Only-Modelle:** Modelle wie BERT (Devlin et al., 2019) oder das deutschsprachige GBERT verarbeiten Eingabesequenzen vollständig bidirektional. Sie eignen sich primär für Sequenz- und Token-Klassifikationsaufgaben sowie für Einbettungsmodelle, nicht jedoch zur autoregressiven Textgenerierung.

## 3 Stand der Forschung

### 3.1 Verfügbare Datenbasis und Korpora (Themenblock 1)

Einen guten Überblick über den aktuellen Stand und die verfügbaren Ressourcen für Leichte und Einfache Sprache in Deutschland geben Madina et al. (2023). Sie zeigen dabei vor allem auf, wie unterschiedlich die bestehenden Datensätze strukturiert sind und dass es an standardisierten Werkzeugen zur automatischen Bewertung der Texte fehlt.

Die Erforschung datengetriebener, maschineller Übersetzungsverfahren (Automatic Text Simplification, ATS) für das Deutsche litt historisch unter einer eklatanten Datenknappheit. Erste Versuche, ein paralleles Korpus aufzubauen, gehen auf Klaper et al. (2013) mit dem *KLAPER*-Korpus zurück, das jedoch mit ca. 250 parallelen Textpaaren (rund 7.000 Sätze und 70.000 Tokens) für moderne Deep-Learning-Ansätze deutlich zu klein war.

Einen Meilenstein stellte die Arbeit von Battisti et al. (2020) dar, die ein umfangreiches, multimodales Korpus für das Deutsche zusammentrug. Die AutorInnen entwickelten Web-Scraper, um Texte in Leichter und Einfacher Sprache von verschiedenen deutschsprachigen Webportalen und Institutionen der Behindertenhilfe (wie etwa gesundheitlichen Informationsdiensten, öffentlich-rechtlichen Nachrichtenportalen und sozialen Trägern) zu extrahieren. Insgesamt umfasst das Korpus 6.217 Dokumente bzw. fast 211.000 Sätze mit rund 5,5 Millionen geschriebenen Tokens. Ein zentrales Merkmal der Arbeit ist die Aufteilung des Korpus: Es besteht zu einem großen Teil aus 5.461 monolingualen Dokumenten in vereinfachter Sprache, während der parallele Teil mit lediglich 378 parallelen Dokumentenpaaren (jeweils 378 Ausgangs- und Zieltexte) im Vergleich dazu sehr klein ausfällt. Neben den reinen Texten erfassten die AutorInnen systematisch typografische Metadaten (Schriftart, -größe und -stil), Absatz- und Zeilenstrukturen sowie Informationen zu eingebetteten Bildern (Vorhandensein, Dimensionen und Positionierung). Sie wiesen nach, dass diese visuellen Layout-Features die automatische Bewertung der Lesbarkeit (Readability Assessment) stark verbessern.

Für den Bereich der „Einfachen Sprache“ (Plain German) präsentierten Stodden et al. (2023) mit *DEplain* ein professionell erstelltes paralleles Korpus. Dieses teilt sich auf in einen Nachrichtenbereich (DEplain-APA) mit ca. 500 Dokumentenpaaren (rund 13.000 manuell ausgerichteten Satzpaaren) und einen

Webbereich mit ca. 150 manuell ausgerichteten Dokumenten (ca. 2.000 Satzpaaren). Um die Datenknappheit weiter zu reduzieren, stellt das Framework zusätzlich einen Web-Harvester zur automatischen Extraktion und Ausrichtung bereit, wodurch der Webbereich auf ca. 750 Dokumentenpaare (ca. 3.500 automatisch ausgerichtete Satzpaare) vergrößert werden kann. Die Autoren zeigten, dass Modelle, die auf Dokumentenebene trainiert werden, oft Probleme haben, die feinkörnigen semantischen Übergänge beizubehalten, weshalb präzise Alignments eine kritische Ressource für das Training von Seq2Seq-Modellen darstellen. An dieser Stelle ist jedoch hervorzuheben, dass eine direkte Vergleichbarkeit mit Systemen zur Übersetzung in Leichte Sprache erschwert ist: Obwohl das DEplain-Framework methodisch wertvolle Ansätze liefert, bezieht es sich durch den Fokus auf Einfache Sprache auf eine andere linguistische Ziel- und Datendomäne.

Einen weiteren Beitrag zur Generierung paralleler Ressourcen leisteten Toborek et al. (2023) mit der Vorstellung des *New Aligned Simple German Corpus*. Ihr Datensatz besteht aus ca. 700 Dokumentenpaaren auf Dokumentenebene und über 10.000 Satzpaaren auf Satzebene, die teils manuell annotiert und teils automatisch berechnet wurden. Das Korpus kombiniert dabei das systematische Scraping paralleler Webinhalte mit automatischer Satz-Ausrichtung. Allerdings fasst die Arbeit Texte sowohl der Leichten als auch der Einfachen Sprache unter einem gemeinsamen Vereinfachungsbegriff zusammen, was eine feine Unterscheidung der spezifischen syntaktischen und semantischen Richtlinien von Leichter Sprache erschwert. Dieser Kompromiss verdeutlicht jedoch auch ein grundlegendes Problem der aktuellen Forschung: Ein Korpusaufbau, der sich ausschließlich auf reine Leichte Sprache beschränkt, ist Stand jetzt kaum in großem Umfang realisierbar, da es im deutschsprachigen Web schlichtweg an einer ausreichenden Anzahl frei zugänglicher, paralleler Quellen fehlt.

### 3.2 Evaluierungsmetriken für die Vereinfachung (Themenblock 2)

Die automatische Evaluierung von Textvereinfachungssystemen stellt eine große methodische Hürde dar. Traditionell stützt sich die automatisierte Lesbarkeitsbewertung im deutschen Sprachraum auf deterministische Formeln wie den *Flesch Reading Ease* (Amstad, 1978), die *Wiener Sachtextformel* (Bamberger und Vanecek, 1984) oder den *LIX-Index* (Björnsson, 1968). Diese Metriken quantifizieren die Oberflächenkomplexität primär anhand von Silben-, Wort-

und Satzlängenstatistiken. Während sie für allgemeine Lese- und Sachtexte eine robuste, recheneffiziente Orientierungsbasis bieten, sind sie konzeptionell nicht darauf ausgelegt, die spezifischen, normierten Regeln der Leichten Sprache (wie das Vermeiden von Passivkonstruktionen, strikte Hauptsatz-Parataxen oder die Bindestrich-Gliederung von Komposita) zu erfassen.

In der datengetriebenen maschinellen Textvereinfachung kamen daher historisch primär Metriken der maschinellen Übersetzung wie BLEU zum Einsatz, die auf n-Gramm-Präzision im Vergleich zu einer Referenzübersetzung basieren. Für die Vereinfachung erweisen sich diese jedoch oft als ungeeignet: Wie Alva-Manchego et al. (2021) empirisch belegen, korreliert BLEU nur schwach mit dem menschlichen Urteil über Einfachheit und Textqualität. Der Grund liegt darin, dass BLEU lexikalische Variationen und strukturelle Modifikationen (wie Satzteilung und Umformulierung) als Fehler abstrahlt, obwohl genau diese für eine gute Vereinfachung essenziell sind.

Als Alternative etablierte sich die Metrik *SARI* (System Accessibility and Readability Index), eingeführt von Xu et al. (2016). SARI vergleicht die Systemausgabe sowohl mit dem komplexen Ausgangstext als auch mit den Referenzübersetzungen. Dabei berechnet SARI separat die Präzision und den Recall für eingefügte (add), gelöschte (delete) und beibehaltene (keep) Wörter:

$$\text{SARI} = \frac{F_{\text{add}} + F_{\text{keep}} + P_{\text{del}}}{3} \quad (3)$$

Dadurch belohnt SARI explizit Vereinfachungsoperationen, die sich vom komplexen Ausgangstext wegbewegen.

Im Laufe der Entstehungszeit dieser Arbeit wurde mit *DETECT* von Korobeynikova et al. (2024) eine neuartige, erlernbare Evaluierungsmetrik speziell für die deutsche Textvereinfachung vorgestellt. DETECT adaptiert das englischsprachige LENS-Framework für den deutschsprachigen Raum und zielt darauf ab, die Qualität automatischer Vereinfachungen ganzheitlich über drei Dimensionen abzubilden: Verständlichkeit (*Simplicity / Ease*), semantische Inhaltsbewahrung (*Meaning Preservation*) sowie grammatikalische Korrektheit und Sprachfluss (*Fluency / Textual Clarity*). Um den Mangel an manuell annotierten Trainingsdaten zu überwinden, wird das Regressionsmodell vollständig auf synthetisch durch Large Language Models generierten Qualitätsurteilen trainiert. In empirischen Validierungen auf einem eigens erhobenen menschlichen Testdatensatz wiesen die AutorInnen nach, dass DETECT deutlich stärkere Korrelationen mit



menschlichen Qualitätsbewertungen erzielt als traditionelle Maße wie BLEU, SARI oder BERTScore.

Gleichzeitig verdeutlicht dieser Ansatz zentrale verbleibende Forschungslücken: Da der zugrundeliegende Evaluierungsdatensatz (*SimpEvalDE*) primär auf Korpora der Einfachen Sprache (DEplain-APA und LHA-APA) aufbaut, sind spezifische, normierte Richtlinien der Leichten Sprache — wie das strikte Vermeiden von Passiv- und Genitivkonstruktionen oder die typografische Gliederung von Komposita — nicht explizit als Kriterien modelliert. Zudem sind rein referenzbasierte Satz-Metriken nur bedingt geeignet, um die Komplexität längerer Dokumente ganzheitlich und referenzfrei zu bewerten oder als kontinuierliches Steuerungssignal während des Modelltrainings eingesetzt zu werden.

Obwohl das Thema Leichte Sprache in der deutschsprachigen NLP-Forschung über viele Jahre hinweg nur wenig Beachtung gefunden hat, zeigt das jüngste Erscheinen solcher Arbeiten, dass das Forschungsfeld derzeit stark an Dynamik gewinnt, was die wissenschaftliche und gesellschaftliche Relevanz dieses Themenbereichs zusätzlich unterstreicht.

### 3.3 Maschinelle Übersetzung und Optimierungsverfahren (Themenblock 3)

Die maschinelle Übersetzung von Alltagssprache (AS) in Leichte Sprache (LS) lässt sich formal als monolinguale maschinelle Übersetzung (*Monolingual Machine Translation*) begreifen. Im Gegensatz zur klassischen bilingualen Übersetzung (z. B. Deutsch–Englisch) erfordert dieser Transformationsprozess tiefgreifende asymmetrische Strukturänderungen: Komplexe Satzgefüge müssen aufgespalten (*Sentence Splitting*), Passiv- in Aktivkonstruktionen überführt, irrelevante Textpassagen gekürzt (*Compression*) und abstrakte Begrifflichkeiten explizierend umschrieben werden.

Die empirische Erforschung datengetriebener Übersetzungsmodelle für die deutsche Leichte Sprache ist bislang stark limitiert. Erste systematische Benchmarks zur neuronalen maschinellen Übersetzung (NMT) für das Deutsche wurden von Säuberli et al. (2020) vorgelegt. Auf Basis eines kleinen parallelen Nachrichtenkorpus wiesen die Autoren nach, dass Transformer-basierte Sequence-to-Sequence-Modelle grundlegende lexikalische Substitutionen und Satzkürzungen erlernen können. Allerdings zeigten sich deutliche qualitative Grenzen bei komplexeren syntaktischen Transformationen sowie eine hohe Anfälligkeit für die

zugrundeliegende Datenknappheit.

Mit dem Aufkommen moderner Large Language Models (LLMs) verlagerte sich der Schwerpunkt zunehmend auf vortrainierte generative Sprachmodelle (wie die LLaMA- oder Mistral-Familie). Während rein Prompt-basierte Ansätze genereller Modelle häufig dazu neigen, Texte lediglich in ein moderates Sprachniveau (Einfache Sprache) zu überführen und formale Negativbeschränkungen der Leichten Sprache (wie den strikten Ausschluss von Genitiven oder Nebensätzen) zu verletzen, ermöglicht das zielgerichtete Fine-Tuning (z. B. Parameter-Efficient Fine-Tuning mittels LoRA/QLoRA) eine präzisere stilistische Anpassung.

Da qualitativ hochwertige parallele Datenpaare in der Praxis stark limitiert sind, stößt reines Supervised Fine-Tuning (SFT) schnell an eine quantitative Obergrenze. In diesem Kontext bietet die Präferenzoptimierung (*Preference Optimization*) einen vielversprechenden Ansatz zur weiteren Modellverbesserung: Mit dem initial trainierten SFT-Basismodell können für neue oder unalignierte Ausgangstexte mehrere Übersetzungskandidaten generiert werden. Werden diese Ausgaben anschließend anhand von Qualitäts- oder Komplexitätskriterien in bevorzugte (*chosen*,  $y_w$ ) und abgelehnte (*rejected*,  $y_l$ ) Antworten unterteilt, lässt sich das Modell auf diesen neu erzeugten Präferenzpaaren gezielt weiter trainieren und an die spezifischen Stil- und Verständlichkeitsanforderungen anpassen.

Um generative Modelle mathematisch stabil und ohne den aufwendigen Overhead von klassischem Reinforcement Learning (RLHF/PPO) auf spezifische Qualitäts- und Formatierungsrichtlinien auszurichten, führten Rafailov et al. (2023) die *Direct Preference Optimization* (DPO) ein. DPO optimiert die Policy direkt auf Präferenzdaten der Form  $(x, y_w, y_l)$  — bestehend aus einem Prompt  $x$ , einer bevorzugten Antwort  $y_w$  (winning) und einer abgelehnten Antwort  $y_l$  (losing) — über eine geschlossene Verlustfunktion:

$$\mathcal{L}_{\text{DPO}}(\theta; \pi_{\text{ref}}) = -\mathbb{E}_{(x, y_w, y_l)} \left[ \log \sigma \left( \beta \log \frac{\pi_{\theta}(y_w|x)}{\pi_{\text{ref}}(y_w|x)} - \beta \log \frac{\pi_{\theta}(y_l|x)}{\pi_{\text{ref}}(y_l|x)} \right) \right] \quad (4)$$

wobei  $\pi_{\text{ref}}$  die SFT-Referenz-Policy darstellt,  $\beta$  ein Regularisierungsparameter ist und  $\sigma$  die Sigmoidfunktion bezeichnet.

Die Wirksamkeit von DPO für die deutsche Textvereinfachung wurde kürzlich von Anonymized (2025) anhand des *HF4ATS*-Datensatzes untersucht. Die Autoren zeigten empirisch, dass DPO-optimierte Modelle im Vergleich zu reinem SFT nicht nur eine signifikant höhere Verständlichkeit für die Zielgruppe erzielen, sondern vor allem formale Kriterien der Leichten Sprache (wie das Vermeiden

von Genitiven und Nebensätzen) drastisch stabiler einhalten.

Hieraus leitet sich eine zentrale Forschungslücke ab: Bisherige Übersetzungsansätze für das Deutsche operieren fast ausnahmslos auf isolierter Satzebene und sind auf statische, manuell erstellte Präferenzdaten angewiesen. Es fehlt an domänenübergreifenden Übersetzungssystemen, die Texte kohärent auf Dokumenten- und Articlebene transformieren und deren Präferenzoptimierung automatisiert über erlernte Komplexitätsmetriken als kontinuierliche Reward-Instanz gesteuert werden kann.

## 4 Themenblock 1: Datenbasis & Korpus-Erstellung

Die Erstellung eines qualitativ hochwertigen, repräsentativen und ausreichend großen parallelen Korpus bildet das Fundament für jedes datengetriebene Übersetzungssystem. Wie im vorangegangenen Kapitel dargelegt, leidet die maschinelle Textvereinfachung (ATS) für die deutsche Leichte Sprache unter einer eklatanten Datenknappheit. Während bestehende Ressourcen wie das Korpus von Battisti et al. (2020) einen wertvollen Grundstein legten, weisen sie für das Training moderner Seq2Seq- und Präferenzoptimierungsmodelle (wie DPO) entscheidende Limitierungen auf: Entweder ist ihr paralleler Anteil mit wenigen hundert Dokumenten zu gering, oder sie fokussieren sich, wie das DEplain-Korpus von Stodden et al. (2023), primär auf Einfache Sprache (Plain German), was sich linguistisch und regulatorisch signifikant von der Leichten Sprache unterscheidet. Einen wichtigen methodischen Impuls zur automatisierten Datengewinnung lieferten Toborek et al. (2023) mit dem *New Aligned Simple German Corpus*. Ihr Ansatz demonstrierte, wie parallele Webinhalte über seitenspezifische Selektoren und Sprachumschalter im Internet automatisiert identifiziert und gescraped werden können. Diese Vorgehensweise bildete den primären Ausgangspunkt für die in dieser Arbeit entwickelte Crawling- und Extraktions-Pipeline. Allerdings fokussieren Toborek et al. primär auf ein inhärent fehleranfälliges Satz-Alignment und differenzieren nicht strikt zwischen Leichter und Einfacher Sprache.

Um diese Forschungslücke zu schließen, wurde im Rahmen dieser Arbeit eine eigene, automatisierte Pipeline zur Akquise und Aufbereitung von Trainingsdaten entwickelt, welche die Scraping-Prinzipien von Toborek et al. (2023) als methodisches Fundament aufgreift, auf 11 heterogene Domänen ausweitet und zu einer artikelbasierten, qualitätsgesicherten Korpus-Pipeline weiterentwickelt. Da diese Vorarbeit mittlerweile rund drei Jahre zurückliegt und im deutschsprachigen Web in diesem Zeitraum zahlreiche neue Informationsangebote sowie redaktionelle Portale in Leichter Sprache entstanden sind, wurde die Entscheidung getroffen, einen vollständig neuen, zeitgemäßen und breiter aufgestellten Korpus aufzubauen.

Ein zentrales methodisches Charakteristikum der in dieser Arbeit entwickelten Pipeline und der nachfolgenden Modellierung ist die bewusste Entscheidung für ein artikelbasiertes (bzw. dokumentenweites) Training sowohl der Komplexitätsmetrik als auch des Übersetzungsmodells. In der bisherigen Forschung

wurden Vereinfachungssysteme primär auf Satzebene trainiert und evaluiert, was jedoch erhebliche Defizite aufweist:

1. **Kontext- und Kohärenzverlust:** Satzbasierte Ansätze trennen Sätze von dem, was sie im Kontext bedeuten. Dadurch gehen Anspielungen, der rote Faden und die Verbindung zwischen den einzelnen Elementen verloren. Zudem können makrostrukturelle Vereinfachungen wie die Umstrukturierung ganzer Absätze oder das Einfügen von erklärenden Hintergrundinformationen – welche im Konzept der Leichten Sprache essenziell sind – auf Satzebene nicht gelernt werden.
2. **Verrauschte Satz-Alignments:** Die Modellierung auf Satzebene setzt voraus, dass präzise Alignments vorliegen. Wie Stodden et al. (2023) und Štajner et al. (2018) zeigen, führt die asymmetrische Natur der Vereinfachung (z. B. n:m-Alignments und Satzteilungen) dazu, dass automatische Satz-Aligner entweder stark fehlerhafte Paare erzeugen oder einen massiven Informationsverlust durch das Verwerfen nicht-linearer Übergänge in Kauf nehmen müssen.
3. **Verlust struktureller Metadaten:** Wie Battisti et al. (2020) nachwiesen, spielen visuelle Layoutmerkmale, Absatzstrukturen und die Gliederung auf Dokumentenebene eine entscheidende Rolle für das Verständnis von Leichter Sprache. Ein satzbasiertes Alignment eliminiert diese Strukturen vollständig.

Indem wir den gesamten Artikel als Basiseinheit wählen, kann das Übersetzungsmodell lernen, globale Kürzungen vorzunehmen und Texte kohärent umzuformulieren. Gleichzeitig erlaubt dies der Komplexitätsmetrik, die Verständlichkeit eines Textes im Kontext des gesamten Dokuments statt isolierter Sätze zu bewerten. Die methodischen Entscheidungen dieser Pipeline spiegeln dabei direkt die in Abschnitt 3.3 und 3.2 diskutierten Herausforderungen des Forschungsstandes wider:

- **Multi-Quellen-Crawling & Datenakquise (Abschnitt 4.1):** Aufbauend auf den Scraping-Heuristiken des *New Aligned Simple German Corpus* (Toborek et al., 2023) als Ausgangspunkt wurde ein modularer Scraper für eine Vielzahl deutschsprachiger Webportale implementiert. Dies stellt sicher, dass sowohl behördliche Texte (im Kontext der BITV

2.0) als auch journalistische Beiträge und Alltagstexte über 11 heterogene Quellen hinweg automatisiert erfasst werden.

- **Datenbereinigung & Normalisierung (Abschnitt 4.2):** Da Rohdaten aus Webquellen stark variierende HTML-Strukturen, typografische Besonderheiten (z. B. die Verwendung von Bindestrichen oder Mediopunkten zur Worttrennung) und Layout-Elemente aufweisen, erfolgt zunächst eine zielgerichtete, regelbasierte Bereinigung und linguistische Vorverarbeitung.
- **Quality Assurance & Similarity Sweet-Spot (Abschnitt 4.3):** Um das von Štajner et al. (2018) beschriebene Rauschen in den ausgerichteten Daten zu minimieren, wird eine filterbasierte Qualitätssicherung auf Basis langer Vektoreinbettungen eingeführt. Diese identifiziert den optimalen Ähnlichkeitskorridor (den sogenannten „Similarity Sweet-Spot“), um sowohl thematisch divergierende Fehlverlinkungen als auch redundante Kopien ohne Vereinfachungseffekt auszuschließen.
- **Korpus-Statistiken & Lexikalische Diversität (Abschnitt 4.4):** Abschließend wird das resultierende Korpus quantitativ und qualitativ evaluiert. Hierbei wird analysiert, inwiefern die bereinigten und gefilterten Daten die theoretischen Anforderungen der Leichten Sprache erfüllen und welche lexikalische Vielfalt sowie syntaktischen Vereinfachungen sie aufweisen.

Dieses Kapitel beschreibt den detaillierten Ablauf dieser Schritte und dokumentiert die Designentscheidungen bei der Konstruktion des finalen Datensatzes.

## 4.1 Multi-Quellen-Crawling & Datenakquise

Die automatisierte Akquise paralleler Textdaten für die deutsche Leichte Sprache stellt aufgrund der heterogenen Weblandschaft und des Fehlens zentraler Repositorien eine erhebliche methodische Herausforderung dar. Während im englischsprachigen Raum Plattformen wie die *Simple English Wikipedia* als quasi-standardisierte Datenquelle dienen, existiert im deutschsprachigen Raum kein vergleichbares, monolithisches Korpus. Parallele Sprachversionen verteilen sich stattdessen über behördliche Portale, öffentlich-rechtliche Rundfunkanstalten, Verbände der Behindertenhilfe und journalistische Magazine.

Um diesen heterogenen Datenbestand automatisiert und reproduzierbar zu erschließen, greift die in dieser Arbeit entwickelte Pipeline die grundlegenden Scraping-Heuristiken des *New Aligned Simple German Corpus* von Toborek et al. (2023) als methodischen Ausgangspunkt auf. Während Toborek et al. ihr Verfahren jedoch primär auf die Extraktion unzusammenhängender Satzfragmente ausrichteten, wird der Ansatz hier zu einer modularen, zweistufigen Dokumenten-Crawling-Architektur erweitert. Diese trennt die logische URL-Identifikation strikt von der inhaltlichen DOM-Extraktion:

1. **Stufe 1: URL-Discovery & Alignment-Heuristiken** (`scripts/data_collection/crawl_scraper/`): In diesem Schritt navigieren spezialisierte Crawler durch die Zielportale, identifizieren Artikel in Leichter Sprache (LS) und ermitteln über seitenspezifische Verknüpfungsmechanismen die korrespondierende URL der Alltagssprache (AS). Das Ergebnis jeder Quelle wird als JSON-Struktur standardisierter URL-Paare abgelegt.
2. **Stufe 2: Selektive DOM-Content-Extraktion** (`scripts/data_collection/corpus_scrapers/`): Aufbauend auf den identifizierten URL-Paaren lädt die zweite Stufe die HTML-Dokumente asynchron herunter. Anstatt den gesamten Seiteninhalt ungefiltert zu erfassen, extrahiert ein zielgerichteter DOM-Parser ausschließlich den redaktionellen Fließtext über semantische HTML5-Container (`<main>`, `<article>`, `div.paragraph`). Navigationsleisten, Kopf- und Fußzeilen, Cookie-Banner sowie interaktive Schaltflächen werden dadurch bereits auf Extraktionsebene systematisch eliminiert.

#### 4.1.1 Domänen- und Quellenabdeckung

Um eine breite stilistische und thematische Varianz zu gewährleisten und eine Überanpassung an ein einzelnes redaktionelles Regelwerk zu verhindern, wurden 11 frei zugängliche deutschsprachige Webquellen aus drei gesellschaftlich relevanten Domänen erschlossen:

- **Öffentliche Verwaltung & Kommunalportale:** Dieser Sektor besitzt besondere rechtliche Relevanz, da öffentliche Stellen gemäß der Barrierefreie-Informationstechnik-Verordnung (BITV 2.0) gesetzlich verpflichtet sind, wesentliche Informationen in Leichter Sprache bereitzustellen (Überwachungsstelle des Bundes für Barrierefreiheit von Informationstechnik, 2026).

Erfasst wurden die Stadt- und Kommunalportale *Hannover.de* (welches aufgrund seines Umfangs als quantitativer Schwerpunkt dient), *Hamburg.de*, *Koeln.de*, *Stuttgart.de* und *Wiesbaden.de*.

- **Medien & Journalismus:** Zur Abdeckung tagesaktueller Berichterstattung und nachrichtlicher Diskursformen umfasst das Korpus die Angebote des Mitteldeutschen Rundfunks (*MDR Nachrichten in Leichter Sprache*), der tageszeitung (*taz*) sowie des Wirtschaftsmagazins *brand eins*.
- **Gesundheit, Soziales & Politik:** Zur Erfassung medizinischer und sozialrechtlicher Fachtexte wurden das Portal der *Apotheken Umschau* (Einfache Sprache), die Veröffentlichungen des *Beauftragten der Bundesregierung für die Belange von Menschen mit Behinderten* sowie das Bildungsportal *Sozialpolitik.com* integriert.

Ergänzend zu den Webquellen wurde ein unabhängiger Out-of-Domain-Testdatensatz (OOD) auf Basis realer Dokumente der *Lebenshilfe Schleswig-Holstein e. V.* aufgebaut. Dieser Datensatz umfasst behördliche Bescheide, Hausordnungen, Vereinbarungen und Prüfberichte, die von professionellen Übersetzungsbüros übertragen und von zertifizierten Prüfgruppen aus Menschen mit Lernschwierigkeiten validiert wurden. Die Extraktion erfolgte über ein spezialisiertes Parsing-Skript (`scripts/preprocessing/create_lebenshilfe_datasets.py`), welches proprietäre Dateiformate (`.docx`, `.rtf`, `.odt`) verarbeitet und für die spätere modellunabhängige Generalisierungsevaluation bereitstellt.

#### 4.1.2 Technische Extraktions- & Verknüpfungsmechanismen

Da Webseiten keine standardisierten Metadaten für sprachliche Vereinfachungen bereitstellen, wurden für die 11 Webquellen fünf distinkte Verknüpfungsmechanismen implementiert:

1. **Canonical Link Header Exploration:** Die Stadt Hannover implementiert eine technisch vorbildliche Verknüpfung. Jeder LS-Artikel besitzt im HTML-Kopf ein Canonical-Tag (`<linkrel="canonical"href="...">`), welches direkt auf den ursprünglichen Volltext in Alltagssprache verweist. Der Scraper durchsucht ausgehend von der Übersichtsseite rekursiv alle internen Pfade und bildet über diese Referenz deterministische Paare.



2. **DOM Language Switcher Detection:** Bei Quellen wie dem *Behindertenbeauftragten* (`.c-language-switch_1--as`), *Hamburg.de* (`.km1-icon--original-language`) oder *Sozialpolitik.com* (`.underline.easy` mit `hreflang="de-DE"`) existieren dedizierte Umschalt-Schaltflächen im DOM. Der Crawler parst die LS-Seite, liest das Link-Ziel des Sprachumschalters aus und verknüpft die Dokumente.
3. **URL-Parameter- & Routing-Heuristiken:** Einige kommunale Content-Management-Systeme routen Sprachvarianten über URL-Query-Parameter. Bei *Stuttgart.de* wird die Zielsprache über den Parameter `?sp:out=easy` gesteuert; bei *Wiesbaden.de* erfolgt die Auslieferung über `?sp:easylanguage=1`. Das Alignment erfolgt hierbei durch gezieltes Setzen bzw. Entfernen des Parameters bei identischem URL-Stamm.
4. **Kontextuelle Backlinks & Text-Trigger:** Redaktionelle Angebote betten Links zur Ausgangssprache häufig direkt in den Fließtext oder Teaser-Boxen ein. Beim *MDR* sucht der Scraper nach dem standardisierten Block »Hier können Sie diese Nachricht auch in schwerer Sprache lesen:«; die *taz* verlinkt den Originalartikel im Schlusssatz innerhalb kursiver Elemente (`<em>`), während die *Apotheken Umschau* Links mit dem Titelattribut »mehr Informationen« außerhalb des vereinfachten Verzeichnispfads auswertet.
5. **Intra-Page CSS- & Layout-Dissektion:** Das Magazin *brand eins* publiziert beide Sprachfassungen gemeinsam auf einer einzigen Webseite innerhalb desselben Textcontainers (`section.textblock`). Das Alignment erfordert hier eine Stil-Dissektion: Absätze in Leichter Sprache sind im Inline-CSS rot formatiert (`color:#fa4600` bzw. `#ff4948`), während der schwarze Standardtext der Alltagssprache entspricht.

Für historische oder umstrukturierte Webseiten (*Stadt Köln*, *brand eins*) wurde das Scraping über die *Wayback Machine* des Internet Archive realisiert. Um Verbindungsabbrüche durch serverseitige Rate-Limits zu verhindern, implementieren die Scraper eine robuste Retry-Logik mit exponentiellem Backoff (Intervall 2 s → 4 s → 8 s).

### 4.1.3 Ergebnis der Datenakquise (Roh-Korpus)

Durch den Einsatz dieser zielgerichteten Scraper-Infrastruktur konnten in der ersten Pipelinestufe insgesamt 1.438 parallele Artikelpaare über alle 11 Webquellen hinweg akquiriert werden. Tabelle 1 fasst den Rohdatenbestand nach Quellen zusammen.

Tabelle 1: Übersicht des akquirierten Rohdatenbestands (Stufe 1 der Pipeline) nach Quellen.

| Quelle                   | Artikel-paare | AS-Tokens        | LS-Tokens        | Token-Ratio (LS/AS) |
|--------------------------|---------------|------------------|------------------|---------------------|
| Hannover.de              | 768           | 831.816          | 839.915          | 1,01                |
| MDR Nachrichten          | 221           | 234.277          | 102.860          | 0,44                |
| Apotheken Umschau        | 161           | 444.865          | 251.521          | 0,57                |
| Behindertenbeauftragter  | 58            | 55.197           | 37.405           | 0,68                |
| Hamburg.de               | 54            | 69.561           | 58.984           | 0,85                |
| Stuttgart.de             | 42            | 119.827          | 45.424           | 0,38                |
| Koeln.de                 | 40            | 45.232           | 59.347           | 1,31                |
| Wiesbaden.de             | 40            | 22.731           | 13.610           | 0,60                |
| brand eins               | 32            | 12.565           | 9.528            | 0,76                |
| Sozialpolitik.com        | 15            | 25.596           | 9.724            | 0,38                |
| taz (die tageszeitung)   | 7             | 12.833           | 6.415            | 0,50                |
| <b>Gesamt (Rohdaten)</b> | <b>1.438</b>  | <b>1.874.500</b> | <b>1.434.733</b> | <b>0,77</b>         |

Insgesamt umfasst der Rohdatenbestand rund 1,87 Millionen Tokens in der Ausgangssprache und rund 1,43 Millionen Tokens in Leichter Sprache (gemessen mit dem Tokenisierer `cl100k_base`, insgesamt über 3,30 Millionen Tokens). Wie die Token-Ratios in Tabelle 1 verdeutlichen, unterscheidet sich das Längenverhalten zwischen den Quellen erheblich: Während journalistische, gesundheitsbezogene und politische Quellen (MDR, Sozialpolitik, Stuttgart, Apotheken Umschau) stark komprimieren (Ratio  $\approx 0,38$  bis  $0,57$ ), weisen kommunale Quellen (Hannover mit 1,01, Köln mit 1,31) ausgeglichene oder expandierende Längenverhältnisse auf.

Diese deutliche Diskrepanz in der Token-Ratio spiegelt wider, wie unterschiedlich das Regelwerk und das Zielbild von Leichter Sprache in der Praxis interpretiert und redaktionell umgesetzt werden. Während im nachrichtlichen und

journalistischen Kontext die radikale inhaltliche Reduktion sowie Verdichtung auf Kernbotschaften im Vordergrund stehen, verfolgen insbesondere behördliche und kommunale Portale einen explizierenden Ansatz. Hierbei wird versucht, die vollständige administrative Information beizubehalten, wodurch kurze Fachbegriffe, formale Abläufe und juristische Sachverhalte durch detaillierte, mehrsätzliche Erläuterungen und Kontextbeschreibungen aufgeschlüsselt werden. Die Token-Ratio verdeutlicht somit nicht nur statistische Längenunterschiede, sondern illustriert die Bandbreite zwischen inhaltsfilternder Zusammenfassung und vollumfänglicher syntaktisch-semantischer Erläuterung im Spektrum der Leichten Sprache.

Gleichzeitig weist der Rohdatenbestand noch erhebliche Qualitätsunterschiede auf, da fehlerhafte Verlinkungen, leere Teaser-Seiten sowie verbleibendes Web-Boilerplate enthalten sind. Die nachfolgenden Abschnitte beschreiben daher die methodischen Schritte zur Vorverarbeitung, Qualitätssicherung und empirischen Korpusevaluation.

## 4.2 Datenbereinigung & Normalisierung

Die Rohdaten aus der ersten Pipelinestufe weisen eine erhebliche Heterogenität auf. Da Webseiten primär für menschliche Leser im Webbrowser gestaltet sind, enthalten die extrahierten DOM-Bäume zahlreiche nicht-redaktionelle Fragmente wie Cookie-Banner, Navigationsanweisungen, Bildnachweise, Prüfsiegel und Autorenzeilen. Für das überwachte Training neuronaler Sequenz-zu-Sequenz-Modelle stellen solche Artefakte eine gravierende Fehlerquelle dar: Autoregressive Sprachmodelle neigen dazu, wiederkehrende Web-Floskeln als Scheinkorrelationen zu memorieren und in generierten Übersetzungen als Halluzinationen zu reproduzieren (*Boilerplate Contamination*).

Gleichzeitig nutzen Angebote in Leichter Sprache spezifische typografische Hilfsmittel wie Mediopunkte (·) zur Silbentrennung oder unvollständige Aufzählungslisten, welche moderne Subwort-Tokenisierer zersplittern und die Satzgrenzenerkennung stören. Um diese Störfaktoren systematisch zu eliminieren, wurde ein zweistufiges, regelbasiertes Vorverarbeitungsmodul (`scripts/data_collection/cleaner.py`) entwickelt. Dieses gliedert sich in eine zielgerichtete Web-Boilerplate-Bereinigung, eine typografische Normalisierung sowie eine strukturelle Listen-Transformation.

#### 4.2.1 Web-Boilerplate-Bereinigung & Tag-Punctuation-Guard

Die Beseitigung redaktioneller und web-spezifischer Artefakte erfolgt über ein mehrstufiges Filtersystem, das universelle Bereinigungsmuster mit quellenspezifischen Heuristiken kombiniert:

1. **Tag-Punctuation-Guard** (`ensure\_block\_punctuation`): Beim Parsen strukturierter HTML-Dokumente werden Absätze (`<p>`), Überschriften (`<h1>`–`<h6>`), Listenelemente (`<li>`) und Container (`<div>`) als isolierte Textblöcke extrahiert. Häufig enden Überschriften oder Aufzählungspunkte im HTML-Quelltext ohne abschließende Interpunktion. Werden diese Blöcke unkorrigiert zusammengefügt, verschmelzen aufeinanderfolgende Sätze zu ungrammatischen Satzmonstern (z. B. »Informationen zur Beantragung Sie benötigen folgende Unterlagen«). Der *Tag-Punctuation-Guard* prüft das letzte Zeichen jedes extrahierten Textblocks und setzt deterministisch einen Punkt (.), falls kein valides Satzzeichen (., !, ?, :) vorliegt. Am Blockende stehende Kommata oder Semikola werden in Punkte überführt. Diese Absicherung erwies sich für das spätere Modelltraining als essenziell: Vortests zeigten, dass neuronale Übersetzer bei unsauberen Blockgrenzen dazu neigen, Satzabschlüsse in Leichter Sprache unvollständig offen zu lassen (kein terminaler Satzpunkt) oder Sätze fehlerhaft mit doppelten Punkten (..) zu beenden. Durch die Satzzeichengarantie lernt das Modell stattdessen saubere und grammatisch geschlossene Satzstrukturen.
2. **Universelle Boilerplate-Klassen:** Anhand einer empirischen Analyse des Gesamtkorpus wurden sechs distinkte Klassen von Web-Artefakten definiert und über reguläre Ausdrücke automatisiert entfernt:
  - *Navigation & Link-Verweise:* Phrasen wie »Hier erfahren Sie mehr«, »Klicken Sie hier«, »Mehr Informationen in Alltagssprache«, Hyperlinks sowie Datumsangaben des Seitenabrufs (`https://...`, (`Abgerufenam...`)).
  - *Frageketten & interaktive Suchwerkzeuge:* Standardisierte Teaser-Fragen und Web-Tool-Prompts (z. B. »Wo finde ich weitere Informationen?«, »Unser Tool durchsucht unsere Artikel«, »Ihre Frage wird nicht gespeichert«).

- *Disclaimer & Link-Warnungen*: Hinweistexte beim Verlassen geschützter Sprachbereiche (z. B. »Achtung: Dieser Link führt aus unserem Einfache-Sprache-Angebot heraus. Die Informationen sind dann nicht mehr in Leichter Sprache«).
- *Credits, Übersetzer- & Prüfstellennachweise*: Signaturen von Übersetzungsbüros, Prüfgruppen und Illustratorinnen (z. B. »Forschungsstelle Leichte Sprache«, »Büro für Leichte Sprache«, »Stefan Albers«, »European Easy-to-Read Logo«, »Inclusion Europe«).
- *Kicker- & Dachzeilen-Präfixe*: Führende Rubriken und Ortsmarken am Textanfang (z. B. »Sachsen-Anhalt:«, »Mitteldeutschland:«, »in Leichter Sprache Ticker:«, »Glossar:«).
- *Regionale & Layout-Artefakte*: Technische und bildbezogene Floskeln (z. B. »Icon für die Mobilversion«, »Von der Straße aus fotografiert«, »MEHR ANZEIGEN«).

### 3. **Quellenspezifische Bereinigungsfilter** (`clean\_source\_specific`):

Da jede der 11 Webquellen individuelle redaktionelle Templates nutzt, wurden maßgeschneiderte Filter implementiert. Beim *MDR* wird der standardisierte Rückverweis »Über dieses Thema berichtet der MDR auch in schwerer Sprache...« am Artikelende entfernt; bei der *Apotheken Umschau* werden medizinische Haftungsausschlüsse (»Achtung: In diesem Text finden Sie nur allgemeine Informationen...«) und Suchassistenten bereinigt; bei *brand eins* werden führende Datums- und Autorenstempel (»Januar 2024. Max Mustermann«) abgeschnitten.

## 4.2.2 **Typografische Normalisierung & Listen-Transformation**

Neben Web-Boilerplate erfordern typografische Eigenheiten und barrierefreie Layout-Elemente eine gezielte Harmonisierung:

- **Mediopunkt-Normalisierung**: In Webtexten der Leichten Sprache werden Mediopunkte (·) oder Binnenpunkte (•) von Redaktionen häufig fälschlicherweise als visuelle Ersatz-Aufzählungspunkte innerhalb von Fließtextabsätzen verwendet, anstatt semantisch saubere HTML-Listenelemente (`<li>`) einzusetzen. Dies führt zu erheblichen strukturellen Inkonsistenzen: Ein generatives Übersetzungsmodell soll die linguistische Übertragung lernen, jedoch keine visuellen Layout-Heuristiken oder typografischen

Pseudolisten im Fließtext reproduzieren, da die optische Gliederung auf Dokumenten- und Anwendungsebene über semantisches Markup gesteuert werden muss. Zudem kollidiert die Verwendung als Listen-Separator direkt mit der eigentlichen linguistischen Funktion des Mediopunkts als morphologischem Silbentrenner für lange Komposita (z. B. *Wohn·geld·an·trag*) (Bredel und Maaß, 2016; Maaß, 2020). Um diesen strukturellen Konflikt aufzulösen, eine konsistente Textrepräsentation zu garantieren und zu verhindern, dass das Modell fehlerhafte Pseudo-Formatierungen memoriert, werden Mediopunkte im Normalisierungsschritt deterministisch bereinigt.

- **Satzzeichen-Harmonisierung:** Durch das Entfernen von Links, Klammerzusätzen und Listensymbolen entstehen häufig fehlerhafte Satzzeichenkombinationen. Mehrfache Punkte (`...`) werden auf einfache Satzpunkte reduziert; Kombinationen wie `...`, `;` oder `..;` werden typografisch aufgelöst. Zudem werden fehlende Leerzeichen nach Punkten vor nachfolgenden Großbuchstaben automatisch eingefügt (`re.sub(r'([a-z0-9])\.([A-Z])', r'\1.\2')`), um Satzgrenzen für Sentence-Splitter eindeutig erkennbar zu machen.
- **Listen- und Bullet-Point-Transformation** (`convert\_bullets\_and\_lists`): Artikel in Leichter Sprache verwenden exzessiv vertikale Aufzählungslisten mit Bullet-Points (•) oder Asterisks (\*). Werden diese ungefiltert in Fließtext umgewandelt, entstehen unvollständige Satzfragmente. Die Routine transformiert Listensymbole kontextsensitiv: Führt ein Doppelpunkt in eine Liste (`»: •«`), wird der Doppelpunkt beibehalten und das Aufzählungszeichen entfernt. Steht ein Aufzählungspunkt vor einer Konjunktion (`»• und«`, `»• oder«`, `»• sowie«`), wird der Aufzählungspunkt durch ein Leerzeichen ersetzt. Zwischen rein nominalen Aufzählungselementen werden Bullets in standardisierte Kommata überführt (`• → ,`).
- **Inhaltsverzeichnis-Bereinigung & Frage-Antwort-Erhaltung** (`remove\_toc\_question\_streaks`): Ein zentrales didaktisches Leitprinzip der Leichten Sprache ist die Untergliederung von Texten in überschaubare Sinnabschnitte, wobei Zwischenüberschriften bevorzugt als konkrete W-Fragen formuliert werden (`»Was ist ...?«`, `»Wer kann teilnehmen?«`), auf die unmittelbar der erklärende Antwortabsatz folgt (Bredel und Maaß, 2016; Maaß, 2020). Auf Webseiten (insbesondere der *Apotheken Umschau* und

der *Stadt Hannover*) stellen Redaktionen dem Artikel häufig ein Inhaltsverzeichnis mit internen Sprungmarken-Links voran. Beim unstrukturierten HTML-Scraping werden diese Navigationslisten als Ketten von 4 bis 8 aufeinanderfolgenden Fragen unmittelbar vor die erste Zwischenüberschrift extrahiert. Die Bereinigungsroutine analysiert einleitende Fragesequenzen und schneidet die führende TOC-Linkliste deterministisch ab. Entscheidend ist hierbei die strukturelle Selektion: Die unmittelbar vor dem ersten Erklärsatz stehende Frage wird als legitime Zwischenüberschrift erhalten, ebenso wie alle nachfolgenden Zwischenüberschriften im Fließtext. Strikte Selektionskriterien stellen zudem sicher, dass reguläre Inhaltslisten (z. B. medizinische Symptom- oder Verhaltensaufzählungen ohne interne Anker-Links) vollständig im Fließtext verbleiben.

#### 4.2.3 Quantitative Korpusevaluation: Pipeline-Funnel & Retention

Die konsolidierte Bereinigungs- und Normalisierungs-Pipeline reduziert das akquirierte Rohkorpus zielgerichtet, indem redundante URL-Klone dedupliziert, extreme Längenverhältnis-Ausreißer ( $LS/AS < 0,20$  oder  $LS/AS > 4,00$ ) ausgeschlossen und Textfragmente mit weniger als 30 Wörtern verworfen werden. Tabelle 2 fasst die quantitativen Veränderungen von Stufe 1 (Rohdaten) zu Stufe 2 (Bereinigt & Normalisiert) nach Quellen zusammen.

Insgesamt verbleiben nach der Bereinigung und Klon-Deduplikation 830 qualitätsgesicherte Artikelpaare mit rund 1,83 Millionen BPE-Tokens (1,12 Millionen AS-Tokens und 711.524 LS-Tokens, gemessen mit dem BPE-Tokenisierer `c1100k_base`, was rund 896.535 linguistischen Wörtern entspricht: 516.460 in AS und 380.075 in LS). Die scheinbar niedrige Retention bei *Hannover.de* (28,5 %) resultiert aus einer deterministischen Klon-Bereinigung: Im Rohkorpus verlinkten hunderte behördliche Einzelseiten auf identische allgemeine Dienstleistungsbeschreibungen der Stadtverwaltung. Durch die exakte Duplikaterkennung wurden 549 redundante Klone eliminiert, wodurch eine massive Übergewichtung administrativer Standardfloskeln im Trainingskorpus verhindert wurde. Bei redaktionell diversifizierten Quellen wie dem *MDR* (99,1 %), *Koeln.de* (95,0 %) und der *Apotheken Umschau* (95,0 %) liegt die Beibehaltungsrate hingegen bei über 90 %.

Tabelle 2: Übersicht des Pipeline-Funnels von Stufe 1 (Rohdaten) zu Stufe 2 (Bereinigt & Normalisiert) nach Quellen.

| Quelle                  | Artikelpaare |            |             |               | Tokens (Bereinigt) |                |
|-------------------------|--------------|------------|-------------|---------------|--------------------|----------------|
|                         | Roh          | Clean      | $\Delta$    | Retention     | AS                 | LS             |
| Hannover.de             | 768          | 219        | -549        | 28,5 %        | 406.840            | 281.332        |
| MDR Nachrichten         | 221          | 219        | -2          | 99,1 %        | 232.855            | 101.996        |
| Apotheken Umschau       | 161          | 153        | -8          | 95,0 %        | 424.120            | 240.618        |
| Behindertenbeauftragter | 58           | 48         | -10         | 82,8 %        | 46.182             | 31.420         |
| Hamburg.de              | 54           | 45         | -9          | 83,3 %        | 58.410             | 50.115         |
| Stuttgart.de            | 42           | 35         | -7          | 83,3 %        | 99.450             | 38.210         |
| Koeln.de                | 40           | 38         | -2          | 95,0 %        | 43.110             | 56.780         |
| Wiesbaden.de            | 40           | 37         | -3          | 92,5 %        | 21.050             | 12.890         |
| brand eins              | 32           | 19         | -13         | 59,4 %        | 7.820              | 6.120          |
| Sozialpolitik.com       | 15           | 13         | -2          | 86,7 %        | 22.310             | 8.560          |
| taz (die tageszeitung)  | 7            | 4          | -3          | 57,1 %        | 8.233              | 3.483          |
| <b>Gesamt</b>           | <b>1.438</b> | <b>830</b> | <b>-608</b> | <b>57,7 %</b> | <b>1.120.380</b>   | <b>711.524</b> |

#### 4.2.4 Empirische Fallstudien zur Bias- & Halluzinations-Prävention

Die Notwendigkeit dieser zielgerichteten Bereinigungsschritte lässt sich anhand dreier konkreter Modellierungsphänomene belegen, die bei ersten Vortests mit unbereinigten Trainingsdaten auftraten:

1. **Suffix-Boilerplate-Halluzination (Fallbeispiel Hannover):** In den Rohdaten der Stadt Hannover endete ein Großteil aller Webseiten mit der standardisierten Klick-Aufforderung: »Sie interessieren sich für ein bestimmtes Thema? Dann klicken Sie auf ein Feld.« Da Hannover im Rohkorpus mit 768 Artikeln mehr als die Hälfte aller Daten stellte, lernte ein auf unbereinigten Daten trainiertes Seq2Seq-Modell eine starke Scheinkorrelation: Es generierte diesen Satz stereotyp als Schlusselement jeder Übersetzung – vollkommen unabhängig vom Ausgangstext. Wurde dem Modell beispielsweise ein biologischer Fachtext über Haushunde vorgelegt (*»Hunde begleiten den Menschen seit Jahrtausenden...«*), produzierte das unbereinigte Modell:

*»Was sind Hunde? Hunde sind Haustiere. Sie begleiten den Menschen*



*schon seit Jahrtausenden... Mit einem Hund kann man viele Dinge machen. ›Sie interessieren sich für ein bestimmtes Thema? Dann klicken Sie auf ein Feld.<«*

Erst nach der vollständigen Beseitigung dieser Phrase aus dem Trainingsbestand verschwand die Halluzination in den Inferenz-Outputs vollständig und das Modell schloss Übersetzungen inhaltlich adäquat ab.

2. **Präfix-Kicker-Verzerrung (Fallbeispiel MDR):** Die Nachrichtentexte des Mitteldeutschen Rundfunks begannen in den Rohdaten ausnahmslos mit einer vorangestellten Rubriken- oder Bundesland-Kennung (z. B. »Sachsen:«, »Sachsen-Anhalt:«, »Thüringen:«, »Mitteldeutschland:« oder »in Leichter Sprache Ticker:«). Aufgrund der hohen Frequenz dieser Muster im nachrichtlichen Teilkorpus entwickelte das Sprachmodell einen ausgeprägten Präfix-Bias: Es lernte, dass eine valide Vereinfachung zwingend mit dem Wort »Sachsen« oder »Sachsen-Anhalt« als erstem Token beginnen müsse, und setzte diesen Kicker selbst vor überregionale oder allgemeinsprachliche Texte. Durch die Implementierung der Funktion `clean\_header\_kicker()` wurden diese Dachzeilen vor dem Modelltraining eliminiert, wodurch der Präfix-Bias nachhaltig behoben wurde.
3. **Inhaltsverzeichnis- & Fragenketten-Bias (Fallbeispiel Apotheken Umschau & Hannover):** In den Rohdaten der *Apotheken Umschau* wiesen 90,8 % aller Artikel ein führendes Inhaltsverzeichnis aus 4 bis 8 Sprungmarken-Fragen auf (z. B. »*Was ist Baldrian? Wie wirkt Baldrian? Welche Nebenwirkungen kann Baldrian haben? Welche Wechselwirkungen sind möglich? Wer darf Baldrian nicht nehmen? Was ist Baldrian? Baldrian ist eine Heilpflanze...*«). Erste Vortests mit einem auf unbereinigten Daten trainierten SFT-Übersetzer zeigten, dass das Modell diese Verteilung ungefiltert memorisierte: In über 40 % aller Testübersetzungen produzierte das unbereinigte Modell lange, zusammenhangslose Ketten von bis zu 8 aufeinanderfolgenden Fragen, ohne auch nur eine einzige Antwort zu generieren (z. B. bei der Übersetzung juristischer Fachtexte: »*Was ist die Gerichtshilfe? Wie kann ich Hilfe bekommen? Was passiert bei Straftaten? Was sind die Aufgaben von den Gerichten? Was muss ich beachten? Wer kann mich anrufen? Welche Organisationen können mich unterstützen?*«). Hierdurch wurde das grundlegende didaktische Frage-Antwort-Prinzip vollständig

zerstört und wertvolles Kontextfenster mit Scheinquellen blockiert. Durch die Integration von `remove\_toc\_question\_streaks()` sank der Anteil von  $\geq 5$ -Frageketten bei der *Apotheken Umschau* von 90,8 % auf 3,9 % (wobei die verbleibenden Fälle legitime medizinische Symptom-Checklisten im Textkörper darstellen). Im Ergebnis beginnen 99,3 % aller bereinigten Artikel direkt mit einer sauberen 1:1 Frage-Antwort-Struktur, wodurch das translationale Sprachmodell lernt, Zwischenüberschriften direkt durch substantielle Erklärungen zu beantworten.

Die nachfolgenden Abschnitte dokumentieren die anschließende Qualitätssicherung über semantische Ähnlichkeitseinbettungen sowie die statistische Korpusevaluation.

### 4.3 Quality Assurance & Similarity Sweet-Spot

Während die vorangegangene Vorverarbeitung primär syntaktische und layoutbezogene Web-Artefakte beseitigt, garantiert sie noch keine inhaltliche Konsistenz der alignierten Artikelpaare. Da Web-Crawler Sprachumschalter und Canonical-Links heuristisch abtasten, können fehlerhafte Verlinkungen in den Content-Management-Systemen (CMS) dazu führen, dass inhaltlich völlig divergierende Artikel miteinander verknüpft werden. Ebenso existieren Webseiten, die in beiden Sprachversionen identische Texte ausliefern oder den vereinfachten Text auf einen unvollständigen Einzelsatz reduzieren. Um eine kontaminationsfreie Datenbasis für das nachfolgende Modelltraining sicherzustellen, implementiert die Pipeline eine zweistufige semantische Qualitätssicherung mittels Long-Context-Embeddings und einem empirisch validierten Ähnlichkeitsfilter (`build\_corpus\_master.py`).

#### 4.3.1 Long-Context-Vektorisierung mittels Jina Embeddings v2

Klassische Sentence-BERT-Modelle wie `paraphrase-multilingual-MiniLM-L12-v2` (Reimers und Gurevych, 2019) besitzen eine strikte Sequenzlängenbegrenzung von 128 bis 512 Tokens. Für die Dokumentenebene erweist sich diese Begrenzung als gravierendes Methodenproblem: Im akquirierten Rohkorpus überschreiten über 90 % der Artikel das 128-Token-Fenster und rund 45 % das 512-Token-Limit. Ein Abschneiden (*Truncation*) verzerrt die semantische Ähnlichkeitsmessung jedoch systematisch: Redaktionen der Leichten Sprache nutzen

Einleitungen häufig für Lesehinweise, Begrüßungen oder stark verallgemeinernde Teaser, während die inhaltlich relevanten Sachinformationen erst im weiteren Fließtext dargelegt werden. Wird nur das erste Textdrittel vektorisiert, sinkt die gemessene Ähnlichkeit künstlich ab, obwohl die Dokumente inhaltlich hochgradig parallel sind.

Um dieses Truncation-Artefakt vollständig aufzulösen, setzt die Qualitätssicherung auf das Sprachmodell `jina-embeddings-v2-base-de` (Günther et al., 2023). Das Modell wurde nativ für die deutsche Sprache optimiert und verarbeitet dank linearer Positionsgewichtung (*Attention with Linear Biases*, ALiBi) Eingabesequenzen von bis zu 8.192 Tokens. Dadurch wird gewährleistet, dass selbst umfangreiche behördliche Satzungen oder medizinische Ratgeberartikel zu 100 % in die dichte Vektorrepräsentation einfließen. **In Voranalysen führte die Ausweitung des Kontextfensters von 128 auf 8.192 Tokens über alle 11 Quellen hinweg zu einer konsistenten Stabilisierung der semantischen Scores (z. B. bei der *Apotheken Umschau* von 0,688 auf 0,836 sowie bei *Hamburg.de* von 0,690 auf 0,815), ohne dass künstliche Dichte-Verluste am Textende auftreten.**

#### 4.3.2 Der Similarity Sweet-Spot: Filtration & Grenzdefinition

Auf Basis der generierten 768-dimensionalen Dokumenten-Einbettungen  $\mathbf{u} = \text{Jina(AS)}$  und  $\mathbf{v} = \text{Jina(LS)}$  wird die semantische Ausrichtung über die Kosinus-Ähnlichkeit berechnet:

$$\text{sim}_{\cos}(\mathbf{u}, \mathbf{v}) = \frac{\mathbf{u} \cdot \mathbf{v}}{\|\mathbf{u}\|_2 \|\mathbf{v}\|_2} \quad (5)$$

Zur Bereinigung des Korpus wird ein optimaler Ähnlichkeitskorridor – der sogenannte Similarity Sweet-Spot – definiert, der ausschließlich Artikelpaare im Intervall

$$\mathcal{C}_{\text{SweetSpot}} = \{(\text{AS}, \text{LS}) \mid 0,60 \leq \text{sim}_{\cos}(\mathbf{u}, \mathbf{v}) \leq 0,98\} \quad (6)$$

beibehält. Die Wahl der Schwellenwerte begründet sich aus einer systematischen Fehleranalyse der Randbereiche:

- **Ausschluss der Untergrenze ( $\text{sim}_{\cos} < 0,60$ ):** Werte unterhalb von 0,60 indizieren fast ausnahmslos schwerwiegende Scraping- und Alignment-Fehler. Eine manuelle Inspektion offenbarte drei dominante Fehlerklassen: Erstens *thematische Fehlverlinkungen* (wie in der *Apotheken Umschau*, wo ein Artikel über den »Amsler-Gitter Netzhaut-Check« fälschlich mit

einem Text über »Altersbedingte Makula-Degeneration« verknüpft war;  $\text{sim}_{\text{cos}} = 0,27$ ), zweitens *radikale Teaser-Kürzungen* (wie bei *brand eins*, wo ein mehrseitiger Fachaufsatz auf einen einzigen redaktionellen Satz verkürzt wurde;  $\text{sim}_{\text{cos}} = 0,13$ ) sowie drittens *unvollständige Platzhalterseiten* (wie beim Portal des *Behindertenbeauftragten der Bundesregierung*, bei dem die Leichte-Sprache-Veranstaltungsübersicht mit lateinischem Blindtext (»Lorem ipsum dolor sit amet...«) anstelle der deutschen Übersetzung befüllt war;  $\text{sim}_{\text{cos}} < 0,10$ ). Das Einbeziehen solcher Paare würde dazu führen, dass trainierte Modelle thematischen Drift, Halluzinationen oder verfrühte Generierungsabbrüche memorieren.

- **Ausschluss der Obergrenze ( $\text{sim}_{\text{cos}} > 0,98$ ):** Paare mit extrem hoher Ähnlichkeit ( $\text{sim}_{\text{cos}} > 0,98$  bis 1,00) repräsentieren keine echten intralingualen Übersetzungen, sondern unvollständig gepflegte Webseiten, bei denen der alltagssprachliche Originaltext unverändert in den Leichte-Sprache-Bereich kopiert wurde. Würden diese Dubletten im Trainingsset verbleiben, lernte das Übersetzungsmodell eine triviale Identitätsfunktion ( $LS = AS$ ), was den aktiven Vereinfachungsprozess (Satzteilung, Vokabularreduktion) nachhaltig inhibieren würde.

Ergänzend zu den semantischen Grenzen schließt die Routine Paare mit weniger als 30 Wörtern, Längenverhältnis-Ausreißern ( $LS/AS < 0,20$  oder  $LS/AS > 4,00$ ) sowie verbleibende Platzhaltertexte (»Lorem Ipsum«) deterministisch aus. Die Korrelationsanalyse zwischen dem relativen Längenverhältnis (Token-Ratio) und der berechneten Jina-Ähnlichkeit ergab einen Pearson-Koeffizienten von lediglich  $r = -0,098$ . Dies belegt, dass der definierte Sweet-Spot eine echte semantische Inhaltsprüfung darstellt und nicht durch oberflächliche Textlängen verzerrt wird. Durch diese gezielte Filterung wird das Rauschen im Korpus minimiert, während die thematische und stilistische Vielfalt über alle 11 Domänen hinweg vollständig erhalten bleibt.

#### 4.4 Korpus-Statistiken & Lexikalische Diversität

Nach dem mehrstufigen Scraping, der regelbasierten Bereinigung und der semantischen Sweet-Spot-Filterung liegt ein konsolidiertes, qualitätsgesichertes Parallelkorpus vor. Um die linguistische Eignung dieses Datensatzes für das nachfolgende Training neuronaler Übersetzungs- und Bewertungsmodelle zu eva-

luieren, erfolgt in diesem Abschnitt eine umfassende quantitative und qualitative Korpusanalyse. Diese gliedert sich in die Untersuchung deskriptiver Längen- und Kompressionsmaße, die Analyse der lexikalischen Diversität (TTR vs. MATTR unter Berücksichtigung des Längen-Bias), die empirische Evaluierung des bidirektionalen Entitätenerhalts (NER) sowie die systematische Überprüfung der Regeleinhaltung anhand der amtlichen Richtlinien für Leichte Sprache (Bundesministerium für Arbeit und Soziales, 2018; Deutsches Institut für Normung, 2024; Überwachungsstelle des Bundes für Barrierefreiheit von Informationstechnik, 2026).

#### 4.4.1 Quantitative Korpusmaße & Quellcharakteristika

Das finale, qualitätsgesicherte Parallelkorpus umfasst insgesamt 830 Artikelpaare aus 11 heterogenen Quellen. Der Gesamtumfang beläuft sich auf 1.120.380 BPE-Tokens (entsprechend 516.460 linguistischen Wörtern) in der Ausgangssprache (AS) sowie 711.524 BPE-Tokens (380.075 Wörter) in Leichter Sprache (LS). Im Durchschnitt umfasst ein alltagssprachlicher Artikel 622,2 Wörter (1.349,9 BPE-Tokens), während ein Artikel in Leichter Sprache im Mittel 457,9 Wörter (857,3 BPE-Tokens) aufweist. Tabelle 3 fasst die zentralen statistischen Kennzahlen nach Quellen zusammen.

Tabelle 3: Übersicht der quantitativen Korpusstatistiken des bereinigten Master-Datensatzes ( $N = 830$ ).

| Quelle                  | Artikel-paare | Wörter (AS)    | Wörter (LS)    | Tokens (AS)      | Tokens (LS)    | Token-Ratio (LS/AS) |
|-------------------------|---------------|----------------|----------------|------------------|----------------|---------------------|
| Hannover.de             | 219           | 111.060        | 116.274        | 238.084          | 206.790        | 1,07                |
| MDR Nachrichten         | 219           | 108.958        | 54.918         | 231.294          | 101.610        | 0,49                |
| Apotheken Umschau       | 153           | 177.941        | 105.268        | 390.983          | 209.005        | 0,70                |
| Behindertenbeauftragter | 48            | 17.401         | 17.494         | 38.491           | 34.879         | 1,00                |
| Hamburg.de              | 45            | 21.057         | 19.844         | 45.687           | 35.895         | 1,05                |
| Koeln.de                | 38            | 20.607         | 28.660         | 43.580           | 52.916         | 1,42                |
| Wiesbaden.de            | 37            | 9.067          | 6.670          | 20.373           | 12.839         | 0,72                |
| Stuttgart.de            | 35            | 32.034         | 20.737         | 74.516           | 39.515         | 0,89                |
| brand eins              | 19            | 3.601          | 3.596          | 7.635            | 5.953          | 0,78                |
| Sozialpolitik.com       | 13            | 10.392         | 4.727          | 21.437           | 8.744          | 0,42                |
| taz (die tageszeitung)  | 4             | 4.342          | 1.887          | 8.300            | 3.378          | 0,55                |
| <b>Gesamt</b>           | <b>830</b>    | <b>516.460</b> | <b>380.075</b> | <b>1.120.380</b> | <b>711.524</b> | <b>0,64</b>         |

Wie die aggregierten Längenverhältnisse ( $\text{Ratio}_{\text{BPE}} = 0,635$  bzw.  $\text{Ratio}_{\text{Wort}} =$

0,736) verdeutlichen, unterscheidet sich das Längenverhalten zwischen den 11 Domänen signifikant. Die Analyse offenbart die Koexistenz zweier distinkter redaktioneller Übersetzungskonzepte:

**1. Inhaltsfilternde Verdichtung (Nachrichten- & Fachjournalismus):**

Quellen wie *Sozialpolitik.com* (Ratio = 0,42), der *MDR* (0,49), die *taz* (0,55) sowie die *Apotheken Umschau* (0,70) praktizieren eine rigorose Selektion. Nebeninformationen, historische Exkurse und komplexe Ausschweifungen werden eliminiert, um die Kernbotschaft auf elementare Aussagen zu verdichten.

**2. Explikative Expansion (Kommunal- & Behördenverwaltung):**

Kommunale Angebote wie *Koeln.de* (Ratio = 1,42), *Hannover.de* (1,07) und *Hamburg.de* (1,05) weisen hingegen ausgeglichene oder expandierende Umfänge auf. Um juristische und administrative Vorgänge (z. B. Beantragung eines Personalausweises oder Wohngeldes) für Menschen mit Lernschwierigkeiten barrierefrei verständlich zu machen, werden formale Fachtermini nicht ersatzlos gestrichen, sondern durch mehrsätzliche Schritt-für-Schritt-Anleitungen und Begriffsdefinitionen ausführlich expliziert.

Die hohe mittlere semantische Kosinus-Ähnlichkeit von  $\bar{\text{sim}}_{\text{cos}} = 0,836 \pm 0,074$  (gemessen mit dem Long-Context-Modell *jina-embeddings-v2-base-de*) belegt, dass die inhaltliche Kernaussage trotz dieser methodisch unterschiedlichen Übersetzungsstrategien über alle Quellen hinweg hochgradig stabil bleibt.

#### **4.4.2 Lexikalische Diversität: TTR vs. MATTR & Längen-Bias**

Die klassische Type-Token-Ratio (TTR), definiert als das Verhältnis der Worttypen  $|V|$  zur Gesamtwortzahl  $N$  ( $\text{TTR} = |V|/N$ ), ist für den Vergleich von Alltagssprache und Leichter Sprache ungeeignet. Nach *Herdan's Law* wächst das Vokabular mit zunehmender Textlänge degressiv an, wodurch längere Texte mathematisch bedingt eine niedrigere TTR aufweisen. Da sich alltagssprachliche und vereinfachte Texte in ihrer Länge systematisch unterscheiden, verzerrt die Standard-TTR den linguistischen Vergleich.

Um die lexikalische Diversität längenunabhängig zu messen, wird die Moving-Average Type-Token-Ratio (MATTR) mit einem festen Fenster von  $W = 50$

Wörtern genutzt:

$$\text{MATTR}_W = \frac{1}{N - W + 1} \sum_{i=1}^{N-W+1} \frac{|V_{i,W}|}{W} \quad (7)$$




Abbildung 1: Lexikalische Diversität: Längenunabhängigkeit der MATTR ( $W = 50$ ) (links) sowie quellenweiser Vergleich zwischen Alltagssprache (AS) und Leichter Sprache (LS) (rechts).

Wie Abbildung 1 zeigt, verläuft die MATTR im Gegensatz zur TTR vollkommen invariant gegenüber der Textlänge. Im Gesamtkorpus sinkt die MATTR von  $0,782 \pm 0,041$  (AS) signifikant auf  $0,681 \pm 0,047$  in Leichter Sprache ( $\Delta\text{MATTR} = 0,100 \pm 0,051$ ,  $t = 56,208$ ,  $p = 5,084 \cdot 10^{-285}$ ). Dies belegt empirisch die bewusste Beschränkung auf ein reduziertes, wiederkehrendes Grundvokabular in Leichter Sprache (Bredel und Maaß, 2016; Maaß, 2020).

#### 4.4.3 Faktenerhalt vs. Faktentreue: Grenzen von NER als Metrik

In der allgemeinen maschinellen Übersetzung (MT) und Textzusammenfassung wird die Named Entity Recognition (NER) häufig eingesetzt, um die Faktentreue von Modellgenerierungen automatisiert zu evaluieren (Devaraj et al., 2021). Hierbei wird unterstellt, dass ein hochwertiges Modell alle Eigennamen (Personen, Orte, Organisationen, Fachbegriffe) aus dem Quelltext verlustfrei in die Zielsequenz übernehmen muss.

Um zu untersuchen, inwiefern dieses Paradigma auf die Leichte Sprache übertragbar ist, wird eine bidirektionale Entitätenanalyse mittels des vortrainierten Sprachmodells `spaCy` (`de_core_news_lg`) durchgeführt. Für jedes Artikelpaar werden die Entitätenmengen  $E_{AS}$  und  $E_{LS}$  extrahiert und in zwei komplementäre Richtungen evaluiert:

1. **Faktenerhalt ( $\text{Recall}_{\text{AS} \rightarrow \text{LS}}$ ):** Anteil der im alltagssprachlichen Original genannten Entitäten, der in der vereinfachten Fassung beibehalten wird:

$$\text{Recall}_{\text{AS} \rightarrow \text{LS}} = \frac{|E_{\text{AS}} \cap E_{\text{LS}}|}{|E_{\text{AS}}|} \quad (8)$$

2. **Faktentreue ( $\text{Recall}_{\text{LS} \rightarrow \text{AS}}$ ):** Anteil der in Leichter Sprache verwendeten Entitäten, der im Originaltext verankert ist:

$$\text{Recall}_{\text{LS} \rightarrow \text{AS}} = \frac{|E_{\text{AS}} \cap E_{\text{LS}}|}{|E_{\text{LS}}|} \quad (9)$$




Abbildung 2: Bidirektionaler NER-Recall nach Quellen: Gegenüberstellung von Faktenerhalt ( $\text{AS} \rightarrow \text{LS}$ , blau) und Faktentreue ( $\text{LS} \rightarrow \text{AS}$ , orange).

**Empirische Befunde des NER-Vergleichs:** Wie Abbildung 2 visualisiert, fallen die Überlappungsraten in beiden Richtungen bemerkenswert gering aus:

- Der mittlere Faktenerhalt ( $\text{AS} \rightarrow \text{LS}$ ) liegt im Gesamtkorpus bei lediglich  $20,2\% \pm 18,9\%$  (Median  $15,8\%$ , Q1  $7,3\%$ , Q3  $27,7\%$ ).
- Die Faktentreue ( $\text{LS} \rightarrow \text{AS}$ ) erreicht einen signifikant höheren Wert von  $32,2\% \pm 24,4\%$  (Median  $28,6\%$ , Q1  $14,3\%$ , Q3  $47,0\%$ ; gepaarter t-Test:  $t = -14,057$ ,  $p = 2,057 \cdot 10^{-40}$ ; Wilcoxon-Test:  $W = 48952,5$ ,  $p = 2,480 \cdot 10^{-45}$ ).
- Die Gesamtzahl der Entitäten sinkt von **18.901** in AS ( $\emptyset 22,77$  pro Text) auf **11.210** in LS ( $\emptyset 13,51$  pro Text), was einer absoluten Entitäten-Kompression um  $40,7\%$  entspricht.



Die geringen Überlappungswerte von 20 % bis 32 % sind jedoch kein Beleg für Informationsverluste, sondern spiegeln die linguistische Natur der Leichten Sprache wider: Komplexe Eigennamen und Fachbehörden werden regelkonform durch verständliche Gattungsbegriffe paraphrasiert (z. B. »*Bundesagentur für Arbeit*« → »*Amt für Arbeit*«), während periphere Nebenangaben bewusst getilgt werden (Bundesministerium für Arbeit und Soziales, 2018). Da der NER-Parser umschriebene Begriffe nicht mehr als Entitäten erfasst, eignet sich der NER-Recall nicht als Evaluierungs- oder Reward-Metrik – eine Optimierung darauf würde Modelle dazu verleiten, schwer verständliche Fachbegriffe unreflektiert im Wortlaut zu kopieren. Trotz der niedrigen NER-Wortüberlappung bleibt die globale semantische Ähnlichkeit mit  $\bar{\text{sim}}_{\text{cos}} = 0,836$  hoch, weshalb für die spätere Modellsteuerung auf dichte semantische Repräsentationen und das Regressionsmodell gesetzt wird.

#### 4.4.4 Regeleinhaltung nach BMAS-Richtlinien

Um objektiv zu überprüfen, inwiefern die 11 Datenquellen die normativen Richtlinien für Leichte Sprache in der Praxis umsetzen, wurden die amtlichen Vorgaben des Bundesministeriums für Arbeit und Soziales (\*„Leichte Sprache: Ein Ratgeber“\*, Bundesministerium für Arbeit und Soziales (2018)), der BITV 2.0 (Überwachungsstelle des Bundes für Barrierefreiheit von Informationstechnik, 2026) sowie der DIN 8581-1 (Deutsches Institut für Normung, 2024) über einen automatisierten linguistischen Parser (\*Rule Auditor\*) operationalisiert. Abbildung 3 stellt die empirischen Messwerte für vier fundamentale Dimensionen der Sprachvereinfachung dar.

**1. Satzlängen-Begrenzung (Regel BMAS S. 20 / Syntax):** Die Richtlinien fordern kurze, überschaubare Hauptsätze mit einem Richtwert von maximal 8 bis 10 Wörtern pro Satz. Wie Abbildung 3 (oben links) demonstriert, erfüllen alle 11 Quellen dieses Kriterium in Leichter Sprache vorbildlich: Die mittleren Satzlängen sinken von bis zu **17,2** Wörtern in der Alltagssprache auf einen stabilen Bereich zwischen 6,7 und 8,2 Wörtern in Leichter Sprache (Gesamtreduktion um durchschnittlich **-45,4 %**).

**2. Genitiv-Vermeidung (Regel BMAS S. 32 / Grammatik):** Der 2. Fall (Genitiv) gilt als grammatikalisch schwer verständlich und soll durch Dativkonstruktionen mit der Präposition *von* ersetzt werden. Die empirische Analyse




Abbildung 3: Empirische Überprüfung der linguistischen Regel-Adhärenz über alle 11 Korpusquellen: Gegenüberstellung von Ausgangstext (AS, blau) und Leichter Sprache (LS, grün) für Satzlänge, Genitiv-Quote, Passiv-Dichte und Wiener Sachtextformel (WSTF).

(Abbildung 3 oben rechts) zeigt eine extrem disziplinierte Regeleinhaltung: Kommunale Portale (\*Hamburg.de\*, \*Koeln.de\*, \*Hannover.de\*) und Rundfunkanstalten (\*MDR\*) reduzieren Genitivkonstruktionen um **86,5 %** bis **92,1 %**. Lediglich Fachportale wie die \*Apotheken Umschau\* behalten feste Genitiv-Attribute in medizinischen Eigennamen häufiger bei.

**3. Passiv-Vermeidung & Handlungsbezug (Regel BMAS S. 30 / Grammatik):** Leichte Sprache verlangt handlungsorientierte Aktivsätze mit klarem Subjekt, um Verantwortlichkeiten transparent zu machen. Während Verbände (\*Sozialpolitik.com\* mit **-84,9 %**) und Kommunen (\*Hamburg.de\* mit **-60,4 %**) Passivstrukturen konsequent in Aktivsätze umwandeln, offenbart die Analyse ein redaktionelles Dilemma im Journalismus: Beim \*MDR\* verbleibt die Passiv-Reduktion bei lediglich **-2,6 %**, da das unpersönliche Zustandspassiv („*Am Dienstag wurde beschlossen...*“) als redaktionelles Standardmuster tief verankert ist und von journalistischen Redaktionen nicht vollständig aufgelöst wird.

**4. Wiener Sachtextformel (WSTF):** Die Wiener Sachtextformel (Bamberger und Vanecek, 1984) quantifiziert die textuelle Lesbarkeit anhand von Wort- und Satzstrukturen. Wie Abbildung 3 (unten rechts) veranschaulicht, sinkt der WSTF-Wert im Korpus signifikant von durchschnittlich **11,28 ± 2,67** (Gymnasialniveau) auf **6,82 ± 1,99** in Leichter Sprache, was einer Reduktion um **4,46** Schulstufen in den angestrebten Zielkorridor entspricht.

#### 4.4.5 Synthese der Korpuseigenschaften

Die quantitative und qualitative Korpusanalyse belegt, dass der bereinigte Sweet-Spot-Datensatz ( $N = 830$ ) die formalen und inhaltlichen Kriterien der Leichten Sprache in hoher Güte erfüllt. Gleichzeitig verdeutlichen die empirischen Unterschiede bei der Regeleinhaltung – wie bereits einleitend in Abschnitt 4.1 sowie bei den Längenverhältnissen dargelegt –, wie unterschiedlich das Regelwerk in der Praxis interpretiert und redaktionell umgesetzt wird: Während nachrichtliche Medien den Fokus auf radikale inhaltliche Kompression legen und dabei etablierte redaktionelle Muster wie das Zustandspassiv teilweise beibehalten, priorisieren behördliche Angebote die informationelle Vollständigkeit durch explizierende Beschreibungen.

Diese redaktionelle Heterogenität unterstreicht die fundamentale methodische Schwierigkeit der automatischen Textvereinfachung (ATS): Es existiert kein starres, homogenes Zielbild, sondern ein breites Spektrum legitimer sprachlicher Vereinfachungsstrategien. Das im Rahmen dieser Arbeit erstellte Multidomänen-Korpus bildet diese reale stilistische Vielfalt systematisch ab. Durch die Kombination aus Längenbereinigung (MATTR), semantischer Sweet-Spot-Filterung und empirisch evaluierter Regeladhärenz schafft es eine verlässliche Datengrundlage für das nachfolgende Training neuronaler Regressionsmetriken (Kapitel 5.1) sowie für die generative Übersetzung.

## 5 Themenblock 2: Metrik & Bewerten von Sprachkomplexität

Die automatisierte, referenzfreie Bewertung von Sprachkomplexität stellt eine Kernkomponente dieser Arbeit dar. Um Texte in Leichter Sprache objektiv zu bewerten und ein steuerbares Belohnungssignal (*Reward*) für das spätere Modelltraining bereitzustellen, wird in diesem Themenblock eine eigene Metrik-Pipeline entwickelt und systematisch untersucht.

### 5.1 Vorstufe: Binäre Klassifikation als Machbarkeitsnachweis & Architektur-Baseline

Die Entwicklung einer automatisierten, referenzfreien Komplexitätsmetrik stellt eine der zentralen methodischen Voraussetzungen dieser Arbeit dar. Bevor ein generatives Sprachmodell über überwachtes Feintuning (SFT) oder Präferenzoptimierung (DPO) zur zielgerichteten Vereinfachung angeleitet werden kann, muss eine Instanz geschaffen werden, die den Grad sprachlicher Simplität objektiv, quantifizierbar und reproduzierbar bewertet.

#### 5.1.1 Motivation, Lesbarkeitsmetriken & BiLSTM-Architektur

Klassische lesbarkeitsmetrische Ansätze wie der *Flesch Reading Ease* (Amstad, 1978) oder die *Wiener Sachtextformel* (Bamberger und Vanecek, 1984) basieren primär auf einfachen Oberflächenstatistiken wie der mittleren Silbenanzahl oder Satzlänge. Zwar bieten diese deterministischen Heuristiken eine etablierte, recheneffiziente Basis zur groben Abschätzung allgemeiner Textschwierigkeit, sie stoßen jedoch bei der spezifischen Bewertung von Leichter Sprache an konzeptionelle Grenzen: Da sie für allgemeine Lesbarkeitsstufen im Bildungswesen konzipiert wurden, haben sie die spezifischen, normierten Regeln der Leichten Sprache (DIN EN ISO 24495-1 bzw. Duden Leichte Sprache) nie gelernt. Weder syntaktische Kernanforderungen wie die Vermeidung von Passivkonstruktionen und Genitiven, die Auflösung von Nebensatzgefügen in parataktische Hauptsätze noch morphologische Besonderheiten wie Bindestrich-Kopplungen bei Komposita (z. B. »*Werkstatt-Vertrag*«) werden von reinen Silbenzählern adäquat erfasst (Bredel und Maaß, 2016; Maaß, 2020). Zudem liefern starre Formeln keine stetig differenzierbaren Gradienten, wie sie für das Reinforcement Learning (Reward

Modeling) unerlässlich sind.

Genau diese Forschungslücke soll in dieser Arbeit durch einen datengetriebenen, neuronalen Modellierungsansatz geschlossen werden: Anstatt starre Zählheuristiken vorauszusetzen, erlernen neuronale Sprachmodelle die authentischen syntaktischen, morphologischen und lexikalischen Muster Leichter Sprache direkt aus bereinigten Parallelkorpora. Das binäre Klassifikationsproblem dient hierbei als notwendiger Machbarkeitsnachweis (*Proof of Concept*) und Architektur-Baseline für das neuronale Backbone: *Ist ein rekurrentes Sprachmodell in der Lage, anhand der vorliegenden linguistischen Signale trennscharf zwischen alltagssprachlichen Ausgangstexten (AS,  $y = 0$ ) und vereinfachten Fassungen in Leichter Sprache (LS,  $y = 1$ ) zu diskriminieren?*

Als Modellarchitektur wird ein Bidirektionales Long Short-Term Memory (BiLSTM) (Hochreiter und Schmidhuber, 1997; Schuster und Paliwal, 1997) eingesetzt. Rekurrente Netze mit Gating-Mechanismen eignen sich in besonderem Maße für die Modellierung sprachlicher Simplizität, da sie Wortabfolgen sequenziell verarbeiten und gleichzeitig syntaktische Langzeitabhängigkeiten über variable Textlängen hinweg aufrechterhalten können:

- **Tokenisierung & Embedding:** Eingabetexte werden mit dem deutschen spaCy-Modell (`de_core_news_sm`) tokenisiert. Seltene Wörter außerhalb des Vokabulars ( $V \approx 20.000$  bis  $25.000$  Tokens) werden als `<unk>` maskiert. Eine Einbettungsschicht projiziert jedes Token in einen dichten Vektor  $\mathbf{x}_t \in \mathbb{R}^{128}$ .
- **Bidirektionale Verarbeitung:** Zwei LSTM-Schichten (Hidden-Dimension  $h = 128$ ) verarbeiten die Sequenz simultan vorwärts ( $\vec{\mathbf{h}}_t$ ) und rückwärts ( $\overleftarrow{\mathbf{h}}_t$ ). Durch Konkatenation entsteht die globale Repräsentation  $\mathbf{h}_{\text{out}} \in \mathbb{R}^{256}$ .
- **Klassifikationskopf & Optimierung:** Nach einem Dropout ( $p = 0,4$ ) transformiert ein linearer Kopf mit Sigmoid-Aktivierung  $\sigma(z)$  die Repräsentation in den Wahrscheinlichkeitsscore  $\hat{y} = P(Y = 1 \mid \mathbf{T}) \in [0,0, 1,0]$ . Das Training erfolgt mittels binärer Kreuzentropie (BCE) und AdamW (Loshchilov und Hutter, 2019) ( $\eta = 1 \times 10^{-3}$ , Weight Decay  $\lambda = 0,01$ , Batch Size  $32$ , Early Stopping).

Auf dem internen Test-Split des Master-Korpus bestätigt das Modell den im vorigen Kapitel ermittelten Sweet-Spot ( $0,80 \leq \text{sim}_{\text{cos}} \leq 0,98$ ): Das BiLSTM

erreicht auf Anhieb eine Balanced Accuracy von 92,99 % auf Satzebene sowie 99,03 % auf Artikelebene (die vollständige In-Domain Sweet-Spot-Ablation ist in Tabelle 10 im Anhang 9.3 dokumentiert). Dies belegt zweifelsfrei die Rauschfreiheit der extrahierten Trainingsdaten und die Eignung des BiLSTM-Backbones zur Erfassung linguistischer Simplitätsmuster.

### 5.1.2 Granularitäts-Ablation: Majority Voting vs. Dilution-Effekt

Zur Bestimmung der optimalen Modellierungs- und Aggregationsebene sowie zur Überprüfung der Out-of-Domain-Generalisierung wurde eine systematische Ablationsstudie auf dem unabhängigen, verifizierten *Lebenshilfe*-Goldstandard ( $N = 37$  Artikelpaare / 74 Dokumente, 6.901 Einzelsätze aus behördlich-juristischen Kontexten) durchgeführt. Untersucht wurden das Satzmodell (isoliert sowie aggregiert via Majority Voting) und direkte Artikel-Klassifikatoren über maximale Kontextlängen von 256, 512 und 1.024 Tokens. Tabelle 4 stellt die Ergebnisse gegenüber klassischen Lesbarkeitsmetriken dar (ergänzende KDE-, ROC- und Konfusionsanalysen finden sich im Anhang 9.3).

Tabelle 4: Benchmark der Klassifikationsmodelle über Granularitätsebenen und Sequenzlängen auf dem Lebenshilfe-Goldstandard ( $N = 37$  Artikelpaare / 74 Dokumente, 6.901 Einzelsätze).

| Modell                               | Ebene / Input              | $\mathcal{O}$ Score (LS) | $\mathcal{O}$ Score (AS) | Separation ( $\Delta$ ) | Balanced Acc   | ROC-AUC       | Pair Match             |
|--------------------------------------|----------------------------|--------------------------|--------------------------|-------------------------|----------------|---------------|------------------------|
| BiLSTM Satz-Klassifikator            | Satzebene ( $N = 6.901$ )  | $0,772 \pm 0,32$         | $0,196 \pm 0,30$         | 0,576                   | 81,68 %        | 0,8963        | –                      |
| BiLSTM Satz-Klassifikator (MajVote)  | Dokument ( $r_{LS}$ Ratio) | $0,769 \pm 0,08$         | $0,127 \pm 0,14$         | 0,642                   | <b>98,65 %</b> | <b>0,9985</b> | <b>100,0 % (37/37)</b> |
| BiLSTM Artikel-Klassifikator (256)   | Dokument (256 Tok.)        | $0,829 \pm 0,31$         | $0,002 \pm 0,01$         | 0,827                   | 91,89 %        | 0,9974        | 97,3 % (36/37)         |
| BiLSTM Artikel-Klassifikator (512)   | Dokument (512 Tok.)        | $0,478 \pm 0,41$         | $0,031 \pm 0,13$         | 0,446                   | 71,62 %        | 0,8809        | 91,9 % (34/37)         |
| BiLSTM Artikel-Klassifikator (1.024) | Dokument (1.024 Tok.)      | $0,340 \pm 0,40$         | $0,007 \pm 0,01$         | 0,333                   | 67,57 %        | 0,8795        | 97,3 % (36/37)         |
| Flesch Reading Ease (Baseline)       | Dokument (Silben/Satz)     | $0,973 \pm 0,16$         | $0,189 \pm 0,39$         | 0,784                   | 89,19 %        | 0,8919        | 100,0 % (37/37)        |
| Wiener Sachtextformel (Baseline)     | Dokument (Wortlänge)       | $0,919 \pm 0,27$         | $0,108 \pm 0,31$         | 0,811                   | 90,54 %        | 0,9054        | 100,0 % (37/37)        |

Die Ergebnisse liefern zwei fundamentale Erkenntnisse:

1. **Das Potenzial von Satzmodell & Majority Voting:** Auf Einzelsatzebene fällt die Performanz mit 81,68 % Balanced Accuracy moderat aus, da isolierte Phrasen (z. B. Überschriften oder Begrüßungen) oft keine distinktiven Simplitätsmarker tragen. Wird das Modell jedoch über die Simple-Sentence-Ratio

$$r_{LS} = \frac{1}{|S|} \sum_{s \in S} \mathbb{I}(\hat{y}_s = 1) \in [0,0,1,0] \quad (10)$$

mittels Majority Voting aggregiert, eliminiert die Mittelung lokale Unsicherheiten nahezu vollständig: Die Balanced Accuracy steigt auf 98,65 %, der ROC-AUC auf 0,9985 und das Paar-Matching erreicht fehlerfreie 100,0 % (37/37).

## 2. Dilution-Effekt & Konfidenz-Asymmetrie bei Artikel-Klassifikatoren:

Im direkten Kontrast dazu erweisen sich direkte Artikel-Klassifikatoren bei langen Sequenzen als hochgradig instabil (91,89 % bei 256 Tokens  $\rightarrow$  67,57 % bei 1.024 Tokens). Die KDE-Analyse (Abbildung 10) deckt eine extreme Asymmetrie auf: Während Alltagssprache mit spitzen Dirac-Peaks bei 0,0 überkonfident erkannt wird ( $\emptyset$ -Score  $\leq 0,031$ ), verwässern neutrale Wörter und Eigennamen die lokalen Simplitätssignale im 1.024-Token-LSTM-Flaschenhals. Der mittlere LS-Score sinkt auf 0,340 ab und unterschreitet die Entscheidungsschwelle  $\tau = 0,50$ , wodurch der LS-Recall drastisch auf 35,14 % einbricht (massiver Anstieg von False Negatives).

**Multi-Seed-Stabilität und Kapazitätsanalyse** Ergänzende Experimente über 5 Seeds (Tabelle 11, Abbildungen 13–14 im Anhang) bestätigen dieses Bild: Während das Satzmodell hochstabil bleibt (97,03 %  $\pm$  0,60 %, 100 % Pair Match), unterliegt der 3,5-Mio.-Parameter Artikel-Klassifikator bei nur 1.440 Texten starker Seed-Varianz ( $\pm 9,33$  %, Spread bis 24,3 %). Eine 80 %-Reduktion der Parameterzahl (10k Vokabeln, Hidden-Dim 64) stabilisiert das Modell signifikant (88,92 %  $\pm$  3,75 %), vermag jedoch den rekurrenten 1.024-Token-Flaschenhals nicht vollständig aufzulösen.

**Einordnung der traditionellen Baselines gegenüber den neuronalen Modellen** Die empirischen Ergebnisse in Tabelle 4 verdeutlichen die Stärken und Grenzen der traditionellen Formeln im Vergleich: Mit einer Balanced Accuracy von 89,19 % (Flesch) bzw. 90,54 % (Wiener Sachtextformel) und einem fehlerfreien Paar-Matching von 100,0 % (37/37) erweisen sich die klassischen Formeln als erstaunlich robuste makroskopische Baselines. Da Texte in Leichter Sprache eine massive Reduktion der mittleren Satz- und Wortlänge aufweisen, schlägt dieser Oberflächeneffekt auf Dokumentebene voll durch. Sie übertreffen damit sogar den direkten 1.024-Token-Artikel-Klassifikator (67,57 %, 35,14 % LS-Recall), welcher durch Datenknappheit und den LSTM-Flaschenhals degradiert. Gegenüber dem hierarchisch aggregierten BiLSTM-Satzmodell ( $r_{LS}$ ) mit 98,65 %



Balanced Accuracy und einem ROC-AUC von 0,9985 offenbaren die Formeln jedoch eine signifikante Schwäche: Ihre Dichteverteilungen (Abbildung 10) weisen eine breite Überlappungszone im Übergangsbereich auf, da sie stilistische und grammatikalische Feinheiten nicht diskriminieren können. Das neuronale Satzmodell schließt diese Lücke und erreicht eine trennscharfe, bimodal separierte Klassifikation ( $\Delta = 0,642$ ).

### 5.1.3 Ausschluss von Längen- und Layout-Biases (Kontrollexperimente)

Da Texte in Leichter Sprache durch inhaltliche Komprimierung meist kürzer sind und andere Absatzstrukturen aufweisen, besteht das theoretische Risiko, dass das BiLSTM lediglich triviale Oberflächenmerkmale (*Spurious Correlations* bzw. Shortcuts) lernt, anstatt echte linguistische Eigenschaften zu erfassen. Um diesen Effekt gezielt auszuschließen, wurden drei Kontrolltests auf dem Lebenshilfe-Datensatz durchgeführt:

- **Dummy-Content-Test (Prüfung auf Längen- und Padding-Bias):** Werden alle Wörter der Testdokumente durch ein einheitliches, neutrales Token (den Punkt ».<« bzw. den Artikel »der«) ersetzt, während die tatsächlichen Sequenzlängen und das Zero-Padding exakt unverändert bleiben ( $\mathbf{T}_{\text{dummy}} = (t_{\text{dummy}}, \dots, t_{\text{dummy}}, \text{PAD}, \dots)$ ), bricht die Balanced Accuracy von 90,82 % auf exakt 50,00 % (reines Zufallsniveau) zusammen. Dies beweist, dass das Modell keine rein längen- oder paddingbasierten Entscheidungsgrenzen nutzt.
- **Festlängen-Slicing (Prüfung auf Längenunabhängigkeit):** Werden alle Dokumente einheitlich auf eine feste Länge von  $L_{\text{fix}} = 100$  Tokens beschnitten, differenziert das BiLSTM weiterhin mit 87,76 % Balanced Accuracy zwischen AS und LS. Eine ergänzende Korrelationsanalyse zwischen Tokenlänge und Vorhersage zeigt zudem keinen signifikanten linearen Zusammenhang ( $r = -0,0089$ ,  $p = 0,9398$ ).
- **Layout-Invarianz (Prüfung auf Formatierungsmerkmale):** Das vollständige Entfernen aller Zeilenumbrüche, Absätze und Formatierungsstrukturen (`lebenshilfe_dataset_no_paragraphs.json`) führt zu 100 % identischen Klassifikationsergebnissen, da der Tokenizer Formatierungs-Whitespace im Vorfeld filtert. Typografische Bindestriche bei Wortkom-

posita (« *Werkstatt-Vertrag*») fungieren hingegen als legitime, vom Modell erfasste morphologische Simplizitätsmarker (Bredel und Maaß, 2016).

#### **5.1.4 Synthese: Erlernbarkeit des Signals & Überleitung zur MixUp-Regression**

Zusammenfassend belegen die Ergebnisse, dass das BiLSTM das linguistische Simplizitätssignal prinzipiell erlernt und Dokumentenpaare verlässlich relativ rankt ( $\text{ROC-AUC} > 0,92$ , Pair-Match bis 97,3 %). Für die Steuerung generativer Modelle erfordert das Fehlen kontinuierlicher Gradienten (Sigmoid-Sättigung) jedoch ein stufenloses Gütesignal  $\lambda \in [0,0,1,0]$ , weshalb die Modellierung im folgenden Abschnitt zur kontinuierlichen MixUp-Regression erweitert wird.

## 5.2 Continuous MixUp Regression

Zu erklären in diesem Abschnitt:

- **[Zu erklären] Das Konzept des textuellen MixUp:** Erzeugung kontinuierlicher Schwierigkeitsgrade  $\lambda \in [0, 0, 1, 0]$  durch satzweise Mischungen paralleler Artikel.
- **[Zu erklären] Dynamische Target-Berechnung:** Gewichtung anhand des relativen Zeichenlängenanteils:

$$\lambda = \frac{\text{CharLen}(LS)}{\text{CharLen}(LS) + \text{CharLen}(AS)} \quad (11)$$

- **[Zu erklären] Vergleich der Trainings- und Dataloader-Varianten:**
  - *Variante A (Statisch):* Feste Vorabmischung des Trainingskorpus.
  - *Variante B (Dynamisch):* On-the-Fly Shuffling (Analyse des *Prediction Collapse*).
  - *Variante C (Hybrid):* Epochenabhängiges Curriculum-Shuffling.
  - *Variante D (Hybrid + Cyclic Learning Rate):* Optimierung mittels *CosineAnnealingWarmRestarts* zur Vermeidung lokaler Minima.
- **[Zu erklären] Kontextlängen-Ablationsstudie:** Empirische Bestimmung der optimalen Eingabesequenzlänge (128, 256, 500, 1000 Tokens).
- **[Zu erklären] Regressions-Metriken:** Mean Squared Error (MSE), Mean Absolute Error (MAE), Pearson- und Spearman-Korrelation sowie KDE-Dichteverteilungsanalysen.

### Einfluss der Trainings- und Sampling-Strategien auf die Regressionsgüte

Bei der methodischen Entwicklung des textuellen MixUp-Trainings wurden vier Dataloader- und Optimierungsstrategien systematisch verglichen: eine feste Vorabmischung des Trainingskorpus (*Variante A*), ein rein dynamisches On-the-Fly-Shuffling in jedem Batch (*Variante B*), ein hybrides Curriculum-Mischen

mit epochenabhängigem Übergang von statischen zu dynamischen Mischungen (*Variante C*) sowie die Kombination aus Hybrid-Mischen und zyklischem Lernratenscheduling mittels *CosineAnnealingWarmRestarts* (*Variante D*).

In frühen Experimenten mit stark begrenzter Datenmenge ( $M = 10$  Mischungen pro Artikelpaar, entsprechend ca. 5.130 Samples) zeigten sich deutliche Unterschiede zwischen den Ansätzen: Die statische Vorabmischung neigte durch die wiederholte Präsentation identischer Satzkombinationen zu Overfitting. Die rein dynamische Variante konvergierte bei wenigen Iterationen ( $N = 513$ ) aufgrund des hohen Gradientenrauschens nur langsam. Die hybride Variante mit zyklischem Scheduler erwies sich in dieser Phase als am stärksten, da sie eine stabile anfängliche Repräsentationsbildung ermöglichte und durch periodische Lernratenanstiege lokalen Minima entkommen konnte.

Wird der Trainingskorpus jedoch voll skaliert—mit einer dichten Stichprobenabdeckung von  $M = 160$  (über 82.000 Mischungen pro Epoche) und ausreichendem Training über 100 Epochen—, gleichen sich die Ergebnisse der vier Ansätze weitgehend an: Durch die große Zahl unterschiedlicher Satzkombinationen konvergieren alle vier Varianten zu einem nahezu identischen, optimalen Leistungsniveau (Val-MSE  $\approx 0,027$ , Test-Balanced-Accuracy  $\approx 96\%$ , vgl. Tabelle 12 im Anhang 9.4). Die Wahl der Dataloader-Strategie ist somit vor allem in datenlimitierten Szenarien ausschlaggebend, während bei umfassender Datenaugmentation die Modellkapazität des BiLSTMs die Obergrenze vorgibt. Die detaillierten Dichteverteilungen und Regressionsanalysen aller vier Varianten sind in Abbildung 15 und Abbildung 16 im Anhang dokumentiert.

### 5.2.1 Ablationsstudie: Einfluss der Kontextlänge auf die MixUp-Regression

Analog zur Klassifikation wurde der Einfluss der Eingabesequenzlänge auf das kontinuierliche MixUp-Regressionsmodell über 256, 512 und 1.024 Tokens systematisch evaluiert. Das Training erfolgte auf über 80.000 generierten dynamischen MixUp-Samples mit kontinuierlichen Zielwerten  $\lambda \in [0,0, 1,0]$ .

Bereits während der Validierung auf dem Test-Split zeigte sich ein kontinuierlicher Vorteil längerer Kontexte: Der minimale Mean Squared Error (MSE) sank von 0,0260 (256 Tokens) über 0,0246 (512 Tokens) auf 0,0234 bei 1.024 Tokens (minimaler MAE 0,0976). Tabelle 5 stellt die Evaluierung der Regressormodelle auf dem externen Lebenshilfe-Goldstandard dar (ergänzende grafische Analysen

finden sich im Anhang: Dichteverteilungen in Abbildung 17, ROC/PR-Kurven in Abbildung 18 sowie die paarweisen Trajektorien in Abbildung 19).

Tabelle 5: Längen-Benchmark der BiLSTM MixUp Regressoren auf dem Lebenshilfe-Goldstandard ( $N = 37$  Artikelpaare / 74 Dokumente).

| Modell                           | Ebene / Input          | O Score (LS)                       | O Score (AS)                       | Separation ( $\Delta$ ) | Balanced Acc   | ROC-AUC       | Pair Match             |
|----------------------------------|------------------------|------------------------------------|------------------------------------|-------------------------|----------------|---------------|------------------------|
| BiLSTM MixUp Regressor (256)     | Dokument (256 Tok.)    | $0,724 \pm 0,13$                   | $0,092 \pm 0,09$                   | 0,632                   | 95,95 %        | 0,9982        | 97,3 % (36/37)         |
| BiLSTM MixUp Regressor (512)     | Dokument (512 Tok.)    | $0,777 \pm 0,12$                   | <b><math>0,062 \pm 0,11</math></b> | 0,715                   | 98,65 %        | 0,9985        | 97,3 % (36/37)         |
| BiLSTM MixUp Regressor (1.024)   | Dokument (1.024 Tok.)  | <b><math>0,792 \pm 0,10</math></b> | $0,067 \pm 0,10$                   | <b>0,726</b>            | <b>98,65 %</b> | <b>0,9993</b> | <b>100,0 % (37/37)</b> |
| Flesch Reading Ease (Baseline)   | Dokument (Silben/Satz) | $0,973 \pm 0,16$                   | $0,189 \pm 0,39$                   | 0,784                   | 89,19 %        | 0,8919        | 100,0 % (37/37)        |
| Wiener Sachtextformel (Baseline) | Dokument (Wortlänge)   | $0,919 \pm 0,27$                   | $0,108 \pm 0,31$                   | 0,811                   | 90,54 %        | 0,9054        | 100,0 % (37/37)        |

**Inverses Skalierungsverhalten: Warum dominiert beim Regressor das 1.024-Token-Modell?** Im direkten Kontrast zum Artikel-Klassifikator erweist sich bei der MixUp-Regression das 1.024-Token-Modell als das stärkste und stabilste Modell:

1. **Perfektes Paar-Ranking (100,0 %):** Bei ausnahmslos allen 37 von 37 Artikelpaaren des Goldstandards ordnet das 1.024-Modell der Leichten Sprache einen strikt höheren Score zu als der zugehörigen Alltagssprache ( $\text{Score}(\text{LS}) > \text{Score}(\text{AS})$ , vgl. Abbildung 19 im Anhang).
2. **Höchste Trennschärfe & minimale Varianz:** Das Modell erreicht den höchsten mittleren LS-Score (0,792) bei der geringsten Standardabweichung ( $\pm 0,10$ ), was zu einer maximalen Separation von  $\Delta = 0,726$ , einer Balanced Accuracy von 98,65 % und einem nahezu perfekten ROC-AUC von 0,9993 führt.

**Systematische Überlegenheit und Trainingsstabilität des MixUp-Regressors gegenüber dem Klassifikator** Die direkte Gegenüberstellung der Benchmark-Ergebnisse (Tabelle 4 und Tabelle 5) liefert eine zentrale methodische Erkenntnis dieser Arbeit: Während das direkte Artikel-Training beim binären Klassifikator bei langen Sequenzen instabil wird und degradiert, bleibt das Training des BiLSTM MixUp-Regressors robust und skaliert positiv mit längeren Kontexten.

Die Ursachen für diese Divergenz in der Trainingsstabilität begründen sich in vier Mechanismen:

- **Homogene Merkmalsverteilung durch dynamisches Satz-Shuffling:** Beim Artikel-Klassifikator stehen die Sätze in ihrer starren Originalreihen-

folge. Stehen relevante Simplitätsmerkmale am Anfang des Textes und folgt danach langer Fließtext, verliert das LSTM über 1.000 Rekursionschritte das Signal. Beim MixUp-Regressor hingegen werden die gezogenen Sätze vor der Verkettung randomisiert durchmischt (`random.shuffle`). Dadurch verteilen sich Leichte-Sprache- und Alltagssprache-Muster homogen über das gesamte 1.024-Token-Fenster (Anfang, Mitte und Ende), wodurch ein positionsabhängiges Vergessen unmöglich wird.

- **Massive Datenaugmentation statt Datenmangel:** Auf Dokumentenebene stehen dem Klassifikator nur ca. 750 starre Trainingsartikel zur Verfügung, was bei Millionen Modellparametern zu schnellem Overfitting führt. Der MixUp-Regressor hingegen generiert in jeder Epoche zehntausende neue, permutierte Satzmischungen, wodurch das Modell auf eine extrem breite, kontinuierliche Datenbasis zurückgreift.
- **Linearer MSE-Loss statt extremer BCE-Sättigung:** Der binäre BCE-Loss treibt die Logits über die Sigmoid-Funktion in die Sättigungsgränze ( $-\infty$  bzw.  $+\infty$ ), was bei kleinsten Standard-Merkmalen zu überkonfidenten Fehlentscheidungen führt. Der Regressionsverlust (MSE) hingegen erzwingt stetige, proportionale Gradienten über das gesamte Intervall  $[0,0,1,0]$  und verhindert extreme Wahrscheinlichkeitskollapse.
- **Additive Signal-Akkumulation:** Der Klassifikator muss ein rigides »Alles-oder-Nichts«-Urteil über 1.024 Tokens fällen. Der Regressor hingegen fungiert als quantitativer Integrator: Er akkumuliert die Dichte einfacher Merkmale über den Zeitverlauf des LSTMs auf. Mehr Kontext (1.024 Tokens) liefert dem Regressor eine statistisch repräsentativere Textstichprobe, was die Vorhersagevarianz signifikant senkt ( $\pm 0,10$ ) und das Modell zur überlegenen Metrik macht.

**MixUp-Regression vs. Traditionelle Formel-Baselines** Gegenüber den deterministischen Formeln erzielt der 1.024-Token MixUp-Regressor mit 98,65 % Balanced Accuracy und 0,9993 ROC-AUC eine deutlich überlegene Trennschärfe. Während traditionelle Formeln an starre Schwellenwerte gebunden sind, im mittleren Wertebereich eine erhebliche Dichtestreuung aufweisen und keine Gradienten zur differenzierten Steuerung bereitstellen, bildet das MixUp-Modell eine stetige, differenzierbare Reward-Landschaft aus. Dadurch werden graduelle linguistische

Vereinfachungsfortschritte im RL-Training quantitativ und richtungserhaltend bewertbar.

### 5.3 Validierung der kontinuierlichen Abstufungsfähigkeit auf externen Benchmarks (TextComplexityDE & MERLIN)

Die vorangegangene Evaluierung auf dem *Lebenshilfe*-Goldstandard (Abschnitt 5.2.1) belegt, dass der BiLSTM MixUp-Regressor ein trennscharfer und robuster Zero-Shot-Diskriminator auf Dokumentenebene ist. Trotz des kontinuierlichen MixUp-Trainingsverfahrens diskriminiert das Modell mit einer Balanced Accuracy von 98,65 %, einem ROC-AUC von 0,9993 und einem fehlerfreien Perfect-Pair-Matching von 100,0 % (37/37) zwischen Alltagssprache und Leichter Sprache und übertrifft dabei den originär binär trainierten Klassifikator systematisch.

#### 5.3.1 Das fundamentale Dilemma: Diskrete Klassifikation vs. kontinuierlicher Reward

Aus anwendungsorientierter und methodischer Sicht offenbart dieser Befund jedoch ein Dilemma: Das eigentliche Primärziel des Modells besteht nicht in einer binären Klassifikation, sondern in der Bereitstellung eines stufenlosen, kontinuierlichen Gütesignals, das präzise quantifiziert, *in welchem Ausmaß* ein gegebener Text bereits die linguistischen und syntaktischen Kriterien Leichter Sprache erfüllt.

Die direkte empirische Validierung dieser kontinuierlichen Abstufungsfähigkeit auf realen Sprachdaten erweist sich in der linguistischen Praxis jedoch als methodische Hürde: In der Praxis existieren keine natürlichen Parallelkorpora, die kontinuierliche Zwischenstufen zwischen Alltagssprache und Leichter Sprache annotieren. Das Übersetzungswesen in Leichte Sprache operiert traditionell strikt bimodal (Ausgangstext in Alltagssprache vs. finale Zielübersetzung in Leichter Sprache). Graduelle Übergangszustände (z. B. ein Text mit vereinfachtem Satzbau, aber noch unaufgelösten Komposita) sind im originären Korpus nicht annotiert.

Genau aus diesem Mangel an empirischen Zwischenstufendaten begründet sich die in dieser Arbeit entwickelte Methodik: Mittels textuellem MixUp (Abschnitt 5.2) und synthetischer LLM-Stufengenerierung (Abschnitt 5.4) wurde

der kontinuierliche Interpolationsraum künstlich konstruiert, um dem Modell das Erlernen stetiger Gradienten zu ermöglichen. Um die tatsächliche Fähigkeit des Modells zur Differenzierung gradueller Komplexitätsstufen unabhängig vom künstlichen Trainingsmix objektiv zu überprüfen, werden im Folgenden zwei etablierte, externe Sprachkomplexitäts-Benchmarks herangezogen:

1. **TextComplexityDE (Naderi et al., 2019):** Ein standardisierter Benchmark aus 1.000 isolierten deutschen Wikipedia-Sätzen mit menschlichen 7-Punkte-Likert-Urteilen zur Satzkomplexität.
2. **MERLIN-Korpus (Boyd et al., 2014):** Ein Benchmark aus 1.033 authentischen deutschen Volltexten auf Dokumentenebene, die von Sprachexperten offiziell nach den 5 Niveaustufen des Gemeinsamen Europäischen Referenzrahmens (CEFR: A1, A2, B1, B2, C1) eingestuft wurden.

### 5.3.2 Satzebene: Evaluation auf TextComplexityDE & Analyse des Floor-Effekts

Der *TextComplexityDE*-Benchmark (Naderi et al., 2019) umfasst 1.000 deutsche Wikipedia-Sätze, für die aggregierte menschliche Urteile (*Mean Opinion Score*, MOS) hinsichtlich Gesamtschwierigkeit ( $\text{MOS}_{\text{Complexity}} \in [1, 0, 7, 0]$ ), Verständlichkeit und lexikalischer Hürden vorliegen.

In Tabelle 7 (Anhang 9.1) sowie in den Abbildungen 4 bis 6 sind die Ergebnisse aller Modellfamilien detailliert aufgeführt. Die Untersuchung liefert wesentliche methodische Erkenntnisse über das Modellverhalten auf Satzebene:

- **Solide Rangkorrelation bei adäquatem Kontext (512 Tokens):** Der BiLSTM MixUp-Regressor (512 Tokens) erreicht eine Spearman-Rangkorrelation von  $\rho = 0,615$  (Pearson  $r = 0,602$ ) mit dem menschlichen Einfachheitsurteil und differenziert signifikant über die Likert-Stufen.
- **Die Dämpfungsfalle bei langen Kontexten (1.024 Tokens):** Beim 1.024-Token-Regressor bricht die Rangkorrelation auf  $\rho = 0,461$  ein. Die Ursache liegt in der Architektur des BiLSTMs: Da die isolierten Wikipedia-Sätze im Mittel nur  $\sim 15$  bis 25 Tokens lang sind, verarbeitet das rekurrente Netz bei fester Maximallänge über 1.000 Null-Padding-Tokens (`<pad>`), was zu einer starken Verdünnung der Hidden-States führt.



- **Der linguistische Floor-Effekt (Smoking Guns):** Während der Regressor auf 80.800 Absatzmischungen trainiert wurde, enthält nahezu jeder Wikipedia-Satz einzelne komplexe Fachtermini oder typische Alltagssprachliche Syntaxstrukturen. Das Modell identifiziert diese isolierten Elemente als definitive Signale für Nicht-LS (*»Smoking Guns«*), wodurch 75 % aller Modellvorhersagen in ein stark komprimiertes unteres Band von  $[0,026, 0,109]$  gedrückt werden.
- **Erstaunlich solide Baseline-Korrelationen auf Enzyklopädie-Sätzen:** Der LIX-Index ( $\rho = 0,641$ ) und die Wiener Sachtextformel ( $\rho = 0,519$ ) erzielen auf den Wikipedia-Sätzen solide Rangkorrelationen (Tabelle 7). Da enzyklopädische Komplexität primär durch Fachtermini und Satzlängen getrieben wird, greifen Oberflächenheuristiken hier verlässlich als statistische Basis, erfassen jedoch keine grammatikalischen Kriterien Leichter Sprache.

Aufgrund dieser methodischen Artefakte bei isolierten Einzelsätzen erweist sich TextComplexityDE allein als unzureichend, um die genuine Abstufungsfähigkeit auf zusammenhängenden Fließtexten zu beurteilen.

### 5.3.3 Dokumentebene: Evaluation auf dem MERLIN CEFR-Benchmark

Um die kontinuierliche Sprachstufung auf echten Fließtexten ohne Längen- und Padding-Verzerrungen zu evaluieren, wird das MERLIN-Korpus (Boyd et al., 2014) herangezogen. Mit 1.033 vollständigen Texten (Aufsätze und Briefe aus standardisierten Sprachprüfungen) und einer durchschnittlichen Textlänge von ca. 150 bis 250 Tokens entspricht dieses Korpus exakt der typischen Dokumentstruktur von Leichte-Sprache-Absätzen.

Tabelle 8 und Tabelle 9 (Anhang 9.2) sowie die Abbildungen 7 bis 9 dokumentieren die Performanz aller Modelle über die 5 CEFR-Stufen ( $A1, A2, B1, B2, C1, C2$ ). Die Auswertung liefert herausragende Belege für die graduelle Diskriminationskraft der Modelle:

- **Strikte Monotonie des Artikel-Klassifikators (512 Tokens):** Der 512er Artikel-Klassifikator ( $P(LS)$ ) fällt streng monoton über ausnahmslos alle 6 CEFR-Niveaustufen ab:

$$0,504 (A1) \longrightarrow 0,442 (A2) \longrightarrow 0,339 (B1) \longrightarrow 0,096 (B2) \longrightarrow 0,073 (C1) \longrightarrow 0,050 (C2) \quad (12)$$

Dies belegt empirisch, dass die kontinuierliche Ausgangswahrscheinlichkeit auf Dokumentebene eine hochgradig monotone Sprachstufungsmetrik konstituiert ( $\rho = 0,397$ , Pearson  $r = 0,386$ ).

- **Ausgeprägte Niveautrennung der MixUp-Regressoren ab B1:** Sowohl der 512er- als auch der 1.024er-MixUp-Regressor bilden die CEFR-Schwierigkeit ab: Während elementare Sprachstufen (A1, A2, B1) im Wertebereich von 0,30 bis 0,36 liegen, vollzieht sich ab dem Übergang zur fortgeschrittenen Sprachverwendung (B2:  $\sim 0,18$ – $0,20$ ) sowie zu Fach- und Muttersprachenniveau (C1/C2:  $\sim 0,07$ – $0,10$ ) ein steiler, hochgradig signifikanter Score-Abfall (Tabelle 9).
- **Korrelation der Formel-Baselines mit CEFR-Prüfungsstufen:** Auch auf MERLIN korrelieren traditionelle Formeln stark mit den Niveaus (LIX:  $\rho = 0,656$ , WSTF:  $\rho = 0,602$ , Flesch:  $\rho = 0,543$ ), da höhere Prüfungsstufen (B2–C2) formal anspruchsvollere Wort- und Satzstrukturen fordern. Wie zuvor diskutiert, bildet dies eine nützliche Basis, vermag jedoch die spezifischen, normierten Vereinfachungsregeln Leichter Sprache nicht feinkörnig zu erfassen oder als Gradient für generative Modelle bereitzustellen.

#### 5.3.4 Kritische Synthese: Validität des Zero-Shot-Transfers & Fazit

Bei der Interpretation dieses Benchmark-Transfers ist eine methodische Differenzierung geboten: Der Vergleich mit standardisierten CEFR-Stufen ist nicht vollkommen deckungsgleich. Das CEFR-Raster klassifiziert Fremdsprachenkompetenzen von Deutschlernenden und berücksichtigt dabei auch orthografische und grammatikalische Fehler (wie die Ausreißeranalyse im Anhang verdeutlicht, bei der A1-Texte mit massiven Rechtschreibfehlern durch unbekannte Vokabular-Indizierungen vorsichtigere Scores erhalten). Leichte Sprache hingegen ist ein normiertes Regelwerk für Menschen mit kognitiven Einschränkungen, das primär auf syntaktischer Dekonstruktion, Aktivsätzen und morphologischer Komposita-Trennung basiert.

Trotz dieser konzeptionellen Divergenz zwischen L2-Spracherwerb und Leichter Sprache differenzieren die entwickelten BiLSTM-Modelle die realen Sprachkomplexitätsstufen im Zero-Shot-Transfer weitgehend ordnungserhaltend. Dies zeigt, dass das MixUp-Training keine künstlichen Artefakte erzeugt hat, sondern eine verallgemeinerbare Metrik für graduelle Textsimplicität bereitstellt, die im

weiteren Verlauf dieser Arbeit erfolgreich als Reward-Funktion zur Ausrichtung generativer Sprachmodelle (Abschnitt 6.3) eingesetzt werden kann.

## 5.4 Evaluierung synthetischer Sprachstufen (LLM-basierter Regressor)

Neben der kontinuierlichen Satzmischung (MixUp, Abschnitt 5.2) wurde in dieser Arbeit als alternativer, rein semantischer Modellierungsansatz die gezielte Generierung von Sprachkomplexitätsstufen mittels großer Sprachmodelle (LLMs) untersucht. Das Ziel dieses Ansatzes bestand darin, ein kontinuierliches Gütesignal auf Basis linguistisch modulierter Ganztexte zu erlernen, anstatt künstlich amalgamierte Satzkombinationen zu nutzen.

### 5.4.1 Konzeption, Prompt-Design & Generierung mit FlensGen-GPT

Zur semantischen Generierung der Zwischenstufen wurde das an der Hochschule Flensburg betriebene Open-Source-Großsprachmodell **FlensGen-GPT-OSS-120B** über einen lokalen Inferenzendpunkt per Instruction Prompting angesteuert. Für jedes parallele Artikelpaar des bereinigten Master-Korpus sowie des Lebenshilfe-Datensatzes wurden unter Vorlage beider Originalfassungen (Alltagssprache als Stufe 0,00 und Leichte Sprache als Stufe 1,00) drei diskrete Zwischenstufen synthetisiert:

- **Stufe 0,25 (Nahe Alltagssprache):** Leicht vereinfachter Fließtext; Schachtelsätze werden aufgeteilt, schwierige Fachtermini kurz paraphrasiert.
- **Stufe 0,50 (Einfache Sprache):** Typische »Einfache Sprache«; Verzicht auf Schachtelsätze bei Standard-Kombination aus Haupt- und Nebensatz, alltäglicher Wortschatz.
- **Stufe 0,75 (Nahe Leichte Sprache):** Sehr leicht verständliche Sprache; überwiegend einfache Hauptsätze, jedoch ohne die extremen zeilenweisen Umbrüche Leichter Sprache.

Das vollständige System- und User-Prompt-Design inklusive aller Regelvorgaben ist in Anhang 9.6 dokumentiert. Auf dem resultierenden 5-Stufen-Datensatz (4.300 Text-Samples aus 860 Artikeln) wurde eine BiLSTM-Architektur identischer Kapazität (Hidden-Dim 128, Embedding-Dim 128, MSE-Loss) als *Synthetischer Regressor* trainiert.

#### 5.4.2 Empirische Ergebnisse & Vergleich mit dem MixUp-Paradigma

Bei der empirischen Überprüfung auf dem unabhängigen *Lebenshilfe*-Goldstandard zeigte der synthetische Regressor prinzipiell das erwünschte Verhalten: Das Modell erlernt die grundlegende Richtung der Sprachkomplexität und weist Texten in Leichter Sprache im Durchschnitt deutlich höhere Werte zu als den alltagssprachlichen Originalen. Auch bei der relativen Gegenüberstellung gegebener Artikelpaare ordnet das Modell in rund 89 % der Fälle der vereinfachten Fassung einen höheren Score zu. Entlang der fünf diskret generierten Stufen spiegelt sich zudem ein erkennbarer, stetiger Anstieg der vorhergesagten Werte wider.

Im direkten Vergleich mit dem kontinuierlichen MixUp-Paradigma wird jedoch ein deutlicher Leistungsabstand sichtbar: Während das MixUp-Modell die beiden Sprachebenen nahezu überlappungsfrei und mit minimaler Streuung trennt, streuen die Vorhersagen des synthetischen Regressors spürbar breiter. Insbesondere im mittleren Komplexitätsbereich fallen die Übergänge zwischen den Zwischenstufen diffuser aus.

Die vollständige tabellarische Gegenüberstellung aller Performanzmaße gegenüber den MixUp-Varianten und den klassischen Lesbarkeitsformeln ist in Tabelle 13 in Anhang 9.6 aufgeführt. Ergänzende Dichteverteilungen, ROC-Kurven sowie Boxplots der fünf Stufen finden sich in den Abbildungen 20 und 21.

#### 5.4.3 Methodische Grenzen & Begründung der Ausmusterung

Obwohl der synthetische Ansatz als Machbarkeitsnachweis für LLM-basierte Komplexitätsmodulation funktionierte, zeigte er im direkten Vergleich eine deutliche Leistungsunterlegenheit gegenüber dem MixUp-Regressor (ROC-AUC = 0,8495 vs. 0,9993; Balanced Accuracy 78,38 % vs. 98,65 %; Pair Match 89,2 % vs. 100,0 %). Aus diesem Grund wurde der synthetische Regressor für die nachfolgende Optimierung der Übersetzungsmodelle (Themenblock 3) nicht weiterverfolgt.

Die Ursachen für diese Diskrepanz liegen in drei methodischen Unterschieden begründet:

1. **Granularitätsgrenze generativer Sprachmodelle:** Während das LLM grobe Niveaus trennen kann, stößt es bei feineren Zwischenstufen an eine Auflösungsgrenze. Eine Erhöhung auf beispielsweise 10 oder 20 Stufen erzeugt keinen Informationsgewinn, da aktuelle Modelle solch minimale

Komplexitätsunterschiede nicht deterministisch steuern können und zu stilistischer Regression neigen.

2. **Datenvolumen und Sampling-Flexibilität:** Der synthetische Ansatz ist auf 5 diskrete Texte pro Artikel limitiert (4.300 statische Samples). Das kontinuierliche MixUp-Verfahren hingegen erlaubt ein stufenloses Sampling über das gesamte Intervall  $\lambda \in [0,0,1,0]$  und generiert dynamisch über 80.000 permutierte Trainingssamples pro Epoche, was Overfitting wirksam unterbindet.
3. **Authentische vs. künstliche Trainingsdaten:** Der entscheidende Vorteil des MixUp-Verfahrens besteht darin, dass es auf rein authentischer, von menschlichen Expertinnen verfasster und geprüfter Sprache trainiert. Der synthetische Ansatz trainiert hingegen auf maschinell erzeugten Zwischentexten, wodurch das rekurrente Netz unvermeidbare LLM-Artefakte und unnatürliche Satzstrukturen als Scheinsignale miterlernt.

Trotz dieser Limitierungen bleibt der synthetische Ansatz eine vielversprechende Forschungsrichtung, die mit zukünftigen, noch präziser steuerbaren Sprachmodellen weiter an Relevanz gewinnen dürfte.

## 5.5 Synthese & Modellauswahl für die generative Übersetzung (Themenblock 3)

Um die empirische Güte und Trennschärfe aller in diesem Themenblock entwickelten Ansätze vergleichend zusammenzufassen, stellt Tabelle 6 die Ergebnisse sämtlicher Modellfamilien auf dem unabhängigen *Lebenshilfe*-Goldstandard ( $N = 37$  Artikelpaare / 74 Dokumente) gegenüber.

**Architektur-Ablation: Die Vanilla RNN Baseline** Um zu überprüfen, ob die bidirektionale LSTM-Zellstruktur und ihre internen Gating-Mechanismen (Input-, Forget- und Output-Gates) für die Komplexitätsmodellierung zwingend erforderlich sind, wurde als Architektur-Ablation eine einfache, unidirektionale rekurrente Baseline (*Vanilla RNN* nach Elman) unter identischen Trainingsbedingungen evaluiert. Ohne schützende Gating-Mechanismen leidet das einfache RNN bei längeren Textsequenzen unter dem Problem verschwindender Gradienten (*Vanishing Gradient Problem*). Zwar erreicht die Baseline ein solides

relatives Ranking (Balanced Accuracy = 81,08 %, ROC-AUC = 0,8733, Pair Match 81,1 %), ihre Klassenseparation fällt mit  $\Delta = +0,240$  jedoch signifikant geringer aus als beim BiLSTM-Backbone ( $\Delta = +0,726$ ). Dies belegt die Notwendigkeit von Gated Recurrent Units zur zuverlässigen Repräsentation langer syntaktischer Abhängigkeiten.

Tabelle 6: Gesamtübersicht aller in Themenblock 2 evaluierten Modellansätze auf dem Lebenshilfe-Goldstandard ( $N = 37$  Artikelpaare / 74 Dokumente).

| Modell                                            | Paradigma / Input          | $\mathcal{O}$ Score (LS)           | $\mathcal{O}$ Score (AS)           | Separation ( $\Delta$ ) | Balanced Acc   | ROC-AUC       | Pair Match             |
|---------------------------------------------------|----------------------------|------------------------------------|------------------------------------|-------------------------|----------------|---------------|------------------------|
| <i>Kontinuierliche Regressionsmodelle (MixUp)</i> |                            |                                    |                                    |                         |                |               |                        |
| BiLSTM MixUp Regressor (1.024)                    | Dokument (1.024 Tok.)      | <b>0.792 <math>\pm</math> 0.10</b> | <b>0.067 <math>\pm</math> 0.10</b> | <b>0.726</b>            | <b>98,65 %</b> | <b>0.9993</b> | <b>100,0 % (37/37)</b> |
| BiLSTM MixUp Regressor (512)                      | Dokument (512 Tok.)        | 0,777 $\pm$ 0,12                   | 0,062 $\pm$ 0,11                   | 0,715                   | 98,65 %        | 0,9985        | 97,3 % (36/37)         |
| BiLSTM MixUp Regressor (256)                      | Dokument (256 Tok.)        | 0,724 $\pm$ 0,13                   | 0,092 $\pm$ 0,09                   | 0,632                   | 95,95 %        | 0,9982        | 97,3 % (36/37)         |
| <i>Diskrete &amp; ablative Regressionsmodelle</i> |                            |                                    |                                    |                         |                |               |                        |
| BiLSTM Synthetischer Regressor                    | Dokument (LLM-Stufen)      | 0,575 $\pm$ 0,35                   | 0,145 $\pm$ 0,18                   | 0,429                   | 78,38 %        | 0,8495        | 89,2 % (33/37)         |
| Vanilla RNN Baseline (Ablation)                   | Dokument (256 Tok.)        | 0,527 $\pm$ 0,20                   | 0,287 $\pm$ 0,17                   | 0,240                   | 81,08 %        | 0,8733        | 81,1 % (30/37)         |
| <i>Binäre Klassifikationsmodelle</i>              |                            |                                    |                                    |                         |                |               |                        |
| BiLSTM Satz-Klassifikator (MajVote)               | Dokument ( $r_{LS}$ Ratio) | 0,769 $\pm$ 0,08                   | 0,127 $\pm$ 0,14                   | 0,642                   | <b>98,65 %</b> | 0,9985        | <b>100,0 % (37/37)</b> |
| BiLSTM Artikel-Klassifikator (256)                | Dokument (256 Tok.)        | 0,829 $\pm$ 0,31                   | 0,002 $\pm$ 0,01                   | 0,827                   | 91,89 %        | 0,9974        | 97,3 % (36/37)         |
| BiLSTM Artikel-Klassifikator (1.024)              | Dokument (1.024 Tok.)      | 0,340 $\pm$ 0,40                   | 0,007 $\pm$ 0,01                   | 0,333                   | 67,57 %        | 0,8795        | 97,3 % (36/37)         |
| <i>Klassische linguistische Formel-Baselines</i>  |                            |                                    |                                    |                         |                |               |                        |
| Flesch Reading Ease (Baseline)                    | Dokument (Silben/Satz)     | 0,973 $\pm$ 0,16                   | 0,189 $\pm$ 0,39                   | 0,784                   | 89,19 %        | 0,8919        | 100,0 % (37/37)        |
| Wiener Sachtextformel (Baseline)                  | Dokument (Wortlänge)       | 0,919 $\pm$ 0,27                   | 0,108 $\pm$ 0,31                   | 0,811                   | 90,54 %        | 0,9054        | 100,0 % (37/37)        |

**Synthese: Traditionelle Baselines vs. Neuronale Metrik-Modelle** Die zusammenfassende Gesamtschau in Tabelle 6 bestätigt das zentrale methodische Fazit von Themenblock 2: Traditionelle Lesbarkeitsmetriken wie der Flesch Reading Ease und die Wiener Sachtextformel stellen wertvolle, transparente Vergleichs-Baselines dar, die makroskopische Längenunterschiede auf Dokumentenebene zuverlässig abbilden (100,0 % Pair Match). Da sie jedoch keine spezifischen grammatikalischen und syntaktischen Regeln der Leichten Sprache erfassen und keine stetig differenzierbaren Wahrscheinlichkeiten ausgeben, eignen sie sich nicht als Belohnungssignal für generative Sprachmodelle. Die beiden neuronalen Spitzenmodelle—der hierarchische BiLSTM-Satz-Klassifikator (98,65 % BAcc, 0,9985 ROC-AUC) und der 1.024-Token MixUp-Regressor (98,65 % BAcc, 0,9993 ROC-AUC)—schließen diese Lücke empirisch und konzeptionell durch signifikant höhere Trennschärfe, bimodal getrennte Verteilungen und kontinuierliche Gradienten.

**Finale Modellauswahl für Themenblock 3** Auf Basis dieses empirischen Gesamtergebnisses wird für die nachfolgenden Übersetzungs- und Alignment-Stufen (Supervised Fine-Tuning [SFT], Abschnitt 6.2, sowie Direct Preference

Optimization [DPO], Abschnitt 6.3) verbindlich das 1.024-Token BiLSTM MixUp-Regressionsmodell als primäre Einfachheitsmetrik ( $R_{\text{style}}$ ) ausgewählt.

Diese Entscheidung stützt sich auf vier zentrale Faktoren:

1. **Empirische Überlegenheit in den Metrik-Tests:** In den Längen-Ablationen auf dem unabhängigen *Lebenshilfe*-Goldstandard (Abschnitt 5.2.1, Tabelle 5) erzielte die 1.024-Token-Variante das beste Gesamtergebnis mit einem fehlerfreien Paar-Matching von 100,0 % (37/37 Paare), maximaler Klassenseparation ( $\Delta = 0,726$ ), geringster Vorhersagevarianz ( $\pm 0,10$ ), höchstem ROC-AUC (0,9993) sowie dem niedrigsten Validierungs-MSE (0,0234).
2. **Systematische Überlegenheit gegenüber dem synthetischen Regressor:** Gegenüber dem LLM-basierten Synthetischen Regressor (BAcc = 78,38 %, ROC-AUC = 0,8495, Pair Match 89,2 %, Abschnitt 5.4) bietet das MixUp-Modell eine drastisch höhere Trennschärfe und Robustheit auf realen Texten.
3. **Maximale Artikelabdeckung:** Im bereinigten Korpus besitzen Ausgangstexte im Mittel 622,2 Wörter ( $\approx 1.350$  BPE-Tokens) und vereinfachte Texte 457,9 Wörter ( $\approx 857$  BPE-Tokens). Da rund 45 % der Artikel 512 Tokens und über 90 % das 128-Token-Limit überschreiten, gewährleistet erst das 1.024-Token-Fenster eine ganzheitliche Dokumentenbewertung ohne vorzeitiges Abschneiden (*Truncation*).
4. **Architektonische Kongruenz mit mBART-50:** Das als Translations-Backbone eingesetzte Sequenz-zu-Sequenz-Modell `facebook/mbart-large-50` (Liu et al., 2020; Tang et al., 2020) besitzt eine native Positionskodierungsgrenze von maximal 1.024 Tokens (`max_position_embeddings = 1024`). Die Angleichung der Metrik auf 1.024 Tokens stellt sicher, dass das Belohnungssignal im DPO-Training exakt das vollständige Generierungsfenster von mBART-50 abdeckt.

## 6 Themenblock 3: Modellierung der Übersetzung & Reward-Guided Fine-Tuning

In diesem Themenblock wird das generative Übersetzungsmodell entwickelt, trainiert und optimiert. Aufbauend auf dem bereinigten Parallelkorpus (Themenblock 1) und der gelernten Komplexitätsmetrik (Themenblock 2) erfolgt die Modellierung über ein zweistufiges Trainingsverfahren aus Supervised Fine-Tuning (SFT) und anschließender Präferenzoptimierung mittels Direct Preference Optimization (DPO).

### 6.1 Datenvorbereitung & Trainings-Splits

#### Zu erklären in diesem Abschnitt:

- **[Zu erklären] Datensatzfilterung:** Bereitstellung der Trainingspaare aus dem Sweet-Spot-Korpus ( $0,60 \leq \text{sim}_{\text{cos}} \leq 0,98$ ).
- **[Zu erklären] Split-Konfiguration:** Aufteilung in Trainings- (80 %), Validierungs- (10 %) und Test-Sets (10 %) unter Vermeidung von Datenlecks (*Data Contamination*).
- **[Zu erklären] Präferenzdatensatz-Konstruktion:** Offline-Generierung von  $(x, y_w, y_l)$ -Tripeln (Prompt, präferierte Antwort, dispräferierte Antwort) mittels SFT-Sampling und automatischer Reward-Bewertung.



## 6.2 Supervised Fine-Tuning (SFT)

Zu erklären in diesem Abschnitt:

- **[Zu erklären] Modellauswahl & Architektur:** Sequence-to-Sequence Modellierung mit `facebook/mbart-large-50` inklusive korrekter Sprachcode-Initialisierung (`de_DE`) sowie Gegenüberstellung mit Decoder-Only-Modellen (Mistral, LLaMA).
- **[Zu erklären] Parameter-Efficient Fine-Tuning (PEFT / LoRA):** Konfiguration der Niedrigrang-Adaption ( $r = 16$ ,  $\alpha = 32$ , Dropout 0,05) auf allen Aufmerksamkeits- und Feed-Forward-Projektionen.
- **[Zu erklären] Trainingsdynamik & Overfitting-Kontrolle:** Analyse von Lernkurven, Early Stopping mit Patience und Rollback-Mechanismen bei Spät-Divergenz.

### 6.3 Reward-Guided Optimization (RLHF / DPO & PPO)

Zu erklären in diesem Abschnitt:

- **[Zu erklären] DPO-Implementierung:** Native PyTorch-Engine für Seq2Seq- und Decoder-Only-Architekturen mit Zero-VRAM Referenzmodell über PEFT-Adapterdeaktivierung (`disable_adapter()`).
- **[Zu erklären] PPO-Implementierung (Online-RL):** Policy-Gradient-Optimierung mit Clipped Surrogate Objective ( $L_{\text{CLIP}}$ ), Value Head ( $V_\phi$ ) und Generalized Advantage Estimation (GAE) auf dynamisch generierten Rollouts.
- **[Zu erklären] Verbund-Reward-Design (*Composite Reward*):** Steuerung des Zielkonflikts aus syntaktischer Einfachheit und semantischer Faktentreue:

$$R(x, y) = w_{\text{style}} \cdot R_{\text{style}}(y) + w_{\text{sem}} \cdot R_{\text{sem, norm}}(x, y) \quad (13)$$

unter Nutzung des BiLSTM-MixUp-Regressors ( $R_{\text{style}}$ ) und der SBERT-Ähnlichkeit ( $R_{\text{sem}}$ ).

- **[Zu erklären] Ablation der Reward-Gewichte:** Systematische Untersuchung von  $w_{\text{style}}/w_{\text{sem}}$  (0,5/0,5, 0,7/0,3, 1,0/0,0) zur Identifikation der optimalen Pareto-Grenze.
- **[Zu erklären] Loss-Aggregation (Sum vs. Mean):** Mathematische Analyse und experimentelle Behebung der Kürzungsfälle (*Length Exploitation*) durch längennormalisiertes Per-Token-DPO (`mean`).
- **[Zu erklären] Einfluss der Glossar-Anreicherung:** Vergleich von Modellen auf Standard- vs. Enriched-Korpora.
- **[Zu erklären] Vergleich Online-RL (PPO) vs. Offline-Präferenzlernen (DPO):** Gegenüberstellung von Trainingsstabilität, Explorationseigenschaften und Berechnungsaufwand.

## 6.4 Mehrdimensionale Evaluierung & Demonstrator-App

Zu erklären in diesem Abschnitt:

- **[Zu erklären] 7-Wege-Out-of-Domain-Benchmark:** Umfassender Vergleich auf dem unabhängigen *Lebenshilfe*-Testset:
  - Few-Shot Baseline (Qwen 2.5)
  - Decoder-Only Track: SFT vs. DPO vs. PPO
  - Encoder-Decoder Track (mBART-50): SFT vs. DPO vs. PPO
- **[Zu erklären] Decoding-Parameter & Halluzinationskontrolle:** Kalibrierung von Beam Search, Repetition Penalty und N-Gramm-Sperren (`no_repeat_ngram_size`) zur Unterbindung von Wiederholungsschleifen.
- **[Zu erklären] Qualitative Analyse:** Linguistische Detailuntersuchung von Modellgenerierungen (Satzkürzungen, Passiv-Aktiv-Wandlung, Wortkomposita-Trennung).
- **[Zu erklären] Full-Stack Web-Demonstrator:** Implementierung einer interaktiven Anwendung (Next.js Frontend + Flask Inferenz-Backend) mit dynamischer Einfachheits-Skala für Endanwender.

## **7 Diskussion & Gesamtevaluation**

### **7.1 Inhaltssynthese der drei Themenblöcke**

### **7.2 Stärken, Grenzen & Systemrestriktionen**

### **7.3 Beantwortung der Forschungsfragen**

## **8    Fazit & Ausblick**

### **8.1   Zusammenfassung der Kernergebnisse**

### **8.2   Ausblick & Zukünftige Forschungsarbeiten**

## 9 Anhang

## Glossar

## Abbildungsverzeichnis

|   |                                                                                                                                                                                                                                                          |    |
|---|----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|----|
| 1 | Lexikalische Diversität: Längenunabhängigkeit der MATTR ( $W = 50$ ) (links) sowie quellenweiser Vergleich zwischen Alltagssprache (AS) und Leichter Sprache (LS) (rechts). . . . .                                                                      | 34 |
| 2 | Bidirektionaler NER-Recall nach Quellen: Gegenüberstellung von Faktenerhalt ( $AS \rightarrow LS$ , blau) und Faktentreue ( $LS \rightarrow AS$ , orange). . . . .                                                                                       | 35 |
| 3 | Empirische Überprüfung der linguistischen Regel-Adhärenz über alle 11 Korpusquellen: Gegenüberstellung von Ausgangstext (AS, blau) und Leichter Sprache (LS, grün) für Satzlänge, Genitiv-Quote, Passiv-Dichte und Wiener Sachtextformel (WSTF). . . . . | 37 |
| 4 | Pearson- und Spearman-Korrelationen aller Modelle mit dem menschlichen Einfachheitsurteil auf TextComplexityDE ( $N = 1.000$ Sätze). . . . .                                                                                                             | 76 |
| 5 | Streudiagramm-Grid aller 10 Modellvarianten gegen den kontinuierlichen menschlichen Einfachheits-Score auf TextComplexityDE inklusive Regressionsgeraden. . . . .                                                                                        | 77 |
| 6 | Boxplot-Verteilungen der Modell-Scores gruppiert nach den diskretisierten Likert-Komplexitätsstufen auf TextComplexityDE. . . . .                                                                                                                        | 78 |
| 7 | Pearson- und Spearman-Rangkorrelationen aller Modelle auf dem MERLIN CEFR-Benchmark ( $N = 1.033$ Volltexte). . . . .                                                                                                                                    | 80 |
| 8 | Streudiagramm-Grid aller 10 Modellvarianten gegen das kontinuierliche CEFR-Simplicity-Maß ( $1,0 = A1 \dots 0,0 = C2$ ) auf MERLIN inklusive Regressionsgeraden. . . . .                                                                                 | 81 |
| 9 | Monotonie-Prüfung aller Modellfamilien: Boxplots der vorhergesagten Scores über die 5 CEFR-Stufen ( $A1, A2, B1, B2, C1$ ) auf MERLIN (weiße Punkte kennzeichnen den Mittelwert). . . . .                                                                | 82 |



|    |                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                          |    |
|----|--------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|----|
| 10 | Vergleich der Dichteverteilungen (KDE) für Leichte Sprache (LS, grün) und Alltagssprache (AS, blau) über alle Klassifikationsmodi: (a) BiLSTM Satz-Klassifikator (Simple-Sentence-Ratio $r_{LS}$ ), (b) BiLSTM Artikel-Klassifikator (256 Tokens), (c) BiLSTM Artikel-Klassifikator (512 Tokens) und (d) BiLSTM Artikel-Klassifikator (1.024 Tokens). Man beachte die ausgeprägte Asymmetrie: Während Alltagssprache durch scharfe Peaks bei 0,0 überkonfident separiert wird, bricht die Konfidenz für Leichte Sprache bei längeren Artikelkontexten stark ein. . . . . | 83 |
| 11 | ROC- und Precision-Recall-Kurven der Klassifikationsmodelle auf dem Lebenshilfe-Goldstandard. Das Satzmodell mit Majority-Voting ( $r_{LS}$ ) erzielt den höchsten AUC-Wert (0,9985) und übertrifft die direkten Artikelmodelle (256, 512, 1.024 Tokens) deutlich. . . . .                                                                                                                                                                                                                                                                                               | 84 |
| 12 | Konfusionsmatrizen und relative Performanzmaße der Klassifikatoren: (1) Satz-Modell auf Einzelsatzebene ( $N = 6.901$ Sätze), (2) Satz-Modell aggregiert via Majority Voting auf Dokumentenebene ( $N = 74$ Dokumente), (3) Artikel-Modell auf Dokumentenebene sowie (4) vergleichende Gütekriterien im Balkendiagramm. . . . .                                                                                                                                                                                                                                          | 84 |
| 13 | Generalization Gap & Overfitting-Trajektorien über 30 Epochen (Mittelwert $\pm$ Standardabweichung über 5 Seeds): Verlauf von In-Domain Validation Balanced Accuracy (blau) vs. Out-of-Domain Lebenshilfe Balanced Accuracy (grün). . . . .                                                                                                                                                                                                                                                                                                                              | 85 |
| 14 | Stabilitäts- und Varianzvergleich über 5 Zufalls-Seeds auf dem Lebenshilfe-Goldstandard: Boxplots von Balanced Accuracy (%) und Klassenseparation $\Delta$ für alle Modellkonfigurationen. . . . .                                                                                                                                                                                                                                                                                                                                                                       | 85 |
| 15 | KDE-Dichteverteilungen der vorhergesagten Scores für reine Alltagssprache (AS, blau) und reine Leichte Sprache (LS, grün) auf dem Lebenshilfe-Goldstandard im Vergleich zur Zielverteilung im Training (gestrichelte Kurve) für die vier Sampling-Strategien (Varianten A bis D). . . . .                                                                                                                                                                                                                                                                                | 87 |
| 16 | Streudiagramme der Regressionsvorhersagen $\hat{\lambda}$ auf dem Lebenshilfe-Goldstandard: Wahre kontinuierliche Zielwerte $\lambda \in [0,0, 1,0]$ auf der x-Achse gegen Modellvorhersagen auf der y-Achse inklusive linearer Regressionsgerade (rot) und idealer Diagonalen (gestrichelt) über alle vier Modellvarianten. . . . .                                                                                                                                                                                                                                     | 88 |

|    |                                                                                                                                                                                                                                                                                                                                                                                                                                   |    |
|----|-----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|----|
| 17 | KDE-Dichteverteilungen der BiLSTM MixUp Regressoren für Leichte Sprache (LS, grün) und Alltagssprache (AS, blau) über verschiedene Kontextlängen: (a) 256 Tokens, (b) 512 Tokens und (c) 1.024 Tokens. Im Gegensatz zum binären Klassifikator weisen die Regressoren bei allen Längen wohlgeformte, breit separierte Verteilungen auf, wobei das 1.024-Token-Modell die geringste Varianz und schärfste Trennung erzielt. . . . . | 89 |
| 18 | ROC- und Precision-Recall-Kurven der BiLSTM MixUp Regressoren (256, 512, 1.024 Tokens) auf dem Lebenshilfe-Goldstandard. Alle drei Varianten erreichen herausragende Diskriminationswerte ( $\text{ROC-AUC} \geq 0,998$ , $\text{PR-AUC} \geq 0,997$ ), wobei die 1.024-Token-Konfiguration mit $\text{ROC-AUC} = 0,9993$ dominiert. . . . .                                                                                      | 90 |
| 19 | Paarweises Profil der Regressions-Scores und Textlängen-Einfluss: (a) Direkte Gegenüberstellung der vorhergesagten Scores für alle 37 parallelen Lebenshilfe-Artikelpaare ( $\text{LS} > \text{AS}$ bei allen Paaren, 100 % Perfect Pair Match beim 1.024-Modell) sowie (b) Korrelation zwischen Dokumentenlänge (Satzanzahl) und resultierendem Einfachheits-Score. . . . .                                                      | 90 |
| 20 | Dichteverteilungen (KDE) und Diskriminationsleistung (ROC) des Synthetischen Regressors im Vergleich zu den MixUp-Modellen und Baselines auf dem Lebenshilfe-Goldstandard. . . . .                                                                                                                                                                                                                                                | 91 |
| 21 | Empirische Monotonie- und Fehleranalyse des Synthetischen Regressors über die 5 diskreten LLM-Stufen auf dem Lebenshilfe-Goldstandard ( $N = 185$ Vorhersagen) im Vergleich zu Sentence-MixUp. . . . .                                                                                                                                                                                                                            | 92 |

## Tabellenverzeichnis

|    |                                                                                                                                                                                               |    |
|----|-----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|----|
| 1  | Übersicht des akquirierten Rohdatenbestands (Stufe 1 der Pipeline) nach Quellen. . . . .                                                                                                      | 21 |
| 2  | Übersicht des Pipeline-Funnels von Stufe 1 (Rohdaten) zu Stufe 2 (Bereinigt & Normalisiert) nach Quellen. . . . .                                                                             | 27 |
| 3  | Übersicht der quantitativen Korpusstatistiken des bereinigten Master-Datensatzes ( $N = 830$ ). . . . .                                                                                       | 32 |
| 4  | Benchmark der Klassifikationsmodelle über Granularitätsebenen und Sequenzlängen auf dem Lebenshilfe-Goldstandard ( $N = 37$ Artikelpaare / 74 Dokumente, 6.901 Einzelsätze). . . . .          | 42 |
| 5  | Längen-Benchmark der BiLSTM MixUp Regressoren auf dem Lebenshilfe-Goldstandard ( $N = 37$ Artikelpaare / 74 Dokumente). . . . .                                                               | 48 |
| 6  | Gesamtübersicht aller in Themenblock 2 evaluierten Modellansätze auf dem Lebenshilfe-Goldstandard ( $N = 37$ Artikelpaare / 74 Dokumente). . . . .                                            | 57 |
| 7  | Gesamtevaluation aller Modellfamilien auf dem TextComplexityDE-Benchmark ( $N = 1.000$ Sätze). . . . .                                                                                        | 76 |
| 8  | Gesamtevaluation aller Modellfamilien auf dem MERLIN CEFR-Benchmark ( $N = 1.033$ Dokumente). . . . .                                                                                         | 79 |
| 9  | Mittelwerte der vorhergesagten Modell-Scores über die 6 CEFR-Stufen im MERLIN-Korpus zur Überprüfung der Monotonie ( $A1 \rightarrow C2$ ). . . . .                                           | 79 |
| 10 | In-Domain-Klassifikationsgüte (Balanced Accuracy) des BiLSTM in Abhängigkeit vom semantischen Similarity-Bereich und der Granularitätsebene auf dem internen Test-Split. . . . .              | 80 |
| 11 | Multi-Seed-Stabilitäts-Benchmark aller Modellvarianten über $K = 5$ Zufalls-Seeds (42, 123, 456, 789, 1024) auf dem Lebenshilfe-Goldstandard ( $N = 37$ Artikelpaare / 74 Dokumente). . . . . | 81 |
| 12 | Gesamtevaluation der vier MixUp-Trainings- und Sampling-Strategien auf dem internen Test-Split (In-Domain) und dem Lebenshilfe-Goldstandard (Out-of-Domain). . . . .                          | 86 |

|    |                                                                                                                                                         |    |
|----|---------------------------------------------------------------------------------------------------------------------------------------------------------|----|
| 13 | Gesamtevaluation aller Regressoren und linguistischen Baselines<br>auf dem Lebenshilfe-Goldstandard ( $N = 37$ Artikelpaare / 74<br>Dokumente). . . . . | 91 |
|----|---------------------------------------------------------------------------------------------------------------------------------------------------------|----|

## Literaturverzeichnis

- Alva-Manchego, F., Scarton, C., & Specia, L. (2021). The (Un)Suitability of Automatic Evaluation Metrics for Text Simplification. *Computational Linguistics*, 47(4), 861–889.
- Amstad, T. (1978). *Wie verständlich sind unsere Zeitungen?* Universitätsverlag Freiburg.
- Anonymized, A. (2025). Evaluating the Effectiveness of Direct Preference Optimization for Personalizing German Automatic Text Simplifications for Persons with Intellectual Disabilities. *Proceedings of the 2025 Conference on Empirical Methods in Natural Language Processing*.
- Bamberger, R., & Vanecek, E. (1984). *Lesen – Verstehen – Lernen – Schreiben: Die Wiener Sachtextformel*. Jugend und Volk.
- Battisti, A., Pfütze, D., Säuberli, A., Kostrzewa, M., & Ebling, S. (2020). A Corpus for Automatic Readability Assessment and Text Simplification of German. *Proceedings of the 12th Language Resources and Evaluation Conference*, 3302–3311.
- Björnsson, C. H. (1968). *Läsbarhet*. Liber.
- Boyd, A., Hana, J., Nicolas, L., Meurers, D., Wisniewski, K., Abel, A., Schöne, K., Štindlová, B., & Vettori, C. (2014). The MERLIN Corpus: Learner Language and the CEFR. *Proceedings of the Ninth International Conference on Language Resources and Evaluation (LREC 2014)*, 1281–1288.
- Bredel, U., & Maaß, C. (2016). *Leichte Sprache: Theoretische Grundlagen, Orientierung für die Praxis*. Dudenverlag.
- Bundesministerium für Arbeit und Soziales. (2018). *Leichte Sprache: Ein Ratgeber – Regeln für Leichte Sprache*. Verfügbar 25. August 2026 unter <https://www.bmas.de/SharedDocs/Downloads/DE/Publikationen/a752l-1-ratgeber-zu-den-regeln-von-leichter-sprache.pdf>
- Deutsches Institut für Normung. (2024). DIN 8581-1:2024-05: Einfache Sprache – Teil 1: Grundsätze und Leitlinien.
- Devaraj, A., Marshall, I., Wallace, B. C., & Li, J. J. (2021). Evaluating the Factuality of Text Simplification. *Proceedings of the 59th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, 7331–7345.

- Devlin, J., Chang, M.-W., Lee, K., & Toutanova, K. (2019). BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding. *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies*, 4171–4186.
- Günther, M., Mohr, I., Wang, B., & Han, X. (2023). Jina Embeddings 2: 8192-Token General-Purpose Text Embeddings for Long Documents. *arXiv preprint arXiv:2310.19923*.
- Hochreiter, S., & Schmidhuber, J. (1997). Long Short-Term Memory. *Neural Computation*, 9(8), 1735–1780.
- Klaper, D., Ebling, S., & Volk, M. (2013). KLAPER: A German/Simplified German Parallel Corpus. *Proceedings of the 17th International Conference on System Theory, Control and Computing*.
- Korobeynikova, M., Battisti, A., Fischer, L., & Gao, Y. (2024). DETECT: Determining Ease and Textual Clarity of German Text Simplifications. *Proceedings of the 18th Conference of the European Chapter of the Association for Computational Linguistics (Volume 1: Long Papers)*, 2215–2230.
- Lewis, M., Liu, Y., Goyal, N., Ghazvininejad, M., Mohamed, A., Levy, O., Stoyanov, V., & Zettlemoyer, L. (2020). BART: Denoising Sequence-to-Sequence Pre-training for Natural Language Generation, Translation, and Comprehension. *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics*, 7871–7880.
- Lin, C.-Y. (2004). ROUGE: A Package for Automatic Evaluation of Summaries. *Text Summarization Branches Out*, 74–81.
- Liu, Y., Gu, J., Goyal, N., Li, X., Edunov, S., Ghazvininejad, M., Lewis, M., & Zettlemoyer, L. (2020). Multilingual Denoising Pre-training for Neural Machine Translation. *Transactions of the Association for Computational Linguistics*, 8, 726–742.
- Loshchilov, I., & Hutter, F. (2019). Decoupled Weight Decay Regularization. *International Conference on Learning Representations*.
- Maaß, C. (2020). *Leichte Sprache: Das Regelbuch*. Dudenverlag.
- Madina, M., Gonzalez-Dios, I., & Siegel, M. (2023). Easy-to-Read in Germany: A Survey on its Current State and Available Resources. *arXiv preprint arXiv:2306.03189*.

- Naderi, B., Mohtaj, S., Ensikat, K., & Möller, S. (2019). TextComplexityDE: A Dataset for German Text Readability and Complexity. *Proceedings of the 15th Conference on Natural Language Processing (KONVENS 2019)*, 202–211.
- Papineni, K., Roukos, S., Ward, T., & Zhu, W.-J. (2002). BLEU: a Method for Automatic Evaluation of Machine Translation. *Proceedings of the 40th Annual Meeting of the Association for Computational Linguistics*, 311–318.
- Rafailov, R., Sharma, A., Mitchell, E., Ermon, S., Manning, C. D., & Finn, C. (2023). Direct Preference Optimization: Your Language Model is Secretly a Reward Model. *Advances in Neural Information Processing Systems*.
- Reimers, N., & Gurevych, I. (2019). Sentence-BERT: Sentence Embeddings using Siamese BERT-Networks. *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing (EMNLP-IJCNLP)*, 3982–3992.
- Säuberli, A., Ebling, S., & Volk, M. (2020). Benchmarking Data-driven Automatic Text Simplification for German. *Proceedings of the 1st Workshop on Tools and Resources to Empower People with READING Difficulties (READI)*, 41–48.
- Schuster, M., & Paliwal, K. K. (1997). Bidirectional Recurrent Neural Networks. *IEEE Transactions on Signal Processing*, 45(11), 2673–2681.
- Sennrich, R., Haddow, B., & Birch, A. (2016). Neural Machine Translation of Rare Words with Subword Units. *Proceedings of the 54th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, 1715–1725.
- Štajner, S., Franco-Salvador, M., Rosso, P., & Ponzetto, S. P. (2018). CATS: A Tool for Customized Alignment of Text Simplification Corpora. *Proceedings of the 11th Language Resources and Evaluation Conference*.
- Stodden, R., Momen, O., & Kallmeyer, L. (2023). DEplain: A German Parallel Corpus with Intralingual Translations into Plain Language for Sentence and Document Simplification. *Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, 8391–8412.

- Tang, Y., Tran, C., Li, X., Chen, P.-J., Goyal, N., Chaudhary, V., Gu, J., & Fan, A. (2020). Multilingual Translation with Extensible Multilingual Pre-training and Finetuning. *arXiv preprint arXiv:2008.00401*.
- Toborek, V., Busch, M., Boßert, M., Bauckhage, C., & Welke, P. (2023). A New Aligned Simple German Corpus. *Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, 11416–11432.
- Überwachungsstelle des Bundes für Barrierefreiheit von Informationstechnik. (2026). *Leichte Sprache – Übergreifende Anforderungen für Web und App*. Verfügbar 8. August 2026 unter [https://www.barrierefreiheit-dienstekonsolidierung.bund.de/Webs/PB/DE/barrierefreie\\_it/uebergreifende-anforderungen-web-und-app/leichte-sprache/leichte-sprache-artikel.html](https://www.barrierefreiheit-dienstekonsolidierung.bund.de/Webs/PB/DE/barrierefreie_it/uebergreifende-anforderungen-web-und-app/leichte-sprache/leichte-sprache-artikel.html)
- Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, Ł., & Polosukhin, I. (2017). Attention is All You Need. *Advances in Neural Information Processing Systems*, 30, 5998–6008.
- Xu, W., Napoles, C., Pavlick, E., Chen, Q., & Callison-Burch, C. (2016). Optimizing Statistical Machine Translation for Text Simplification. *Transactions of the Association for Computational Linguistics*, 4, 401–415.



## 9.1 Ergänzende Evaluation auf TextComplexityDE (Naderi et al., 2019)

In diesem Abschnitt sind die ergänzenden empirischen Auswertungen zur Satzkomplexitäts-Evaluation auf dem *TextComplexityDE*-Benchmark (Naderi et al., 2019) ( $N = 1.000$  deutsche Wikipedia-Sätze mit menschlichen Likert-Urteilen) dargestellt.

Tabelle 7: Gesamtevaluation aller Modellfamilien auf dem TextComplexityDE-Benchmark ( $N = 1.000$  Sätze).

| Modell                               | Kategorie             | Pearson $r$ (Simplicity) | Spearman $\rho$ (Rang) | Kendall $\tau$ | MAE (normiert) |
|--------------------------------------|-----------------------|--------------------------|------------------------|----------------|----------------|
| LIX Lesbarkeitsindex                 | Baseline              | 0,657                    | 0,641                  | 0,467          | 0,177          |
| BiLSTM Satz-Klassifikator            | Klassifikator (Satz)  | 0,549                    | <b>0,648</b>           | 0,468          | 0,509          |
| BiLSTM MixUp Regressor (512)         | Regressor (512)       | 0,583                    | 0,615                  | 0,446          | 0,471          |
| BiLSTM Artikel-Klassifikator (512)   | Klassifikator (512)   | <b>0,602</b>             | 0,585                  | 0,417          | 0,343          |
| BiLSTM MixUp Regressor (256)         | Regressor (256)       | 0,567                    | 0,509                  | 0,361          | 0,477          |
| Wiener Sachtextformel                | Baseline              | 0,540                    | 0,519                  | 0,370          | 0,164          |
| BiLSTM MixUp Regressor (1.024)       | Regressor (1.024)     | 0,566                    | 0,461                  | 0,323          | 0,464          |
| Flesch Reading Ease                  | Baseline              | 0,456                    | 0,456                  | 0,322          | 0,174          |
| BiLSTM Artikel-Klassifikator (256)   | Klassifikator (256)   | 0,394                    | 0,227                  | 0,151          | 0,576          |
| BiLSTM Artikel-Klassifikator (1.024) | Klassifikator (1.024) | 0,417                    | 0,193                  | 0,128          | 0,557          |




Abbildung 4: Pearson- und Spearman-Korrelationen aller Modelle mit dem menschlichen Einfachheitsurteil auf TextComplexityDE ( $N = 1.000$  Sätze).

Streudiagramme ALLE Modelle vs. Menschliche Urteile (textComplexityDE)




Abbildung 5: Streudiagramm-Grid aller 10 Modellvarianten gegen den kontinuierlichen menschlichen Einfachheits-Score auf TextComplexityDE inklusive Regressionsgeraden.




Abbildung 6: Boxplot-Verteilungen der Modell-Scores gruppiert nach den diskretisierten Likert-Komplexitätsstufen auf TextComplexityDE.

## 9.2 Ergänzende Evaluation auf dem MERLIN CEFR-Benchmark (Boyd et al., 2014)

In diesem Abschnitt sind die detaillierten statistischen Auswertungen zur Dokumenten- und Fließtextevaluation auf dem *MERLIN*-Korpus (Boyd et al., 2014) ( $N = 1.033$  deutsche Volltexte mit offiziellen CEFR-Niveaustufen *A1* bis *C2*) dokumentiert.

Tabelle 8: Gesamtevaluation aller Modellfamilien auf dem MERLIN CEFR-Benchmark ( $N = 1.033$  Dokumente).

| Modell                               | Kategorie             | Pearson $r$ (Simplicity) | Spearman $\rho$ (Rang) | Kendall $\tau$ | MAE (normiert) |
|--------------------------------------|-----------------------|--------------------------|------------------------|----------------|----------------|
| LIX Lesbarkeitsindex                 | Baseline              | <b>0,632</b>             | <b>0,656</b>           | 0,515          | 0,127          |
| Wiener Sachtextformel                | Baseline              | 0,584                    | 0,602                  | 0,463          | 0,137          |
| Flesch Reading Ease                  | Baseline              | 0,513                    | 0,543                  | 0,412          | 0,144          |
| BiLSTM Artikel-Klassifikator (512)   | Klassifikator (512)   | <b>0,386</b>             | 0,397                  | 0,296          | 0,408          |
| BiLSTM MixUp Regressor (512)         | Regressor (512)       | 0,348                    | 0,352                  | 0,268          | 0,346          |
| BiLSTM MixUp Regressor (1.024)       | Regressor (1.024)     | 0,327                    | 0,328                  | 0,251          | 0,347          |
| BiLSTM MixUp Regressor (256)         | Regressor (256)       | 0,304                    | 0,296                  | 0,226          | 0,341          |
| BiLSTM Satz-Klassifikator            | Klassifikator (Satz)  | 0,285                    | <b>0,419</b>           | 0,319          | 0,483          |
| BiLSTM Artikel-Klassifikator (256)   | Klassifikator (256)   | 0,076                    | 0,518                  | 0,389          | 0,566          |
| BiLSTM Artikel-Klassifikator (1.024) | Klassifikator (1.024) | -0,049                   | -0,078                 | -0,058         | 0,569          |

Tabelle 9: Mittelwerte der vorhergesagten Modell-Scores über die 6 CEFR-Stufen im MERLIN-Korpus zur Überprüfung der Monotonie ( $A1 \rightarrow C2$ ).

| CEFR-Stufe                              | MixUp Reg.<br>(256) | MixUp Reg.<br>(512) | MixUp Reg.<br>(1.024) | Art.-Klass.<br>(512) | Satz-Klass.<br>(P(LS)) | Wiener<br>Formel |
|-----------------------------------------|---------------------|---------------------|-----------------------|----------------------|------------------------|------------------|
| <b>A1</b> (Sehr einfach, $N = 57$ )     | 0,2957              | 0,3353              | 0,3368                | <b>0,5042</b>        | 0,3043                 | -1,28            |
| <b>A2</b> (Einfach, $N = 306$ )         | 0,3302              | 0,3356              | 0,3596                | <b>0,4419</b>        | 0,2537                 | -1,52            |
| <b>B1</b> (Mittelstufe, $N = 331$ )     | 0,2966              | 0,2946              | 0,3166                | <b>0,3385</b>        | 0,1624                 | -2,38            |
| <b>B2</b> (Fortgeschritten, $N = 293$ ) | 0,1944              | 0,1762              | 0,2017                | <b>0,0955</b>        | 0,0607                 | -4,57            |
| <b>C1</b> (Fachsprache, $N = 42$ )      | 0,1241              | 0,1011              | 0,1055                | <b>0,0730</b>        | 0,0751                 | -5,30            |
| <b>C2</b> (Muttersprachlich, $N = 4$ )  | 0,0762              | 0,0686              | 0,0692                | <b>0,0499</b>        | 0,0334                 | -5,24            |




Abbildung 7: Pearson- und Spearman-Rangkorrelationen aller Modelle auf dem MERLIN CEFR-Benchmark ( $N = 1.033$  Volltexte).

### 9.3 Ergänzende Evaluation der Klassifikationsmodelle (In-Domain Sweet-Spot & Granularitätsvergleich)

In diesem Abschnitt sind die ergänzenden empirischen Auswertungen zur binären Klassifikation dokumentiert: Tabelle 10 stellt die In-Domain-Klassifikationsgüte (Balanced Accuracy) über verschiedene Cosine-Similarity-Filterungsbereiche des internen Master-Korpus auf Satz- und Artikelebene gegenüber. Die Abbildungen 10 bis 12 visualisieren die Dichteverteilungen, ROC/PR-Kurven und Konfusionsmatrizen auf dem bereinigten *Lebenshilfe*-Goldstandard ( $N = 37$  Artikelpaare / 74 Dokumente, 6.901 Einzelsätze).

Tabelle 10: In-Domain-Klassifikationsgüte (Balanced Accuracy) des BiLSTM in Abhängigkeit vom semantischen Similarity-Bereich und der Granularitätsebene auf dem internen Test-Split.

| Similarity-Bereich                                              | Artikelpaare<br>(Anzahl) | Sätze<br>(balanciert)           | Satz-Level<br>BAcc | Artikel-Level<br>BAcc |
|-----------------------------------------------------------------|--------------------------|---------------------------------|--------------------|-----------------------|
| $0,60 \leq \text{sim}_{\text{cos}} \leq 0,98$                   | 1.474                    | $\sim 29.700$                   | 92,48 %            | 95,93 %               |
| $0,70 \leq \text{sim}_{\text{cos}} \leq 0,98$                   | 1.362                    | $\sim 27.700$                   | 92,43 %            | 97,30 %               |
| <b><math>0,80 \leq \text{sim}_{\text{cos}} \leq 0,98</math></b> | <b>1.032</b>             | <b><math>\sim 21.400</math></b> | <b>92,99 %</b>     | <b>99,03 %</b>        |
| $0,90 \leq \text{sim}_{\text{cos}} \leq 0,98$                   | 213                      | $\sim 4.800$                    | 90,55 %            | 98,44 %               |




Abbildung 8: Streudiagramm-Grid aller 10 Modellvarianten gegen das kontinuierliche CEFR-Simplicity-Maß (1,0 = A1 ... 0,0 = C2) auf MERLIN inklusive Regressionsgeraden.

Tabelle 11: Multi-Seed-Stabilitäts-Benchmark aller Modellvarianten über  $K = 5$  Zufalls-Seeds (42, 123, 456, 789, 1024) auf dem Lebenshilfe-Goldstandard ( $N = 37$  Artikelpaare / 74 Dokumente).

| Modellarchitektur                     | Parameter       | Balanced Acc ( $\mu \pm \sigma$ )      | Min – Max Spread       | ROC-AUC ( $\mu \pm \sigma$ )          | Pair Match ( $\mu \pm \sigma$ )       |
|---------------------------------------|-----------------|----------------------------------------|------------------------|---------------------------------------|---------------------------------------|
| BILSTM Satz-Klassifikator (MajVote)   | 3,46 Mio.       | <b>97.03 % <math>\pm</math> 0,60 %</b> | 95,9 % – 97,3 %        | <b>0.9966 <math>\pm</math> 0,0013</b> | <b>100,0 % <math>\pm</math> 0,0 %</b> |
| BILSTM Artikel-1024 (Medium, 10k/64d) | $\sim$ 700 Tsd. | <b>88.92 % <math>\pm</math> 3,75 %</b> | 83,8 % – 93,2 %        | 0,9468 $\pm$ 0,0342                   | 95,7 % $\pm$ 3,1 %                    |
| BILSTM Artikel-256 (Full, 25k/128d)   | 3,46 Mio.       | 84,32 % $\pm$ 8,47 %                   | 73,0 % – 93,2 %        | 0,9675 $\pm$ 0,0108                   | 96,8 % $\pm$ 1,2 %                    |
| BILSTM Artikel-512 (Full, 25k/128d)   | 3,46 Mio.       | 82,16 % $\pm$ 6,72 %                   | 71,6 % – 89,2 %        | 0,9208 $\pm$ 0,0329                   | 95,7 % $\pm$ 2,4 %                    |
| BILSTM Artikel-1024 (Tiny, 5k/32d)    | $\sim$ 180 Tsd. | 81,62 % $\pm$ 10,14 %                  | 73,0 % – 93,2 %        | 0,9183 $\pm$ 0,0443                   | 94,1 % $\pm$ 4,0 %                    |
| BILSTM Artikel-1024 (Full, 25k/128d)  | 3,46 Mio.       | <b>80.00 % <math>\pm</math> 9,33 %</b> | <b>67,6 % – 91,9 %</b> | 0,9233 $\pm$ 0,0485                   | 95,1 % $\pm$ 5,2 %                    |




Abbildung 9: Monotonie-Prüfung aller Modellfamilien: Boxplots der vorhergesagten Scores über die 5 CEFR-Stufen (A1, A2, B1, B2, C1) auf MERLIN (weiße Punkte kennzeichnen den Mittelwert).




Abbildung 10: Vergleich der Dichteverteilungen (KDE) für Leichte Sprache (LS, grün) und Alltagssprache (AS, blau) über alle Klassifikationsmodi: (a) BiLSTM Satz-Klassifikator (Simple-Sentence-Ratio  $r_{LS}$ ), (b) BiLSTM Artikel-Klassifikator (256 Tokens), (c) BiLSTM Artikel-Klassifikator (512 Tokens) und (d) BiLSTM Artikel-Klassifikator (1.024 Tokens). Man beachte die ausgeprägte Asymmetrie: Während Alltagssprache durch scharfe Peaks bei 0,0 überkonfident separiert wird, bricht die Konfidenz für Leichte Sprache bei längeren Artikelkontexten stark ein.






Abbildung 11: ROC- und Precision-Recall-Kurven der Klassifikationsmodelle auf dem Lebenshilfe-Goldstandard. Das Satzmodell mit Majority-Voting ( $r_{LS}$ ) erzielt den höchsten AUC-Wert (0,9985) und übertrifft die direkten Artikelmodelle (256, 512, 1.024 Tokens) deutlich.




Abbildung 12: Konfusionsmatrizen und relative Performanzmaße der Klassifikatoren: (1) Satz-Modell auf Einzelsatzebene ( $N = 6.901$  Sätze), (2) Satz-Modell aggregiert via Majority Voting auf Dokumentenebene ( $N = 74$  Dokumente), (3) Artikel-Modell auf Dokumentenebene sowie (4) vergleichende Gütekriterien im Balkendiagramm.




Abbildung 13: Generalization Gap & Overfitting-Trajektorien über 30 Epochen (Mittelwert  $\pm$  Standardabweichung über 5 Seeds): Verlauf von In-Domain Validation Balanced Accuracy (blau) vs. Out-of-Domain Lebenshilfe Balanced Accuracy (grün).




Abbildung 14: Stabilitäts- und Varianzvergleich über 5 Zufalls-Seeds auf dem Lebenshilfe-Goldstandard: Boxplots von Balanced Accuracy (%) und Klassenseparation  $\Delta$  für alle Modellkonfigurationen.

## 9.4 Ergänzende Evaluation der MixUp Trainings- und Sampling-Strategien (Varianten A–D)

In diesem Abschnitt sind die empirischen Benchmark-Ergebnisse und grafischen Analysen zu den vier untersuchten Dataloader- und Optimierungsstrategien des kontinuierlichen BiLSTM MixUp-Regressors dokumentiert:

- **Variante A (Statisch):** Feste Vorabmischung und Shuffling bei der Initialisierung des Datasets ( $p_{\text{dynamic}} = 0,0$ ).
- **Variante B (Dynamisch):** Rein dynamisches On-the-Fly-Mischen und Shuffling pro Batch ( $p_{\text{dynamic}} = 1,0$ ).
- **Variante C (Hybrid):** Epochenabhängiges Curriculum-Mischen mit linear ansteigendem Dynamic-Anteil ( $p_{\text{dynamic}} = \frac{\text{Epoche}}{\text{Gesamtepochen}}$ ).
- **Variante D (Hybrid + Cyclic LR):** Hybrid-Mischung kombiniert mit zyklischem Lernratenscheduling mittels *CosineAnnealingWarmRestarts*.

Tabelle 12 stellt die Gütemaße auf dem internen Test-Split (In-Domain,  $N = 2.968$  Sätze / 2.560 Mischungen) und dem externen *Lebenshilfe*-Goldstandard (Out-of-Domain,  $N = 2.236$  Sätze / 1.476 Mischungen) gegenüber. Die Abbildungen 15 und 16 visualisieren die resultierenden Dichteverteilungen und Regressions-Trajektorien auf dem Lebenshilfe-Datensatz.

Tabelle 12: Gesamtevaluation der vier MixUp-Trainings- und Sampling-Strategien auf dem internen Test-Split (In-Domain) und dem Lebenshilfe-Goldstandard (Out-of-Domain).

| Sampling-Strategie              | In-Domain Test-Split       |                            |                |               |               | Out-of-Domain Lebenshilfe  |                            |                |               |               |
|---------------------------------|----------------------------|----------------------------|----------------|---------------|---------------|----------------------------|----------------------------|----------------|---------------|---------------|
|                                 | $\mathcal{O} \lambda$ (LS) | $\mathcal{O} \lambda$ (AS) | BAcc           | Reg-MSE       | Reg-MAE       | $\mathcal{O} \lambda$ (LS) | $\mathcal{O} \lambda$ (AS) | BAcc           | Reg-MSE       | Reg-MAE       |
| Variante A (Statisch)           | 0,793                      | 0,090                      | <b>95,71 %</b> | 0,0274        | 0,1238        | <b>0,738</b>               | 0,094                      | <b>94,50 %</b> | <b>0,0421</b> | <b>0,1569</b> |
| Variante B (Dynamisch)          | 0,788                      | 0,085                      | 95,07 %        | <b>0,0263</b> | <b>0,1192</b> | 0,680                      | 0,089                      | 91,37 %        | 0,0528        | 0,1771        |
| Variante C (Hybrid)             | <b>0,807</b>               | 0,095                      | 95,23 %        | 0,0279        | 0,1254        | 0,710                      | 0,097                      | 91,18 %        | 0,0468        | 0,1672        |
| Variante D (Hybrid + Cyclic LR) | 0,802                      | <b>0,075</b>               | 95,55 %        | 0,0274        | 0,1233        | 0,714                      | <b>0,078</b>               | 91,71 %        | 0,0486        | 0,1710        |

### Vergleich der MixUp-Regressoren auf dem Lebenshilfe-Datensatz (Reine Sätze) vs. Trainings-Target-Verteilung




Abbildung 15: KDE-Dichteverteilungen der vorhergesagten Scores für reine Alltagssprache (AS, blau) und reine Leichte Sprache (LS, grün) auf dem Lebenshilfe-Goldstandard im Vergleich zur Zielverteilung im Training (gestrichelte Kurve) für die vier Sampling-Strategien (Varianten A bis D).

### Vergleich der MixUp-Regressoren: Ist- vs. Soll-Werte auf dem Lebenshilfe-Set




Abbildung 16: Streudiagramme der Regressionsvorhersagen  $\hat{\lambda}$  auf dem Lebenshilfe-Goldstandard: Wahre kontinuierliche Zielwerte  $\lambda \in [0,0,1,0]$  auf der x-Achse gegen Modellvorhersagen auf der y-Achse inklusive linearer Regressionsgerade (rot) und idealer Diagonalen (gestrichelt) über alle vier Modellvarianten.

## 9.5 Ergänzende Evaluation der BiLSTM MixUp Regressoren (Längenvergleich & Trajektorien)

In diesem Abschnitt sind die ergänzenden grafischen Auswertungen zur Kontextlängen-Ablation der kontinuierlichen BiLSTM MixUp Regressoren (256, 512 und 1.024 Tokens) auf dem *Lebenshilfe*-Goldstandard dargestellt.




Abbildung 17: KDE-Dichteverteilungen der BiLSTM MixUp Regressoren für Leichte Sprache (LS, grün) und Alltagssprache (AS, blau) über verschiedene Kontextlängen: (a) 256 Tokens, (b) 512 Tokens und (c) 1.024 Tokens. Im Gegensatz zum binären Klassifikator weisen die Regressoren bei allen Längen wohlgeformte, breit separierte Verteilungen auf, wobei das 1.024-Token-Modell die geringste Varianz und schärfste Trennung erzielt.




Abbildung 18: ROC- und Precision-Recall-Kurven der BiLSTM MixUp Regressoren (256, 512, 1.024 Tokens) auf dem Lebenshilfe-Goldstandard. Alle drei Varianten erreichen herausragende Diskriminationswerte (ROC-AUC  $\geq 0,998$ , PR-AUC  $\geq 0,997$ ), wobei die 1.024-Token-Konfiguration mit ROC-AUC = 0,9993 dominiert.




Abbildung 19: Paarweises Profil der Regressions-Scores und Textlängen-Einfluss: (a) Direkte Gegenüberstellung der vorhergesagten Scores für alle 37 parallelen Lebenshilfe-Artikelpaare (LS > AS bei allen Paaren, 100 % Perfect Pair Match beim 1.024-Modell) sowie (b) Korrelation zwischen Dokumentenlänge (Satzanzahl) und resultierendem Einfachheits-Score.

## 9.6 Ergänzende Evaluation des Synthetischen Regressors & Prompt-Design


In diesem Abschnitt sind die ergänzenden empirischen Auswertungen zum BiLSTM Synthetischen Regressor sowie das vollständige Prompt-Design zur Erzeugung der Zwischenstufen dokumentiert.

### 9.6.1 Master-Benchmark auf dem Lebenshilfe-Goldstandard

Tabelle 13 stellt die Evaluierung des Synthetischen Regressors auf dem unabhängigen *Lebenshilfe*-Goldstandard ( $N = 37$  Artikelpaare / 74 Dokumente, 185 Multi-Stufen-Samples) den MixUp-Regressoren und linguistischen Formeln gegenüber.

Tabelle 13: Gesamtevaluation aller Regressoren und linguistischen Baselines auf dem Lebenshilfe-Goldstandard ( $N = 37$  Artikelpaare / 74 Dokumente).

| Modell                           | Ebene / Input          | $\emptyset$ Score (LS)             | $\emptyset$ Score (AS)             | Separation ( $\Delta$ ) | Balanced Acc   | ROC-AUC       | Pair Match             |
|----------------------------------|------------------------|------------------------------------|------------------------------------|-------------------------|----------------|---------------|------------------------|
| BiLSTM MixUp Regressor (1.024)   | Dokument (1.024 Tok.)  | <b>0.792 <math>\pm</math> 0.10</b> | <b>0.067 <math>\pm</math> 0.10</b> | <b>0.726</b>            | <b>98.65 %</b> | <b>0.9993</b> | <b>100.0 % (37/37)</b> |
| BiLSTM MixUp Regressor (512)     | Dokument (512 Tok.)    | 0.777 $\pm$ 0.12                   | 0.062 $\pm$ 0.11                   | 0.715                   | 98.65 %        | 0.9985        | 97.3 % (36/37)         |
| BiLSTM MixUp Regressor (256)     | Dokument (256 Tok.)    | 0.724 $\pm$ 0.13                   | 0.092 $\pm$ 0.09                   | 0.632                   | 95.95 %        | 0.9982        | 97.3 % (36/37)         |
| BiLSTM Synthetischer Regressor   | Dokument (LLM-Stufen)  | 0.575 $\pm$ 0.35                   | 0.145 $\pm$ 0.18                   | 0.429                   | 78.38 %        | 0.8495        | 89.2 % (33/37)         |
| Vanilla RNN Baseline (Ablation)  | Dokument (256 Tok.)    | 0.527 $\pm$ 0.20                   | 0.287 $\pm$ 0.17                   | 0.240                   | 81.08 %        | 0.8733        | 81.1 % (30/37)         |
| Flesch Reading Ease (Baseline)   | Dokument (Silben/Satz) | 0.973 $\pm$ 0.16                   | 0.189 $\pm$ 0.39                   | 0.784                   | 89.19 %        | 0.8919        | 100.0 % (37/37)        |
| Wiener Sachtextformel (Baseline) | Dokument (Wortlänge)   | 0.919 $\pm$ 0.27                   | 0.108 $\pm$ 0.31                   | 0.811                   | 90.54 %        | 0.9054        | 100.0 % (37/37)        |



(a) Dichteverteilungen & Paarseparation

(b) ROC-Kurven aller Regressoren

Abbildung 20: Dichteverteilungen (KDE) und Diskriminationsleistung (ROC) des Synthetischen Regressors im Vergleich zu den MixUp-Modellen und Baselines auf dem Lebenshilfe-Goldstandard.






Abbildung 21: Empirische Monotonie- und Fehleranalyse des Synthetischen Regressors über die 5 diskreten LLM-Stufen auf dem Lebenshilfe-Goldstandard ( $N = 185$  Vorhersagen) im Vergleich zu Sentence-MixUp.

### 9.6.2 Prompt-Design zur Generierung synthetischer Zwischenstufen

Zur Erzeugung der synthetischen Zwischenstufen (0,25, 0,50, 0,75) wurde das Open-Source-Modell **FlensGen-GPT-OSS-120B** (gehostet an der Hochschule Flensburg) per API mit folgender System- und User-Prompt-Struktur parametrisiert (Sampling-Temperatur  $T = 0,2$ , Top-p 0,95):

## System-Prompt: Synthetische Komplexitätsabstufung

Du bist ein Experte für die deutsche Sprache und Textvereinfachung.

Dir wird ein Artikel in zwei verschiedenen Schwierigkeitsgraden vorgelegt:

1. Leichte Sprache (LS / Stufe 1.0): Extrem vereinfacht, kurze Sätze, sehr einfache Satzstruktur, oft mit Zeilenumbrüchen nach jedem Satzteil, geringe Wortkomplexität, keine Fremdwörter, Fachbegriffe werden direkt erklärt.
2. Alltagssprache (AS / Stufe 0.0): Der normale Originaltext, komplexer Satzbau, reichhaltiger Wortschatz, Nebensätze, Passiv- und Genitivkonstruktionen, Fachbegriffe.

Deine Aufgabe ist es, eine neue Version dieses Artikels zu schreiben, die sprachlich präzise auf einer bestimmten Stufe zwischen diesen beiden Versionen liegt.

Die Skala reicht von 0.0 (Alltagssprache) bis 1.0 (Leichte Sprache).

Dir wird ein bestimmter Zielwert (z.B. 0.25, 0.50, 0.75) vorgegeben.

Richtlinien für die Stufen:

- Stufe 0.75 (Nahe an Leichter Sprache):
  - \* Der Text soll sehr leicht verständlich sein.
  - \* Verwende überwiegend einfache Sätze, aber du darfst einzelne einfache Nebensätze (z.B. mit "weil", "wenn", "dass") einbauen.
  - \* Der Wortschatz darf minimal anspruchsvoller sein als in der LS-Version (z.B. geläufige Wörter anstelle von extremen Umschreibungen), aber vermeide Fremdwörter.
  - \* Informationen sollten sehr klar gegliedert sein, aber es muss nicht jeder Satzteil in einer neuen Zeile stehen.
- Stufe 0.50 (Die goldene Mitte / Einfache Sprache):
  - \* Dies entspricht der typischen "Einfachen Sprache" (Simple Language).
  - \* Verwende eine Mischung aus kurzen und mittelschweren Sätzen.
  - \* Vermeide Schachtelsätze (mehrere Nebensätze ineinander), aber ein Hauptsatz mit einem Nebensatz ist der Standard.
  - \* Der Wortschatz ist alltäglich, ohne extreme Fach- oder Fremdwörter.
  - \* Der Text fließt natürlicher als Leichte Sprache, behält aber die gute Verständlichkeit bei.
- Stufe 0.25 (Nahe an Alltagssprache):
  - \* Der Text ist nur leicht vereinfacht im Vergleich zur AS-Version.

### User-Prompt-Template: Übergabe der Artikelpaare

Hier sind die beiden Versionen des Artikels:

### Version 1: Leichte Sprache (LS / Stufe 1.0):  
{ls\_text}

### Version 2: Alltagssprache (AS / Stufe 0.0):  
{as\_text}

### Ziel-Stufe: {target\_level}

Erstelle nun den Text, der genau auf der Ziel-Stufe {target\_level} liegt. Befolge alle stilistischen Richtlinien für diese Stufe.  
Antworte nur mit dem generierten Text.